

Informe académico: implementación del ajuste de distribuciones candidatas a retornos por ticker

Sistema Recomendador de Inversiones FinPUC

Abril 2026

Resumen

Este informe documenta la implementación completa del script *ajustar_distribuciones_retornos*, cuyo objetivo es evaluar si los retornos diarios de cada ticker filtrado se aproximan mejor a alguna distribución estadística conocida. El procedimiento calcula retornos diarios totales, ajusta distribuciones candidatas mediante máxima verosimilitud, compara los modelos con criterios de información AIC y BIC, aplica pruebas de normalidad y genera archivos de salida para la interpretación financiera. A partir de los resultados entregados, se concluye que los retornos de los tickers no siguen una distribución normal: las pruebas Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk rechazan normalidad en el 100 % de los casos analizados. Las distribuciones que dominan son Johnson SU, t-Student y normal generalizada, lo que sugiere presencia de colas pesadas, asimetría y concentración de retornos alrededor de cero.

Índice

1. Introducción	3
2. Objetivo del script	3
3. Estructura general de la implementación	3
4. Apartado 1: Configuración principal	4
5. Apartado 2: Lectura de archivos y cálculo de retornos	5
5.1. Extracción del ticker	5
5.2. Lectura y validación del CSV	5
5.3. Cálculo de retornos diarios totales	6

6. Apartado 3: Pruebas de normalidad	6
6.1. Prueba Jarque–Bera	6
6.2. Prueba D’Agostino–Pearson	7
6.3. Prueba Shapiro–Wilk	7
7. Apartado 4: Distribuciones candidatas	7
8. Apartado 5: Ajuste por máxima verosimilitud	8
9. Apartado 6: Criterios AIC y BIC	8
10. Apartado 7: Prueba Kolmogorov–Smirnov aproximada	9
11. Apartado 8: Gráficos de ajuste	9
12. Apartado 9: Proceso principal	10
13. Archivos de salida	10
14. Resultados obtenidos	11
14.1. Tamaño del análisis	11
14.2. Mejores distribuciones según AIC y BIC	11
14.3. Consistencia entre AIC y BIC	12
14.4. Resultados de normalidad	12
14.5. Bondad de ajuste aproximada por Kolmogorov–Smirnov	12
15. Discusión financiera	13
16. Implicancias para el modelo de portafolios	13
17. Limitaciones del análisis	14
18. Conclusiones	14

1. Introducción

El análisis estadístico de los retornos financieros es una etapa relevante para la construcción de modelos de optimización de portafolios. En modelos clásicos como media-varianza de Markowitz, el riesgo se resume mediante la varianza y la covarianza de los retornos. Sin embargo, en datos financieros reales, los retornos diarios suelen presentar características que se apartan de la normalidad, tales como colas pesadas, asimetría, exceso de curtosis y episodios de volatilidad extrema.

En este contexto, el script analizado permite estudiar empíricamente la forma distribucional de los retornos de cada ticker filtrado. La finalidad no es imponer una única distribución para todo el universo de acciones, sino identificar, ticker por ticker, qué familia paramétrica describe mejor los retornos observados dentro de un conjunto finito de distribuciones candidatas.

El análisis se aplica sobre una base previamente filtrada, donde ya se eliminaron activos con problemas de historia, capitalización, precio, clasificación o volatilidad, y donde además se excluyeron registros asociados al periodo 2020–2022. Por lo tanto, el universo estudiado corresponde a acciones con suficiente historia fuera del periodo pandémico y aptas para alimentar etapas posteriores del sistema recomendador.

2. Objetivo del script

El objetivo general del script es determinar si los retornos diarios de cada ticker filtrado se aproximan mejor a una distribución normal, t-Student, Laplace, logística, skew-normal, normal generalizada o Johnson SU.

Los objetivos específicos son:

- a) Leer los archivos CSV correspondientes a los tickers filtrados.
- b) Calcular retornos diarios totales usando precios de cierre y dividendos.
- c) Ajustar múltiples distribuciones candidatas a los retornos de cada ticker.
- d) Comparar los ajustes mediante log-verosimilitud, AIC y BIC.
- e) Evaluar normalidad mediante pruebas formales.
- f) Exportar resultados agregados y por ticker para facilitar la interpretación.
- g) Generar gráficos de ajuste entre histogramas empíricos y densidades paramétricas.

3. Estructura general de la implementación

El script se organiza en seis grandes bloques:

1. Configuración principal.
2. Funciones auxiliares de lectura y cálculo de retornos.
3. Pruebas de normalidad.
4. Ajuste de distribuciones.
5. Generación de gráficos.
6. Proceso principal y exportación de resultados.

Esta organización permite separar claramente la preparación de datos, el sustento estadístico y la generación de archivos finales. Además, facilita la trazabilidad del análisis, ya que cada archivo de salida corresponde a una etapa específica del procedimiento.

4. Apartado 1: Configuración principal

El primer bloque define las rutas, columnas esperadas y parámetros generales del experimento. Las variables principales son:

Variable	Descripción
RUTA_TICKERS_FILTRADOS	Carpeta que contiene los CSV finales de acciones filtradas.
RUTA_SALIDA	Carpeta donde se guardan los resultados del ajuste de distribuciones.
COLUMNA_FECHA	Nombre de la columna de fecha, definida como <code>Date</code> .
COLUMNA_PRECIO	Nombre de la columna de precio, definida como <code>Close</code> .
COLUMNA_DIVIDENDOS	Nombre de la columna de dividendos, definida como <code>Dividends</code> .
TIPO_RETORNO	Tipo de retorno a calcular; por defecto se usa <code>simple_total</code> .
MIN_RETORNOS_VALIDOS	Número mínimo de retornos requeridos para ajustar distribuciones.
RETORNO_MINIMO_PERMITIDO	Umbral inferior para remover retornos extremos asociados a errores de datos.
RETORNO_MAXIMO_PERMITIDO	Umbral superior para remover retornos extremos asociados a errores de datos.
GENERAR_GRAFICOS_AJUSTE	Indica si se generan gráficos de ajuste por ticker.
MAX_GRAFICOS_TICKER	Número máximo de tickers para los cuales se generan gráficos.

Tabla 1: Variables principales de configuración del script.

Desde un punto de vista metodológico, esta etapa fija las reglas del experimento. En particular, se exige un mínimo de 250 retornos válidos para evitar ajustar distribuciones sobre muestras demasiado pequeñas. Además, se eliminan retornos diarios menores a -95% o mayores a 300% , criterio que busca controlar errores de datos, precios mal ajustados o registros atípicos incompatibles con el análisis financiero estándar.

5. Apartado 2: Lectura de archivos y cálculo de retornos

5.1. Extracción del ticker

La función `obtener\_ticker\_desde\_nombre` estandariza nombres de archivos como:

- `stock\_return\_AAPL.csv`
- `stock return AAPL.csv`
- `AAPL.csv`

y devuelve únicamente el ticker en mayúsculas. Esta etapa es importante porque permite que el análisis no dependa estrictamente de un único formato de nombre de archivo.

5.2. Lectura y validación del CSV

La función `leer\_csv\_ticker` lee cada archivo y valida que existan, al menos, las columnas `Date` y `Close`. Si la columna `Dividends` no existe, se crea con valor cero. Luego, el script:

1. convierte las fechas a formato `datetime` con zona UTC;
2. transforma precios y dividendos a valores numéricos;
3. elimina fechas inválidas;
4. elimina precios nulos o no positivos;
5. ordena las observaciones cronológicamente.

Este procesamiento evita que errores de formato afecten el cálculo de retornos y el ajuste estadístico posterior.

5.3. Cálculo de retornos diarios totales

El retorno simple total del ticker i en el día t se define como:

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (1)$$

donde $P_{i,t}$ es el precio de cierre del ticker i en el día t y $D_{i,t}$ corresponde al dividendo por acción pagado en ese día.

Esta definición es financieramente más completa que el retorno puramente basado en precios, ya que incorpora la ganancia por dividendos. En acciones con pagos frecuentes de dividendos, ignorar $D_{i,t}$ subestimaría la rentabilidad total del inversionista.

El script también permite calcular retornos logarítmicos totales:

$$r_{i,t}^{\log} = \log \left(\frac{P_{i,t} + D_{i,t}}{P_{i,t-1}} \right). \quad (2)$$

Sin embargo, para mantener consistencia con el análisis previo, se utiliza el retorno simple total.

6. Apartado 3: Pruebas de normalidad

La función `calcular\_pruebas\_normalidad` aplica tres pruebas formales para evaluar si los retornos podrían provenir de una distribución normal. La hipótesis nula general es:

$$H_0 : r_{i,t} \sim \mathcal{N}(\mu_i, \sigma_i^2). \quad (3)$$

Si el valor-p es menor a 0.05, se rechaza la hipótesis de normalidad al 5 %.

6.1. Prueba Jarque–Bera

La prueba Jarque–Bera utiliza la asimetría y la curtosis de la muestra. Su estadístico se define como:

$$JB = \frac{n}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right), \quad (4)$$

donde S es la asimetría muestral, K es la curtosis muestral y n es el tamaño de la muestra. Bajo normalidad, se espera $S = 0$ y $K = 3$. Por ello, valores elevados del estadístico indican desviaciones relevantes respecto de la normalidad.

6.2. Prueba D’Agostino–Pearson

La prueba D’Agostino–Pearson combina transformaciones de asimetría y curtosis para construir un estadístico global de normalidad. En términos intuitivos, evalúa simultáneamente si la distribución observada tiene una forma compatible con una normal en sus dos momentos de forma principales.

6.3. Prueba Shapiro–Wilk

La prueba Shapiro–Wilk compara los cuantiles ordenados de la muestra con los cuantiles esperados bajo normalidad. Su estadístico puede escribirse como:

$$W = \frac{\left(\sum_{j=1}^n a_j x_{(j)}\right)^2}{\sum_{j=1}^n (x_j - \bar{x})^2}, \quad (5)$$

donde $x_{(j)}$ son los datos ordenados y a_j son coeficientes derivados de los cuantiles normales esperados. En muestras grandes, la prueba puede ser muy sensible, por lo que el script limita su aplicación a una muestra de hasta 5000 observaciones cuando el ticker tiene demasiados retornos.

7. Apartado 4: Distribuciones candidatas

El script considera siete distribuciones candidatas. Todas tienen soporte en la recta real o pueden representar valores positivos y negativos de retornos, por lo que son razonables para modelar retornos diarios.

Distribución	Interpretación financiera
Normal	Modelo simétrico base. Supone colas relativamente delgadas y ausencia de asimetría.
t-Student	Permite colas más pesadas que la normal. Es útil cuando existen eventos extremos más frecuentes.
Laplace	Presenta mayor concentración cerca de cero y colas más pesadas que la normal.
Logística	Distribución simétrica con colas algo más pesadas que la normal.
Skew-normal	Extiende la normal incorporando asimetría mediante un parámetro de forma.
Normal generalizada	Permite modificar la concentración central y el grosor de las colas mediante un parámetro de forma.
Johnson SU	Familia flexible que puede representar asimetría, colas pesadas y formas distribucionales complejas.

Tabla 2: Distribuciones candidatas consideradas en el script.

8. Apartado 5: Ajuste por máxima verosimilitud

Para cada ticker i y distribución candidata d , el script estima un vector de parámetros $\theta_{i,d}$ mediante máxima verosimilitud. Formalmente:

$$\hat{\theta}_{i,d} = \arg \max_{\theta} \sum_{t=1}^{T_i} \log f_d(r_{i,t}; \theta), \quad (6)$$

donde $f_d(\cdot)$ es la función de densidad de la distribución candidata d y T_i es el número de retornos válidos del ticker i .

La log-verosimilitud maximizada se define como:

$$\ell_{i,d} = \sum_{t=1}^{T_i} \log f_d(r_{i,t}; \hat{\theta}_{i,d}). \quad (7)$$

Una mayor log-verosimilitud indica que la distribución asigna mayor densidad a los retornos observados. Sin embargo, comparar únicamente log-verosimilitud puede favorecer distribuciones más flexibles, por lo que el script utiliza AIC y BIC para penalizar complejidad.

9. Apartado 6: Criterios AIC y BIC

El criterio de información de Akaike se calcula como:

$$AIC = 2k - 2\ell, \quad (8)$$

mientras que el criterio bayesiano de Schwarz se calcula como:

$$BIC = k \ln(n) - 2\ell, \quad (9)$$

donde k es el número de parámetros estimados, n es el número de observaciones y ℓ es la log-verosimilitud maximizada.

Ambos criterios buscan balancear ajuste y parsimonia. La regla de decisión es seleccionar la distribución con menor AIC o menor BIC. La diferencia conceptual es que BIC penaliza con mayor fuerza la cantidad de parámetros cuando el tamaño muestral es grande. Por esta razón, AIC suele favorecer modelos más flexibles, mientras que BIC suele seleccionar distribuciones más simples.

10. Apartado 7: Prueba Kolmogorov–Smirnov aproximada

Además de AIC y BIC, el script calcula el estadístico Kolmogorov–Smirnov:

$$D = \sup_x |F_n(x) - F_{\hat{\theta}}(x)|, \quad (10)$$

donde $F_n(x)$ es la función de distribución empírica y $F_{\hat{\theta}}(x)$ es la función de distribución acumulada de la distribución ajustada.

El valor-p de esta prueba se interpreta con cautela, porque los parámetros de la distribución se estiman usando los mismos datos sobre los cuales se aplica la prueba. Por lo tanto, el valor-p es una referencia aproximada de ajuste, no una prueba definitiva de validez distribucional.

11. Apartado 8: Gráficos de ajuste

La función `graficar\_ajuste\_ticker` genera un histograma de los retornos observados y superpone las tres mejores densidades ajustadas según AIC. Para evitar que valores extremos dominen la escala del gráfico, el eje horizontal se define entre los cuantiles 0.5 % y 99.5 % de los retornos.

Estos gráficos son útiles porque complementan los criterios numéricos con una evaluación visual. En particular, permiten observar si una distribución reproduce adecuadamente la concentración central, la asimetría o las colas de la distribución empírica.

12. Apartado 9: Proceso principal

La función `main` coordina todo el análisis. Su flujo lógico es:

1. Verificar que `scipy` esté instalado.
2. Verificar que exista la carpeta de tickers filtrados.
3. Crear la carpeta de salida y la carpeta de gráficos.
4. Recorrer todos los archivos CSV disponibles.
5. Leer cada ticker y calcular sus retornos.
6. Excluir tickers con menos de 250 retornos válidos.
7. Aplicar pruebas de normalidad.
8. Ajustar todas las distribuciones candidatas.
9. Seleccionar la mejor distribución por AIC y por BIC.
10. Exportar resultados a archivos CSV.
11. Generar un archivo de interpretación general.

La implementación es modular: si una distribución no logra ajustarse para un ticker específico, el script continúa con las restantes. Si un ticker no puede analizarse, se registra el motivo en un archivo separado.

13. Archivos de salida

El script genera los siguientes archivos:

Archivo	Contenido
<code>ajuste_distribuciones_por_ticker.csv</code>	Resultados de todas las distribuciones ajustadas para cada ticker.
<code>mejor_distribucion_por_ticker.csv</code>	Mejor distribución por ticker según AIC y según BIC.
<code>resumen_mejores_distribuciones.csv</code>	Resumen agregado de mejores distribuciones.
<code>pruebas_normalidad_por_ticker.csv</code>	Resultados de Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk.
<code>tickers_no_analizados.csv</code>	Tickers omitidos y motivo de exclusión.
<code>interpretacion_resultado.txt</code>	Guía breve para interpretar los resultados.
<code>graficos_ajuste/</code>	Histogramas con densidades ajustadas.

Tabla 3: Archivos generados por el script.

14. Resultados obtenidos

14.1. Tamaño del análisis

El análisis final contiene **601 tickers**. Para cada uno se ajustaron siete distribuciones candidatas, lo que genera un total de **4207 ajustes distribucionales**. El número de retornos válidos por ticker presenta las siguientes estadísticas:

Indicador	Valor
Tickers analizados	601
Distribuciones candidatas por ticker	7
Ajustes totales	4207
Mínimo de retornos por ticker	2518
Mediana de retornos por ticker	7949
Promedio de retornos por ticker	8262.83
Máximo de retornos por ticker	15400

Tabla 4: Resumen del tamaño muestral analizado.

La cantidad de retornos por ticker es suficiente para realizar una comparación estadística robusta entre familias distribucionales. La mediana de 7949 retornos indica que, en general, los tickers conservan una historia amplia después de aplicar los filtros de calidad y excluir el periodo 2020–2022.

14.2. Mejores distribuciones según AIC y BIC

Distribución	Mejor AIC	% AIC	Mejor BIC	% BIC
Johnson SU	247	41.10 %	180	29.95 %
t-Student	179	29.78 %	241	40.10 %
Normal generalizada	174	28.95 %	176	29.28 %
Laplace	1	0.17 %	4	0.67 %
Normal	0	0.00 %	0	0.00 %
Logística	0	0.00 %	0	0.00 %
Skew-normal	0	0.00 %	0	0.00 %

Tabla 5: Conteo de mejores distribuciones por criterio de información.

Los resultados muestran diferencias relevantes entre AIC y BIC. Según AIC, la distribución Johnson SU es la más frecuente, con 247 tickers, equivalente al 41.10 % del total. Luego aparecen t-Student, con 179 tickers, y normal generalizada, con 174 tickers.

Según BIC, la distribución t-Student pasa a ser la más frecuente, con 241 tickers, equivalente al 40.10 % del total. Esto es coherente con la mayor penalización de BIC sobre modelos con más parámetros: Johnson SU es muy flexible, pero su complejidad puede ser castigada cuando otra distribución más parsimoniosa ofrece un ajuste suficientemente bueno.

Un resultado importante es que la distribución normal no fue seleccionada como mejor distribución para ningún ticker, ni por AIC ni por BIC. Tampoco dominaron la distribución logística ni la skew-normal. Esto sugiere que la forma empírica de los retornos requiere principalmente modelos capaces de capturar colas pesadas y, en algunos casos, asimetría.

14.3. Consistencia entre AIC y BIC

AIC y BIC coincidieron en la mejor distribución para 532 tickers, lo que representa el 88.52 % del total. Por lo tanto, en la mayoría de los casos, ambos criterios identifican la misma familia distribucional. Las discrepancias se concentran principalmente en casos donde AIC selecciona Johnson SU y BIC selecciona t-Student.

Esta diferencia es metodológicamente esperable. AIC prioriza capacidad predictiva relativa y tolera mayor flexibilidad; BIC se orienta más hacia parsimonia y penaliza con mayor fuerza los modelos con más parámetros. En términos prácticos, si el objetivo es obtener el mejor ajuste empírico posible, Johnson SU puede ser atractiva. Si el objetivo es construir un modelo más simple y estable para simulación o escenarios, t-Student puede ser preferible.

14.4. Resultados de normalidad

Prueba	Rechazos al 5 %	Porcentaje
Jarque–Bera	601	100.00 %
D’Agostino–Pearson	601	100.00 %
Shapiro–Wilk	601	100.00 %
Las tres pruebas simultáneamente	601	100.00 %

Tabla 6: Resultados agregados de pruebas de normalidad.

Las tres pruebas rechazan normalidad en todos los tickers analizados. Esto constituye evidencia contundente contra el supuesto de retornos diarios normales. Desde el punto de vista financiero, este resultado es relevante porque la normalidad tiende a subestimar la probabilidad de pérdidas extremas cuando la distribución real tiene colas pesadas.

14.5. Bondad de ajuste aproximada por Kolmogorov–Smirnov

Usando la mejor distribución según AIC, 220 de 601 tickers tienen un valor-p aproximado de Kolmogorov–Smirnov mayor a 0.05, equivalente al 36.61 %. Según BIC, esto ocurre en 219

tickers, equivalente al 36.44 %.

Esto indica que, aunque Johnson SU, t-Student y normal generalizada son mejores que la normal en términos relativos, una distribución paramétrica simple no captura perfectamente todos los rasgos empíricos de los retornos en una parte importante de los tickers. Este punto es importante para la modelación posterior: no basta con seleccionar una familia paramétrica, también se debe reconocer que los retornos financieros pueden presentar cambios de régimen, volatilidad condicional y dependencia temporal.

15. Discusión financiera

Los resultados son consistentes con patrones ampliamente observados en series financieras:

1. **Colas pesadas:** la presencia dominante de t-Student y normal generalizada indica que los eventos extremos son más frecuentes que bajo una normal.
2. **Asimetría y flexibilidad:** la alta frecuencia de Johnson SU bajo AIC sugiere que muchos tickers requieren una distribución capaz de capturar sesgos y formas no simétricas.
3. **Baja validez de la normalidad:** la normal no fue seleccionada para ningún ticker y fue rechazada por todas las pruebas de normalidad.
4. **Parquedad versus ajuste:** BIC favorece t-Student por ser más parsimoniosa, mientras que AIC favorece Johnson SU por su flexibilidad.

Para el sistema recomendador FinPUC, esto tiene implicancias directas. Si el modelo de optimización utiliza únicamente media y varianza, puede perder información relevante sobre riesgo extremo. En particular, una cartera evaluada solo con volatilidad podría parecer aceptable aunque tenga exposición significativa a pérdidas de cola.

16. Implicancias para el modelo de portafolios

Los resultados sugieren que el supuesto normal debe usarse con cautela. En modelos de optimización media-varianza, la normalidad facilita la interpretación del riesgo, pero no es estrictamente necesaria para calcular medias, varianzas y covarianzas. No obstante, si se desea proyectar escenarios desfavorables, calcular Value at Risk, Conditional Value at Risk o simular trayectorias futuras, la elección distribucional se vuelve más importante.

A partir de los resultados, se recomiendan tres alternativas metodológicas:

1. **Usar t-Student para simulaciones base:** es una alternativa parsimoniosa, captura colas pesadas y fue la distribución más frecuente bajo BIC.

2. **Usar Johnson SU para análisis por ticker:** cuando el objetivo sea ajustar de manera más flexible cada activo, especialmente si se observan asimetrías.
3. **Complementar con métodos empíricos:** bootstrap histórico, simulaciones por bloques o modelos de volatilidad condicional pueden capturar rasgos que una distribución estática no representa completamente.

17. Limitaciones del análisis

A pesar de su utilidad, el procedimiento tiene algunas limitaciones:

1. Los parámetros se estiman y evalúan sobre la misma muestra, por lo que algunas pruebas de ajuste deben interpretarse como aproximadas.
2. El test Kolmogorov–Smirnov no corrige formalmente por estimación de parámetros.
3. El análisis considera distribuciones incondicionales, pero los retornos financieros suelen presentar dependencia temporal y clustering de volatilidad.
4. La exclusión de 2020–2022 responde a una decisión metodológica del proyecto, pero también elimina un periodo con eventos extremos relevantes.
5. La comparación se limita a siete distribuciones candidatas; podrían existir otras familias con mejor desempeño.

18. Conclusiones

A partir de la implementación y los resultados obtenidos, se concluye lo siguiente:

1. El script implementa una metodología completa y replicable para evaluar distribuciones candidatas por ticker, desde lectura de datos hasta exportación de resultados e interpretación.
2. La normalidad es rechazada de manera sistemática: las pruebas Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk rechazan normalidad en el 100 % de los 601 tickers analizados.
3. La distribución normal no fue seleccionada como mejor ajuste para ningún ticker, ni por AIC ni por BIC.
4. Según AIC, la distribución Johnson SU es la más frecuente, lo que indica que la flexibilidad para capturar asimetría y colas complejas mejora el ajuste empírico.
5. Según BIC, la distribución t-Student es la más frecuente, lo que muestra que una distribución más simple con colas pesadas ofrece un buen balance entre ajuste y parsimonia.

6. En términos financieros, los retornos del universo filtrado presentan colas pesadas y desviaciones relevantes respecto de la normalidad. Por ello, para análisis de riesgo, simulación de escenarios y evaluación de pérdidas extremas, conviene complementar el enfoque media-varianza con distribuciones de colas pesadas o métodos empíricos.
7. El resultado más relevante para FinPUC es que la estimación de riesgo no debería depender exclusivamente del supuesto normal. Para escenarios desfavorables, estrés financiero o métricas como VaR y CVaR, la t-Student, Johnson SU o normal generalizada ofrecen aproximaciones más realistas.

Referencias

- [1] Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- [2] Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464.
- [3] Jarque, C. M., & Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255–259.
- [4] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality. *Biometrika*, 52(3/4), 591–611.
- [5] Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.