

FinPUC

Presentación 2 - Sistema Recomendador de Portafolios

Patricio Andres Acevedo Flores

Benjamín Alonso Cano Araya

Matías Benjamín Catalán Contreras

Gaspar Ten Berg Yunusic

Diego Benjamín Villalobos Michea

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ESCUELA DE INGENIERÍA

ICS2122 — Taller de Investigación Operativa (Capstone)



Contexto del Problema



Objetivo

Maximizar retorno del cliente y utilidad de FinPUC vía comisiones



5 Perfiles de Riesgo


Volatilidad anual máxima de 8% (muy conservador) a 40% (muy arriesgado)



Restricción

Respuesta < 10 seg, recomendación semanal, 601 activos

Datos y Universo de Inversión



Retornos diarios totales (precio + dividendos) sobre 9 años de historia común. Universo F5 filtrado por liquidez, capitalización, historia mínima y volatilidad razonable; periodo pandemia excluido.

2.489 retornos diarios comunes

11 sectores industriales representados

Sesgo sectorial corregido: Servicios Financieros pasó de 61% a representación balanceada tras filtros.

Distribuciones de las Acciones

Insight estadístico

Normalidad rechazada: 601/601 tickers fallan Jarque-Bera, D'Agostino y Shapiro-Wilk.

Colas pesadas: la normal no fue mejor ajuste en ningún activo.

Muestra robusta: 601 tickers, 4.207 ajustes y mediana de 7.949 retornos por ticker.

Implicancia para FinPUC

Volatilidad no basta: media-varianza ordena riesgo, pero puede subestimar pérdidas extremas.

Simulación base: t-Student es opción parsimoniosa para escenarios y CVaR.

Ajuste por activo: Johnson SU captura asimetría y colas complejas cuando se requiere precisión.

Metodología: Markowitz Media-Varianza

Formulación

$$\text{máx } w^T \mu - (\gamma/2) w^T \Sigma w$$

sujeto a:

- $\sum_i w_i = 1$ Suma de pesos igual a 1
- $0 \leq w_i \leq \bar{w}_p$ Peso por activo acotado
- $252 \cdot w^T \Sigma w \leq \bar{\sigma}_p^2$ Varianza anualizada $\leq \bar{\sigma}^2$

Implementación

Solver: CVXPY + CLARABEL

Shrinkage: $\lambda = 0.20$ (Ledoit-Wolf simplificado)

Proyección: Nearest PSD para estabilidad numérica

Activos: 601 acciones simultáneas

Relajación: Si la cota de volatilidad es infactible, se relaja sólo esa restricción y se registra

Perfil	Muy conservador	Conservador	Neutro	Arriesgado	Muy arriesgado
γ / Vol. máx	80 / 8%	45 / 12%	20 / 18%	8 / 28%	3 / 40%

Diseño Experimental: Splits Aleatorios

Ventana base de 9 años

Cada combinación (train, test) cumple:

$$\text{años}_{\text{train}} + \text{años}_{\text{test}} \leq 9$$

28 combinaciones posibles (test de 2 a 8 años)

70 ventanas aleatorias seleccionadas con semilla reproducible

560 evaluaciones de portafolios sobre 601 activos

1.392 puntos de frontera eficiente registrados

Estructura por años de test

Años test	Splits	Ventanas	Train mín–máx
2	7	19	1–7
3	6	16	1–6
4	5	13	1–5
5	4	10	1–4
6–8	3–1	7–1	1–3

Cuando $\text{train} + \text{test} = 9$, solo 1 posición factible;
si < 9 , hasta 3 inicios aleatorios.

Experimento	Combinaciones	Ventanas	Evaluaciones	Activos	Frontera pts.
Splits aleatorios	28	70	560	601	1.392

Contexto: Sensibilidad al Horizonte de Calibración

Motivación

Un único split (train, test) puede ser favorable o desfavorable por azar. La pregunta real es: ¿cuántos años de historia conviene usar?

- **Sesgo de selección:** un solo periodo de prueba puede capturar un régimen atípico.
- **Estabilidad temporal:** los parámetros μ y Σ estimados varían según la ventana elegida.
- **Trazabilidad académica:** semilla fija garantiza reproducibilidad exacta del experimento.
- **Validación exigente:** 70 ventanas sobre 28 combinaciones entregan imagen realista de sensibilidad.

Portafolio	Sharpe futuro	Mejor split	Ret. futuro	Vol. futuro	Drawdown
Benchmark	2.057 ★	h6_f2	64.1%	30.5%	-20.5%

Contexto: Sensibilidad al Horizonte de Calibración

Hallazgos clave

- **No hay regla monótona:** el mejor split varía por perfil y régimen de mercado.
- **5:2 lidera en tests cortos:** Sharpe promedio global 2.34, el más alto entre todas las combinaciones.
- **Defensivos más estables:** mínima varianza y muy conservador mantienen Sharpe mayor a 1.7 en todos los horizontes.
- **Horizontes largos degradan:** al pasar de 2 a 8 años de test, el Sharpe del benchmark cae de 2.32 a 1.71.
- **Perfiles agresivos sensibles:** su Sharpe varía fuertemente con el periodo — mayor riesgo de modelo.
- **Brecha teórico vs real:** ideal de mercado: Sharpe teórico 5.01 vs 1.80 real — patrón clásico de overfitting.

Portafolio	Sharpe futuro	Mejor split	Ret. futuro	Vol. futuro	Drawdown
Benchmark	2.057 ★	h6_f2	64.1%	30.5%	-20.5%

Validación Robusta: Ventanas Móviles

No usamos un único split train/test. Evaluamos 6 horizontes $\times$ 3 ventanas = 18 evaluaciones fuera de muestra por portafolio.


Horizonte	Años históricos	Años futuros	Sharpe futuro medio
h_7f_2	7	2	2.32
h_6f_3	6	3	2.07
h_5f_4	5	4	1.88
h_4f_5	4	5	1.66
h_3f_6	3	6	1.60
h_2f_7	2	7	1.35



Hallazgo clave

7 años de historia + 2 de prueba (h_7f_2) ofrece el mejor balance entre estabilidad estadística y vigencia de la información. A menor historia, las estimaciones se vuelven inestables.

Validación Robusta: HeatMap



El mejor Sharpe futuro promedio se alcanza con 5 años de historia y 2 años de prueba (h5_f2), con valor 2.34. Los tests cortos concentran los mejores resultados, mientras que al aumentar los años futuros el desempeño tiende a caer.

KPIs y Métricas de Desempeño

Perspectiva del Cliente

- ✓ **Sharpe Ratio**
Retorno por unidad de riesgo
- ✓ **Retorno esperado anualizado**
Rentabilidad proyectada según los retornos esperados del modelo.
- ✓ **Máximo Drawdown**
Mayor caída porcentual desde un máximo histórico de la cartera
- ✓ **CVaR 95% diario**
Pérdida esperada en escenarios extremos, condicionada al peor 5% de los casos.
- ✓ **Cumplimiento del perfil de riesgo**
Grado en que la cartera recomendada respeta la tolerancia al riesgo del cliente

Perspectiva de la Empresa

- ✓ **Utilidad por comisiones**
Ingresos estimados por transacciones y/o rebalanceos ejecutados.
- ✓ **Tiempo de respuesta**
< 10 segundos por recomendación
- ✓ **Tasa de adopción de recomendaciones**
Porcentaje de recomendaciones aceptadas o ejecutadas por los clientes.
- ✓ **Volumen administrado**
Monto total asociado a carteras generadas por el sistema.



Persepectiva de la empresa pendiente para Entrega 3 (Requieren Simulación)

Caso Base

Portafolio equiponderado conformado por las 20 acciones de mayor capitalización bursátil del dataset, con pesos iguales de 5% por activo.

=

CONSTRUCCIÓN

Pesos idénticos

$w_i = 1/N = 5\%$

$\forall i = 1, \dots, N; N = 20$



UNIVERSO

Top 20 acciones

Mayor capitalización
del dataset



REBALANCEO

Mensual

Al inicio de cada
ventana de evaluación



RESTRICCIÓN

Ninguna

Sin límite de riesgo ni
objetivo de retorno


Caso Base

Portafolio equiponderado conformado por las 20 acciones de mayor capitalización bursátil del dataset, con pesos iguales de 5% por activo.

¿Por qué este benchmark?

- **Naive diversification:** sin parámetros estimados, elimina error en $\hat{\mu}$ y $\hat{\Sigma}$, a menudo supera modelos sofisticados out-of-sample.
- **Referencia estándar:** DeMiguel et al. (2009) — el portafolio $1/N$ supera a MV en 7 de 7 datasets reales.
- **El umbral real:** si Markowitz no supera $1/N$, la complejidad del modelo no se justifica.

Benchmark: Top 20 equiponderado



Caso Base vs. Markowitz

Benchmark: equiponderado top 20 por capitalización de mercado

Portafolio	Sharpe futuro	Retorno anual	Volatilidad	Drawdown	CVaR 95%
Mínima varianza	1.81	26.2%	13.5%	-10.4%	1.43%
Muy conservador	1.83	31.8%	16.6%	-11.8%	1.46%
Conservador	1.78	36.0%	19.9%	-13.5%	1.58%
Neutro	1.85	45.6%	25.4%	-15.4%	1.89%
Arriesgado	1.83	64.2%	36.2%	-19.4%	2.65%
Muy arriesgado	1.78	78.5%	43.4%	-25.9%	3.52%
Benchmark	1.96	57.3%	28.9%	-20.8%	2.60%

Promedios fuera de muestra: 6 horizontes $\times$ 3 ventanas = 18 evaluaciones por portafolio

Análisis de Resultados

Coherencia riesgo-retorno

Los perfiles más arriesgados obtienen mayor retorno pero con mayor volatilidad, drawdown y CVaR. El modelo diferencia correctamente los 5 perfiles.

Benchmark competitivo

El benchmark top-20 obtiene el mayor Sharpe (1.96). Esto refleja el buen desempeño de grandes empresas en el período evaluado, no una falla del optimizador.

Frontera teórica vs. real

El portafolio de tangencia cae de **Sharpe 3.98 teórico a 1.66 real**: alta sensibilidad a errores en la estimación de μ . El orden de riesgo sí se preserva fuera de muestra.

Ventana óptima: h7_f2

7 años de calibración y 2 de prueba da el Sharpe más alto y estable. Los perfiles arriesgados se benefician más de h6_f3 (6 históricos, 3 futuros).

Frontera Eficiente y Validación Futura



Fortalezas, Debilidades y Mejoras

Fortalezas

- Base teórica sólida y validada
- 601 activos simultáneos
- Validación multi-ventana robusta
- Eficiente computacionalmente ($< 10s$)
- Perfiles coherentes con perfil de riesgo

Debilidades

- Portafolios estáticos (sin rebalanceo)
- Sensible a estimación de μ
- Sin costos de transacción
- Asume normalidad de retornos
- Tasa libre de riesgo fija

Mejoras (Entrega 3)

- Black-Litterman para estimar μ
- CVaR operacional como restricción
- Rebalanceo semanal dinámico
- Comisiones $k\%$ integradas
- Modelos factoriales para μ y Σ
- Dinámica del cliente (P_1, P_2)

Plan de Trabajo — Próximos Pasos

Cumplimiento Plan Entrega 1

- ✓ Filtrado de datos
- ✓ Ajuste de distribución de los retornos históricos
- ✓ Modelo base Markowitz implementado
- ✓ Validación del modelo con datos históricos

Próximas Etapas

1. Implementar Black-Litterman con views
2. Simulación de rebalanceo con comisiones
3. Lógica de aceptación/abandono (P_1, P_2)
4. Generación de escenarios Monte Carlo
5. Integración y presentación final

Cronograma estimado — Entrega 3

Semana 1–2

Black-Litterman + CVaR

Semana 3–4

Rebalanceo + comisiones

Semana 5–6

Monte Carlo + integración

Bibliografía

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.

He, G., & Litterman, R. (1999). The intuition behind Black–Litterman model portfolios. *Goldman Sachs Asset Management*.

Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.

Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.

D'Acunto, F., Prabhala, N., & Rossi, A. G. (2019). The promises and pitfalls of robo-advising. *Review of Financial Studies*, 32(5), 1983–2020.

Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.