

Implementación y calibración secuencial del modelo Black–Litterman

Proyecto Capstone FinPUC

Junio 2026

1. Propósito de la calibración

La versión anterior del recomendador FinPUC incorporaba Black–Litterman como una extensión natural del modelo media-varianza, pero varios de sus parámetros centrales se encontraban fijados de manera heurística: la matriz de *views* P , el vector de retornos esperados de las opiniones Q , la matriz de incertidumbre Ω y el escalar τ . Para que la metodología fuera defendible en la Entrega 3, se implementó una calibración secuencial basada en evidencia computacional. El objetivo no fue encontrar el óptimo global de todas las combinaciones posibles, porque esa búsqueda sería costosa y poco trazable, sino construir una heurística ordenada que permitiera explicar cada decisión metodológica.

La calibración se ejecutó sobre un universo común de 601 activos, con los mismos escenarios de datos utilizados en la entrega anterior: una base de entrenamiento sin pandemia y otra con pandemia. El horizonte principal se mantuvo en $h7_f2$, es decir, siete años de historia y dos años de evaluación fuera de muestra, con rebalanceo semestral. Esta decisión mantiene la comparabilidad con Markowitz y evita que la calibración de Black–Litterman se beneficie de una ventana distinta a la usada por el caso base.

2. Caso base: Markowitz y benchmark

El punto de partida de la historia metodológica es el caso base. Markowitz representa la optimización financiera pura: estima retornos esperados y covarianzas históricas, y luego selecciona portafolios según el perfil de riesgo del cliente. El benchmark equiponderado, en cambio, funciona como control no paramétrico: no depende de estimaciones de μ ni de Σ , por lo que permite medir si la sofisticación del optimizador realmente agrega valor.

En los resultados previos, Markowitz mostraba un comportamiento ambivalente. En el escenario sin pandemia, el portafolio “Ideal de mercado” alcanzaba un Sharpe alto, pero este desempeño era sensible a la estimación histórica. Al incorporar datos de pandemia al entrenamiento, los perfiles más agresivos se deterioraban de forma importante. El benchmark, aunque menos sofisticado, mantenía una referencia exigente por su diversificación simple en activos grandes. Esta tensión justificó la introducción de Black–Litterman: no para maximizar retorno bruto a cualquier costo, sino para estabilizar las estimaciones y reducir la dependencia de señales históricas extremas.

Cuadro 1: Referencia metodológica del caso base

Escenario	Modelo	Retorno total	Drawdown	Sharpe
Sin pandemia	Markowitz, Ideal de mercado	76.5 %	-12.6 %	2.51
Con pandemia	Markowitz, Muy conservador	54.5 %	-10.2 %	2.02
Ambos	Benchmark equiponderado	101.4 %	-21.9 %	2.05

La lectura de esta tabla no es que un modelo sea universalmente superior. El benchmark logra mayor retorno bruto, pero acepta caídas más profundas. Markowitz puede entregar mejor retorno ajustado por riesgo en ventanas favorables, pero es vulnerable a cambios de régimen. Por ello, la calibración de Black–Litterman se diseñó con una regla explícita: una configuración no podía ser seleccionada solo por mejorar Sharpe si empeoraba materialmente el drawdown frente a Markowitz.

3. Camino de calibración secuencial

3.1. Criterio de selección

Cada etapa se evaluó con un score robusto que combina Sharpe, mejora de Sharpe frente a Markowitz, retorno anual, drawdown, CVaR y estabilidad. Además, se agregó una regla de resiliencia: si una configuración empeoraba el drawdown promedio frente a Markowitz en más de tres puntos porcentuales, quedaba degradada en el ranking. Esta regla fue clave, porque una versión inicial de la calibración elegía momentum agresivo con alto Sharpe, pero a costa de caídas más severas. El criterio final corrige ese sesgo y alinea el experimento con el objetivo del proyecto: recomendar una metodología estable, no una estrategia que solo gane en una métrica.

3.2. Paso 1: selección de familia de *view*

La primera decisión fue determinar qué tipo de información debía entrar al posterior Black–Litterman. Se compararon cuatro familias: momentum general, momentum sobre el top de capitalización a seis meses, momentum top/bottom por capitalización a un año, y una *view* macro de desempleo. En esta etapa se mantuvieron fijos $\tau = 0,05$, la confianza base de momentum en 0.50 y la confianza de desempleo en 0.35.

El resultado fue metodológicamente relevante. Momentum general obtuvo el mayor Sharpe medio, pero también deterioró el drawdown promedio frente a Markowitz. Bajo una lectura puramente oportunista, esa familia habría sido seleccionada. Sin embargo, al aplicar la regla de resiliencia, la *view* de desempleo se convirtió en la alternativa ganadora. Su Sharpe medio fue 1.579 y su mejora promedio frente a Markowitz fue moderada, 0.076 puntos, pero su drawdown promedio fue 2.69 puntos porcentuales mejor que el caso base. La decisión fue, por tanto, privilegiar una señal macro defensiva antes que una señal de momentum con mayor retorno pero peor cola de pérdidas.

Cuadro 2: Selección de familia de *view*

Familia	Sharpe medio	Δ Sharpe	Drawdown medio	Score
Desempleo macro	1.579	0.076	-12.9 %	0.595
Momentum top market-cap 6M	1.605	0.101	-15.7 %	0.587
Momentum general	1.705	0.201	-20.0 %	0.277
Momentum top/bottom 1Y	1.489	-0.014	-16.4 %	0.132

3.3. Paso 2: estructura interna de P

Una vez elegida la familia de desempleo, la calibración se concentró en la estructura de P . En este caso, P no selecciona ganadores y perdedores por ranking de retornos, sino que expresa una opinión relativa entre sectores cíclicos y defensivos. Con un desempleo asumido menor al neutral, el modelo favorece sectores cíclicos frente a sectores defensivos; si el desempleo asumido aumenta sobre el neutral, la dirección de la señal se invierte.

Se evaluaron tres niveles de desempleo asumido, 4 %, 5 % y 6 %, combinados con β macro de 0.5, 1.0 y 1.5. La mejor configuración fue desempleo asumido de 4 % y $\beta = 1,5$. Esta elección no debe interpretarse como una predicción macroeconómica exacta, sino como una calibración de escenario: bajo una economía con desempleo por debajo de su nivel neutral, una exposición moderada a sectores cíclicos mejora el balance retorno-riesgo sin deteriorar la cola de pérdidas.

Cuadro 3: Calibración de la estructura macro de P					
Desempleo asumido	β macro	Sharpe medio	Δ Sharpe	Drawdown medio	Score
4 %	1.5	1.713	0.009	-9.8 %	0.650
4 %	1.0	1.712	0.007	-9.8 %	0.606
4 %	0.5	1.710	0.006	-9.7 %	0.562
5 %	0.5–1.5	1.709	0.004	-9.7 %	0.510
6 %	1.5	1.704	-0.000	-9.7 %	0.350

3.4. Paso 3: intensidad de Q

Luego se calibró la intensidad del vector Q mediante un factor de escala $q_{\text{scale}} \in \{0,5, 1,0, 1,5\}$. Esta etapa responde a una pregunta distinta a la anterior: una vez definida la dirección de la opinión macro, cuánta fuerza debe tener esa opinión en el posterior. El mejor resultado se obtuvo con $q_{\text{scale}} = 1,5$, que elevó el Sharpe medio a 1.715 y mantuvo un drawdown promedio cercano a -9.8 %.

La interpretación es que una *view* macro demasiado tenue casi no desplaza el prior de equilibrio, mientras que una intensidad mayor entrega una corrección visible sin generar el deterioro de drawdown observado en momentum. Por eso se seleccionó $q_{\text{scale}} = 1,5$: no por maximizar retorno aislado, sino porque incrementa la contribución de la señal manteniendo estable el perfil de pérdidas.

3.5. Paso 4: confianza de Ω

La matriz Ω se calibró mediante el nivel de confianza de la *view*. Se probaron valores de 0.20, 0.35 y 0.50. El ganador fue 0.20, es decir, una confianza baja. Este resultado es coherente con la naturaleza de la señal: el desempleo usado es un escenario macro asumido, no una serie externa observada en tiempo real dentro del modelo. Por tanto, no conviene imponerlo con la misma fuerza que una señal de mercado directamente medida.

La baja confianza permite que Black–Litterman conserve el ancla del prior de equilibrio y use la *view* macro como corrección suave. En términos prácticos, esta etapa evita que el modelo se convierta en una apuesta sectorial excesiva. El Sharpe medio aumentó a 1.722 y el drawdown medio se mantuvo bajo control, cerca de -9.9 %.

3.6. Paso 5: ajuste final de τ

Finalmente se evaluó $\tau \in \{0,01, 0,025, 0,05, 0,10, 0,20\}$ manteniendo fija la *view* de desempleo, $q_{\text{scale}} = 1,5$ y confianza 0.20. El mejor resultado fue $\tau = 0,20$, con Sharpe medio 1.730, mejora

promedio de 0.025 puntos de Sharpe frente a Markowitz y drawdown promedio de -9.8 %.

La elección de τ debe leerse como una sensibilidad final del prior. En esta implementación, Ω se calcula en función de $P\tau\Sigma P^\top$ y la confianza, por lo que τ no opera como un simple multiplicador de la *view*; también afecta la covarianza posterior y, por lo tanto, la estabilidad de la optimización. La calibración muestra que un τ mayor entrega una versión levemente más flexible del prior sin romper la restricción de resiliencia.

Cuadro 4: Configuración final calibrada

Componente	Valor final
Familia de <i>view</i>	Desempleo macro asumido
Desempleo asumido	4 %
Desempleo neutral	5 %
β macro	1.5
q_{scale}	1.5
Confianza para Ω	0.20
τ	0.20
Criterio de selección	Score robusto con penalización de drawdown

4. Robustez y escenarios complejos

El modelo calibrado final no debe presentarse como una metodología que gana en todos los escenarios. Su aporte es más específico: reduce la severidad de las caídas en escenarios donde Markowitz es sensible al error de estimación. Esto se observa con claridad en el escenario con pandemia. Para el perfil Arriesgado, Black–Litterman calibrado alcanza Sharpe 1.71 frente a 1.17 de Markowitz, una mejora de 46.7 %, y reduce el drawdown desde -19.1 % a -11.9 %. Para el perfil Muy arriesgado, el Sharpe sube de 0.71 a 1.08 y el drawdown mejora desde -29.2 % a -24.7 %. En el perfil Neutro, el Sharpe aumenta de 1.66 a 1.79 y el drawdown mejora desde -11.1 % a -9.3 %.

Cuadro 5: Modelo calibrado frente a Markowitz en escenario con pandemia

Perfil	Sharpe BL	Sharpe Markowitz	Mejora	Drawdown BL	Drawdown Markowitz
Neutro	1.79	1.66	7.8 %	-9.3 %	-11.1 %
Arriesgado	1.71	1.17	46.7 %	-11.9 %	-19.1 %
Muy arriesgado	1.08	0.71	51.7 %	-24.7 %	-29.2 %
Conservador	1.78	1.78	0.2 %	-9.0 %	-8.9 %
Muy conservador	1.77	1.79	-0.9 %	-8.9 %	-8.8 %

La validación robusta confirma la misma idea con un matiz importante. En ventanas móviles para el perfil Neutro, Black–Litterman calibrado obtuvo Sharpe medio 1.44, inferior al 1.63 de Markowitz, pero su drawdown medio fue -11.1 %, mejor que el -13.5 % del caso base. Por lo tanto, el modelo calibrado no es superior si se evalúa únicamente por Sharpe promedio en todas las ventanas. Su fortaleza está en la contención de pérdidas: sacrifica parte del retorno esperado para reducir la exposición a caídas más profundas.

Esta distinción es central para la conclusión del proyecto. Si el objetivo fuera maximizar Sharpe promedio en cualquier condición, el modelo no sería una mejora universal. Si el objetivo es construir

un recomendador más resiliente para clientes con sensibilidad a pérdidas, la configuración calibrada es defendible, especialmente en perfiles donde Markowitz se deteriora ante información de estrés.

5. Integración posterior con Monte Carlo P4

Una vez calibrado el portafolio, sus KPIs fueron usados como entrada para la simulación Monte Carlo P4. Esta integración se realizó después de la optimización financiera. La utilidad de la empresa no entró en la función objetivo del optimizador de portafolios; se calculó posteriormente como consecuencia del saldo administrado, la aceptación de recomendaciones y el retiro del cliente. Esta separación es metodológicamente necesaria: el portafolio se optimiza para el cliente, mientras que la empresa evalúa después la sostenibilidad económica de esa recomendación.

Los resultados P4 muestran que la configuración calibrada no domina comercialmente a Markowitz en todos los casos. El mejor score P4 observado corresponde a Markowitz en el perfil Neutro sin pandemia, con riqueza media USD 2,813, retiro 0.9 %, utilidad empresa USD 194 y score 2,998. En comparación, Black–Litterman calibrado obtiene en el perfil Neutro sin pandemia riqueza media USD 2,306, retiro 0.9 %, utilidad empresa USD 145 y score 2,442. La diferencia se explica porque el modelo calibrado es más defensivo: reduce drawdown, pero también disminuye retorno esperado y, por ende, saldo administrado futuro.

Cuadro 6: Evaluación posterior P4: cliente y empresa

Modelo	Escenario	Perfil	Riqueza	Retiro	Utilidad	Score P4
Markowitz	Sin pandemia	Neutro	2,813	0.9 %	194	2,998
Markowitz	Sin pandemia	Conservador	2,533	14.4 %	198	2,587
Markowitz	Con pandemia	Neutro	2,389	0.7 %	154	2,536
BL calibrado	Sin pandemia	Conservador	2,457	14.9 %	194	2,501
BL calibrado	Con pandemia	Conservador	2,393	13.7 %	189	2,445
BL calibrado	Con pandemia	Neutro	2,278	0.4 %	142	2,417

La simulación P4, por tanto, no contradice la calibración. Más bien, aclara el uso del modelo. Black–Litterman calibrado no debe venderse como el máximo generador de riqueza terminal. Su función es distinta: entregar una alternativa más conservadora en términos de drawdown para perfiles donde la permanencia del cliente y la tolerancia a pérdidas son variables relevantes. La utilidad de FinPUC se mantiene como una métrica posterior, y su menor valor relativo en algunos casos refleja precisamente el costo de una recomendación más defensiva.

6. Conclusión

La calibración secuencial permitió transformar Black–Litterman desde un conjunto de parámetros elegidos heurísticamente a una metodología defendible. El camino de calibración mostró que una selección basada solo en Sharpe habría favorecido momentum general; sin embargo, esa alternativa empeoraba el drawdown promedio frente al caso base. Al incorporar explícitamente una penalización por deterioro de pérdidas, el modelo final recomendado pasó a ser Black–Litterman con *view* macro de desempleo, desempleo asumido de 4 %, desempleo neutral de 5 %, $\beta = 1.5$, $q_{\text{scale}} = 1.5$, confianza 0.20 y $\tau = 0.20$.

La recomendación principal es utilizar esta configuración calibrada como metodología defensiva para perfiles Neutro, Arriesgado y Muy arriesgado cuando el entrenamiento incorpora escenarios

complejos como la pandemia. En el escenario con pandemia, el modelo mejora el Sharpe del perfil Neutro en 7.8 %, del perfil Arriesgado en 46.7 % y del perfil Muy arriesgado en 51.7 % frente a Markowitz. Además, reduce el drawdown en esos tres perfiles: de -11.1 % a -9.3 % en Neutro, de -19.1 % a -11.9 % en Arriesgado, y de -29.2 % a -24.7 % en Muy arriesgado. Esta evidencia respalda una conclusión fuerte pero acotada: Black–Litterman calibrado no reemplaza a Markowitz en todos los contextos, pero sí entrega una mejora robusta para perfiles expuestos al deterioro de estimaciones históricas bajo estrés.

Para perfiles conservadores, la recomendación debe ser más cuidadosa. En Muy conservador y Conservador las diferencias de Sharpe frente a Markowitz son pequeñas, y en algunos casos no compensan la complejidad adicional del modelo. En términos P4, Markowitz mantiene mejores scores en varios escenarios porque genera mayor riqueza terminal y, por lo tanto, mayor saldo administrado. Por ello, la conclusión de negocio no es que Black–Litterman calibrado maximice siempre la utilidad de FinPUC, sino que ofrece una alternativa metodológicamente más resiliente cuando el objetivo prioritario es controlar pérdidas y sostener una recomendación defendible ante escenarios adversos.

En síntesis, la Entrega 3 debe presentar esta calibración como una historia de aprendizaje: Markowitz establece el caso base, momentum revela el riesgo de perseguir Sharpe sin control de drawdown, la *view* de desempleo introduce una señal macro más estable, y la calibración de P , Q , Ω y τ permite llegar a una configuración final trazable. La recomendación final no es universal, sino segmentada: Black–Litterman calibrado con desempleo es recomendable para perfiles de mayor exposición al riesgo en escenarios de estrés, mientras que Markowitz y el benchmark siguen siendo referencias necesarias para evaluar riqueza terminal y desempeño comercial.