

Metodología de calibración secuencial del modelo Black–Litterman

Proyecto Capstone FinPUC

Junio 2026

1. Objetivo metodológico

El objetivo de esta implementación fue transformar el uso de Black–Litterman desde una configuración heurística, definida manualmente, hacia una calibración experimental y defendible. En la versión anterior del proyecto, los componentes principales del modelo, es decir, la matriz de opiniones P , el vector de retornos esperados de las opiniones Q , la matriz de incertidumbre Ω y el parámetro τ , se encontraban fijados con criterios razonables pero no validados empíricamente. Para la Entrega 3, el foco metodológico fue construir un proceso trazable que permitiera responder por qué se eligió cada componente del modelo.

La calibración no buscó resolver un problema de optimización global sobre todas las combinaciones posibles. Esa estrategia habría requerido evaluar simultáneamente familias de *views*, estructuras alternativas de P , intensidades de Q , niveles de confianza para Ω , valores de τ , perfiles de riesgo y escenarios de datos. Además de su costo computacional, una búsqueda exhaustiva habría dificultado explicar la contribución marginal de cada decisión. Por ello, se implementó una calibración secuencial: en cada etapa se fija lo ya seleccionado, se varía un conjunto acotado de parámetros y se escoge la configuración ganadora según métricas fuera de muestra.

La lógica central es la siguiente: primero se decide qué tipo de información debe expresar la *view*; luego se calibra cómo se traduce esa información en la matriz P ; posteriormente se ajusta la intensidad del retorno esperado de la opinión Q ; después se calibra la incertidumbre Ω ; y finalmente se realiza una sensibilidad de τ . Esta secuencia genera una historia metodológica clara: desde el caso base Markowitz hasta una versión final de Black–Litterman calibrada por evidencia.

2. Datos, universo y escenarios

La calibración se ejecutó sobre un universo común de 601 acciones estadounidenses. Para cada activo se construyó una serie diaria de retorno total usando precios de cierre y dividendos:

$$r_{i,t} = \frac{Close_{i,t} + Dividends_{i,t}}{Close_{i,t-1}} - 1.$$

El uso de retorno total es relevante porque evita medir el desempeño solo por apreciación de precio e incorpora distribuciones de dividendos. Luego, las series individuales se unieron mediante una intersección de fechas comunes, eliminando observaciones con datos faltantes. Esta decisión sacrifica parte de la muestra, pero asegura que todos los portafolios se evalúen sobre el mismo calendario y el mismo universo de activos.

Se consideraron dos escenarios de datos:

- **Escenario sin pandemia:** base filtrada que excluye el período de pandemia, usada para analizar el comportamiento del modelo en un contexto de mercado más regular.

- **Escenario con pandemia:** base que incorpora el período de estrés asociado a la pandemia, usada para evaluar si el modelo mantiene resiliencia frente a cambios bruscos de régimen.

En ambos escenarios se usó la misma estructura temporal principal: siete años de historia para estimación y dos años fuera de muestra para evaluación, lo que en el código se identifica como horizonte $h7_f2$. La etapa fuera de muestra se dividió en segmentos de rebalanceo semestral, usando aproximadamente 126 días hábiles por rebalanceo. En cada segmento, el modelo se reestima con toda la información disponible hasta ese momento y luego se evalúa en el tramo siguiente.

3. Caso base Markowitz

Antes de calibrar Black–Litterman, se calculó un caso base comparable con Markowitz. Este caso base cumple dos funciones. Primero, entrega una referencia financiera directa: qué ocurre si se optimiza solamente con medias y covarianzas históricas. Segundo, permite que cada configuración candidata de Black–Litterman sea evaluada no en abstracto, sino en términos de mejora o deterioro frente a una metodología conocida.

Para cada ventana de entrenamiento se estimaron los retornos esperados históricos μ y la matriz de covarianzas Σ . La covarianza se estabilizó mediante una contracción parcial hacia su diagonal:

$$\Sigma_{\text{shrunk}} = (1 - \lambda)\Sigma + \lambda \text{diag}(\Sigma),$$

donde λ corresponde al parámetro de *shrinkage* utilizado en la implementación. Esta corrección reduce la dependencia de covarianzas muestrales ruidosas y ayuda a que el optimizador no responda excesivamente a relaciones espurias entre activos.

Luego, para cada perfil de riesgo se resolvió una versión restringida del problema media-varianza:

$$\max_w \quad \mu^\top w - \frac{\gamma}{2} w^\top \Sigma w,$$

sujeto a:

$$\sum_i w_i = 1, \quad 0 \leq w_i \leq \bar{w}_{\text{perfil}}.$$

El parámetro γ representa la aversión al riesgo del perfil y $\bar{w}_{\text{perfil}}$ representa el peso máximo permitido por activo. En perfiles con restricción de volatilidad anual, el portafolio obtenido por gradiente proyectado se mezcla con el portafolio de mínima varianza cuando la volatilidad excede el límite del perfil. Esta estructura evita concentraciones extremas y mantiene comparabilidad entre Markowitz y Black–Litterman, ya que ambos usan el mismo optimizador y las mismas restricciones por perfil.

Cuadro 1: Perfiles de riesgo usados en la optimización

Perfil	γ	Peso máximo por activo	Límite de volatilidad anual
Muy conservador	80.0	5 %	8 %
Conservador	45.0	7 %	12 %
Neutro	20.0	10 %	18 %
Arriesgado	8.0	15 %	28 %
Muy arriesgado	3.0	20 %	40 %

4. Formulación Black–Litterman implementada

Black–Litterman se implementó como una corrección bayesiana del retorno esperado de equilibrio. A diferencia de Markowitz, que usa directamente la media histórica, Black–Litterman parte de un prior implícito de mercado y luego lo ajusta con opiniones estructuradas.

Primero se calculan pesos de mercado w_{mkt} a partir de capitalización bursátil. Luego se estima el coeficiente de aversión representativo del mercado:

$$\delta = \frac{E[R_{mkt}] - r_f}{\text{Var}(R_{mkt})},$$

donde R_{mkt} es el retorno del portafolio ponderado por capitalización y r_f es la tasa libre de riesgo usada en el proyecto. Con ello se obtiene el prior de retornos de equilibrio:

$$\pi = \delta \Sigma w_{mkt}.$$

La opinión del analista o del experimento se codifica con tres objetos:

- P : matriz que indica qué combinación relativa de activos recibe la opinión.
- Q : retorno esperado asociado a esa opinión.
- Ω : incertidumbre de la opinión.

En esta implementación se usó una sola *view* por configuración, por lo que P tiene dimensión $1 \times N$, Q es escalar y Ω es una matriz 1×1 . El posterior de retornos esperados se calcula como:

$$\mu_{BL} = \pi + \tau \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} (Q - P \pi).$$

La covarianza posterior se calcula como:

$$\Sigma_{BL} = (1 + \tau) \Sigma - \tau \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} P \tau \Sigma.$$

La matriz Ω se definió en función de la varianza implícita de la opinión y de un parámetro de confianza:

$$\Omega = \frac{P(\tau \Sigma)P^\top}{c},$$

donde c representa el nivel de confianza asignado a la *view*. Un valor mayor de c reduce Ω y, por lo tanto, hace que la opinión pese más en el posterior. Un valor menor de c aumenta Ω y deja que el prior de equilibrio domine con mayor fuerza. Esta definición permite calibrar la confianza de forma interpretable, sin fijar manualmente una varianza arbitraria para la opinión.

5. Construcción de las familias de *views*

La primera etapa de la metodología consistió en decidir qué tipo de información debía entrar al modelo. Se consideraron cuatro familias iniciales:

1. **Momentum general**: selecciona activos ganadores y perdedores según retorno acumulado reciente dentro del universo completo.

2. **Momentum top market-cap 6M**: restringe el universo a las acciones de mayor capitalización y calcula momentum con ventana de seis meses.
3. **Momentum top/bottom market-cap 1Y**: selecciona ganadores y perdedores dentro de un universo acotado por capitalización y usa una ventana anual.
4. **Desempleo macro asumido**: expresa una opinión relativa entre sectores cíclicos y sectores defensivos según un escenario macro de desempleo.

La familia de momentum se construyó calculando:

$$M_i = \prod_{t \in L} (1 + r_{i,t}) - 1,$$

donde L es la ventana de *lookback*. Los activos con mayor M_i forman el lado largo de P y los activos con menor M_i forman el lado corto. En una versión equiponderada, cada activo largo recibe peso positivo igual y cada activo corto recibe peso negativo igual. En versiones alternativas, los pesos pueden depender de capitalización o ranking. El retorno esperado de la opinión se calcula como el retorno promedio diario del portafolio long-short implícito:

$$Q = q_{\text{scale}} \cdot \frac{1}{T} \sum_{t=1}^T r_t^\top P^\top.$$

La familia de desempleo se construyó de forma distinta. Primero se clasificaron sectores en dos grupos. Los sectores cíclicos fueron Technology, Consumer Cyclical, Industrials, Financial Services, Communication Services, Energy y Basic Materials. Los sectores defensivos fueron Healthcare, Consumer Defensive, Utilities y Real Estate. Si el desempleo asumido es menor que el desempleo neutral, la *view* favorece sectores cíclicos y toma posición relativa corta en defensivos. Si el desempleo asumido es mayor que el neutral, la dirección se invierte.

El vector P de la *view* macro se pondera por capitalización dentro de cada lado:

$$\sum_{i \in Long} P_i = 1, \quad \sum_{j \in Short} P_j = -1.$$

El retorno esperado de la opinión macro se define como:

$$Q = \frac{|u_{\text{neutral}} - u_{\text{asumido}}| \cdot \beta_{\text{macro}} \cdot q_{\text{scale}}}{252}.$$

Esta expresión traduce la distancia entre desempleo asumido y neutral a una señal diaria comparable con retornos diarios. El parámetro β_{macro} controla la sensibilidad de la opinión al escenario macro y q_{scale} controla la intensidad final de Q .

6. Métricas de evaluación

Cada configuración candidata se evaluó fuera de muestra, no solamente sobre parámetros estimados. Para cada portafolio rebalanceado se calculó retorno total, retorno anualizado, volatilidad anualizada, Sharpe, drawdown máximo y CVaR diario al 95 %.

El Sharpe se definió como:

$$Sharpe = \frac{R_{ann} - r_f}{\sigma_{ann}}.$$

El drawdown máximo se calculó sobre la curva de riqueza acumulada:

$$MDD = \min_t \left(\frac{W_t}{\max_{s \leq t} W_s} - 1 \right).$$

El CVaR diario al 95 % se calculó como la pérdida promedio condicional en el 5 % peor de los días. En la implementación, las pérdidas se definen como $-r_t$ y luego se promedia la cola superior de esas pérdidas.

La selección no se hizo con una sola métrica. Para cada etapa se construyó un *score* robusto que combina:

- Sharpe medio.
- Mejora media de Sharpe frente a Markowitz.
- Drawdown medio.
- CVaR medio.
- Estabilidad del Sharpe, medida por su desviación estándar.
- Retorno anual medio.

Antes de combinar las variables, cada métrica se normaliza dentro del conjunto de candidatos de la etapa. El *score* base se calcula como:

$$\begin{aligned} Score_{base} = & 0,35 \cdot \widetilde{Sharpe} + 0,25 \cdot \Delta \widetilde{Sharpe} + 0,15 \cdot \widetilde{Drawdown} \\ & + 0,10 \cdot \widetilde{CVaR} + 0,10 \cdot \sigma(\widetilde{Sharpe}) + 0,05 \cdot \widetilde{R}_{ann}. \end{aligned}$$

Los superíndices negativos indican que una menor magnitud es preferible; por ejemplo, menor CVaR y menor desviación del Sharpe. Además, se agregó una regla de resiliencia: si el drawdown promedio de una configuración empeora en más de tres puntos porcentuales frente a Markowitz, la configuración se degrada en el ranking aunque tenga mayor retorno o mayor Sharpe. Esta regla fue incorporada porque el objetivo del proyecto no es encontrar una estrategia que maximice una métrica aislada, sino una recomendación defendible para clientes expuestos a pérdidas.

7. Secuencia de calibración

7.1. Etapa 0: definición del caso base

La etapa cero consiste en calcular Markowitz con el mismo universo, las mismas ventanas, los mismos perfiles, el mismo rebalanceo y las mismas métricas que usará Black–Litterman. Este paso es indispensable porque todas las mejoras se miden contra una referencia homogénea. En la ejecución final, el caso base produjo 10 observaciones: cinco perfiles por dos escenarios.

7.2. Etapa 1: selección de familia de *view*

La primera etapa calibrada responde a la pregunta: *qué señal debe entrar al modelo*. Se probaron cuatro configuraciones base, manteniendo fijos los demás parámetros. Para momentum se usó confianza 0.50 y $\tau = 0,05$; para desempleo se usó confianza 0.35 y $\tau = 0,05$. La evaluación se realizó

sobre ambos escenarios y todos los perfiles de riesgo, por lo que cada familia se juzgó con una mirada amplia.

Cuadro 2: Espacio de búsqueda de la etapa 1

Configuración	Familia	Parámetros iniciales
<code>stage1_momentum</code>	Momentum general	Lookback 252, top/bottom 20, pesos iguales
<code>stage1_mcap20_6m</code>	Momentum market-cap	Lookback 126, universo 20, long/short 10
<code>stage1_mcap40_1y</code>	Momentum market-cap	Lookback 252, universo 40, long/short 20
<code>stage1_desempleo</code>	Desempleo macro	Desempleo 4 %, neutral 5 %, $\beta = 1,0$

El resultado de esta etapa fue relevante para la historia del modelo. Momentum general obtuvo el mayor Sharpe medio, pero deterioró el drawdown promedio frente a Markowitz en más de tres puntos porcentuales. Por lo tanto, fue penalizado por la regla de resiliencia. La familia ganadora fue desempleo macro asumido, con Sharpe medio 1.579, mejora media de Sharpe de 0.076 y mejora de drawdown de 2.69 puntos porcentuales frente a Markowitz.

7.3. Etapa 2: estructura interna de P

Una vez seleccionada la familia de *view*, la segunda etapa calibra la estructura interna de P . Esta etapa responde a la pregunta: *cómo se traduce la señal elegida a posiciones relativas*. El espacio de búsqueda depende de la familia ganadora. Si hubiese ganado momentum, se habrían probado ventanas de 63, 126 y 252 días, tamaños long-short alternativos y ponderaciones por igualdad, ranking o capitalización. Como ganó desempleo, la calibración se concentró en desempleo asumido y sensibilidad macro.

Para la familia macro se probaron:

$$u_{\text{asumido}} \in \{4\%, 5\%, 6\%\}, \quad \beta_{\text{macro}} \in \{0,5, 1,0, 1,5\}.$$

El desempleo neutral se mantuvo en 5 %. Esta grilla permite evaluar tres regímenes: desempleo bajo, neutral y alto. Cuando el desempleo asumido es 4 %, el modelo favorece cíclicos frente a defensivos; cuando es 6 %, favorece defensivos frente a cíclicos; cuando es 5 %, la distancia al neutral es cero y la opinión pierde fuerza direccional.

Esta etapa se evaluó usando el perfil Neutro en ambos escenarios. La decisión de usar un perfil central evita que la estructura de P quede calibrada para un extremo de aversión al riesgo. La configuración ganadora fue desempleo asumido de 4 % y $\beta_{\text{macro}} = 1,5$, con Sharpe medio 1.713 y drawdown medio -9.8 %. Metodológicamente, esto indica que la mejor traducción de la señal macro fue una opinión procíclica moderadamente intensa, no una postura defensiva pura.

7.4. Etapa 3: intensidad de Q

La tercera etapa calibra el factor q_{scale} . La dirección de P ya estaba definida; ahora se ajusta cuánta fuerza tiene el retorno esperado de la opinión. Se probaron:

$$q_{\text{scale}} \in \{0,5, 1,0, 1,5\}.$$

Con $q_{\text{scale}} = 0,5$, la opinión entra de manera tenue y el posterior se mantiene más cerca del prior. Con $q_{\text{scale}} = 1,5$, la opinión desplaza más el retorno esperado. El ganador fue $q_{\text{scale}} = 1,5$, con Sharpe medio 1.715. La mejora respecto a $q_{\text{scale}} = 1,0$ fue pequeña pero consistente y no generó un deterioro

material de drawdown. Esta etapa justifica que la señal macro no solo se incluya en dirección, sino también con una intensidad suficiente para alterar el posterior.

7.5. Etapa 4: confianza y matriz Ω

La cuarta etapa calibra la confianza de la opinión. En esta implementación, la confianza no se incorpora directamente como un peso subjetivo, sino a través de Ω :

$$\Omega = \frac{P(\tau\Sigma)P^\top}{c}.$$

Por lo tanto, calibrar c equivale a decidir cuánto ruido se asigna a la opinión. Para la familia de desempleo se probaron:

$$c \in \{0,20, 0,35, 0,50\}.$$

El ganador fue $c = 0,20$, el nivel de confianza más bajo de la grilla. Aunque parezca contraintuitivo, el resultado es coherente. La *view* de desempleo se basa en un escenario macro asumido, no en una predicción econométrica externa incorporada al modelo. Por ello, una confianza baja permite que la opinión actúe como corrección suave al prior de equilibrio, sin convertir el portafolio en una apuesta sectorial excesiva. Con esta configuración, el Sharpe medio subió a 1.722 y el drawdown permaneció estable.

7.6. Etapa 5: sensibilidad final de τ

La quinta etapa calibra τ , manteniendo fijos P , Q y la regla de Ω seleccionadas. Se probaron:

$$\tau \in \{0,01, 0,025, 0,05, 0,10, 0,20\}.$$

En Black–Litterman, τ controla la incertidumbre del prior. En esta implementación también afecta Ω , porque Ω depende de $P(\tau\Sigma)P^\top$. Por lo tanto, τ no puede interpretarse como un multiplicador aislado: modifica simultáneamente la sensibilidad del posterior y la covarianza posterior. El ganador fue $\tau = 0,20$, con Sharpe medio 1.730, mejora media de Sharpe de 0.025 frente a Markowitz y drawdown medio -9.8 %.

Cuadro 3: Ganadores por etapa de calibración

Etapa	Configuración ganadora	Sharpe medio	Δ Sharpe	Score robusto
Familia de <i>view</i>	Desempleo macro	1.579	0.076	0.595
Estructura de P	$u = 4\%$, $\beta = 1,5$	1.713	0.009	0.650
Intensidad de Q	$q_{\text{scale}} = 1,5$	1.715	0.010	0.650
Confianza de Ω	$c = 0,20$	1.722	0.017	0.650
Sensibilidad de τ	$\tau = 0,20$	1.730	0.025	0.976

8. Configuración final

La configuración final calibrada corresponde a Black–Litterman con una *view* macro de desempleo:

Cuadro 4: Configuración final de Black–Litterman

Componente	Valor seleccionado
Familia de <i>view</i>	Desempleo macro asumido
Dirección de <i>P</i>	Largo en sectores cíclicos, corto en defensivos
Ponderación de <i>P</i>	Capitalización dentro de cada lado
Desempleo asumido	4 %
Desempleo neutral	5 %
β_{macro}	1.5
q_{scale}	1.5
Confianza <i>c</i> para Ω	0.20
τ	0.20

Esta configuración no debe entenderse como una predicción puntual de desempleo. Su interpretación correcta es metodológica: dentro del espacio acotado de *views* probado, la opinión macro procíclica con baja confianza y τ alto entregó el mejor balance entre retorno ajustado por riesgo y control de drawdown. La baja confianza evita sobrerreaccionar; el q_{scale} elevado permite que la opinión sea visible; y $\tau = 0,20$ entrega flexibilidad suficiente al prior para que Black–Litterman se diferencie de Markowitz.

9. Validación final por perfiles

Una vez escogida la configuración final, se recalculó Black–Litterman para los cinco perfiles de riesgo y los dos escenarios de datos. Esta etapa ya no calibra; solamente evalúa el modelo final. Luego se comparó contra Markowitz para determinar en qué perfiles la configuración calibrada es recomendable.

La regla de recomendación fue:

$$\text{Recomendado} \iff \Delta \text{Sharpe} \% > 0 \quad \text{y} \quad \Delta \text{Drawdown} > -3 \text{ pp.}$$

La primera condición exige mejora porcentual de Sharpe frente a Markowitz. La segunda impide recomendar un modelo que mejore Sharpe a costa de empeorar sustancialmente las caídas. Esta regla es consistente con el criterio usado en la calibración.

En el escenario con pandemia, la configuración final fue especialmente favorable para perfiles Neutro, Arriesgado y Muy arriesgado. En Arriesgado, el Sharpe subió de 1.17 a 1.71 y el drawdown mejoró de -19.1 % a -11.9 %. En Muy arriesgado, el Sharpe subió de 0.71 a 1.08 y el drawdown mejoró de -29.2 % a -24.7 %. En Neutro, el Sharpe subió de 1.66 a 1.79 y el drawdown mejoró de -11.1 % a -9.3 %. En perfiles conservadores, las mejoras fueron marginales o no dominantes, por lo que la recomendación debe ser más cautelosa.

10. Validación robusta

La validación robusta tuvo un objetivo distinto al de la calibración principal. No buscó volver a escoger parámetros, sino revisar si la conclusión dependía excesivamente de una ventana temporal específica. Para ello se evaluó el perfil Neutro en ventanas alternativas de entrenamiento y prueba:

$$(h, f) \in \{(7, 2), (6, 2), (5, 2), (4, 2)\},$$

con desplazamientos semestrales de la ventana fuera de muestra. Algunas ventanas se omitieron automáticamente cuando la muestra disponible no era suficiente. En total, la validación generó 22 filas de resultados entre Black–Litterman calibrado y Markowitz base.

El resultado debe leerse con cuidado. En promedio, Markowitz obtuvo mayor Sharpe en las ventanas robustas del perfil Neutro, mientras que Black–Litterman calibrado tuvo mejor drawdown medio. Esto confirma que el modelo calibrado no es una herramienta que “gana en todo”. Su aporte está en la resiliencia: reduce la severidad de las pérdidas aun cuando puede sacrificar parte del retorno ajustado por volatilidad en ciertas ventanas.

11. Integración posterior con Monte Carlo P4

Después de la calibración y validación financiera, los resultados de los portafolios se usaron como insumo para la simulación Monte Carlo P4. Esta etapa es posterior a la optimización. La utilidad de la empresa no entra en Markowitz ni en Black–Litterman; no se usa para escoger pesos, ni para modificar P , Q , Ω o τ . Se calcula después como una consecuencia de la riqueza simulada, los retiros del cliente y el saldo administrado.

La separación es clave. El optimizador de portafolios debe representar el objetivo financiero del cliente, sujeto a restricciones de riesgo. La empresa evalúa posteriormente si esa recomendación genera un saldo administrado sostenible. Mezclar ambos objetivos dentro del optimizador habría cambiado la naturaleza del problema, porque el modelo podría recomendar carteras que maximizan comisiones o saldo administrado aunque no sean las mejores para el cliente.

La simulación P4 muestra que Black–Litterman calibrado no domina siempre a Markowitz en riqueza terminal ni en utilidad de la empresa. Esto es coherente con su perfil más defensivo: al reducir drawdown, también puede reducir retorno esperado y saldo administrado futuro. Por lo tanto, P4 no se usa para invalidar la calibración, sino para interpretar sus consecuencias comerciales.

12. Productos de salida del experimento

La implementación genera archivos intermedios y finales que permiten auditar el experimento:

Cuadro 5: Principales archivos generados por la calibración

Archivo	Contenido
00_markowitz_base.csv	Resultados fuera de muestra del caso base Markowitz para los cinco perfiles y dos escenarios.
01_espacio_busqueda.csv	Resumen del espacio de búsqueda usado en cada etapa de calibración.
stage1_familia_view_ranking.csv	Ranking de familias de <i>views</i> según score robusto.
stage2_estructura_P_ranking.csv	Ranking de estructuras internas de P para la familia ganadora.
stage3_intensidad_Q_ranking.csv	Sensibilidad del factor q_{scale} .
stage4_confianza_Omega_ranking.csv	Sensibilidad de la confianza usada para construir Ω .
stage5_tau_ranking.csv	Sensibilidad final de τ .
08_final_bl_calibrado.csv	Resultados finales de Black–Litterman calibrado para todos los perfiles y escenarios.
09_recomendacion_por_perfil.csv	Comparación contra Markowitz y etiqueta de recomendación por perfil.

Archivo	Contenido
10_validacion_robusta_final.csv	Resultados de ventanas robustas para revisar sensibilidad temporal.
11_p4_bl_calibrado_vs_markowitz.csv	Evaluación posterior Monte Carlo P4 para cliente y empresa.
historia_calibracion_bl.md	Resumen narrativo automático de ganadores, recomendación, robustez y P4.

Además, se generaron gráficos para apoyar la narrativa del informe final: camino de score por etapa, mapa de calor de estructura macro, sensibilidad de confianza, sensibilidad de τ y mejora porcentual de Sharpe por perfil.



Figura 1: Evolución del score robusto del ganador en cada etapa de calibración.

13. Interpretación metodológica final

La calibración secuencial cumple tres funciones metodológicas. Primero, reduce arbitrariedad: los parámetros de Black–Litterman ya no se fijan “al ojo”, sino que se seleccionan mediante comparación empírica fuera de muestra. Segundo, mantiene explicabilidad: al calibrar una dimensión por vez, es posible justificar qué decisión se tomó en cada etapa y por qué. Tercero, incorpora resiliencia: el criterio de selección penaliza configuraciones que mejoran Sharpe deteriorando drawdown, lo que evita recomendar estrategias frágiles.

El resultado final es una configuración Black–Litterman con *view* macro de desempleo, desempleo asumido de 4 %, desempleo neutral de 5 %, $\beta_{\text{macro}} = 1,5$, $q_{\text{scale}} = 1,5$, confianza 0.20 y $\tau = 0,20$. Esta configuración debe presentarse como una recomendación segmentada, no universal. Es especialmente defendible para perfiles con mayor exposición al riesgo en escenarios complejos, porque mejora Sharpe y reduce drawdown frente a Markowitz en el escenario con pandemia. Para perfiles conservadores y para objetivos de riqueza terminal pura, Markowitz sigue siendo una referencia competitiva.

En síntesis, la metodología implementada permite contar una historia completa: Markowitz establece la línea base; las familias de *views* muestran que no toda mejora de Sharpe es deseable; la estructura de P traduce la señal elegida a una opinión relativa; Q determina la intensidad de esa opinión; Ω regula su incertidumbre; τ ajusta la sensibilidad del prior; y las validaciones finales muestran dónde el modelo calibrado agrega valor y dónde no. Esa es la contribución central de la calibración secuencial.