

Plan de acción posterior al feedback del 9 de junio Calibración Black–Litterman y validación final FinPUC

Proyecto Capstone FinPUC

Junio 2026

1. Objetivo del plan

El feedback del profesor del 9 de junio introduce una corrección metodológica central: los resultados actuales de Black–Litterman no pueden cerrarse usando la misma ventana para calibrar parámetros, validar la configuración y alimentar la simulación Monte Carlo P4. Aunque la calibración secuencial ya resolvió la arbitrariedad inicial de P , Q , Ω y τ , todavía existe riesgo de *overfitting* temporal si la configuración final se escoge mirando el mismo período que luego se presenta como test económico final.

El objetivo de este plan es ordenar el trabajo pendiente antes de la entrega y presentación final. La propuesta se organiza en cuatro ejes: separar horizontes, ampliar escenarios mediante ventanas móviles, medir la dinámica temporal del portafolio y preparar una defensa metodológica. El resultado esperado no es cambiar el relato completo del proyecto, sino fortalecerlo: pasar de "encontramos una configuración ganadora.^a ¿calibramos, validamos y testeamos la configuración en horizontes separados".

2. Diagnóstico de la situación actual

La implementación actual en `calibracion_secuencial_bl.py` realiza correctamente una calibración secuencial:

1. Calcula Markowitz base comparable.
2. Evalúa familias de *views*.
3. Calibra estructura de P .
4. Calibra intensidad de Q .
5. Calibra confianza de Ω .
6. Calibra τ .
7. Recalcula el modelo final para todos los perfiles.
8. Evalúa una robustez adicional.
9. Ejecuta P4 posterior usando los KPIs finales.

El problema no está en la lógica secuencial, sino en la separación temporal. El modelo usa el horizonte principal $h7_f2$ para decidir configuraciones y luego utiliza resultados del mismo tipo de ventana para alimentar P4. Desde el punto de vista estadístico, P4 deja de ser una evaluación limpia si el período ya influyó en la selección de parámetros. Por tanto, la acción prioritaria es rediseñar el pipeline para que cada resultado tenga un rol temporal explícito.

3. Prioridades de implementación

Cuadro 1: Orden recomendado de trabajo

Prioridad	Tarea	Justificación
1	Separar horizontes de calibración, validación y test P4	Corrige el riesgo metodológico más grave: P4 no puede usar datos ya vistos por la calibración.
2	Generalizar rolling windows con etiqueta de rol	Aumenta observaciones fuera de muestra y permite evaluar distintos regímenes de mercado.
3	Reejecutar calibración solo en Horizonte 1	La selección de P , Q , Ω y τ debe quedar congelada antes de mirar validación y P4.
4	Validar modelo congelado en Horizonte 2	Permite confirmar robustez sin volver a escoger parámetros.
5	Ejecutar P4 solo en Horizonte 3	Produce el resultado final limpio para cliente y empresa.
6	Agregar métricas de dinámica del portafolio	Responde al feedback sobre turnover, composición inicial/final y concentración sectorial.
7	Actualizar informe y presentación	Reescribe la historia metodológica con defensa frente a preguntas esperables.

4. Eje 1: reestructuración de horizontes

4.1. Principio metodológico

La nueva estructura debe separar tres funciones estadísticas:

- **Horizonte 1: calibración de parámetros.** Se usa para escoger familia de *view*, estructura de P , intensidad de Q , confianza de Ω y τ .
- **Horizonte 2: validación de la calibración.** Se usa para evaluar la configuración congelada. No se puede cambiar ningún parámetro mirando este horizonte, salvo que se declare formalmente que el diseño falló y se vuelve al proceso completo.
- **Horizonte 3: test final limpio para P4.** Se usa solo al final, una vez cerrado el modelo. Sus resultados alimentan Monte Carlo P4 y la conclusión económica cliente–empresa.

La regla debe ser estricta: el Horizonte 3 no participa en ningún ranking, grilla, selección ni ajuste narrativo del modelo. Su función es simular la aplicación real de FinPUC sobre un período no observado durante el diseño.

4.2. Propuesta temporal concreta

Se recomienda construir todos los cortes de manera cronológica y no aleatoria, porque en series financieras el orden temporal es parte del problema. Para cada escenario de datos se debe generar una lista de ventanas tipo $h7_f2$:

$$W_j = [Train_j^{7y}, Test_j^{2y}],$$

donde $Train_j^{7y}$ corresponde a siete años de entrenamiento y $Test_j^{2y}$ corresponde a dos años fuera de muestra. Las ventanas se desplazan cada semestre:

$$start_{j+1} = start_j + 126 \text{ días hábiles.}$$

Luego, las ventanas se asignan a roles:

- **Calibración:** primeras ventanas cronológicas disponibles, por ejemplo 60 % de las ventanas generadas.
- **Validación:** ventanas intermedias, por ejemplo 20 %.
- **Test P4:** últimas ventanas cronológicas, por ejemplo 20 %, reservando especialmente la ventana más reciente como test final principal.

Si la cantidad de ventanas disponibles es baja, se debe usar una versión mínima:

$$\text{Calibración} = 50 \%, \quad \text{Validación} = 25 \%, \quad \text{Test P4} = 25 \%.$$

Lo importante no es el porcentaje exacto, sino que los períodos de test fuera de muestra usados para P4 sean posteriores y no hayan sido usados para elegir el modelo.

4.3. Implementación computacional

El script central afectado es:

- `Entrega_3/04_calibracion_black_litterman/calibracion_secuencial_bl.py`

Se recomienda refactorizar el manejo temporal agregando las siguientes funciones:

1. `generate_rolling_windows`: genera todas las ventanas $h7_f2$ posibles con desplazamiento semestral.
2. `assign_window_roles`: asigna cada ventana a calibración, validación o test P4.
3. `evaluate_config_on_windows`: evalúa una configuración solo sobre ventanas con el rol indicado.
4. `run_calibration_pipeline`: ejecuta las cinco etapas de calibración usando exclusivamente Horizonte 1.
5. `validate_frozen_config`: evalúa la configuración ganadora en Horizonte 2 sin modificarla.
6. `run_clean_p4`: genera KPIs financieros y ejecuta P4 solo sobre Horizonte 3.

La salida debe incluir un archivo de auditoría:

- `00_windows_roles.csv`: escenario, `window_id`, fechas de entrenamiento, fechas de test, rol asignado.

Este archivo es clave para defender que P4 no usó datos vistos durante la calibración.

4.4. Cambios en outputs

Los archivos actuales deben separarse por rol:

- `calibration/stage1_familia_view_ranking.csv`
- `calibration/stage2_estructura_P_ranking.csv`
- `calibration/stage3_intensidad_Q_ranking.csv`
- `calibration/stage4_confianza_Omega_ranking.csv`
- `calibration/stage5_tau_ranking.csv`
- `validation/validacion_config_congelada.csv`
- `test_p4/p4_test_limpio.csv`
- `test_p4/kpis_financieros_test_limpio.csv`

La presentación final debe mostrar explícitamente esta separación. Una frase defendible sería: "Los parámetros se calibraron en el primer bloque temporal, se validaron sin ajuste en el segundo bloque y P4 se ejecutó exclusivamente en el tercer bloque".

5. Eje 2: ampliación de escenarios mediante rolling windows

5.1. Problema actual

El resultado actual resume principalmente 10 observaciones finales: cinco perfiles por dos escenarios. Eso es insuficiente para defender una conclusión robusta, porque una configuración puede parecer buena por un período específico. El profesor pidió multiplicar observaciones fuera de muestra usando ventanas móviles.

5.2. Diseño de ventanas móviles

Se propone generar ventanas con los siguientes parámetros:

- Historial de estimación: 7 años.
- Horizonte fuera de muestra: 2 años.
- Paso entre ventanas: 126 días hábiles.
- Rebalanceo interno: semestral.
- Escenarios: con pandemia y sin pandemia, si ambos tienen historia suficiente.

Cada ventana produce resultados por modelo y perfil:

$$N_{\text{obs}} = N_{\text{windows}} \times N_{\text{escenarios}} \times N_{\text{perfiles}} \times N_{\text{modelos}}.$$

Si, por ejemplo, se obtienen 12 ventanas cronológicas, dos escenarios, cinco perfiles y tres modelos, la evaluación pasa de 10 observaciones estáticas a:

$$12 \times 2 \times 5 \times 3 = 360$$

observaciones modelo–perfil–escenario. Aunque las ventanas se solapan parcialmente, el análisis gana exposición a distintos regímenes y permite reportar distribuciones, percentiles y peores casos.

5.3. Métricas agregadas por ventana

Para cada modelo, perfil y escenario se deben reportar:

- Sharpe medio y mediano.
- Percentil 25 y percentil 10 del Sharpe.
- Peor Sharpe observado.
- Drawdown medio y peor drawdown.
- CVaR medio.
- Porcentaje de ventanas donde BL supera a Markowitz en Sharpe.
- Porcentaje de ventanas donde BL mejora drawdown.
- Porcentaje de ventanas donde BL cumple ambas condiciones: mayor Sharpe y drawdown no peor por más de 3 puntos porcentuales.

Estas métricas permiten cambiar el tono del informe: no se afirma que BL gana siempre, sino que se cuantifica en qué proporción de escenarios aporta valor y cuál es su peor caso.

5.4. Modificaciones de código

En `calibracion_secuencial_bl.py` se debe reemplazar la evaluación actual basada en `latest_split` y `rolling_split` puntual por una estructura general de ventanas. La función actual `rolling_split` puede reutilizarse conceptualmente, pero debe convertirse en un generador de múltiples ventanas con metadatos completos.

También se recomienda agregar:

- `window_id`
- `window_role`
- `train_start`
- `train_end`
- `test_start`

- `test_end`
- `rebalance_id`

en todos los outputs de resultados y de *views*. Sin esos campos, después será difícil auditar si una observación pertenece a calibración, validación o test final.

6. Eje 3: métricas de dinámica del portafolio

6.1. Motivación

El profesor pidió analizar cómo evoluciona el portafolio a lo largo de los rebalances. Esto es distinto a evaluar solo Sharpe o drawdown. Una cartera puede tener buen desempeño fuera de muestra, pero ser difícil de implementar si exige transacciones excesivas o si su retorno depende de una sola industria. Por eso deben agregarse métricas de turnover, cambio de composición y concentración sectorial.

6.2. Turnover semestral

Para cada rebalanceo t , sea w_t el vector de pesos objetivo después de optimizar y sea w_{t-}^{drift} el vector de pesos del portafolio anterior justo antes de rebalancear, después de incorporar la rentabilidad acumulada desde el rebalanceo anterior. El turnover implementable se define como:

$$TO_t = \frac{1}{2} \sum_{i=1}^N |w_{i,t} - w_{i,t-}^{drift}|.$$

El factor 1/2 evita contar doble las compras y ventas. Para el primer rebalanceo, donde no existe cartera previa, se puede reportar NaN o medir el turnover contra una cartera inicial en efectivo; para el informe conviene excluirlo del promedio.

El turnover promedio por ventana será:

$$\overline{TO} = \frac{1}{T-1} \sum_{t=2}^T TO_t.$$

También se debe reportar:

- turnover máximo;
- turnover mediano;
- porcentaje de rebalances con turnover superior a 20 %, 40 % y 60 %;
- comparación de turnover entre Markowitz y BL calibrado.

6.3. Variación de composición inicial versus final

Sea w_1 el vector de pesos del primer rebalanceo de una ventana y w_T el vector del último rebalanceo. Se proponen tres métricas:

$$D_{L1}^{init-final} = \frac{1}{2} \sum_i |w_{i,T} - w_{i,1}|,$$

$$Overlap_K^{init-final} = \frac{|TopK(w_1) \cap TopK(w_T)|}{K},$$

$$HHI_t = \sum_i w_{i,t}^2, \quad N_{eff,t} = \frac{1}{HHI_t}.$$

La primera mide distancia total de composición. La segunda mide persistencia de los principales activos. La tercera y cuarta miden concentración efectiva. Estas métricas deben calcularse por modelo, perfil, escenario y ventana.

6.4. Concentración sectorial de pesos y retornos

La concentración sectorial debe medirse de dos formas complementarias. Primero, concentración sectorial de pesos:

$$W_{s,t} = \sum_{i \in s} w_{i,t}.$$

Con ello se calcula:

$$HHI_t^{sector} = \sum_s W_{s,t}^2.$$

Segundo, concentración sectorial de contribución a retornos. Para cada día d del segmento posterior al rebalanceo t :

$$CR_{s,d} = \sum_{i \in s} w_{i,t} r_{i,d}.$$

La contribución acumulada sectorial de la ventana puede aproximarse como:

$$CR_s = \sum_{d \in \text{test}} CR_{s,d}.$$

Luego se reporta:

$$ShareReturn_s = \frac{|CR_s|}{\sum_k |CR_k|}.$$

El uso de valor absoluto evita que sectores con contribuciones positivas y negativas se cancelen artificialmente. Para el informe, se deben mostrar los tres sectores con mayor contribución absoluta al retorno y el porcentaje acumulado de esos tres sectores. Si un solo sector explica, por ejemplo, 80 % del retorno absoluto, el modelo es menos diversificado de lo que parece por número de activos.

6.5. Outputs propuestos

Se deben crear al menos cuatro archivos nuevos:

- `weights_by_rebalance.csv`: pesos por activo en cada rebalanceo.
- `turnover_summary.csv`: turnover por modelo, perfil, escenario y ventana.
- `composition_stability.csv`: distancia inicial-final, overlap top-K, HHI y número efectivo.

- `sector_return_contribution.csv`: contribución sectorial a retornos y concentración sectorial.

Para esto, `evaluate_rebalanced_config` debe guardar los pesos calculados en cada rebalanceo, no solo los retornos agregados. Actualmente la función conserva métricas finales y registros de *views*; se debe agregar una tercera salida: `weights_df`.

7. Eje 4: integración limpia con P4

7.1. Regla de separación

P4 debe recibir como input solamente los KPIs financieros calculados en Horizonte 3. No debe recibir resultados de calibración ni validación. La utilidad de la empresa sigue siendo posterior al optimizador y no debe entrar en la selección de pesos.

La nueva secuencia será:

1. Calibrar BL en Horizonte 1.
2. Congelar parámetros: familia de desempleo, $u = 4\%$, $u_{neutral} = 5\%$, $\beta = 1,5$, $q_{scale} = 1,5$, $c = 0,20$, $\tau = 0,20$, salvo que la nueva calibración con horizontes separados cambie el ganador.
3. Validar la configuración congelada en Horizonte 2.
4. Si la validación es aceptable, evaluar KPIs en Horizonte 3.
5. Enviar solo esos KPIs a Monte Carlo P4.

7.2. Scripts afectados

Cuadro 2: Archivos afectados por la reestructuración

Archivo	Cambio requerido
Entrega_3/04_calibracion_black_litterman/calibracion_secuencial_bl.py	Refactorizar ventanas, separar roles, guardar pesos por rebalanceo, recalculando outputs de calibración, validación y test P4 limpio.
Entrega_3/Entrega2/02_black_litterman/black_litterman.ipynb	Solo si se mantiene como notebook explicativo: actualizar celdas para reflejar configuración final y nueva separación temporal.
Entrega_3/Entrega2/03_p4_montecarlo/p4_montecarlo_recomendador_portafolios.ipynb	Ajustar para leer KPIs del Horizonte 3, no de resultados de calibración.
Entrega_3/01_simulacion_k/simulacion_comisiones_k.ipynb	Si usa KPIs de portafolio, actualizar fuente de datos hacia <code>test_p4</code> .
Entrega_3/02_simulacion_lambda/simulacion_lambda_multiobjetivo.ipynb	Revisar si incorpora resultados financieros; si lo hace, separar inputs de validación y test.

Archivo	Cambio requerido
Entrega_3/04_calibracion_black_litterman/informe_calibracion_bl.tex	Reescribir resultados para dejar claro que los resultados P4 provienen de Horizonte 3 limpio.

8. Batería de defensa metodológica

8.1. Pregunta 1: ¿Por qué calibración secuencial y no iterativa o simultánea?

Respuesta corta. Porque el espacio de búsqueda simultáneo es demasiado grande, costoso y menos explicable; la calibración secuencial permite aislar el aporte marginal de cada decisión y construir una defensa metodológica trazable.

Respuesta técnica. Una búsqueda simultánea tendría que combinar familias de *views*, ventanas de momentum, tamaños long-short, ponderaciones de P , intensidades de Q , niveles de confianza, valores de τ , perfiles de riesgo, escenarios y ventanas temporales. Eso genera un número de combinaciones alto y, más importante, dificulta saber si una configuración gana por la señal económica, por la intensidad de la opinión, por la confianza, por el perfil o por una ventana específica. La secuencia usada responde en orden: primero qué información entra, luego cómo se traduce en P , luego cuánta fuerza tiene Q , luego cuánta confianza tiene Ω y finalmente cuán sensible es el prior mediante τ .

Defensa con datos actuales. La calibración secuencial reveló algo que una búsqueda ciega podría ocultar: momentum general tenía mayor Sharpe medio, 1.705, pero empeoraba el drawdown promedio frente a Markowitz en 4.42 puntos porcentuales. La regla secuencial con penalización de drawdown permitió escoger desempleo, que tenía menor Sharpe medio inicial, 1.579, pero mejoraba el drawdown en 2.69 puntos porcentuales. Esta diferencia justifica que el criterio no sea maximizar Sharpe de manera oportunista.

8.2. Pregunta 2: ¿Por qué es válido usar una sola *view* de desempleo?

Respuesta corta. Porque el profesor indicó que una sola *view* es aceptable si está bien calibrada y validada. En este proyecto, una sola *view* permite mantener interpretabilidad, evitar sobreparametrización y defender claramente el mecanismo económico.

Respuesta técnica. Combinar varias *views* aumenta el número de parámetros: se deben calibrar varias filas de P , varios valores de Q , una matriz Ω potencialmente con covarianzas entre opiniones y pesos relativos entre señales. Con la cantidad de datos disponible, agregar *views* puede mejorar ajuste dentro de muestra pero empeorar capacidad de generalización. Usar una sola *view* robusta es una decisión conservadora: reduce grados de libertad y hace que el posterior Black–Litterman tenga una fuente de ajuste económico identificable.

Defensa con datos actuales. La *view* de desempleo no fue elegida porque sonara razonable, sino porque sobrevivió a la comparación contra momentum. En el escenario con pandemia, la configuración final mejoró Sharpe en perfiles relevantes: Neutro de 1.66 a 1.79, Arriesgado de 1.17 a 1.71 y Muy arriesgado de 0.71 a 1.08. Además, redujo drawdown en esos mismos perfiles. Por tanto, la *view* única tiene evidencia empírica y un relato económico coherente: expresa una rotación relativa entre sectores cíclicos y defensivos.

Respuesta si preguntan por combinación de *views*. Se puede reconocer que una extensión natural sería calibrar una segunda *view*, por ejemplo momentum, de forma independiente y luego estudiar una matriz Ω conjunta. Sin embargo, para la entrega final se prioriza un modelo parsimonioso

y defendible. No se descarta la combinación, pero se evita introducirla sin suficiente validación fuera de muestra.

8.3. Pregunta 3: ¿Por qué es coherente que la confianza sea baja, $c = 0,20$?

Respuesta corta. Porque la *view* de desempleo usada es un escenario macro asumido, no una predicción macroeconómica observada en tiempo real. Una confianza baja permite que la opinión corrija suavemente el prior sin dominarlo.

Respuesta técnica. La implementación define:

$$\Omega = \frac{P(\tau\Sigma)P^\top}{c}.$$

Por lo tanto, menor c implica mayor incertidumbre de la opinión y menor desplazamiento del posterior hacia Q . Esto es apropiado para una señal macro de escenario. En cambio, momentum es una señal directamente medida con retornos recientes y podría justificar niveles de confianza mayores. La baja confianza evita transformar Black–Litterman en una apuesta sectorial fuerte basada en un supuesto macro.

Defensa con datos actuales. Al calibrar $c \in \{0,20,0,35,0,50\}$, ganó $c = 0,20$ con Sharpe medio 1.722, superior a las alternativas evaluadas en esa etapa, manteniendo drawdown cercano a -9.9 %. Esto confirma que el modelo funcionó mejor cuando la *view* se usó como corrección suave y no como señal dominante.

8.4. Pregunta 4: ¿Por qué desempleo ganó sobre momentum si momentum tenía más Sharpe?

Respuesta. Porque el criterio de selección no maximiza Sharpe de forma aislada. Momentum general alcanzó Sharpe medio 1.705, pero con drawdown medio -20.0 % y deterioro de drawdown frente a Markowitz. La *view* de desempleo tuvo Sharpe medio menor en la primera etapa, 1.579, pero mejoró drawdown y obtuvo mejor score robusto. Dado que FinPUC es un recomendador para clientes, no una estrategia especulativa, la estabilidad ante pérdidas pesa en la recomendación.

8.5. Pregunta 5: ¿Qué cambia después del feedback del 9 de junio?

Respuesta. Cambia la estructura de evaluación. Antes, la calibración, validación y P4 estaban demasiado cerca temporalmente. Ahora los parámetros se calibran en un primer bloque, se validan en un segundo bloque no visto y P4 se ejecuta en un tercer bloque limpio. Además, se agregan rolling windows y métricas de dinámica del portafolio para mostrar implementabilidad y no solo KPIs financieros agregados.

9. Tareas de código versus tareas de análisis

Cuadro 3: Clasificación operativa de tareas

Tipo	Tarea	Entregable esperado
Código	Crear generador de rolling windows con roles	00_windows_roles.csv y trazabilidad temporal.

Tipo	Tarea	Entregable esperado
Código	Ejecutar calibración solo en Horizonte 1	Rankings de etapas bajo carpeta <code>calibration</code> .
Código	Evaluar configuración congelada en Horizonte 2	Tabla <code>validation/validacion_config_congelada.csv</code> .
Código	Ejecutar P4 solo en Horizonte 3	Tabla <code>test_p4/p4_test_limpio.csv</code> .
Código	Guardar pesos por rebalanceo	Tabla <code>weights_by_rebalance.csv</code> .
Código	Calcular turnover, composición y concentración sectorial	Tablas de dinámica del portafolio.
Análisis	Interpretar resultados de validación	Decidir si BL sigue siendo recomendación segmentada o si debe suavizarse la conclusión.
Análisis	Reescribir sección de robustez	Enfatizar distribución por ventanas, no solo escenario pandemia.
Análisis	Actualizar conclusión por perfil	Separar conclusión financiera, conclusión P4 y advertencias.
Present.	Preparar defensa metodológica	Diapositiva con Q&A: secuencial, una <i>view</i> , confianza baja, horizonte limpio.

10. Checklist final antes de la entrega

1. Existe un archivo `00_windows_roles.csv` que prueba la separación temporal.
2. Ninguna ventana de test P4 aparece en archivos de calibración.
3. Los parámetros finales se congelan antes de generar P4.
4. Los resultados finales reportan número de ventanas, no solo cinco perfiles por dos escenarios.
5. El informe incluye turnover semestral promedio y máximo.
6. El informe compara composición inicial versus final.
7. El informe muestra si los retornos vienen de pocos sectores o de una contribución diversificada.
8. La presentación tiene una respuesta preparada para calibración secuencial versus simultánea.
9. La presentación tiene una respuesta preparada para una sola *view* versus combinación.
10. La presentación tiene una respuesta preparada para confianza baja $c = 0,20$.

11. Cierre

La acción más urgente es corregir la arquitectura temporal. Sin esa separación, cualquier resultado P4 queda vulnerable a la crítica de *overfitting*. Una vez resuelto ese punto, las rolling windows y las métricas de dinámica del portafolio permiten fortalecer el argumento central: Black-Litterman con *view* macro de desempleo no debe defenderse como un modelo que gana siempre, sino como una configuración parsimoniosa, calibrada y potencialmente más resiliente en perfiles y escenarios donde Markowitz es más sensible a errores de estimación.