



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ESCUELA DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

ICS2122 - TALLER DE INVESTIGACIÓN OPERATIVA (CAPSTONE)

FINPUC

ENTREGA 2

GRUPO 13

INTEGRANTES:

PATRICIO ANDRES ACEVEDO FLORES

BENJAMÍN ALONSO CANO ARAYA

MATÍAS BENJAMÍN CATALÁN CONTRERAS

GASPAR TEN BERG YUNUSIC

DIEGO BENJAMÍN VILLALOBOS MICHEA

Miembros del Comité:

PROFESOR GUÍA: AGUSTÍN MATÍAS ANTONIO CHIU
LÓPEZ

AYUDANTE TUTOR: JUAN ENRIQUE HURTADO BROWNE

Santiago de Chile, Mayo 2026

ÍNDICE DE CONTENIDOS

ÍNDICE DE FIGURAS	vi
ÍNDICE DE TABLAS	vii
ABSTRACT	viii
RESUMEN	ix
1. Introducción	1
2. Descripción del problema	3
2.1. Contexto y motivación	3
2.2. Ciclo operacional	3
2.3. Perfiles de riesgo	4
2.4. Formulación del problema	4
2.4.1. Decisión principal	4
2.4.2. Objetivos	4
2.4.3. Restricciones	4
2.5. Datos disponibles	5
2.5.1. Fuente y estructura	5
2.5.2. Proceso de filtrado	5
2.5.3. Justificación del filtrado	6
2.5.4. Diseño experimental: escenarios con y sin pandemia	7
2.5.5. Riesgos y limitaciones de los datos	7
3. Metodología	9
3.1. Revisión bibliográfica	9
3.1.1. Modelos fundamentales de optimización de portafolios	9
3.1.2. El modelo Black-Litterman	9
3.1.3. Estimación de covarianzas y medidas de riesgo	10

3.1.4.	Sistemas de asesoría financiera automatizada	10
3.1.5.	Fortalezas y debilidades de la metodología seleccionada	11
3.2.	Arquitectura general del sistema	12
3.3.	Estimación de parámetros	12
3.3.1.	Retornos esperados	12
3.3.2.	Matriz de covarianzas con <i>shrinkage</i>	12
3.3.3.	Anualización	13
3.4.	Optimización media-varianza de Markowitz	13
3.4.1.	Formulación por perfil de riesgo	13
3.4.2.	Frontera eficiente y portafolio de tangencia	14
3.4.3.	Rebalanceo semestral	14
3.5.	Modelo Black-Litterman	15
3.5.1.	Prior de equilibrio de mercado	15
3.5.2.	Incorporación de <i>views</i>	15
3.5.3.	Construcción de <i>views</i>	15
3.6.	Simulación Monte Carlo (P4)	17
3.6.1.	Objetivo	17
3.6.2.	Funciones de comportamiento del cliente	17
3.6.3.	Estructura de la simulación	17
3.6.4.	Escenarios proyectados	18
3.6.5.	Reproducibilidad	19
3.7.	Análisis distribucional de retornos	19
3.8.	Validación robusta	19
4.	Supuestos	21
4.1.	Supuestos sobre los datos	21
4.2.	Supuestos de mercado	21
4.3.	Supuestos estadísticos	21
4.4.	Supuestos de optimización	22
4.5.	Supuestos de rebalanceo	22

4.6.	Supuestos del experimento pandemia	23
4.7.	Supuestos de la simulación Monte Carlo (P4)	23
4.8.	Plan de sensibilidad	24
5.	KPIs	25
5.1.	Indicadores de desempeño (KPIs)	25
5.1.1.	Perspectiva del cliente	25
5.1.2.	Perspectiva de la empresa	26
5.1.3.	Score combinado P4	26
6.	Caso Base	28
6.1.	Definición	28
6.2.	Justificación	28
6.3.	Métricas del caso base	28
6.4.	Validación como línea base	29
7.	Implementación y Herramientas	30
7.1.	Entorno computacional	30
7.2.	Librerías principales	30
7.3.	Reproducibilidad	31
7.4.	Estructura de archivos y outputs	31
8.	Resultados y análisis	33
8.1.	Análisis distribucional de retornos	33
8.2.	Markowitz vs benchmark	34
8.2.1.	Impacto de la pandemia en Markowitz	35
8.2.2.	Validación robusta	35
8.3.	Black-Litterman	35
8.3.1.	Análisis por <i>view</i>	36
8.3.2.	Black-Litterman vs Markowitz	36
8.4.	Simulación Monte Carlo (P4)	37
8.4.1.	Promedios por técnica en escenario neutro	37

8.4.2.	Ranking del recomendador (Score P4)	37
8.4.3.	Ganadores por escenario proyectado	38
8.5.	Análisis integrado	39
8.5.1.	Comparación de las tres capas	39
8.5.2.	Hallazgos principales	39
8.5.3.	Limitaciones y posibles mejoras	40
9.	Conclusiones	41
9.1.	Conclusiones principales	41
9.2.	Puntos fuertes de la metodología	42
9.3.	Puntos débiles y propuestas de mejora	43
9.4.	Plan de trabajo: avance y fases restantes	44
9.4.1.	Comparación entre planificación original y avance real	44
9.4.2.	Dificultades encontradas	44
9.4.3.	Fase 3: Evaluación y mejoras (12 mayo – 15 junio)	45
9.4.4.	Fase 4: Cierre y entrega final (13 – 26 junio)	45
	REFERENCES	46
	Uso de IA	47

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

2.1	Perfiles de riesgo del cliente y tolerancia máxima a pérdidas.	4
2.2	Cascada de filtrado aplicada al universo sin pandemia.	6
2.3	Cascada de filtrado aplicada al universo con pandemia.	6
3.1	Configuración de las cuatro variantes de <i>views</i> Black-Litterman.	16
6.1	KPIs del benchmark equiponderado top-20 (horizonte h7_f2, 601 activos, rebalanceo semestral).	29
8.1	Resumen transversal de estadísticos por ticker (universo F5 sin pandemia). .	33
8.2	Mejor familia distribucional según AIC y BIC.	33
8.3	Comparación Markowitz vs benchmark (horizonte h7_f2, 601 activos, rebalanceo semestral).	34
8.4	Mejor portafolio Black-Litterman por <i>view</i> y escenario (horizonte h7_f2). . .	36
8.5	Promedios por técnica en escenario neutro (promedio de perfiles).	37
8.6	Top 5 ranking P4 en escenario neutro.	38
8.7	Comparación final: mejor portafolio por modelo y escenario.	39
9.1	Comparación entre planificación original (Informe 1) y avance real.	44

ABSTRACT

This report documents the development and implementation of an investment recommendation system for FinPUC, a fictitious financial advisory platform that generates personalized portfolios for clients in the US stock market. The system serves five risk profiles and pursues a dual objective: maximizing client expected returns and maximizing firm revenue from transaction fees.

The investment universe comprises 601 stocks filtered from 1,406 tickers. Three methodological layers of increasing complexity were implemented and compared: Markowitz mean-variance optimization with semiannual rebalancing, Black-Litterman with four quantitative view variants (general momentum, 6-month and 1-year capitalization-weighted momentum, and an assumed macroeconomic unemployment scenario), and a Monte Carlo simulation of 5,000 trajectories over 260 weeks modeling client acceptance, withdrawal, and firm commissions across six techniques.

Results show that the Black-Litterman variant with 6-month capitalization-weighted momentum dominates the recommender ranking, achieving an expected terminal wealth of USD 8,974 and a P4 score of 9,417 for the most aggressive risk profile with pandemic training data. Including pandemic data (2020–2022) in training deteriorates aggressive Markowitz portfolios by up to 1.1 Sharpe points, while Black-Litterman variants exhibit greater stability across regimes.

Keywords: portfolio optimization, Markowitz, Black-Litterman, Monte Carlo simulation, recommender system, semiannual rebalancing, CVXPY.

RESUMEN

El presente informe documenta el desarrollo e implementación de un sistema recomendador de inversiones para FinPUC, una plataforma ficticia de asesoría financiera que genera portafolios personalizados para clientes del mercado accionario estadounidense. El sistema atiende cinco perfiles de riesgo —desde muy conservador hasta muy arriesgado— y opera bajo un doble objetivo: maximizar el retorno esperado del cliente y maximizar la utilidad de la empresa por comisiones de transacción.

El universo de trabajo comprende 601 acciones, obtenidas tras filtrar 1 406 tickers por criterios de liquidez, capitalización bursátil, historia disponible y volatilidad. Se implementaron y compararon tres capas metodológicas de complejidad creciente. La primera es la optimización media-varianza de Markowitz, resuelta mediante programación cuadrática con CVXPY, con rebalanceo semestral cada 126 días hábiles. La segunda extiende Markowitz con el modelo Black-Litterman, que combina un prior de equilibrio de mercado con cuatro variantes de *views* cuantitativas: momentum general, momentum por capitalización a 6 meses y a 1 año, y un escenario macro de desempleo asumido. La tercera capa es una simulación Monte Carlo de 5 000 trayectorias durante 260 semanas que modela la dinámica completa del cliente —aceptación de recomendaciones, retiro ante pérdidas y comisiones— para las seis técnicas evaluadas. Como caso base se utiliza un benchmark equiponderado de los 20 activos con mayor capitalización, cuyo desempeño no depende de estimación de parámetros.

Los resultados muestran que la variante Black-Litterman con momentum por capitalización a 6 meses domina el ranking del recomendador, alcanzando una riqueza terminal esperada de USD 8 974 y un score P4 de 9 417 en el perfil muy arriesgado con datos de pandemia. El benchmark equiponderado se confirma como un competidor exigente en retorno bruto (Sharpe 2.05), pero con volatilidad y drawdown significativamente mayores. Incluir el período de pandemia (2020–2022) en el entrenamiento deteriora los portafolios

agresivos de Markowitz hasta en 1.1 puntos de Sharpe, mientras que las variantes Black-Litterman muestran mayor estabilidad frente al cambio de régimen.

Palabras clave: optimización de portafolios, Markowitz, Black-Litterman, simulación Monte Carlo, sistema recomendador, rebalanceo semestral, CVXPY.

1. INTRODUCCIÓN

La gestión eficiente del capital constituye uno de los problemas fundamentales de las finanzas modernas. El problema de optimización de portafolios, formalizado por Markowitz (1952), establece los fundamentos matemáticos de la diversificación y define la frontera eficiente como el conjunto de portafolios óptimos en el espacio riesgo-retorno. En la práctica, el universo de activos puede comprender cientos de instrumentos, los clientes presentan perfiles de riesgo heterogéneos y las condiciones del mercado evolucionan continuamente. En este contexto, la consolidación de plataformas de asesoría financiera automatizada ha generado una demanda creciente de sistemas capaces de producir recomendaciones personalizadas, fundamentadas y actualizadas de forma periódica (D'Acunto, Prabhala, & Rossi, 2019).

El presente informe documenta la segunda fase del proyecto FinPUC, una plataforma ficticia de recomendación de inversiones desarrollada en el marco del curso Taller de Investigación Operativa (ICS2122) de la Pontificia Universidad Católica de Chile. En la primera entrega se definió el alcance del problema, se realizó la revisión bibliográfica y se propuso un modelo híbrido que combina Black-Litterman como núcleo optimizador con simulación de Monte Carlo para generación de escenarios. Esta segunda entrega presenta la implementación computacional completa de dicho modelo, incluyendo tres capas metodológicas: Markowitz, Black-Litterman con cuatro variantes de *views* y simulación Monte Carlo; resultados comparativos contra un caso base equiponderado, y validación mediante múltiples horizontes de entrenamiento y escenarios con y sin pandemia.

El sistema opera en dos escalas temporales complementarias. A nivel de optimización, los pesos del portafolio se recalculan cada semestre (126 días hábiles bursatil) mediante rebalanceo con estimación actualizada de parámetros. A nivel de simulación del cliente, el modelo Monte Carlo evalúa semanalmente durante 260 semanas si el cliente acepta la recomendación vigente o retira sus fondos, generando métricas de riqueza terminal,

probabilidad de ganancia y utilidad de la empresa. La decisión central consiste en determinar la fracción del capital a asignar a cada acción de un universo de 601 activos, maximizando simultáneamente el retorno esperado del inversionista y la utilidad de FinPUC por comisiones, sujeto a restricciones de riesgo y a un límite operacional de 10 segundos por recomendación.

El informe se organiza de la siguiente forma: el Capítulo 2 describe el problema y los datos; el Capítulo 3 presenta la metodología seleccionada y su formulación matemática; el Capítulo 4 documenta los supuestos; el Capítulo 5 define los indicadores de desempeño; el Capítulo 6 describe el caso base; el Capítulo 7 detalla la implementación y herramientas; el Capítulo 8 reporta los resultados y su análisis; y el Capítulo 9 concluye con los hallazgos principales, puntos fuertes y débiles, y el plan de trabajo restante.

2. DESCRIPCIÓN DEL PROBLEMA

2.1. Contexto y motivación

La gestión de inversiones enfrenta hoy una realidad operacional desafiante: los inversionistas individuales deben tomar decisiones complejas sobre cómo distribuir su capital entre un universo amplio de activos, considerando su tolerancia al riesgo, el horizonte de inversión y las condiciones cambiantes del mercado. FinPUC es una plataforma ficticia de recomendación de inversiones diseñada para atender clientes del mercado accionario norteamericano, clasificados según su perfil de riesgo. El sistema debe generar periódicamente portafolios óptimos para cada cliente, maximizando su retorno esperado y la utilidad de la empresa por comisiones de transacción.

2.2. Ciclo operacional

El sistema opera en dos escalas temporales. A nivel de optimización, los pesos del portafolio se recalculan cada semestre (126 días hábiles bursátil) mediante rebalanceo: se reestiman los parámetros μ y Σ con la ventana histórica acumulada hasta ese punto y se resuelve nuevamente el problema de optimización. Dentro de cada semestre, los pesos se mantienen constantes.

A nivel de simulación del cliente (Monte Carlo P4), el sistema evalúa semanalmente durante 260 semanas (5 años) el comportamiento del inversionista. Cada semana, el cliente puede aceptar la recomendación vigente con probabilidad $P_2(x)$ o rechazarla. Si acepta, se ejecuta la transacción y la empresa cobra una comisión proporcional $k\% = 1\%$ sobre el monto transado. Si la pérdida acumulada del cliente supera la tolerancia de su perfil, existe una probabilidad $P_1(x)$ de que retire sus fondos de la plataforma. El capital del cliente evoluciona en función de las fluctuaciones de precios y la entrega de dividendos, que se acumulan en una cuenta denominada caja chica.

2.3. Perfiles de riesgo

Se consideran cinco perfiles de clientes según su tolerancia máxima a pérdidas anuales, detallados en la Tabla 2.1.

Tabla 2.1. Perfiles de riesgo del cliente y tolerancia máxima a pérdidas.

Perfil	Tolerancia máxima
Muy conservador	0%
Conservador	5%
Neutro	15%
Arriesgado	30%
Muy arriesgado	40%

2.4. Formulación del problema

2.4.1. Decisión principal

Para cada perfil de riesgo y cada punto de rebalanceo, el sistema debe determinar el vector de pesos $w \in \mathbb{R}^n$ que asigna una fracción del capital a cada una de las $n = 601$ acciones del universo.

2.4.2. Objetivos

El problema persigue dos objetivos simultáneos:

- (i) Maximizar el retorno esperado del portafolio del cliente, medido como $\mu^\top w$.
- (ii) Maximizar la utilidad de FinPUC, derivada de las comisiones $k\%$ generadas por las transacciones aceptadas por el cliente.

2.4.3. Restricciones

- **No venta en corto:** $w_i \geq 0$ para todo i .
- **Presupuesto completo:** $\sum_{i=1}^n w_i = 1$.

- **Concentración máxima:** $w_i \leq w_{\max} = 0.20$ para todo i .
- **Riesgo por perfil:** $w^\top \Sigma w \leq \sigma_{\max}^2$, donde la cota depende del perfil de riesgo.
- **Tiempo de cómputo:** el sistema debe generar la recomendación en menos de 10 segundos.

2.5. Datos disponibles

2.5.1. Fuente y estructura

Los datos corresponden a registros históricos del mercado accionario estadounidense. El dataset original comprende 1 406 archivos CSV, uno por ticker, con precios diarios que cubren aproximadamente desde el año 2000 hasta marzo de 2026. Cada archivo incluye fecha, precio de apertura y cierre, máximo y mínimo del día, volumen de transacciones, dividendos y factores de *split*. Adicionalmente, se dispone de un archivo de metadatos con información fundamental de cada empresa: sector, industria, tipo de instrumento y capitalización de mercado.

El retorno diario total de cada acción se calcula incorporando dividendos:

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (2.1)$$

donde $P_{i,t}$ es el precio de cierre del activo i en el día t y $D_{i,t}$ el dividendo pagado en esa fecha.

2.5.2. Proceso de filtrado

A partir del universo crudo de 1 406 tickers se aplicó un proceso de filtrado secuencial. La Tabla 2.2 detalla la cascada para el escenario sin pandemia (universo final: 601 activos) y la Tabla 2.3 para el escenario con pandemia (636 activos).

Tabla 2.2. Cascada de filtrado aplicada al universo sin pandemia.

Filtro	Criterio operacional	Tickers	Retención F0
F0	Archivos CSV encontrados	1.406	100,0%
F1	Precio $\geq$ USD 5; historia $\geq$ 5 años; cap. $\geq$ USD 300M o sin dato	827	58,8%
F2	Excluye <i>Shell Companies</i> , sector desconocido y no EQUITY	824	58,6%
F3	Capitalización bursátil $\geq$ USD 2B	659	46,9%
F4	Historia fuera de pandemia $\geq$ 10 años, aproximada por 2.500 filas	606	43,1%
F5	Volatilidad anualizada fuera de pandemia entre 5% y 100%	601	42,7%

Tabla 2.3. Cascada de filtrado aplicada al universo con pandemia.

Filtro	Criterio operacional	Tickers	Retención F0
F0	Archivos CSV encontrados	1.406	100,0%
F1	Precio $\geq$ USD 5; historia $\geq$ 5 años; cap. $\geq$ USD 300M o sin dato	884	62,9%
F2	Excluye <i>Shell Companies</i> , sector desconocido y no EQUITY	881	62,7%
F3	Capitalización bursátil $\geq$ USD 2B	686	48,8%
F4	Historia $\geq$ 10 años, aproximada por 2.500 filas	641	45,6%
F5	Volatilidad anualizada entre 5% y 100%	636	45,2%

2.5.3. Justificación del filtrado

El filtrado no es un paso administrativo: define qué fenómeno financiero se está modelando. F1 remueve acciones con baja historia, precios muy bajos o capitalización extremadamente reducida. El precio mínimo evita que variaciones de centavos generen retornos artificialmente explosivos; el umbral de historia reduce estimaciones inestables; permitir capitalización faltante en F1 evita excluir tempranamente activos que podrían ser válidos pero tienen metadatos incompletos.

F2 restringe el análisis a instrumentos accionarios ordinarios con clasificación interpretable. Excluir *Shell Companies*, sectores *Unknown* e instrumentos distintos de EQUITY protege la comparabilidad entre activos y evita mezclar acciones operativas con vehículos corporativos, fondos, warrants u otros instrumentos con dinámica de precios distinta.

F3 eleva la capitalización mínima a USD 2B, haciendo que el universo sea más invertible y reduciendo el peso de micro y small caps, cuyos retornos suelen estar afectados por

menor liquidez, saltos idiosincráticos y costos de transacción no modelados. F4 exige al menos diez años de historia fuera del periodo 2020–2022, requisito central para estimar parámetros distribucionales con una muestra suficientemente amplia. F5 elimina series con volatilidad anualizada demasiado baja o demasiado alta, interpretadas como señales de precios rígidos, errores de datos o activos incompatibles con un portafolio tradicional.

2.5.4. Diseño experimental: escenarios con y sin pandemia

La evaluación del sistema se realiza bajo dos escenarios que comparten el mismo período futuro de evaluación (2 años fuera de muestra) pero difieren en la ventana de entrenamiento. El escenario “sin pandemia” excluye las observaciones de 2020–2022, estimando μ y Σ con un mercado relativamente normal. El escenario “con pandemia” las incluye, incorporando correlaciones de estrés y volatilidad extrema. Cualquier diferencia en resultados entre ambos escenarios se interpreta como efecto de la información usada para calibrar, no como diferencias de mercado futuro.

Esta separación responde a que la pandemia generó un quiebre de régimen: cambios abruptos de correlación, volatilidad, liquidez y política monetaria. Para la optimización, incorporar esos años entrega información valiosa sobre cómo se comportan los activos cuando la diversificación falla parcialmente. Para el análisis distribucional base, excluirlos permite caracterizar el comportamiento regular de los retornos sin contaminación por un episodio extraordinario.

2.5.5. Riesgos y limitaciones de los datos

Se identifican cinco riesgos principales. Primero, el **sesgo de supervivencia**: exigir historia larga y capitalización alta favorece empresas grandes, líquidas y sobrevivientes, reduciendo la representatividad de firmas pequeñas, recientes o quebradas. Segundo, el **sesgo sectorial**: más de un tercio del universo final pertenece a servicios financieros (36,3%), por lo que la matriz de covarianzas puede reflejar sobrerrepresentación de ese

sector. Tercero, el **riesgo de exclusión pandémica**: para distribución base reduce contaminación, pero también elimina observaciones extremas reales. Cuarto, el **riesgo de medición**: el filtro de volatilidad usa retornos de precio, mientras el análisis posterior incorpora dividendos, lo que puede reintroducir saltos asociados a eventos corporativos. Quinto, la **construcción de la matriz de retornos** mediante `join="inner"` puede eliminar observaciones relevantes si algunos activos tienen huecos en sus series.

3. METODOLOGÍA

3.1. Revisión bibliográfica

3.1.1. Modelos fundamentales de optimización de portafolios

La optimización de portafolios tiene su origen en el trabajo seminal de Markowitz (Markowitz, 1952), que formalizó el principio de diversificación mediante el modelo media-varianza. Su propuesta establece que un inversionista racional selecciona portafolios sobre la frontera eficiente, es decir, aquellos que maximizan el retorno esperado para un nivel de riesgo dado. La principal limitación del modelo es su sensibilidad a las estimaciones de μ y Σ : pequeños errores en los retornos esperados pueden generar portafolios concentrados o irrazonables (Michaud, 1989). En el presente proyecto, esta fragilidad se observa empíricamente: el portafolio Ideal de mercado de Markowitz exhibe un Sharpe teórico de 5,01 que colapsa a 1,80 fuera de muestra con datos de pandemia, confirmando el fenómeno de *overfitting* documentado por Michaud.

El modelo CAPM de Sharpe (Sharpe, 1964) extiende el trabajo de Markowitz introduciendo un modelo de equilibrio de mercado, donde el retorno esperado de un activo depende únicamente de su exposición al riesgo sistemático, medido por el coeficiente β . El modelo multifactorial de Fama y French (Fama & French, 1993) incorpora dos factores adicionales —tamaño (SMB) y valor (HML)— para capturar anomalías empíricas. Aunque estos modelos no se implementan directamente en FinPUC, informan la construcción del prior de equilibrio en Black-Litterman: los retornos implícitos $\pi = \delta \Sigma w_{\text{market}}$ asumen que el mercado está en equilibrio, lo que es consistente con la lógica del CAPM.

3.1.2. El modelo Black-Litterman

Black y Litterman (Black & Litterman, 1992) propusieron un enfoque bayesiano que combina el equilibrio implícito del mercado con expectativas subjetivas del inversionista. El prior se obtiene invirtiendo el problema de Markowitz: dado que el mercado está en

equilibrio, los retornos implícitos son $\pi = \delta \Sigma w_{\text{market}}$. Las *views* se incorporan mediante una actualización bayesiana que produce estimaciones más estables y portafolios menos extremos. He y Litterman (He & Litterman, 1999) documentaron la implementación práctica del modelo, destacando su capacidad para generar portafolios intuitivamente razonables sin restricciones artificiales de peso. Idzorek (Idzorek, 2005) extendió el marco proponiendo métodos para calibrar la confianza de cada *view*, problema que en FinPUC se aborda fijando $c = 0.50$ para las *views* de momentum y $c = 0.35$ para la de desempleo.

3.1.3. Estimación de covarianzas y medidas de riesgo

Ledoit y Wolf (Ledoit & Wolf, 2004) propusieron el método de *shrinkage* para la estimación de matrices de covarianza de grandes dimensiones, demostrando que la combinación convexa entre la covarianza muestral y un estimador estructurado reduce el error de estimación fuera de muestra. En FinPUC se implementa con $\lambda = 0.20$, valor seleccionado para estabilizar una matriz de 601×601 sin perder demasiada estructura de correlación. La elección de λ no fue optimizada formalmente y constituye un supuesto del modelo.

Rockafellar y Uryasev (Rockafellar & Uryasev, 2000) introdujeron el Valor en Riesgo Condicional (CVaR) como medida coherente de riesgo, superando las limitaciones del VaR estándar al cuantificar la severidad promedio de las pérdidas en la cola. En el proyecto, el CVaR al 95% se utiliza como indicador de desempeño complementario al Sharpe, no como restricción del optimizador. Esta decisión responde a que la implementación con CVXPY utiliza cotas de volatilidad por perfil, que son computacionalmente más eficientes para la restricción de 10 segundos.

3.1.4. Sistemas de asesoría financiera automatizada

En el contexto de plataformas de *robo-advisory*, D’Acunto, Prabhala y Rossi (D’Acunto et al., 2019) documentaron cómo la automatización ha democratizado el acceso a estrategias de inversión, permitiendo recomendaciones personalizadas a bajo costo operacional. FinPUC se enmarca en esta línea, con la particularidad de que incorpora explícitamente

el comportamiento del cliente (funciones P_1 y P_2) y la utilidad de la empresa (comisiones $k\%$) como variables del modelo, lo que va más allá de la optimización financiera pura.

3.1.5. Fortalezas y debilidades de la metodología seleccionada

La combinación de Black-Litterman con Monte Carlo ofrece tres fortalezas principales respecto a las alternativas revisadas:

- (i) Portafolios más estables que Markowitz puro, al anclar las estimaciones al equilibrio de mercado. Los resultados del proyecto confirman esto: con datos de pandemia, el mejor BL obtiene Sharpe 2,38 mientras Markowitz cae a 2,02.
- (ii) Capacidad de incorporar señales cuantitativas (*views*) de forma controlada, permitiendo que el gestor exprese creencias sin abandonar el marco teórico.
- (iii) Generación natural de los tres escenarios requeridos (desfavorable, neutro, favorable) mediante la simulación Monte Carlo, sin necesidad de modelar explícitamente cambios de régimen.

Las debilidades principales son:

- (i) La calidad del resultado depende de la calidad de los *views* incorporados. En FinPUC, la view de desempleo es un supuesto fijo (no un dato observado), lo que limita su validez predictiva. Una *view* incorrecta puede deteriorar el portafolio respecto al prior de equilibrio.
- (ii) Los parámetros $\tau = 0.05$ y la construcción de Ω carecen de interpretación directa y requieren calibración. En la implementación actual se usa una formulación estándar ($\Omega = P\tau\Sigma P^\top/c$), pero no se realizó análisis de sensibilidad sobre τ .
- (iii) La simulación Monte Carlo asume retornos normales, pese a que el análisis distribucional rechaza normalidad en todos los activos. Esto subestima eventos extremos y puede generar tasas de retiro optimistas.

- (iv) El modelo no incorpora costos de transacción en la etapa de optimización, solo como comisión en la simulación. Esto puede producir portafolios con alto turnover que serían subóptimos en la práctica.

3.2. Arquitectura general del sistema

El sistema se estructura en tres capas metodológicas de complejidad creciente, ejecutadas secuencialmente. La primera capa implementa la optimización media-varianza de Markowitz como línea base analítica. La segunda extiende Markowitz con el modelo Black-Litterman, que incorpora un prior de equilibrio de mercado y *views* cuantitativas. La tercera capa es una simulación Monte Carlo que traduce las métricas financieras de las capas anteriores en proyecciones de riqueza del cliente y utilidad de la empresa. Adicionalmente, un benchmark equiponderado funciona como caso base independiente de parámetros estimados. En total, el sistema compara seis técnicas: Equiponderado, Markowitz, y cuatro variantes de Black-Litterman (momentum general, momentum por capitalización a 6 meses, momentum por capitalización a 1 año, y desempleo macro).

3.3. Estimación de parámetros

3.3.1. Retornos esperados

Los retornos esperados $\mu \in \mathbb{R}^n$ se estiman como promedios diarios históricos de los retornos totales de cada acción en la ventana de entrenamiento.

3.3.2. Matriz de covarianzas con *shrinkage*

La matriz de covarianzas muestral Σ_{muestral} se estabiliza mediante *shrinkage* lineal hacia su diagonal (Ledoit & Wolf, 2004):

$$\Sigma_{\text{shrink}} = (1 - \lambda) \Sigma_{\text{muestral}} + \lambda \cdot \text{diag}(\Sigma_{\text{muestral}}), \quad (3.1)$$

con $\lambda = 0.20$. Esto reduce el error de estimación fuera de muestra en matrices de alta dimensión ($n = 601$), donde la covarianza muestral tiende a sobreajustar correlaciones espurias. La matriz resultante se fuerza a ser semidefinida positiva mediante proyección espectral (`nearest_psd`), truncando valores propios negativos a cero. Este paso es requisito para que los problemas cuadráticos resueltos por CVXPY sean convexos.

3.3.3. Anualización

Los retornos se anualizan asumiendo 252 días hábiles bursátil por año: $R_{\text{anual}} = \bar{r}_{\text{diario}} \times 252$. La volatilidad se escala como $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \times \sqrt{252}$. La tasa libre de riesgo se fija en $R_f = 2\%$ anual.

3.4. Optimización media-varianza de Markowitz

3.4.1. Formulación por perfil de riesgo

Para cada perfil de riesgo con parámetro de aversión γ y cota de volatilidad σ_{max}^2 , se resuelve el problema cuadrático:

$$\max_w \quad \mu^\top w - \frac{1}{2} \gamma w^\top \Sigma w \quad (3.2)$$

sujeto a:

$$\sum_{i=1}^n w_i = 1 \quad (3.3)$$

$$0 \leq w_i \leq 0.20 \quad \forall i = 1, \dots, n \quad (3.4)$$

$$w^\top \Sigma w \leq \sigma_{\text{max}}^2 \quad (\text{cuando el perfil lo requiere}) \quad (3.5)$$

La restricción $w_i \geq 0$ impide ventas cortas; la suma igual a 1 invierte todo el capital; y la cota superior $w_{\text{max}} = 0.20$ evita concentración extrema en un solo activo. Cuando la cota de volatilidad hace infactible un perfil, se relaja esa cota manteniendo las demás restricciones.

3.4.2. Frontera eficiente y portafolio de tangencia

La frontera eficiente se construye resolviendo, para 30 retornos objetivo r_{obj} equiespaciados:

$$\min_w w^\top \Sigma w \quad \text{s.a.} \quad \mu^\top w \geq r_{\text{obj}}, \quad \sum_i w_i = 1, \quad 0 \leq w_i \leq 0.20 \quad (3.6)$$

El portafolio de tangencia (“Ideal de mercado”) se selecciona como el punto de la frontera que maximiza el ratio de Sharpe:

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p} \quad (3.7)$$

donde R_p es el retorno anualizado del portafolio y σ_p su volatilidad anualizada. Este portafolio es teórico: asume conocimiento perfecto de los parámetros, por lo que su desempeño fuera de muestra mide el grado de *overfitting* de la estimación histórica.

3.4.3. Rebalanceo semestral

El período futuro de evaluación (2 años, ≈ 504 días hábiles) se divide en segmentos de 126 días. Al inicio de cada segmento:

- (i) Se extiende la ventana de entrenamiento incorporando los retornos futuros ya realizados hasta ese punto.
- (ii) Se reestiman μ y Σ con la ventana acumulada.
- (iii) Se resuelven nuevamente los problemas de optimización para todos los perfiles.
- (iv) Los nuevos pesos se aplican al segmento siguiente.

Dentro de cada segmento, los pesos se mantienen constantes. Las métricas finales se calculan concatenando los retornos diarios de todos los segmentos.

3.5. Modelo Black-Litterman

3.5.1. Prior de equilibrio de mercado

El modelo parte de que, en equilibrio, los retornos implícitos del mercado son consistentes con los pesos observados por capitalización (Black & Litterman, 1992; He & Litterman, 1999):

$$\pi = \delta \cdot \Sigma \cdot w_{\text{market}} \quad (3.8)$$

donde w_{market} son los pesos normalizados por capitalización bursátil y δ es el coeficiente de aversión al riesgo implícito:

$$\delta = \frac{R_{\text{market}} - R_f}{\sigma_{\text{market}}^2} \quad (3.9)$$

3.5.2. Incorporación de *views*

Dadas las *views* representadas por la matriz de selección $P \in \mathbb{R}^{k \times n}$, el vector de expectativas $Q \in \mathbb{R}^k$ y la matriz de incertidumbre $\Omega \in \mathbb{R}^{k \times k}$, el retorno esperado posterior es:

$$\mu_{\text{BL}} = \pi + \tau \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} (Q - P \pi) \quad (3.10)$$

con $\tau = 0.05$. La covarianza posterior se calcula como:

$$\Sigma_{\text{BL}} = (1 + \tau) \Sigma - \tau^2 \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} P \Sigma \quad (3.11)$$

y se fuerza a ser semidefinida positiva mediante `nearest_psd`. Con μ_{BL} y Σ_{BL} se resuelven los mismos problemas de optimización que en Markowitz.

3.5.3. Construcción de *views*

Se implementan cuatro *views* independientes, cada una generando su propia versión del modelo Black-Litterman. La Tabla 3.1 resume su configuración.

Tabla 3.1. Configuración de las cuatro variantes de *views* Black-Litterman.

View	Tipo	Lookback	Long	Short	Confianza	Universo
Momentum	Endógena	252 días	20	20	0.50	601 activos
Momentum Top20 6M	Market-cap	126 días	10	10	0.50	Top 20
Momentum Top20-Bottom20 1Y	Market-cap	252 días	20	20	0.50	Top 40
Desempleo	Macro asumida	1 764 días	466	135	0.35	601 activos

3.5.3.1. Views de momentum

Las *views* de momentum seleccionan activos por retorno acumulado durante el período de lookback. La matriz P tiene una fila que asigna $+1/n_{\text{long}}$ a los activos con mayor retorno y $-1/n_{\text{short}}$ a los de menor retorno. El valor Q corresponde a la diferencia promedio diaria entre los retornos de ambos grupos. La variante general opera sobre los 601 activos; las variantes por capitalización restringen el universo a los activos con mayor market cap (top 20 o top 40).

3.5.3.2. View de desempleo

Es un supuesto macroeconómico fijo, no un dato observado. Se asume una tasa de desempleo de 4% contra un nivel neutral de 5%. Con desempleo bajo, se favorecen sectores cíclicos (Technology, Consumer Cyclical, Industrials, Financial Services, Basic Materials, Real Estate, Energy) sobre defensivos (Healthcare, Consumer Defensive, Utilities, Communication Services). La señal es proporcional a la diferencia entre ambas tasas, escalada por $\beta_{\text{macro}} = 1.0$ y convertida a retorno diario dividiendo por 252. La confianza se fija en $c = 0.35$, menor que la de momentum, reflejando que es un supuesto y no una observación.

3.5.3.3. Calibración de Ω

Para cada *view*, la incertidumbre se calibra como:

$$\Omega = \frac{P \cdot (\tau \Sigma) \cdot P^\top}{c} \quad (3.12)$$

donde c es la confianza de la *view*. Con una sola *view* ($k = 1$), Ω es escalar y la formulación se simplifica.

3.6. Simulación Monte Carlo (P4)

3.6.1. Objetivo

La tercera capa traduce los KPIs financieros de Markowitz y Black-Litterman en proyecciones de riqueza para el cliente y utilidad para la empresa. Simula el comportamiento completo del sistema recomendador durante 260 semanas (5 años), incorporando las decisiones del cliente mediante funciones logísticas.

3.6.2. Funciones de comportamiento del cliente

La probabilidad de retiro ante pérdidas se modela como:

$$P_1(x_1) = \frac{1}{1 + \exp(-s(x_1 - \hat{x}_1))} \quad (3.13)$$

donde $x_1 = (C_0 - W_t)/C_0$ es la pérdida actual respecto al capital inicial, $\hat{x}_1$ es la tolerancia máxima del perfil, y $s = 20$ es la sensibilidad logística. P_1 se activa únicamente cuando $x_1 > \hat{x}_1$; en caso contrario, la probabilidad de retiro es cero.

La probabilidad de aceptación de una recomendación es:

$$P_2(x_2) = \frac{1}{1 + \exp(-s(x_2 - \hat{x}_2))} \quad (3.14)$$

donde x_2 es la tasa de retorno ofrecida en la recomendación y $\hat{x}_2$ es el umbral de tolerancia al riesgo del perfil.

3.6.3. Estructura de la simulación

Para cada combinación de escenario de datos (con/sin pandemia), técnica (6 alternativas), perfil de riesgo (5 niveles) y escenario proyectado (desfavorable, neutro, favorable),

se ejecutan $N = 5000$ simulaciones independientes. En total, esto genera $2 \times 6 \times 5 \times 3 = 180$ combinaciones, cada una con 5 000 trayectorias.

Cada simulación opera semana a semana:

- (i) El cliente decide si acepta la recomendación inicial mediante P_2 .
- (ii) Si acepta, invierte $C_0 = 1\,000$ USD y paga comisión inicial $k\% = 1\%$.
- (iii) Cada semana se simula el retorno semanal del portafolio como $r_{\text{sem}} \sim \mathcal{N}(\mu_{\text{sem}}, \sigma_{\text{sem}}^2)$, calibrado desde los KPIs anualizados de los modelos anteriores.
- (iv) Cada semana se ofrece una nueva recomendación. Si el cliente la acepta (con probabilidad P_2), se cobra comisión $k\%$ sobre el 5% de la riqueza actual (fracción de rotación asumida).
- (v) Si la pérdida acumulada respecto a C_0 supera la tolerancia del perfil, se evalúa retiro con P_1 .
- (vi) Si el cliente retira, la simulación se detiene y la riqueza terminal es el valor al momento del retiro.

3.6.4. Escenarios proyectados

Los tres escenarios se calibran a partir del retorno anualizado base R_{base} y la volatilidad anualizada σ_{base} de cada técnica:

$$R_{\text{favorable}} = R_{\text{base}} + 0.5 \sigma_{\text{base}} \quad (3.15)$$

$$R_{\text{neutro}} = R_{\text{base}} \quad (3.16)$$

$$R_{\text{desfavorable}} = R_{\text{base}} - 0.5 \sigma_{\text{base}} \quad (3.17)$$

Esto genera un abanico simétrico de $\pm 0.5\sigma$ alrededor del caso base.

3.6.5. Reproducibilidad

La simulación utiliza semillas deterministas generadas mediante SHA-256 a partir de la combinación única de escenario, técnica, *view* y perfil. Esto garantiza que cada celda del experimento es reproducible individualmente sin afectar a las demás.

3.7. Análisis distribucional de retornos

Complementariamente a la optimización, se realizó un análisis distribucional sobre los retornos diarios del universo F5 sin pandemia, con el objetivo de caracterizar la forma estadística de los retornos y evaluar la validez del supuesto de normalidad.

Se ajustaron siete familias paramétricas candidatas: normal, t-Student, Laplace, logística, skew-normal, normal generalizada y Johnson SU. Los parámetros se estimaron por máxima verosimilitud. Para cada familia m se calcularon los criterios de información:

$$AIC_m = 2k_m - 2\ell_m, \quad BIC_m = k_m \log(n) - 2\ell_m, \quad (3.18)$$

donde k_m es el número de parámetros, n la cantidad de retornos y ℓ_m la log-verosimilitud. Se aplicaron adicionalmente pruebas de normalidad (Shapiro-Wilk, D'Agostino-Pearson, Jarque-Bera) y una prueba Kolmogorov–Smirnov aproximada. Los resultados de este análisis se reportan en el Capítulo 9.

3.8. Validación robusta

Para evitar que las conclusiones dependan de un único horizonte de entrenamiento, se implementaron dos mecanismos de validación:

- **Splits aleatorios:** se evaluaron 70 particiones train/test aleatorias, generando una distribución de Sharpe fuera de muestra para cada portafolio y técnica.

- **Ventanas móviles robustas:** se probaron 18 horizontes oficiales (desde h2_f7 hasta h7_f2, variando la proporción de datos de entrenamiento versus evaluación), midiendo cómo cambia el Sharpe futuro promedio al extender o reducir la ventana histórica.

El horizonte central seleccionado es h7_f2 (7 años de entrenamiento, 2 años de evaluación), que ofrece el mejor Sharpe futuro promedio tanto para Markowitz (2.32) como para las variantes Black-Litterman (2.32 desempleo, 2.22 momentum). La validación confirma que horizontes más largos de entrenamiento producen estimaciones más estables, con Sharpe decreciente al reducir la ventana histórica.

4. SUPUESTOS

4.1. Supuestos sobre los datos

- Los precios de cierre y dividendos contenidos en los CSV representan adecuadamente la información disponible para cada activo.
- El retorno total incorpora reinversión implícita de dividendos.
- El uso de `join="inner"` para construir la matriz de retornos no introduce sesgo relevante al eliminar fechas no comunes entre activos.
- La metadata de capitalización de mercado permite construir un benchmark representativo y pesos de equilibrio para Black-Litterman, reconociendo que puede existir sesgo de supervivencia.

4.2. Supuestos de mercado

- Las carteras son *long-only*: $w_i \geq 0$ para todo i .
- Se invierte el 100% del capital disponible ($\sum w_i = 1$), sin apalancamiento.
- Divisibilidad perfecta de las acciones (fracciones permitidas).
- Se omiten costos de transacción, impuestos, *spreads* bid-ask, restricciones de liquidez, impacto de mercado y *slippage* en la etapa de optimización. En la simulación Monte Carlo, los costos se incorporan como comisión $k\% = 1\%$ sobre transacciones.
- La tasa libre de riesgo se mantiene constante en $R_f = 2\%$ anual durante todo el horizonte de evaluación.

4.3. Supuestos estadísticos

- Los retornos históricos contienen información útil sobre retornos y riesgos futuros (estabilidad temporal parcial de μ y Σ).
- La covarianza muestral se estabiliza mediante *shrinkage* de 20%: $\Sigma_{\text{shrink}} = (1 - \lambda)\Sigma + \lambda \cdot \text{diag}(\Sigma)$, con $\lambda = 0.20$.

- La anualización usa 252 días hábiles, con volatilidad escalada por $\sqrt{252}$.
- Los retornos semanales simulados en Monte Carlo siguen una distribución normal $\mathcal{N}(\mu_{\text{sem}}, \sigma_{\text{sem}}^2)$, pese a que el análisis distribucional muestra que los retornos diarios presentan colas pesadas y curtosis elevada.

4.4. Supuestos de optimización

- Los problemas resueltos por CVXPY son convexos y representan adecuadamente la decisión de inversión.
- Cuando la cota de volatilidad hace infactible un perfil, se relaja esa cota manteniendo las demás restricciones.
- El portafolio de tangencia se aproxima seleccionando el mayor Sharpe entre puntos discretos de la frontera eficiente (30 puntos en Markowitz, 12 en Black-Litterman).
- Las *views* de Black-Litterman no requieren cubrir todos los activos. Los activos sin *view* explícita retienen el prior de equilibrio π y reciben ajustes indirectos por correlación a través de la matriz Σ , lo que garantiza coherencia interna del vector de retornos esperados. Las variantes por capitalización operan sobre subconjuntos de 20 a 40 activos; la variante de momentum general y la de desempleo operan sobre los 601 activos del universo.

4.5. Supuestos de rebalanceo

- El rebalanceo se ejecuta cada 126 días hábiles (aproximadamente un semestre bursátil).
- Dentro de cada segmento de rebalanceo, los pesos se mantienen constantes.
- En cada punto de rebalanceo, la ventana de entrenamiento se extiende incorporando los retornos futuros ya realizados, sin usar datos aún no observados.

4.6. Supuestos del experimento pandemia

- El período futuro fuera de muestra se mantiene fijo entre escenarios “con pandemia” y “sin pandemia”.
- Las diferencias entre escenarios se interpretan como efecto de la información usada para calibrar, no como diferencias de mercado futuro.
- La base sin pandemia excluye correctamente las observaciones de 2020–2022; la base con pandemia las conserva.

4.7. Supuestos de la simulación Monte Carlo (P4)

- Cada cliente inicia con capital $C_0 = 1\,000$ USD.
- La comisión por transacción es $k = 1\%$, aplicada sobre C_0 al inicio y sobre el 5% de la riqueza actual en cada recomendación aceptada (fracción de rotación asumida).
- La pérdida del cliente se mide respecto al capital inicial C_0 , no respecto al máximo histórico de riqueza alcanzado. Esto implica que un cliente cuya riqueza creció y luego cayó no activa P_1 mientras siga por encima de C_0 .
- La sensibilidad logística $s = 20$ escala las diferencias decimales en P_1 y P_2 para producir efectos observables. Para el perfil muy conservador (tolerancia 0%), cualquier pérdida por mínima que sea genera una probabilidad de retiro cercana a 1.
- Los escenarios proyectados se construyen como $R_{\text{base}} \pm 0.5\sigma$, generando un abanico simétrico. En la realidad, las distribuciones de retornos presentan asimetría negativa, pero esta simplificación es aceptable para un modelo académico.
- Las 5 000 simulaciones por combinación son suficientes para estabilizar las métricas de interés (riqueza terminal, tasa de retiro, utilidad empresa) con un error estándar razonable.

4.8. Plan de sensibilidad

Para evaluar el impacto de estos supuestos se realizan tres análisis de sensibilidad:

- (i) Comparación sistemática entre escenarios con y sin pandemia en el entrenamiento, midiendo el delta de Sharpe por portafolio y técnica.
- (ii) Validación mediante 70 splits aleatorios y 18 ventanas móviles robustas con distintos horizontes de calibración (desde h2_f7 hasta h7_f2).
- (iii) Proyecciones Monte Carlo bajo tres escenarios (desfavorable, neutro, favorable) que modifican el retorno esperado en $\pm 0.5\sigma$ respecto al caso base, evaluando cómo cambian la riqueza terminal, la tasa de retiro y la utilidad de la empresa.

5. KPIS

5.1. Indicadores de desempeño (KPIs)

Los indicadores se organizan en dos perspectivas: cliente y empresa; y en dos niveles de evaluación: métricas de optimización (calculadas sobre retornos diarios reales fuera de muestra) y métricas de simulación (calculadas sobre las 5 000 trayectorias Monte Carlo por combinación).

5.1.1. Perspectiva del cliente

5.1.1.1. Métricas de optimización (Capas 1–2)

- **Retorno total rebalanceado:** ganancia acumulada durante el período futuro, $R_{\text{total}} = \prod_t (1 + r_t) - 1$. Permite comparar directamente el resultado final de cada técnica.
- **Retorno anualizado:** $R_{\text{anual}} = (1 + R_{\text{total}})^{1/T} - 1$, donde T es el número de años del período. Normaliza la comparación entre horizontes de distinta duración.
- **Volatilidad anualizada:** $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \cdot \sqrt{252}$. Mide la dispersión del retorno y es el denominador del Sharpe.
- **Ratio de Sharpe rebalanceado:** $\text{Sharpe} = (R_{\text{anual}} - R_f) / \sigma_{\text{anual}}$, con $R_f = 0.02$. Es el indicador central de eficiencia: cuánto retorno se obtiene por unidad de riesgo asumido. Valores superiores a 2.0 indican un desempeño destacado en el período evaluado.
- **Máximo drawdown:** mayor caída porcentual desde un máximo acumulado de riqueza. Mide el riesgo de trayectoria y es especialmente relevante para perfiles conservadores, cuya tolerancia a pérdidas es baja.
- **CVaR diario al 95%:** pérdida esperada promedio en el 5% peor de días. A diferencia del VaR, que solo indica el umbral de pérdida, el CVaR cuantifica la severidad promedio en la cola, proporcionando una medida de riesgo coherente (Rockafellar & Uryasev, 2000).

5.1.1.2. Métricas de simulación (Capa 3 – Monte Carlo)

- **Riqueza terminal esperada:** valor monetario final promedio desde capital inicial $C_0 = 1\,000$ USD, calculado sobre las 5 000 simulaciones. Traduce el retorno financiero a un valor tangible para el cliente.
- **Probabilidad de ganancia:** fracción de simulaciones donde la riqueza terminal supera C_0 . Informa al cliente sobre la probabilidad de no perder dinero.
- **Tasa de retiro:** fracción de simulaciones donde el cliente retira fondos antes del fin del horizonte. Una tasa alta indica que la técnica genera pérdidas que superan frecuentemente la tolerancia del perfil, lo que tiene consecuencias directas tanto para el cliente (pierde exposición al mercado) como para la empresa (pierde ingresos futuros por comisiones).

5.1.2. Perspectiva de la empresa

- **Utilidad por comisiones:** ingreso acumulado de la empresa por comisiones $k = 1\%$ sobre transacciones. Incluye comisión inicial sobre C_0 y comisiones posteriores sobre una fracción de rotación asumida del 5% de la riqueza en cada recomendación aceptada. Este KPI captura el objetivo de negocio de FinPUC.
- **Tasa de aceptación de recomendaciones:** fracción de recomendaciones aceptadas por el cliente, determinada por P_2 . Una tasa baja indica que las recomendaciones no superan el umbral de atractivo para el perfil, reduciendo tanto la rotación como la utilidad de la empresa.

5.1.3. Score combinado P4

Para rankear las alternativas se define un score que integra ambas perspectivas:

$$\text{Score}_{P4} = E[\text{Riqueza terminal}] + E[\text{Utilidad empresa}] \cdot (1 - \text{Tasa de retiro}) \quad (5.1)$$

Este indicador penaliza las alternativas con alta tasa de retiro, ya que un cliente que abandona la plataforma deja de generar comisiones futuras. El término $(1 - \text{Tasa de retiro})$ actúa como factor de retención: una técnica con alta utilidad bruta pero retiro frecuente obtiene un score inferior a una con utilidad moderada pero clientes estables.

El Score P4 es el indicador final para la toma de decisiones del sistema recomendador: determina qué combinación de técnica, *view* y perfil ofrece el mejor equilibrio entre valor para el cliente y rentabilidad para la empresa.

6. CASO BASE

6.1. Definición

El caso base es un benchmark equiponderado de los 20 activos con mayor capitalización bursátil del universo de 601 acciones. Cada activo del benchmark recibe un peso de $1/20 = 5\%$ y los 581 activos restantes reciben peso cero.

6.2. Justificación

El benchmark equiponderado cumple tres funciones como línea base:

- (i) **Independencia de parámetros estimados:** no utiliza μ ni Σ , por lo que no está sujeto a error de estimación. Cualquier modelo que no supere al benchmark carece de valor agregado práctico.
- (ii) **Diversificación simple:** distribuye capital entre las empresas más grandes por capitalización, ofreciendo una cobertura natural de mercado sin requerir análisis sofisticado.
- (iii) **Invariancia entre escenarios:** al no depender de la ventana de entrenamiento, el benchmark mantiene las mismas métricas con y sin pandemia en los datos históricos. Esto lo convierte en un punto de referencia estable para aislar el efecto de la estimación de parámetros en los modelos optimizados.

6.3. Métricas del caso base

La Tabla 6.1 presenta los KPIs del benchmark equiponderado. Al ser independiente de la ventana de entrenamiento, las métricas son idénticas en ambos escenarios (con y sin pandemia).

El benchmark captura un retorno bruto alto (101.4% en 2 años), pero a costa de una volatilidad y un drawdown significativamente mayores que los portafolios optimizados.

Tabla 6.1. KPIs del benchmark equiponderado top-20 (horizonte h7_f2, 601 activos, rebalanceo semestral).

Indicador	Valor
Retorno total rebalanceado	101.4%
Retorno anualizado	41.9%
Volatilidad anualizada	19.5%
Máximo drawdown	−21.9%
CVaR diario 95%	2.8%
Ratio de Sharpe rebalanceado	2.05

Su Sharpe de 2.05 establece el umbral mínimo de desempeño: las técnicas que no superen este valor no aportan beneficio neto respecto a una regla de asignación trivial. En la práctica, el Markowitz con datos de pandemia (Sharpe 2.02) apenas iguala al benchmark, mientras que las mejores variantes de Black-Litterman lo superan (hasta Sharpe 2.38 con momentum por capitalización a 6 meses).

6.4. Validación como línea base

El benchmark también se evalúa en la simulación Monte Carlo (Capa 3). En el escenario neutro, el benchmark equiponderado genera una riqueza terminal media de USD 4 234 con una tasa de retiro de 22.9% y una utilidad empresa media de USD 234. Estos valores sirven como referencia para evaluar si las técnicas optimizadas mejoran simultáneamente la experiencia del cliente (mayor riqueza, menor retiro) y el negocio de FinPUC (mayor utilidad por comisiones).

7. IMPLEMENTACIÓN Y HERRAMIENTAS

7.1. Entorno computacional

La implementación se realizó en Python 3.11. Los códigos se organizan en tres notebooks de Jupyter ejecutados secuencialmente:

- (i) `markowitz_vs_benchmark_rebalanceo_pandemia.ipynb`: optimización media-varianza de Markowitz con rebalanceo semestral, benchmark equiponderado top-20 y comparación de escenarios con y sin pandemia. Incluye validación robusta mediante 70 splits aleatorios y 18 ventanas móviles.
- (ii) `black_litterman.ipynb`: extensión Black-Litterman con cuatro variantes de *views* (momentum general, momentum top-20 a 6 meses, momentum top-20/bottom-20 a 1 año, y desempleo macro). Reutiliza la misma infraestructura de perfiles, rebalanceo y métricas.
- (iii) `p4_montecarlo_recomendador_portafolios.ipynb`: simulación Monte Carlo del sistema recomendador. Toma como insumo los CSV de salida de los dos notebooks anteriores y genera 5 000 trayectorias por cada una de las 180 combinaciones.

La lógica central de optimización reside en un script base compartido (`markowitz_cvxpy_benchmark_teorico.py`) que es importado por los dos primeros notebooks. Este script contiene las funciones de estimación de parámetros (μ , Σ con shrinkage, `nearest_psd`), resolución de problemas CVXPY, cálculo de frontera eficiente y métricas de desempeño. Centralizar esta lógica garantiza consistencia entre Markowitz y Black-Litterman y facilita la auditoría del código.

7.2. Librerías principales

- **CVXPY**: resolución de problemas de optimización cuadrática convexa para cada perfil de riesgo y punto de frontera eficiente.

- **NumPy / SciPy:** álgebra lineal, proyección espectral para `nearest_psd`, funciones logísticas P_1 y P_2 , y generación de números aleatorios con semillas SHA-256.
- **Pandas:** manipulación de matrices de retornos, covarianzas y series temporales; exportación de resultados a CSV.
- **Matplotlib:** generación de gráficos de fronteras eficientes, heatmaps de sensibilidad, rankings de Sharpe y bandas de simulación Monte Carlo.
- **Hashlib:** generación de semillas deterministas por combinación para reproducibilidad de la simulación.

7.3. Reproducibilidad

La simulación Monte Carlo utiliza semillas deterministas generadas mediante SHA-256 a partir de la combinación única de escenario de datos, técnica, *view*, perfil y escenario proyectado. Esto garantiza que cada celda del experimento es reproducible individualmente sin afectar a las demás.

Adicionalmente, cada notebook incluye una celda de validación final (*checklist*) que verifica:

- La existencia de todos los archivos de salida esperados.
- La ausencia de valores NaN en columnas críticas (Sharpe, retorno total, riqueza terminal).
- La consistencia de conteos (número de filas por escenario, perfil y técnica).

7.4. Estructura de archivos y outputs

El repositorio se organiza de la siguiente forma:

Entrega 2/

```
|-- Implementacion caso benchmark teorico/
```

```

| |-- markowitz_cvxpy_benchmark_teorico.py
| |-- markowitz_vs_benchmark_rebalanceo_pandemia.ipynb
| |-- black_litterman.ipynb
| |-- p4_montecarlo_recomendador_portafolios.ipynb
| |-- outputs_markowitz_.../
| | |-- rebalance_summary_h7_f2_601activos.csv
| | |-- comparison_sin_vs_con_pandemia_h7_f2_601activos.csv
| | |-- validacion_robusta_ventanas_moviles.csv
| |-- outputs_black_litterman/
| | |-- bl_rebalance_summary_h7_f2_601activos.csv
| | |-- comparison_three_models_kpis_h7_f2_601activos.csv
| | |-- bl_views_h7_f2_601activos.csv
| |-- outputs_p4_montecarlo_recomendador/
| | |-- p4_montecarlo_summary.csv
| | |-- p4_neutral_scenario_summary.csv
| | |-- p4_ranking_recomendador.csv

```

Los CSV de salida están diseñados para ser trazables: cada fila identifica unívocamente la combinación de escenario, técnica, *view* y perfil, permitiendo reproducir cualquier tabla o gráfico del informe directamente desde los datos exportados.

El código fuente completo está disponible en el repositorio del proyecto: <https://github.com/Psacevedo/Capstone.git>.

8. RESULTADOS Y ANÁLISIS

8.1. Análisis distribucional de retornos

El análisis distribucional se realizó sobre los 601 tickers del universo F5 sin pandemia, generando 4 207 ajustes paramétricos. La Tabla 8.1 resume los estadísticos transversales.

Tabla 8.1. Resumen transversal de estadísticos por ticker (universo F5 sin pandemia).

Variable	Mín.	Mediana	Media	Máx.
<i>n</i> retornos	2 518	7 949	8 263	15 400
Media diaria	0,011%	0,093%	0,102%	0,577%
Vol. anualizada	19,3%	36,5%	39,6%	214,9%
VaR 5%	−6,18%	−3,04%	−3,18%	−1,63%
CVaR 5%	−10,93%	−4,81%	−5,09%	−2,52%
Asimetría	−8,40	0,90	3,44	99,13
Curtosis exc.	3,42	26,90	179,07	10 151

Dos hechos destacan. Primero, la curtosis excede ampliamente la normalidad en prácticamente todos los activos: la mediana de curtosis excedente es 26.9, frente a 0 bajo normalidad. Segundo, la asimetría es positiva en la mayoría de los casos (mediana 0.90), lo que sugiere colas derechas más pesadas que las izquierdas en el universo filtrado.

La Tabla 8.2 muestra la distribución seleccionada como mejor ajuste según AIC y BIC.

Tabla 8.2. Mejor familia distribucional según AIC y BIC.

Distribución	AIC	%	BIC	%
Johnson SU	247	41,1	180	30,0
t-Student	179	29,8	241	40,1
Normal generalizada	174	29,0	176	29,3
Laplace	1	0,2	4	0,7
Normal/log./skew-n.	0	0,0	0	0,0

La normal no es seleccionada como mejor distribución para ningún ticker, y las tres pruebas de normalidad rechazan la hipótesis nula al 5% en los 601 casos. La convergencia

entre AIC y BIC es alta: ambos criterios coinciden en 532 tickers (88,5%). Las discrepancias son informativas: AIC favorece Johnson SU (más flexible, captura asimetrías), mientras BIC prefiere t-Student (colas pesadas con mayor parsimonia).

La prueba KS aproximada entrega valores-p mayores a 0,05 para solo el 36,5% del universo bajo la mejor distribución. Esto confirma que, aunque las familias seleccionadas mejoran sustantivamente el supuesto normal, una distribución paramétrica estática no captura todos los rasgos de las series. Persisten efectos de dependencia temporal, volatilidad condicional y cambios de régimen.

Implicancia para el modelo: la simulación Monte Carlo asume retornos semanales normales, lo que subestima eventos extremos. Los resultados de riqueza terminal y tasa de retiro deben interpretarse como estimaciones bajo un régimen “normal”, no como predicciones robustas ante crisis.

8.2. Markowitz vs benchmark

La Tabla 8.3 compara los KPIs del mejor portafolio Markowitz contra el benchmark equiponderado en ambos escenarios de entrenamiento.

Tabla 8.3. Comparación Markowitz vs benchmark (horizonte h7.f2, 601 activos, rebalanceo semestral).

Escenario	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	CVaR 95%	Sharpe
Sin pandemia	Ideal de mercado	76,5%	32,8%	12,3%	−12,6%	1,7%	2,51
Sin pandemia	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,8%	2,05
Con pandemia	Muy conservador	54,5%	24,3%	11,0%	−10,2%	1,5%	2,02
Con pandemia	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,8%	2,05

Sin pandemia, el portafolio Ideal de mercado alcanza el mayor Sharpe del experimento (2,51), superando al benchmark por 0,46 puntos. Sin embargo, su retorno bruto (76,5%) es inferior al del benchmark (101,4%): la ganancia en eficiencia proviene de una volatilidad

significativamente menor (12,3% vs 19,5%) y un drawdown más contenido (−12,6% vs −21,9%).

Con pandemia en el entrenamiento, el mejor Markowitz es Muy conservador con Sharpe 2,02, prácticamente igualando al benchmark. Esto indica que incluir el período 2020–2022 en la estimación de μ y Σ deteriora la capacidad de Markowitz para generar valor por encima de una regla trivial.

8.2.1. Impacto de la pandemia en Markowitz

La Figura ?? muestra el delta de Sharpe (con pandemia menos sin pandemia) para cada portafolio. El deterioro es generalizado y asimétrico: los perfiles más agresivos sufren las mayores caídas. El portafolio Ideal de mercado pierde 1,11 puntos de Sharpe, Muy arriesgado pierde 0,86 y Arriesgado pierde 0,57. En contraste, Mínima varianza (−0,09) y Benchmark (−0,00) son prácticamente inmunes. Esto confirma que la sensibilidad a la pandemia es proporcional a la dependencia del modelo en la estimación de retornos esperados: los perfiles agresivos explotan más las diferencias en μ , que son las más contaminadas por el shock.

8.2.2. Validación robusta

La validación por ventanas móviles confirma que horizontes más largos de entrenamiento producen Sharpe futuros más altos: h7_f2 obtiene un Sharpe promedio de 2,32, que decrece monotonamente hasta 1,35 en h2_f7. Los 70 splits aleatorios muestran que el horizonte óptimo para Markowitz es h7_f2 en la validación robusta oficial.

8.3. Black-Litterman

La Tabla 8.4 presenta el mejor portafolio por *view* y escenario.

Tabla 8.4. Mejor portafolio Black-Litterman por *view* y escenario (horizonte h7.f2).

Escenario	View	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	CVaR 95
Sin pandemia	mom. top20 6m	Neutro	72,3%	31,2%	11,9%	−12,9%	1,6
Sin pandemia	desempleo	Neutro	63,1%	27,7%	10,5%	−10,4%	1,4
Sin pandemia	momentum	Muy conserv.	64,0%	28,1%	10,9%	−10,1%	1,5
Sin pandemia	mom. top20-b20 1y	Conservador	63,1%	27,7%	10,9%	−10,7%	1,5
Con pandemia	mom. top20 6m	Neutro	69,5%	30,2%	11,9%	−11,7%	1,6
Con pandemia	desempleo	Arriesgado	71,9%	31,1%	12,4%	−13,3%	1,7
Con pandemia	mom. top20-b20 1y	Neutro	65,6%	28,7%	12,1%	−12,8%	1,7
Con pandemia	momentum	Conservador	56,4%	25,0%	11,2%	−10,3%	1,5

8.3.1. Análisis por *view*

La variante **momentum top-20 a 6 meses** domina en ambos escenarios, con Sharpe 2,46 (sin pandemia) y 2,38 (con pandemia). Esta *view* opera sobre un universo reducido (top 20 por capitalización, 10 long y 10 short, 126 días de lookback) que combina liquidez con señal de momentum de mediano plazo.

La *view* de **desempleo** es la segunda más competitiva. Es notable que con pandemia obtiene Sharpe 2,36 en el perfil Arriesgado, superando al Markowitz puro por 0,34 puntos. Esto sugiere que el prior de equilibrio de Black-Litterman actúa como estabilizador cuando las estimaciones históricas están contaminadas por el shock pandémico.

La *view* de **momentum general** (20 long, 20 short sobre los 601 activos) es la más volátil: con pandemia su mejor Sharpe cae a 2,06 (apenas igualando al benchmark), mientras que sin pandemia alcanza 2,38.

8.3.2. Black-Litterman vs Markowitz

La mejora de BL sobre Markowitz se concentra en el escenario con pandemia. La mayor ganancia se observa en BL desempleo/Arriesgado, con un delta de Sharpe de 1,19 puntos sobre el Markowitz equivalente. Sin pandemia, la diferencia es menor porque Markowitz ya funciona bien cuando la estimación histórica es estable. Esto confirma que

el valor agregado de Black-Litterman es principalmente defensivo: anclar las estimaciones al equilibrio de mercado protege contra errores de estimación en períodos de estrés.

8.4. Simulación Monte Carlo (P4)

8.4.1. Promedios por técnica en escenario neutro

La Tabla 8.5 resume los promedios por técnica en el escenario proyectado neutro, promediando los 5 perfiles de riesgo.

Tabla 8.5. Promedios por técnica en escenario neutro (promedio de perfiles).

Técnica	View	Riqueza media	Retiro prom.	Utilidad empresa	Prob. g
Equiponderado	No aplica	USD 4 234	22,9%	USD 234	
BL Mom. Top20 6M	momentum_top20_6m	USD 4 123	18,6%	USD 253	
BL Momentum	momentum	USD 3 698	24,9%	USD 223	
BL Mom. Top20-B20 1Y	mom_top20_bottom20_1y	USD 3 213	19,9%	USD 174	
BL Desempleo	desempleo	USD 3 055	18,7%	USD 160	
Markowitz	Retornos históricos	USD 2 970	21,3%	USD 159	

El Equiponderado lidera en riqueza bruta (USD 4 234), pero con la segunda tasa de retiro más alta (22,9%). BL Momentum Top20 6M ofrece un equilibrio superior: riqueza comparable (USD 4 123), menor retiro (18,6%), mayor utilidad para la empresa (USD 253) y mayor probabilidad de ganancia (81,3%). Markowitz ocupa el último lugar en riqueza media (USD 2 970), lo que refuerza la conclusión de que sin *views* el modelo no genera suficiente valor para el cliente promedio.

8.4.2. Ranking del recomendador (Score P4)

La Tabla 8.6 presenta el top 5 del ranking por Score P4 en escenario neutro.

BL Momentum Top20 6M con perfil Muy arriesgado y datos de pandemia domina el ranking con un score de 9 417. Esta alternativa combina la mayor riqueza terminal

Tabla 8.6. Top 5 ranking P4 en escenario neutro.

Rank	Escenario	Técnica	Perfil	Riqueza	Retiro	Utilidad	Score P4
1	Con pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 8 974	3,1%	USD 474	9 417
2	Sin pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 7 753	2,0%	USD 419	8 151
3	Con pandemia	BL Momentum	Muy arriesgado	USD 6 436	14,6%	USD 335	6 625
4	Sin pandemia	BL Momentum	Muy arriesgado	USD 5 568	12,8%	USD 302	5 831
5	Con pandemia	BL Mom. Top20 6M	Arriesgado	USD 5 212	3,8%	USD 285	5 486

(USD 8 974), la menor tasa de retiro entre los perfiles agresivos (3,1%) y la mayor utilidad para la empresa (USD 474). El dominio de esta variante se explica por tres factores: (i) la view por capitalización concentra la señal de momentum en activos líquidos y estables, reduciendo ruido; (ii) el lookback de 126 días captura tendencias de mediano plazo sin sobreajustar a movimientos de corto plazo; y (iii) el perfil Muy arriesgado maximiza la exposición a retorno, y su alta tolerancia (40%) hace que P_1 casi nunca se active.

8.4.3. Ganadores por escenario proyectado

- **Favorable:** BL Momentum / Muy arriesgado / Con pandemia, riqueza esperada USD 12 786.
- **Neutro:** BL Momentum Top20 6M / Muy arriesgado / Con pandemia, riqueza esperada USD 8 974.
- **Desfavorable:** Equiponderado / Muy arriesgado / Sin pandemia, riqueza esperada USD 3 759.

La rotación de ganadores entre escenarios es informativa: en condiciones favorables, la técnica más agresiva (BL Momentum sobre 601 activos) domina por retorno bruto. En condiciones desfavorables, el Equiponderado —que no depende de estimaciones que se deterioran— ofrece mayor protección. BL Momentum Top20 6M domina el escenario neutro porque equilibra señal de momentum con estabilidad del prior de mercado.

8.5. Análisis integrado

8.5.1. Comparación de las tres capas

La Tabla 8.7 sintetiza el mejor resultado de cada modelo por escenario.

Tabla 8.7. Comparación final: mejor portafolio por modelo y escenario.

Escenario	Modelo	View	Portafolio	Ret. total	Sharpe	Drawdown
Sin pandemia	Markowitz	Ret. históricos	Ideal de mercado	76,5%	2,51	−12,6%
Sin pandemia	Black-Litterman	mom. top20 6m	Neutro	72,3%	2,46	−12,9%
Sin pandemia	Equiponderado	No aplica	Benchmark	101,4%	2,05	−21,9%
Con pandemia	Black-Litterman	mom. top20 6m	Neutro	69,5%	2,38	−11,7%
Con pandemia	Black-Litterman	desempleo	Arriesgado	71,9%	2,36	−13,3%
Con pandemia	Equiponderado	No aplica	Benchmark	101,4%	2,05	−21,9%
Con pandemia	Markowitz	Ret. históricos	Muy conserv.	54,5%	2,02	−10,2%

8.5.2. Hallazgos principales

- (i) **Sin pandemia, Markowitz domina en Sharpe (2,51)**, pero este resultado depende del portafolio Ideal de mercado, que es teórico y exhibe overfitting severo. Black-Litterman ofrece un Sharpe comparable (2,46) con menor dependencia de la estimación puntual de μ .
- (ii) **Con pandemia, Black-Litterman domina** (Sharpe 2,38 y 2,36 según la view), superando a Markowitz (2,02) por más de 0,3 puntos. El prior de equilibrio actúa como estabilizador, amortiguando el efecto de las estimaciones contaminadas por el shock pandémico.
- (iii) **El benchmark equiponderado es un competidor exigente** en retorno bruto (101,4%), pero su volatilidad (19,5%) y drawdown (−21,9%) son inaceptables para perfiles conservadores. Su Sharpe de 2,05 establece el piso mínimo de desempeño.

- (iv) **La validación robusta confirma la estabilidad de los resultados:** el Sharpe futuro decrece monotonamente al reducir la ventana de entrenamiento, lo que descarta que el horizonte $h7_f2$ sea un artefacto favorable.
- (v) **En Monte Carlo, BL Momentum Top20 6M domina el ranking** con score P4 de 9 417, combinando alta riqueza terminal, baja tasa de retiro y la mayor utilidad para la empresa.

8.5.3. Limitaciones y posibles mejoras

- La simulación Monte Carlo asume retornos normales, pese a que el análisis distribucional rechaza normalidad en todos los activos. Usar distribuciones t-Student o Johnson SU en la simulación produciría colas más realistas y tasas de retiro potencialmente mayores.
- La pérdida en P4 se mide respecto al capital inicial, no respecto al máximo alcanzado (drawdown). Implementar drawdown como trigger de P_1 sería más realista para clientes que perciben pérdida relativa a su peak.
- La sensibilidad logística $s = 20$ no fue sometida a análisis de sensibilidad. Valores distintos de s cambiarían materialmente las tasas de retiro y aceptación.
- La view de desempleo usa una tasa asumida fija (4% vs 5% neutral), no datos macroeconómicos observados. Alimentarla con series reales de desempleo mejoraría su validez.
- Los escenarios proyectados son simétricos ($\pm 0,5\sigma$), ignorando la asimetría negativa observada en los retornos. Incorporar sesgo negativo en el escenario desfavorable produciría proyecciones más conservadoras.
- No se incorporan costos de transacción explícitos en la optimización. Incluir restricciones de rotación como penalización en la función objetivo reduciría el turnover y mejoraría la consistencia entre las capas de optimización y simulación.

9. CONCLUSIONES

9.1. Conclusiones principales

El proyecto implementó y comparó tres capas metodológicas para el sistema recomendador de FinPUC: optimización media-varianza de Markowitz, Black-Litterman con cuatro variantes de *views*, y simulación Monte Carlo del comportamiento cliente-empresa. Los hallazgos principales son:

- (i) **Black-Litterman supera a Markowitz cuando la estimación histórica está contaminada.** Con datos de pandemia, la mejor variante BL (momentum top-20 a 6 meses, Sharpe 2,38) supera al mejor Markowitz (Sharpe 2,02) por 0,36 puntos. Sin pandemia, Markowitz alcanza Sharpe 2,51 con el portafolio Ideal de mercado, pero este resultado es teórico y exhibe overfitting severo (Sharpe teórico 5,01 vs real 1,80 en escenario con pandemia).
- (ii) **El benchmark equiponderado es un competidor exigente.** Con un Sharpe estable de 2,05 y retorno bruto de 101,4%, el benchmark establece un piso alto. Solo las variantes BL lo superan consistentemente en eficiencia ajustada por riesgo, aunque a costa de menor retorno bruto.
- (iii) **La view de momentum por capitalización a 6 meses domina el ranking del recomendador.** Con score P4 de 9 417 (riqueza USD 8 974, retiro 3,1%, utilidad empresa USD 474), esta variante ofrece el mejor equilibrio entre valor para el cliente y rentabilidad para FinPUC.
- (iv) **La inclusión de pandemia en el entrenamiento deteriora los portafolios agresivos de Markowitz** hasta en 1,1 puntos de Sharpe, pero tiene un efecto neutro o positivo en las variantes BL. Esto confirma que el prior de equilibrio de Black-Litterman actúa como estabilizador ante cambios de régimen.
- (v) **Los retornos diarios rechazan normalidad en todos los activos.** Las distribuciones t-Student y Johnson SU dominan el ajuste paramétrico (70% y 41%

respectivamente por BIC y AIC). Esto tiene implicancias directas para la simulación Monte Carlo, que asume retornos normales y por tanto subestima eventos extremos.

- (vi) **La validación robusta confirma la estabilidad de los resultados.** El Sharpe futuro decrece monotonamente al reducir la ventana de entrenamiento (de 2,32 en $h7_f2$ a 1,35 en $h2_f7$), descartando que el horizonte central sea un artefacto favorable.

9.2. Puntos fuertes de la metodología

- La combinación de tres capas (Markowitz, Black-Litterman, Monte Carlo) permite evaluar el valor agregado de cada componente de forma incremental: primero la optimización pura, luego la incorporación de *views*, y finalmente la dinámica del cliente.
- El caso base equiponderado, independiente de parámetros estimados, provee una línea de comparación exigente y estable que no favorece a ningún modelo por construcción.
- La evaluación bajo dos escenarios de entrenamiento (con y sin pandemia) aísla el efecto de la información histórica en la calibración, manteniendo fijo el período de evaluación fuera de muestra.
- La validación mediante 70 splits aleatorios y 18 ventanas móviles reduce el riesgo de conclusiones inducidas por un período favorable único.
- Las funciones P_1 y P_2 hacen trazable el comportamiento del cliente: se puede cuantificar cómo cambian las tasas de retiro y aceptación al variar perfiles y técnicas.
- Las semillas SHA-256 por combinación garantizan reproducibilidad completa de cada celda del experimento Monte Carlo.

9.3. Puntos débiles y propuestas de mejora

- **Supuesto de normalidad en Monte Carlo:** los retornos se simulan como normales pese a que el análisis distribucional rechaza normalidad en todos los activos. Para la entrega final se propone usar distribuciones t-Student o Johnson SU, calibradas por ticker, para generar trayectorias con colas más realistas.
- **View de desempleo con tasa fija:** la view macro usa un supuesto fijo (4% vs 5% neutral), no datos observados. Alimentarla con series reales de desempleo (por ejemplo, BLS FRED) le daría validez empírica y permitiría evaluar su capacidad predictiva.
- **Ausencia de costos de transacción en la optimización:** la comisión $k\%$ se modela solo en Monte Carlo, no como restricción del optimizador. Incluir una penalización por rotación en la función objetivo ($\|w_{\text{nuevo}} - w_{\text{anterior}}\|_1 \leq \delta$) reduciría el turnover y mejoraría la consistencia entre capas.
- **Pérdida medida vs capital inicial:** P_1 se activa cuando la pérdida supera la tolerancia respecto a C_0 , no respecto al máximo alcanzado. Un cliente que duplicó su dinero y luego pierde 30% nunca activa P_1 mientras siga arriba de C_0 . Implementar drawdown como trigger sería más realista.
- **Sensibilidad logística no evaluada:** $s = 20$ es un hiperparámetro con impacto material. Se propone un análisis de sensibilidad sobre $s \in \{5, 10, 20, 50\}$ para la entrega final.
- **Escenarios proyectados simétricos:** los escenarios $\pm 0,5\sigma$ ignoran la asimetría negativa observada en los retornos. Incorporar un factor de sesgo en el escenario desfavorable produciría proyecciones más conservadoras.

9.4. Plan de trabajo: avance y fases restantes

9.4.1. Comparación entre planificación original y avance real

La Tabla 9.1 compara las fases planificadas en el Informe 1 con el estado actual del proyecto.

Tabla 9.1. Comparación entre planificación original (Informe 1) y avance real.

Tarea	Planificado	Estado	Comentario
Comprensión del problema y modelamiento	Mar–Abr 2026	Completada	Definición de perfiles, P_1 , P_2 y modelo base.
Revisión bibliográfica	Mar–Abr 2026	Completada	Markowitz, CAPM, Fama-French, BL, CVaR.
Limpieza y análisis exploratorio de datos	Abr 2026	Completada	Filtrado F0–F5, análisis distribucional de 601 tickers.
Implementación Markowitz base	Abr–May 2026	Completada	CVXPY con rebalanceo semestral, escenarios pandemia.
Implementación Black-Litterman	Abr–May 2026	Completada	4 variantes de views implementadas y evaluadas.
Simulación Monte Carlo P4	May 2026	Completada	5 000 simulaciones $\times$ 180 combinaciones.
Validación robusta	May 2026	Completada	70 splits aleatorios + 18 ventanas móviles.
Integración del sistema en tiempo real	May–Jun 2026	Pendiente	Falta interfaz de recomendación con respuesta <10 s.
Optimización computacional	Jun 2026	Pendiente	Profiling de tiempos, caché de resultados.
Documentación final	Jun 2026	En curso	Informe 2 en redacción.

9.4.2. Dificultades encontradas

Las principales dificultades fueron: (i) la dimensionalidad del problema ($n = 601$ activos) requirió shrinkage y nearest_psd para que CVXPY convergiera de forma estable; (ii) la implementación de las 4 views de BL demandó más tiempo del planificado por la necesidad de construir la matriz P y calibrar Ω para cada variante; y (iii) la simulación

Monte Carlo con 180 combinaciones $\times$ $5\,000$ trayectorias $\times$ 260 semanas requirió optimización de las semillas SHA-256 para mantener reproducibilidad sin penalizar el tiempo de ejecución.

9.4.3. Fase 3: Evaluación y mejoras (12 mayo – 15 junio)

- Análisis de sensibilidad sobre s (sensibilidad logística), τ (BL) y λ (shrinkage).
- Incorporación de costos de transacción como restricción de rotación en la optimización.
- Evaluación de distribuciones no normales en la simulación Monte Carlo.
- Integración del sistema con restricción de tiempo de 10 segundos.

9.4.4. Fase 4: Cierre y entrega final (13 – 26 junio)

- Preparación de la Presentación Final y redacción del Informe Final.
- Documentación del modelo final y estructuración del repositorio GitHub.
- Revisión y correcciones finales del informe.
- Entrega final del proyecto: 26 de junio de 2026.

REFERENCES

- Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. doi: 10.2469/faj.v48.n5.28
- D’Acunto, F., Prabhala, N., & Rossi, A. G. (2019). The promises and pitfalls of robo-advising. *Review of Financial Studies*, 32(5), 1983–2020. doi: 10.1093/rfs/hhz017
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. doi: 10.1016/0304-405X(93)90023-5
- He, G., & Litterman, R. (1999). *The intuition behind Black–Litterman model portfolios* (Tech. Rep.). Goldman Sachs Asset Management.
- Idzorek, T. M. (2005). A step-by-step guide to the Black-Litterman model. In *Forecasting expected returns in the financial markets* (pp. 17–38). Academic Press.
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. doi: 10.1016/S0047-259X(03)00096-4
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. doi: 10.1111/j.1540-6261.1952.tb01525.x
- Michaud, R. O. (1989). The Markowitz optimization enigma: Is ‘optimized’ optimal? *Financial Analysts Journal*, 45(1), 31–42. doi: 10.2469/faj.v45.n1.31
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41. doi: 10.21314/JOR.2000.038
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442. doi: 10.1111/j.1540-6261.1964.tb02865.x

USO DE IA

Completar