



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ESCUELA DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

ICS2122 - TALLER DE INVESTIGACIÓN OPERATIVA (CAPSTONE)

FINPUC

GRUPO 13

INTEGRANTES:

PATRICIO ANDRES ACEVEDO FLORES

BENJAMÍN ALONSO CANO ARAYA

MATÍAS BENJAMÍN CATALÁN CONTRERAS

GASPAR TEN BERG YUNUSIC

DIEGO BENJAMÍN VILLALOBOS MICHEA

PROFESOR GUÍA: AGUSTÍN MATÍAS ANTONIO CHIU
LÓPEZ

AYUDANTE TUTOR: JUAN ENRIQUE HURTADO BROWNE

Santiago de Chile, Marzo 2026

© 2026, GRUPO 13

ANEXO N°1: ANÁLISIS DE DATOS

Este anexo presenta la fuente de datos, la estructura de los archivos, los criterios de clasificación sectorial, los niveles de filtrado aplicados y la caracterización del universo final de acciones utilizado en el modelo P4. [Ver documento completo](#)

Descripción de la Fuente de Datos

Los datos históricos provienen del directorio `Data/Historical_Stocks/` del repositorio del proyecto. Fueron descargados con la librería `yfinance` de Yahoo Finance, incluyendo precios de cierre ajustados por splits, volumen, dividendos y metadatos fundamentales por ticker.

Estructura de archivos

El directorio contiene **1.407 archivos**:

- **1.406 archivos CSV** individuales con el formato `stock_return_<TICKER>.csv`
- **1 archivo de metadatos** `stocks_info.txt` con información fundamental de cada ticker (sector, industria, descripción, capitalización de mercado, empleados, etc.)

Formato de los CSV

Cada archivo contiene precios diarios con las siguientes columnas:

Columna	Tipo	Descripción
Date	datetime	Fecha de cierre (zona horaria US/Eastern)
Open	float	Precio de apertura ajustado
High	float	Precio máximo del día
Low	float	Precio mínimo del día
Close	float	Precio de cierre ajustado por splits
Volume	int	Volumen de transacciones
Dividends	float	Dividendo distribuido ese día (USD/acción)
Stock Splits	float	Factor de split (0 si no hubo split)

Nota: Los precios están ajustados hacia atrás (*backward-adjusted*) por splits de acciones, pero *no* por dividendos. Los dividendos se registran explícitamente en la columna `Dividends` y serán usados directamente para alimentar la **caja chica** del modelo de optimización.

Cobertura temporal

Indicador	Valor	Detalle
Total de tickers en archivos CSV	1.406	
Tickers con datos válidos	1.165	83% del total
Tickers con datos vacíos o errores	239	17% sin datos
Fecha de corte más frecuente	2026-03-13	1.158 tickers
Mediana de filas por archivo	6.532	$\approx$ 26 años
Tickers con ≥ 5 años (1.250 filas)	1.039	
Tickers con ≥ 10 años (2.500 filas)	912	

Los años de inicio más frecuentes son 1980 (100 tickers), 1999 (52), 2021 (49) y 1973 (41), lo que refleja una mezcla de empresas consolidadas y listados recientes, incluyendo SPACs post-2020.

Clasificación Sectorial

Sistema de clasificación

Los tickers se clasifican usando la taxonomía sectorial de **GICS**¹ a través de los metadatos de Yahoo Finance, que asigna a cada empresa un `sector` y una `industry` (subsector).

El archivo `stocks_info.txt` contiene 1.406 entradas en formato:

```
TICKER;{'sector': '...', 'industry': '...', 'marketCap':  
        ..., ...}
```

Distribución sectorial del universo completo

La Tabla 0.1 muestra la distribución de los tickers con datos válidos por sector.

¹Global Industry Classification Standard, desarrollado por MSCI y S&P Dow Jones Indices.

Table 0.1. Distribución sectorial del universo completo con datos válidos

Sector	Tickers	% del total
Financial Services	716	61.4%
Technology	81	6.9%
Industrials	74	6.4%
Healthcare	64	5.5%
Consumer Cyclical	59	5.1%
Consumer Defensive	38	3.3%
Real Estate	32	2.7%
Utilities	31	2.7%
Basic Materials	22	1.9%
Energy	21	1.8%
Communication Services	20	1.7%
Unknown	8	0.7%
Total	1.166	100%

Nota: Financial Services representa el 61% del universo crudo debido a la alta presencia de bancos regionales, gestores de activos y shell companies (SPACs). El filtrado posterior reducirá significativamente este sesgo sectorial.

Subsectores predominantes en Financial Services

Subsector (Industry)	Tickers	%
Banks – Regional	317	44.3%
Asset Management	101	14.1%
Capital Markets	56	7.8%
Credit Services	45	6.3%
Shell Companies	42	5.9%
Insurance – Property & Casualty	41	5.7%
Banks – Diversified	19	2.7%
Insurance – Life	17	2.4%
Insurance – Specialty	16	2.2%
Insurance Brokers	16	2.2%
Otros	46	6.4%
Total	716	100%

Tipos de instrumento

El campo `quoteType` de Yahoo Finance indica que 1.165 tickers corresponden a EQUITY (acciones individuales de empresas) y 1 ticker es MUTUALFUND (excluido del análisis). El universo es prácticamente homogéneo en acciones individuales.

Capitalización de Mercado

Se definen los siguientes rangos estándar de capitalización:

Categoría	Rango (USD)	Tickers	%
Mega cap	$\geq 200\text{B}$	50	4.3%
Large cap	10B – 200B	473	40.6%
Mid cap	2B – 10B	193	16.6%
Small cap	300M – 2B	234	20.1%
Micro cap	$< 300\text{M}$	210	18.0%
Sin dato	—	6	0.5%
Total con datos		1.160	

Niveles de Filtrado

Se definen cinco niveles de filtrado en cascada, cada uno más restrictivo que el anterior. El objetivo es obtener un universo operacional que sea **líquido, estable, representativo y estadísticamente válido** para el optimizador de Markowitz.

La secuencia de filtros es la siguiente:

[leftmargin=2em]

- **F0 — Universo crudo:** 1.406 tickers
- **F1 — Liquidez básica:** 883 tickers (precio ≥ 5 USD, historia ≥ 5 años)
- **F2 — Sin shells ni desconocidos:** 881 tickers (excluye Shell Companies y sector Unknown)
- **F3 — Large/Mega cap:** 686 tickers (capitalización $\geq 2\text{B}$ USD)
- **F4 — Historia suficiente:** 641 tickers (≥ 10 años de datos)
- **F5 — Volatilidad razonable (universo final):** 636 tickers ($5\% \leq \sigma_{ann} \leq 100\%$)

Razones de exclusión

La Tabla 0.2 desglosa cuántos tickers fueron eliminados en cada filtro y por qué razón:

Table 0.2. Razones de exclusión del universo final F5

Razón de exclusión	Tickers	%
Historial < 10 años	254	47.9%
Cap. mkt $< 2B$ o sin dato	233	43.9%
Precio de cierre < 5 USD	37	7.0%
Volatilidad fuera de rango	5	0.9%
Datos vacíos o errores de lectura	239	—
Total excluidos (F0→F5)	529	

Definición formal de cada filtro

F1 — Liquidez básica. Un ticker i pertenece a $\mathcal{F}_1$ si y solo si cumple: número de filas con precios válidos $n_i \geq 1.250$ (≈ 5 años de historia), precio de cierre más reciente $P_i^{\text{last}} \geq 5$ USD, y capitalización de mercado $\text{Cap}_i \geq 300M$ USD (o sin dato). Esto excluye penny stocks y acciones ilíquidas sin historia suficiente para estimar parámetros estadísticos confiables.

F2 — Calidad de clasificación. $\mathcal{F}_2 \subset \mathcal{F}_1$: adicionalmente se excluye si `industry` = “Shell Companies” o `sector` = “Unknown”. Las shell companies, principalmente SPACs, no tienen operaciones reales ni retornos representativos, y los tickers sin sector asignado no pueden incluirse en análisis sectoriales.

F3 — Large/Mega cap. $\mathcal{F}_3 \subset \mathcal{F}_2$: adicionalmente se requiere $\text{Cap}_i \geq 2 \times 10^9$ USD. Las empresas de capitalización media-alta tienen mayor liquidez de mercado, menores spreads bid-ask, y sus precios reflejan mejor la información pública disponible, condición implícita del modelo de Markowitz.

F4 — Historia suficiente. $\mathcal{F}_4 \subset \mathcal{F}_3$: adicionalmente $n_i \geq 2.500$ (≈ 10 años de datos diarios). Con 10 años de historia se captura al menos un ciclo económico completo, incluyendo crisis (2008–09, 2020) y expansiones, lo que es necesario para la estimación robusta de matrices de covarianza.

F5 — Volatilidad razonable (universo final). $\mathcal{F}_5 \subset \mathcal{F}_4$: adicionalmente se requiere:

$$5\% \leq \hat{\sigma}_i^{\text{ann}} \leq 100\% \quad \text{donde} \quad \hat{\sigma}_i^{\text{ann}} = \hat{\sigma}_i^{\text{diaria}} \times \sqrt{252}$$

$\sigma < 5\%$ indicaría datos incorrectos o instrumentos no bursátiles; $\sigma > 100\%$ corresponde a activos especulativos extremos incompatibles con el modelo de media-varianza.

Universo Final: 636 Acciones

El universo final contiene **636 acciones** con historia ≥ 10 años, capitalización $\geq 2\text{B}$ USD, precio ≥ 5 USD, y volatilidad anualizada entre 5% y 100%.

Distribución sectorial del universo final

Table 0.3. Estadísticas por sector — universo F5 (636 tickers)

Sector	N	$\bar{\sigma}_{ann}$	$\overline{CAGR}$	% con dividendos
Financial Services	237	37.5%	10.6%	95%
Technology	73	44.6%	16.5%	70%
Industrials	64	34.6%	13.2%	95%
Healthcare	59	37.3%	13.4%	66%
Consumer Cyclical	55	41.2%	13.9%	78%
Consumer Defensive	33	29.3%	11.4%	97%
Utilities	29	24.7%	9.7%	100%
Real Estate	29	34.8%	11.3%	93%
Energy	20	37.5%	11.5%	100%
Basic Materials	19	35.1%	11.5%	100%
Communication Services	18	36.7%	14.6%	78%
Total	636	36.6%	11.9%	90%

Utilities es el sector de menor volatilidad promedio (24.7%), adecuado para perfiles conservadores con dividendos garantizados (100%). Technology lidera en CAGR (16.5%) pero con alta volatilidad (44.6%). Consumer Defensive combina volatilidad baja (29.3%) con dividendos casi universales (97%). Financial Services sigue siendo el sector más grande (37% del universo F5).

Table 0.4. Top subsectores por sector en el universo F5

Sector	Subsector (Industry)	N
Financial Services	Banks – Regional	93
	Asset Management	26
	Capital Markets	19
	Insurance – P&C	18
	Banks – Diversified	18
Technology	Semiconductors	14
	Software – Application	13
	Software – Infrastructure	12
	IT Services	10
	Computer Hardware	5
Industrials	Specialty Industrial Machinery	14
	Aerospace & Defense	11
	Integrated Freight & Logistics	5
	Airlines	4
Healthcare	Diagnostics & Research	11
	Medical Devices	10
	Drug Manufacturers – General	9
	Medical Instruments & Supplies	9
Consumer Cyclical	Packaging & Containers	6
	Auto Parts	6
	Restaurants	6
	Travel Services	5
Real Estate	REIT – Specialty	7
	REIT – Residential	6
	REIT – Retail	5
Energy	Oil & Gas E&P	8
	Oil & Gas Midstream	4
	Oil & Gas Refining	3
Basic Materials	Specialty Chemicals	10
	Agricultural Inputs	2
Utilities	Utilities – Regulated Electric	23
	Utilities – Diversified	2
	Utilities – Regulated Gas	2
Communication Services	Entertainment	6
	Telecom Services	5
	Internet Content & Information	4

Representantes por sector (top 5 por capitalización)

Table 0.5. Top 5 Technology (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
NVDA	NVIDIA Corp.	4.381	59.5%	36.7%	1999
AAPL	Apple Inc.	3.676	43.8%	18.9%	1980
MSFT	Microsoft Corp.	2.940	33.2%	24.6%	1986
AVGO	Broadcom Inc.	1.527	37.9%	40.6%	2009
MU	Micron Technology	480	60.3%	14.8%	1984

Table 0.6. Top 5 Healthcare (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
LLY	Eli Lilly & Co.	882	27.5%	13.9%	1972
JNJ	Johnson & Johnson	582	22.8%	13.8%	1962
ABBV	AbbVie Inc.	388	26.3%	19.6%	2013
MRK	Merck & Co.	286	24.9%	12.4%	1962
UNH	UnitedHealth Group	256	39.8%	20.9%	1984

Table 0.7. Top 5 Financial Services (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
JPM	JPMorgan Chase	764	35.0%	13.0%	1980
V	Visa Inc.	592	28.5%	19.5%	2008
MA	Mastercard Inc.	444	32.4%	27.4%	2006
BAC	Bank of America	341	37.5%	6.7%	1973
HSBC	HSBC Holdings	269	27.0%	5.9%	1999

Table 0.8. Top 5 Consumer Defensive + Utilities (perfiles conservadores)

Ticker	Sector	Empresa	Cap (B)	σ_{ann}	CAGR	Inicio
WMT	Cons. Def.	Walmart Inc.	1.009	29.1%	19.0%	1972
COST	Cons. Def.	Costco Wholesale	447	31.0%	13.2%	1986
PG	Cons. Def.	Procter & Gamble	353	21.3%	10.5%	1962
KO	Cons. Def.	Coca-Cola Co.	333	22.8%	12.3%	1962
NEE	Utilities	NextEra Energy	193	21.8%	11.1%	1973

Implicaciones para el Modelo de Optimización

Conexión con parámetros del modelo

El universo F5 alimenta directamente los parámetros del modelo MO-MS-SNLP descrito en la formulación matemática del P4:

Table 0.9. Conexión entre parámetros del modelo y fuente de datos

Parámetro	Fuente en los datos	Notas
$r_{i,t}^s$ (retorno escenario s)	Columna <code>Close</code> , retornos diarios	Agregado a retornos semanales
$d_{i,t}$ (dividendos)	Columna <code>Dividends</code>	Alimenta <code>CC_t</code> (caja chica)
μ_i (retorno esperado)	CAGR histórico o media móvil	Percentil 10/50/90 por escenario
Σ_{ij} (covarianza)	Retornos diarios, ventana de 2 años	Estimación rolling para rebalanceo
α_p (tolerancia de pérdida)	Perfil de riesgo del cliente	5 niveles: 0%, 5%, 15%, 30%, 40%

Sub-universos recomendados por perfil de riesgo

Para mantener el problema computacionalmente tratable y respetar la restricción de respuesta < 10 segundos, se sugieren los siguientes sub-universos:

Table 0.10. Sub-universos recomendados por perfil de riesgo

Perfil	Tamaño sugerido	Criterio de selección
Muy conservador (0%)	30–50 acciones	$\sigma_{ann} < 30\%$, dividendos, sectores Utilities y Cons. Def.
Conservador (5%)	50–80 acciones	$\sigma_{ann} < 35\%$, dividendos $\geq 50\%$ del universo sectorial
Neutro (15%)	80–120 acciones	Todos los sectores, pesos del universo F5
Arriesgado (30%)	100–150 acciones	Incluye Tech y Consumer Cyclical de alta volatilidad
Muy arriesgado (40%)	Sin restricción	Universo F5 completo (636 acciones)

Para el prototipo inicial se recomienda trabajar con un universo de **50–100 acciones** seleccionadas por sector (representantes por capitalización), lo que garantiza la resolución en Gurobi en < 1 segundo para el LP de capas 0–2.

Consideraciones sobre la caja chica

Los dividendos en la columna `Dividends` representan el monto en USD por acción en la fecha de pago. Para el modelo:

$$d_{i,t} = \text{Dividends}_{i,t} \cdot \frac{w_{i,t} \cdot V_{t-1}}{P_{i,t}} \quad (0.1)$$

donde $P_{i,t}$ es el precio de cierre de la semana t y V_{t-1} el valor del portafolio en la semana anterior. El 90% del universo F5 distribuye dividendos, lo que implica que la caja chica será activa para la gran mayoría de portafolios.

Conclusión

En síntesis, a partir de un universo inicial de **1.406 tickers** se construyó un universo final de **636 acciones** aptas para alimentar el modelo de optimización del proyecto. El proceso de depuración permitió eliminar instrumentos con información incompleta, baja liquidez, escasa historia o comportamiento incompatible con el enfoque de media-varianza.

El resultado es un universo más estable, representativo y utilizable computacionalmente, con presencia de 11 sectores económicos, una volatilidad promedio anualizada de 36.6%, y una alta proporción de acciones que pagan dividendos. Esto permite que el conjunto final no solo sea adecuado para la estimación de retornos y covarianzas, sino también consistente con la lógica financiera del modelo, incluyendo la incorporación de caja chica vía dividendos.

Documento generado con datos al 13 de marzo de 2026.

Fuente: Yahoo Finance vía `yfinance`. Análisis: Python 3.11.

ANEXO N°2: VISUALIZADOR DE DATOS

Visualizador de Datos en Entorno Docker (<https://github.com/Psacevedo/Capstone>)

Introducción

Como parte del análisis exploratorio de los datos del proyecto FinPUC, se desarrolló un visualizador interactivo de información financiera implementado dentro de un entorno Docker. El objetivo de esta herramienta es facilitar la comprensión del comportamiento histórico de las acciones, permitiendo analizar precios, retornos y otras variables relevantes de manera eficiente y reproducible. Como parte del análisis exploratorio de los datos del proyecto FinPUC, se desarrolló un visualizador interactivo de información financiera implementado dentro de un entorno Docker. El objetivo de esta herramienta es facilitar la comprensión del comportamiento histórico de las acciones, permitiendo analizar precios, retornos y otras variables relevantes de manera eficiente y reproducible.

Este visualizador se construyó utilizando herramientas de programación asistidas por inteligencia artificial, lo que permitió acelerar su desarrollo e integración con el dataset disponible.

Objetivo del Visualizador

El visualizador tiene como propósito principal:

- Explorar el comportamiento histórico de las acciones disponibles en el dataset.
- Analizar tendencias de precios y retornos.
- Identificar patrones relevantes para la construcción del modelo de optimización de portafolios.
- Facilitar el análisis preliminar requerido en el proyecto.

Este análisis es clave dado que el modelo de inversión depende directamente de la evolución de precios, dividendos y volatilidad de los activos disponibles.

Descripción General del Sistema

El sistema fue implementado dentro de un contenedor Docker, lo que permite asegurar portabilidad, reproducibilidad y facilidad de ejecución en distintos entornos.

La arquitectura general del sistema se compone de los siguientes elementos:

- **Contenedor Docker:** encapsula todas las dependencias necesarias para ejecutar el visualizador.
- **Backend en Python:** encargado de procesar los datos históricos de las acciones.
- **Módulo de visualización:** permite generar gráficos interactivos de precios y métricas financieras.
- **Dataset:** conjunto de archivos CSV con información histórica de las acciones (precios, volumen, dividendos, etc.).

Flujo de Funcionamiento

El funcionamiento del sistema puede describirse en las siguientes etapas:

- (i) **Carga de datos:** el sistema lee los archivos CSV correspondientes a cada acción.
- (ii) **Preprocesamiento:** se limpian los datos, se manejan valores faltantes y se estructuran en un formato adecuado para su análisis.
- (iii) **Cálculo de métricas:** se calculan variables relevantes como retornos, volatilidad y acumulación de dividendos.
- (iv) **Visualización:** se generan gráficos que permiten analizar la evolución de las acciones en el tiempo.

Funcionalidades del Visualizador

El visualizador desarrollado permite:

- Visualizar precios históricos de las acciones.
- Analizar retornos acumulados.
- Observar distribuciones de variables financieras.
- Comparar distintas acciones.
- Identificar tendencias y comportamientos relevantes.

Estas funcionalidades permiten obtener una comprensión más profunda del dataset, el cual contiene información de precios, volumen y dividendos de múltiples acciones del mercado estadounidense.

Uso de Docker

El uso de Docker permite encapsular completamente el entorno de ejecución del visualizador. Esto presenta varias ventajas:

- **Reproducibilidad:** cualquier usuario puede ejecutar el sistema sin preocuparse por dependencias.
- **Portabilidad:** el sistema puede ejecutarse en distintos sistemas operativos.
- **Escalabilidad:** facilita futuras extensiones del proyecto.

El flujo de ejecución es el siguiente:

- (i) Construcción de la imagen Docker mediante el archivo `Dockerfile`.
- (ii) Levantamiento del contenedor.
- (iii) Ejecución del visualizador dentro del contenedor.

Interfaz del Visualizador

El sistema presenta una interfaz que permite al usuario seleccionar distintas acciones y visualizar sus respectivos gráficos.




Figure 0.1. Vista general del visualizador de acciones

TICKER	EMPRESA	INDUSTRIA	PRECIO	MKT CAP	CAGR	VOLATILIDAD	BETA	P/E	DIV YIELD
JPM	JP Morgan Chase & Co.	Banks - Diversified	\$283.44	\$764.4B	+13.0%	35.0%	1.06	14.2	212.0%
V	Visa Inc.	Credit Services	\$307.14	\$592.2B	+19.5%	28.4%	0.79	28.9	87.0%
MA	Mastercard Incorporated	Credit Services	\$497.99	\$444.4B	+27.4%	32.2%	0.84	30.1	70.0%
BAC	Bank of America Corpora...	Banks - Diversified	\$46.72	\$341.2B	+6.7%	37.4%	1.26	12.3	240.0%
HSBC	HSBC Holdings, plc.	Banks - Diversified	\$78.19	\$268.8B	+5.9%	27.1%	0.47	13.0	480.0%
MS	Morgan Stanley	Capital Markets	\$154.87	\$245.9B	+12.2%	44.0%	1.21	15.2	258.0%
GS	Goldman Sachs Group, In...	Capital Markets	\$782.21	\$234.6B	+10.9%	35.9%	1.34	15.2	230.0%
WFC	Wells Fargo & Company	Banks - Diversified	\$74.10	\$232.6B	+12.4%	32.7%	1.07	11.8	243.0%
RY	Royal Bank Of Canada	Banks - Diversified	\$161.26	\$225.7B	+15.9%	24.1%	0.94	15.1	297.0%
AXP	American Express Compa...	Credit Services	\$299.96	\$206.6B	+10.8%	34.7%	1.15	19.5	127.0%
MUFU	Mitsubishi UFJ Financial ...	Banks - Diversified	\$16.43	\$185.5B	+2.8%	34.8%	0.16	15.5	301.0%
C	Citigroup, Inc.	Banks - Diversified	\$105.69	\$184.9B	+5.8%	39.7%	1.13	15.1	227.0%
SCHW	Charles Schwab Corporat...	Capital Markets	\$93.06	\$165.4B	+16.7%	43.8%	0.92	20.0	138.0%
CAN	Banco Santander S.A. Sn	Banks - Diversified	\$10.77	\$146.8B	+7.5%	36.1%	0.92	11.2	260.0%

Figure 0.2. Acciones disponibles del sector de servicios financieros




Figure 0.3. Ejemplo de acción Visa Inc




Figure 0.4. Visualizador gráfico del precio de cierre semanal de Visa Inc



Figure 0.5. Gráfico de volumen y dividendos de Visa Inc

Relación con el Problema de Optimización

El visualizador cumple un rol fundamental en la comprensión del dataset utilizado para el desarrollo del sistema recomendador de inversiones.

En particular, permite:

- Validar la calidad de los datos.
- Analizar la volatilidad de los activos.
- Observar tendencias relevantes para la estimación de retornos esperados.
- Apoyar la selección del universo de acciones.

Esto es consistente con los requerimientos del proyecto, donde el comportamiento histórico de los activos impacta directamente en la construcción de portafolios y en la toma de decisiones de inversión.

Limitaciones

A pesar de sus ventajas, el visualizador presenta algunas limitaciones:

- Dependencia de la calidad de los datos disponibles.
- Capacidad limitada para análisis en tiempo real.
- Enfoque principalmente exploratorio, no predictivo.

Estas limitaciones serán abordadas en etapas futuras del proyecto mediante el desarrollo de modelos más avanzados.

Conclusiones

El desarrollo del visualizador en Docker permitió facilitar significativamente el análisis exploratorio del dataset, entregando herramientas visuales que apoyan la comprensión del comportamiento de los activos financieros.

Además, el uso de Docker asegura que el sistema sea reproducible y escalable, lo que resulta clave para futuras etapas del proyecto, donde se integrarán modelos de optimización y recomendación de portafolios.

En este sentido, el visualizador constituye una herramienta fundamental de apoyo en el proceso de toma de decisiones y en la validación de los supuestos del modelo.

**ANEXO N°3: DECLARACIÓN DE USO DE IA EN ESTE INFORME Y
PRESENTACIÓN ASOCIADA**

Grupo:_____ 13 _____

¿Hicieron uso de herramientas de IA en su trabajo para este informe y/o presentación?

SI ___ X ___ NO _____

¿Cuáles de las siguientes alternativas mejor describe el uso que hicieron de IA (puede ser más de una)

- X Apoyo a la redacción, ortografía, estructura gramatical, etc., de los documentos.
- X Apoyo al análisis de datos e información asociada al problema.
 - Búsqueda y/o filtro de referencias, contenidos web, literatura, etc., relevante al proyecto.
 - Apoyo para el desarrollo de modelos asociados al proyecto.
- X Apoyo en el desarrollo de código computacional necesario para el proyecto
 - Apoyo en el análisis de resultados (por ejemplo, de distintas corridas computacionales, tendencias de predicciones, etc.)
- x Apoyo para construir figuras, diagramas, etc.
 - Apoyo para obtener conclusiones a partir de los análisis de resultados.
- X Otro, especificar: Generación de un entorno Docker para visualización interactiva de datos financieros.

Herramientas utilizadas: Claude (principalmente para generación de código, estructuración del visualizador y apoyo en redacción).

Reflexión sobre el uso de IA:

La inteligencia artificial fue utilizada como una herramienta de apoyo relevante en el desarrollo del proyecto, particularmente en la generación del visualizador de datos financieros implementado en un entorno Docker. A través de IA, se logró estructurar de manera eficiente un sistema capaz de procesar y visualizar información histórica de acciones, facilitando el análisis exploratorio del dataset entregado.

En específico, la IA permitió acelerar el desarrollo de código, proponer estructuras de implementación y sugerir formas de visualización adecuadas para analizar tendencias, retornos y comportamientos históricos de los activos. Sin embargo, todas las soluciones generadas fueron revisadas, ajustadas y validadas por el equipo, asegurando su correcto funcionamiento y coherencia con los objetivos del proyecto.

En este sentido, la IA no reemplazó el trabajo del grupo, sino que actuó como un apoyo que permitió aumentar la productividad y enfocarse en aspectos más relevantes del análisis, como la interpretación de resultados y la formulación del problema de optimización. Tal como se señala en los lineamientos del curso, el uso de IA fue realizado de manera responsable y crítica, evitando depender ciegamente de sus resultados y manteniendo el control sobre las decisiones del proyecto.

Esta declaración debe ser firmada por todos los integrantes del grupo:

Patricio Andres Acevedo Flores



Benjamín Alonso Cano Araya



Matías Benjamín Catalán Contreras



Gaspar Ten Berg Yunusic



Diego Benjamín Villalobos Michea




TABLE OF CONTENTS

Anexo N°1: Análisis de datos	ii
Descripción de la Fuente de Datos	ii
Clasificación Sectorial	iv
Capitalización de Mercado	vi
Niveles de Filtrado	vii
Universo Final: 636 Acciones	ix
Implicaciones para el Modelo de Optimización	xiii
Conclusión	xv
 Anexo N°2: Visualizador de Datos	 xvi
Visualizador de Datos en Entorno Docker (https://github.com/Psacevedo/Capstone)	xvi
Introducción	xvi
Objetivo del Visualizador	xvi
Descripción General del Sistema	xvii
Flujo de Funcionamiento	xvii
Funcionalidades del Visualizador	xviii
Uso de Docker	xviii
Interfaz del Visualizador	xix
Relación con el Problema de Optimización	xxi
Limitaciones	xxii
Conclusiones	xxii
 Anexo N°3: Declaración de uso de IA en este informe y presentación asociada	 xxiii
 LIST OF FIGURES	 xxvii
 LIST OF TABLES	 xxviii
 ABSTRACT	 xxix

RESUMEN	xxx
1. INTRODUCCIÓN	1
2. DESCRIPCIÓN DEL PROBLEMA	2
2.1. Contexto y motivación	2
2.2. Descripción del sistema FinPUC	2
2.2.1. Ciclo operacional semanal	2
2.2.2. Perfiles de riesgo	3
2.3. Formulación del problema	4
2.3.1. Decisión principal	4
2.3.2. Objetivos	4
2.3.3. Restricciones	5
2.4. Datos disponibles	5
2.4.1. Fuente y estructura	5
2.4.2. Clasificación sectorial	7
2.5. Proceso de filtrado del universo de acciones	7
2.6. Análisis del universo final	9
3. REVISIÓN BIBLIOGRÁFICA	10
4. DISCUSIÓN METODOLÓGICA	12
5. PASOS FUTUROS	16
Plan de Trabajo	16
Fase 1: Definición y Modelamiento (completada)	16
Fase 2: Implementación Inicial (9 abril – 10 mayo)	16
Fase 3: Evaluación y Mejoras (12 mayo – 15 junio)	17
Fase 4: Cierre y Entrega Final (13 – 26 junio)	18
6. CONCLUSIONES	19
REFERENCES	21

LIST OF FIGURES

0.1	Vista general del visualizador de acciones	xix
0.2	Acciones disponibles del sector de servicios financieros	xix
0.3	Ejemplo de acción Visa Inc	xx
0.4	Visualizador gráfico del precio de cierre semanal de Visa Inc	xx
0.5	Gráfico de volumen y dividendos de Visa Inc	xxi
2.1	Flujo del ciclo semanal del sistema recomendador FinPUC. Elaboración propia.	3
5.1	Adaptación visual de la Carta Gantt del proyecto, generada con apoyo de inteligencia artificial a partir de los datos del plan de trabajo del equipo. La versión original no se incluye directamente en el informe debido a su extensión horizontal, que impide su visualización completa en una sola página.	18

LIST OF TABLES

0.1	Distribución sectorial del universo completo con datos válidos	v
0.2	Razones de exclusión del universo final F5	viii
0.3	Estadísticas por sector — universo F5 (636 tickers)	x
0.4	Top subsectores por sector en el universo F5	xi
0.5	Top 5 Technology (por capitalización de mercado)	xii
0.6	Top 5 Healthcare (por capitalización de mercado)	xii
0.7	Top 5 Financial Services (por capitalización de mercado)	xii
0.8	Top 5 Consumer Defensive + Utilities (perfiles conservadores)	xiii
0.9	Conexión entre parámetros del modelo y fuente de datos	xiii
0.10	Sub-universos recomendados por perfil de riesgo	xiv
2.1	Perfiles de riesgo y tolerancia de pérdida de FinPUC.	4
2.2	Estructura de los archivos de datos históricos por ticker.	6
2.3	Distribución sectorial del universo crudo con datos válidos (1.165 tickers).	7
2.4	Cascada de filtros aplicados al universo de acciones.	8
2.5	Estadísticas por sector en el universo final F5 (636 acciones).	9

ABSTRACT

This work addresses the portfolio optimization problem for FinPUC, a fictional financial advisory platform that generates personalized investment recommendations for clients across five risk profiles: very conservative, conservative, neutral, risky, and very risky. The system operates on a weekly cycle in which optimal portfolios are recommended, balancing each client's expected return against the commission-based utility generated for the firm. The core decision consists of determining the fraction of capital to allocate to each stock within a universe of 636 assets, filtered by liquidity, market capitalization, data availability, and reasonable volatility.

The problem is formulated as a multi-objective stochastic nonlinear program, where expected portfolio return and FinPUC's utility are simultaneously maximized, subject to risk constraints measured by Conditional Value-at-Risk (CVaR) and a maximum computation time of 10 seconds per recommendation. A literature review covering the foundational models of portfolio optimization was conducted, including Markowitz mean-variance theory (1952), the Capital Asset Pricing Model (Sharpe, 1964), the Fama-French multi-factor model (1993), and the Bayesian Black-Litterman approach (1992). A hybrid model is proposed that combines the robustness of the Black-Litterman optimizer with Monte Carlo scenario generation and asset rotation constraints, aiming to deliver stable, personalized portfolios under real-time computational restrictions.

Keywords: portfolio optimization, Black-Litterman, Markowitz, CVaR, risk profiles, recommendation system, multi-objective optimization.

RESUMEN

El presente trabajo aborda el problema de optimización de portafolios de inversión para FinPUC, una plataforma ficticia de asesoría financiera que genera recomendaciones personalizadas para clientes con cinco perfiles de riesgo: muy conservador, conservador, neutro, arriesgado y muy arriesgado. El sistema opera bajo un ciclo semanal en el que se recomiendan portafolios óptimos considerando tanto el retorno esperado del cliente como la utilidad generada por comisiones para la empresa. La decisión central consiste en determinar la fracción del capital a asignar a cada acción de un universo de 636 activos, filtrados según criterios de liquidez, capitalización bursátil, historia disponible y volatilidad razonable.

El problema se enmarca como un programa no lineal multi-objetivo estocástico, donde se maximiza simultáneamente el retorno esperado del portafolio y la utilidad de FinPUC, sujeto a restricciones de riesgo medidas mediante el Valor en Riesgo Condicional (CVaR) y a un tiempo de cómputo máximo de 10 segundos por recomendación. Se realizó una revisión bibliográfica que cubre los modelos fundamentales de optimización de portafolios, incluyendo la teoría media-varianza de Markowitz (1952), el CAPM de Sharpe (1964), el modelo multifactorial de Fama y French (1993) y el enfoque bayesiano de Black-Litterman (1992). Se propone un modelo híbrido que combina la robustez del optimizador Black-Litterman con generación de escenarios mediante Monte Carlo y restricciones de rotación de activos, con el objetivo de entregar portafolios estables y personalizados dentro de las restricciones computacionales del sistema.

Palabras Claves: optimización de portafolios, Black-Litterman, Markowitz, CVaR, perfiles de riesgo, sistema recomendador, optimización multi-objetivo.

1. INTRODUCCIÓN

La gestión eficiente del capital es uno de los problemas fundamentales de las finanzas modernas. El problema de optimización de portafolios, formalizado por [Markowitz \(1952\)](#), establece los fundamentos matemáticos de la diversificación y define la frontera eficiente como el conjunto de portafolios óptimos en el espacio riesgo-retorno. En la práctica, el universo de activos puede comprender cientos o miles de instrumentos, los clientes presentan perfiles de riesgo heterogéneos y las condiciones del mercado evolucionan continuamente. En el contexto de sistemas automatizados de asesoría financiera, las recomendaciones deben generarse con rapidez y de forma personalizada ([D'Acunto, Prabhala, & Rossi, 2019](#)), democratizando el acceso a estrategias antes reservadas a asesores especializados. El presente informe aborda la optimización de portafolios en el marco de FinPUC, una plataforma ficticia de recomendación de inversiones del curso Taller de Investigación Operativa de la Pontificia Universidad Católica de Chile. FinPUC genera recomendaciones semanales para clientes clasificados en cinco perfiles de riesgo: muy conservador, conservador, neutro, arriesgado y muy arriesgado. La decisión central consiste en determinar, para cada cliente y cada semana, la fracción del capital a asignar a cada acción del universo disponible. El problema tiene una doble dimensión: maximizar el retorno esperado del cliente y maximizar la utilidad de FinPUC por comisiones de transacción, sujeto a restricciones de riesgo mediante CVaR ([Rockafellar & Uryasev, 2000](#)) y un límite de 10 segundos de cómputo por recomendación. El universo comprende 636 acciones del mercado norteamericano, seleccionadas de 1.406 *tickers* tras filtros de liquidez, capitalización, historia y volatilidad. Se revisaron los modelos fundamentales de optimización: el CAPM ([Sharpe, 1964](#)), el modelo multifactorial ([Fama & French, 1993](#)) y el enfoque bayesiano de Black-Litterman ([He & Litterman, 1999](#)). A partir de esta revisión, se propone un modelo híbrido que utiliza Black-Litterman como núcleo optimizador, complementado con simulación de Monte Carlo y restricciones de rotación de activos.

2. DESCRIPCIÓN DETALLADA DEL PROBLEMA

2.1. Contexto y motivación

La gestión de inversiones enfrenta hoy una realidad operacional desafiante: los inversionistas individuales deben tomar decisiones complejas sobre cómo distribuir su capital entre un universo amplio de activos, considerando su tolerancia al riesgo, el horizonte de inversión y las condiciones cambiantes del mercado. La consolidación de plataformas de asesoría financiera automatizada ha generado una demanda creciente de sistemas capaces de producir recomendaciones personalizadas, fundamentadas y actualizadas de forma periódica (D'Acunto et al., 2019).

FinPUC es una plataforma ficticia de recomendación de inversiones diseñada para atender a clientes del mercado accionario norteamericano, clasificados según su perfil de riesgo. El sistema debe generar semanalmente una cartera óptima para cada cliente, maximizando su retorno esperado sin exceder el umbral de riesgo asociado a su perfil, y al mismo tiempo maximizando la utilidad de la empresa derivada de las comisiones por transacción. La complejidad del problema surge de la necesidad de equilibrar estos dos objetivos potencialmente contrapuestos, dentro de una restricción operacional de tiempo de cómputo que no supere los 10 segundos por recomendación.

2.2. Descripción del sistema FinPUC

2.2.1. Ciclo operacional semanal

El sistema opera bajo un ciclo semanal iniciado cada lunes. En cada iteración, el optimizador genera una recomendación de portafolio óptimo para cada cliente según su perfil de riesgo. El cliente evalúa la recomendación y puede aceptarla o rechazarla. Si la acepta, con probabilidad $P_2(x)$, se ejecuta la transacción correspondiente y la empresa cobra una comisión proporcional $k\%$ sobre el monto transado. Si rechaza, el cliente mantiene su portafolio actual. Al cierre de la semana, el capital del cliente evoluciona en función de

los precios de cierre y los dividendos percibidos. Si la pérdida acumulada supera el umbral de tolerancia del perfil, el cliente puede abandonar la plataforma con probabilidad $P_1(x)$. El ciclo se reinicia el lunes siguiente con los datos de mercado actualizados.

La Figura 2.1 ilustra este flujo de forma esquemática.



Figure 2.1. Flujo del ciclo semanal del sistema recomendador FinPUC. Elaboración propia.

2.2.2. Perfiles de riesgo

FinPUC clasifica a sus clientes en cinco perfiles de riesgo, caracterizados por un umbral de pérdida máxima tolerable α_p sobre el capital invertido. La Tabla 2.1 describe cada perfil y su tolerancia asociada.

Table 2.1. Perfiles de riesgo y tolerancia de pérdida de FinPUC.

Perfil	Descripción	Tolerancia α_p
Muy conservador	No admite pérdidas sobre el capital	0%
Conservador	Tolera pérdidas mínimas	5%
Neutro	Tolerancia moderada al riesgo	15%
Arriesgado	Acepta pérdidas significativas	30%
Muy arriesgado	Alta tolerancia al riesgo	40%

2.3. Formulación del problema

2.3.1. Decisión principal

La decisión central del sistema consiste en determinar, para cada cliente c y cada semana t , el vector de pesos $\mathbf{w}_t^c = (w_{1,t}^c, \dots, w_{n,t}^c)$ que representa la fracción del capital total asignada a cada acción i del universo disponible $\mathcal{S}$. Formalmente:

$$w_{i,t}^c \geq 0, \quad \sum_{i \in \mathcal{S}} w_{i,t}^c = 1.$$

2.3.2. Objetivos

El problema posee una estructura multi-objetivo con dos funciones a optimizar simultáneamente:

(i) **Maximizar el retorno esperado del portafolio del cliente:**

$$\max_{\mathbf{w}} \mathbb{E} \left[\sum_{i \in \mathcal{S}} w_i \cdot r_i \right]$$

donde r_i es el retorno aleatorio de la acción i durante la semana siguiente.

- (ii) **Maximizar la utilidad de FinPUC** derivada de las comisiones generadas por los cambios de portafolio recomendados, ponderada por la probabilidad de aceptación del cliente $P_2(\mathbf{w})$.

2.3.3. Restricciones

Las principales restricciones del modelo son:

- **Restricción de riesgo:** el riesgo del portafolio, medido mediante el Valor en Riesgo Condicional (CVaR) al nivel de confianza correspondiente al perfil p , no puede superar el umbral α_p :

$$\text{CVaR}_\beta(\mathbf{w}) \leq \alpha_p.$$

El CVaR, propuesto por [Rockafellar and Uryasev \(2000\)](#), es una medida de riesgo coherente que cuantifica la pérdida esperada en los peores escenarios.

- **Restricción de tiempo de cómputo:** el sistema debe generar la recomendación en a lo más 10 segundos, lo que condiciona directamente el tamaño del universo de activos y la complejidad del modelo de optimización.
- **No venta en corto:** $w_{i,t} \geq 0$ para todo i .
- **Presupuesto completo:** $\sum_i w_{i,t} = 1$.

2.4. Datos disponibles

2.4.1. Fuente y estructura

Los datos históricos provienen del directorio `Data/Historical_Stocks/` del repositorio del proyecto, descargados mediante la librería `yfinance` de Yahoo Finance. El directorio contiene 1.407 archivos: 1.406 archivos CSV individuales con el formato `stock_return-<TICKER>.csv` y un archivo de metadatos `stocks_info.txt` con

información fundamental por ticker (sector, industria, capitalización de mercado, entre otros).

Cada archivo CSV contiene precios diarios ajustados con las columnas descritas en la Tabla 2.2.

Table 2.2. Estructura de los archivos de datos históricos por ticker.

Columna	Tipo	Descripción
Date	fecha	Fecha de cierre (zona horaria US/Eastern)
Open	flotante	Precio de apertura ajustado por splits
High	flotante	Precio máximo del día
Low	flotante	Precio mínimo del día
Close	flotante	Precio de cierre ajustado por splits
Volume	entero	Volumen de transacciones
Dividends	flotante	Dividendo distribuido ese día (USD/acción)
Stock Splits	flotante	Factor de split (0 si no hubo split)

Cabe destacar que los precios están ajustados hacia atrás por splits de acciones, pero no por dividendos. Los dividendos se registran explícitamente en la columna `Dividends` y se utilizan directamente para alimentar la *caja chica* del modelo de optimización, que acumula los flujos de dividendos durante el ciclo semanal.

2.4.2. Clasificación sectorial

Table 2.3. Distribución sectorial del universo crudo con datos válidos (1.165 tickers).

Sector	Tickers	% del total
Financial Services	716	61.4%
Technology	81	6.9%
Industrials	74	6.4%
Healthcare	64	5.5%
Consumer Cyclical	59	5.1%
Consumer Defensive	38	3.3%
Real Estate	32	2.7%
Utilities	31	2.7%
Basic Materials	22	1.9%
Energy	21	1.8%
Communication Services	20	1.7%
Unknown	8	0.7%
Total	1.165	100%

2.5. Proceso de filtrado del universo de acciones

Para obtener un universo operacional líquido, estable, representativo y estadísticamente válido para el optimizador, se aplicaron cinco niveles de filtrado en cascada sobre el universo crudo de 1.406 tickers. El objetivo de esta cascada es asegurar que los activos del portafolio tengan liquidez suficiente, historia histórica adecuada para la estimación de parámetros estadísticos, y que sus retornos sean representativos del mercado.

La Tabla 2.4 resume los criterios y resultados de cada filtro.

Table 2.4. Cascada de filtros aplicados al universo de acciones.

Nivel	Criterio	Tickers	Retenidos
F0	Universo crudo	1.406	100%
F1	Precio ≥ 5 USD, historia ≥ 5 años	883	62.8%
F2	Excluye <i>shell companies</i> y sector desconocido	881	62.7%
F3	Capitalización de mercado ≥ 2 B USD	686	48.8%
F4	Historia ≥ 10 años (≥ 2.500 registros diarios)	641	45.6%
F5	$5\% \leq \hat{\sigma}_{\text{ann}} \leq 100\%$	636	45.2%

Las principales razones de exclusión del universo crudo fueron: historial insuficiente (menos de 10 años, 47.9% de los excluidos), capitalización de mercado inferior a 2B USD (43.9%), precio de cierre inferior a 5 USD (7.0%) y volatilidad fuera del rango aceptable (0.9%). Estos criterios responden a justificaciones específicas: el filtro de liquidez básica (**F1**) excluye *penny stocks* e instrumentos ilíquidos sin historia suficiente para estimar parámetros estadísticos confiables. El filtro de calidad de clasificación (**F2**) elimina *shell companies* (principalmente SPACs) que no tienen operaciones reales ni retornos representativos, así como tickers sin sector asignado que no pueden incluirse en análisis sectoriales. El filtro de *large/mega cap* (**F3**) reconoce que las empresas de alta capitalización presentan mayor liquidez, menores *spreads* bid-ask y sus precios reflejan mejor la información pública disponible, condición implícita del modelo de Markowitz (Markowitz, 1952). El filtro de historia suficiente (**F4**) se fundamenta en que la estimación robusta de matrices de covarianza requiere una razón datos/variables adecuada; con 10 años de historia se captura al menos un ciclo económico completo, incluyendo las crisis de 2008-09 y 2020. Finalmente, el filtro de volatilidad razonable (**F5**) excluye volatilidades anualizadas inferiores al 5%, que indican datos incorrectos o instrumentos no bursátiles, y superiores al 100%, que corresponden a activos especulativos extremos incompatibles con el modelo de media-varianza.

2.6. Análisis del universo final

El universo operacional resultante (F5) comprende 636 acciones del mercado norteamericano. La Tabla 2.5 presenta las estadísticas agregadas por sector: volatilidad anualizada promedio, tasa de crecimiento anual compuesto (CAGR) histórica y proporción de acciones que distribuyen dividendos.

Table 2.5. Estadísticas por sector en el universo final F5 (636 acciones).

Sector	N	$\bar{\sigma}_{\text{ann}}$	CAGR prom.	% con dividendos
Financial Services	237	37.5%	10.6%	95%
Technology	73	44.6%	16.5%	70%
Industrials	64	34.6%	13.2%	95%
Healthcare	59	37.3%	13.4%	66%
Consumer Cyclical	55	41.2%	13.9%	78%
Consumer Defensive	33	29.3%	11.4%	97%
Utilities	29	24.7%	9.7%	100%
Real Estate	29	34.8%	11.3%	93%
Energy	20	37.5%	11.5%	100%
Basic Materials	19	35.1%	11.5%	100%
Communication Services	18	36.7%	14.6%	78%
Total	636	36.6%	11.9%	90%

3. REVISIÓN BIBLIOGRÁFICA

La literatura en optimización de portafolios ha evolucionado desde enfoques clásicos hacia modelos que buscan mayor robustez frente a la incertidumbre y errores de estimación. El punto de partida corresponde al modelo de media-varianza de Markowitz (1952), el cual establece un marco para analizar la relación entre retorno y riesgo considerando la covarianza entre activos. Su principal aporte radica en mostrar cómo la estructura de correlaciones permite construir portafolios más eficientes, sentando las bases de la diversificación como principio fundamental en la gestión de inversiones (Markowitz, 1952).

No obstante, en aplicaciones con universos amplios de activos, este enfoque presenta dificultades relevantes. En particular, la estimación de los retornos esperados y de la matriz de covarianza introduce una alta sensibilidad en los resultados, lo que puede derivar en portafolios poco estables. Esta problemática ha motivado el desarrollo de modelos orientados a mejorar la estimación de retornos y reducir la dependencia de parámetros altamente inciertos.

En este contexto, el Capital Asset Pricing Model (CAPM) propone una simplificación al modelar el retorno esperado en función de un único factor sistemático asociado al mercado (Sharpe, 1964). Si bien este enfoque reduce la complejidad del problema de estimación, su capacidad explicativa es limitada debido a supuestos restrictivos, tales como la existencia de mercados perfectamente eficientes, inversionistas con expectativas homogéneas y la posibilidad de endeudamiento a tasa libre de riesgo. Como extensión, los modelos multifactoriales, como el propuesto por Fama y French (1993), incorporan factores adicionales que permiten capturar patrones empíricos en los retornos, mejorando su capacidad descriptiva en los mercados reales (Fama & French, 1993).

Por otra parte, una de las principales limitaciones de los enfoques anteriores es su dependencia de estimaciones puntuales, lo que introduce inestabilidad en los portafolios

resultantes. Para abordar este problema, el modelo de Black-Litterman propone un enfoque bayesiano que combina retornos de equilibrio con información adicional, permitiendo obtener estimaciones más estables y coherentes, evitando soluciones extremas. (He & Litterman, 1999).

En paralelo, la literatura ha avanzado hacia medidas de riesgo que permiten capturar de mejor forma el comportamiento de los retornos en escenarios adversos. En este sentido, el Conditional Value at Risk (CVaR) se posiciona como una alternativa a la varianza, al enfocarse en la pérdida esperada en la cola de la distribución. Esta medida presenta propiedades matemáticas favorables que facilitan su incorporación en modelos de optimización y permiten una mejor representación del riesgo en contextos financieros (Rockafellar & Uryasev, 2000).

En presencia de incertidumbre, los enfoques basados en simulación permiten complementar estos modelos al generar escenarios posibles de retornos. En particular, los métodos de Monte Carlo han sido utilizados para representar la variabilidad del mercado y evaluar el desempeño de portafolios bajo distintas condiciones, constituyendo una herramienta relevante en el análisis de riesgo y toma de decisiones (Glasserman, 2004).

Una extensión relevante de los modelos clásicos consiste en incorporar fricciones de mercado, tales como costos de transacción o comisiones asociadas al rebalanceo de portafolios. En este contexto, el problema de optimización deja de centrarse únicamente en la maximización del retorno esperado, pasando a considerar un trade-off entre los beneficios de ajustar el portafolio y los costos asociados a dichas decisiones. Este tipo de formulaciones permite construir funciones objetivo más realistas, donde múltiples componentes son considerados simultáneamente, reflejando de mejor forma las condiciones en las que operan los mercados financieros. En particular, este enfoque ha sido utilizado para modelar funciones de valor que integran tanto el retorno esperado y los costos de transacción. (Myers, 2009).

4. DISCUSIÓN METODOLÓGICA

El problema abordado en este trabajo consiste en diseñar un sistema de recomendación de portafolios para FinPUC, cuyo objetivo es maximizar simultáneamente el retorno esperado de los inversionistas y la utilidad de la empresa. Este problema presenta desafíos asociados a la estimación de retornos, la representación del riesgo y el comportamiento del cliente. En este contexto, se analizan distintas metodologías propuestas en la literatura, con el fin de evaluar sus ventajas y limitaciones, y construir a partir de ellas un enfoque integrado.

El modelo de media-varianza de Markowitz constituye la base conceptual del problema, al plantear una relación explícita entre retorno esperado y riesgo. En su forma clásica, este modelo puede representarse como:

$$\max_w w^\top \mu - \lambda w^\top \Sigma w \quad (4.1)$$

donde w corresponde a los pesos del portafolio, μ a los retornos esperados y Σ a la matriz de covarianza. Su principal ventaja radica en su simplicidad y en la capacidad de capturar los beneficios de la diversificación. Sin embargo, presenta una alta sensibilidad a errores en la estimación de los retornos, lo que puede generar portafolios inestables, especialmente en contextos con un gran número de activos.

Para abordar esta limitación, se consideran modelos de estimación de retornos más estructurados, como el modelo multifactorial de Fama y French, el cual permite representar los retornos como función de distintos factores de riesgo:

$$r_i = \alpha_i + \beta_{i1}f_1 + \beta_{i2}f_2 + \beta_{i3}f_3 \quad (4.2)$$

Este enfoque captura patrones sistemáticos en los retornos. No obstante, si bien mejora la estimación de de estos, no resuelve directamente el problema de asignación óptima del portafolio.

En esta línea, se incorpora el modelo de Black-Litterman, el cual permite combinar información de mercado con estimaciones adicionales, generando retornos esperados más

estables y coherentes. En particular, este modelo parte de un vector de retornos de equilibrio implícitos en el mercado, al cual se le incorporan “vistas” o expectativas adicionales, obteniendo una estimación ajustada de la forma:

$$\mu_{BL} = \text{combinación de retornos de equilibrio y estimaciones adicionales} \quad (4.3)$$

La principal ventaja de este enfoque es que reduce la inestabilidad característica del modelo de media-varianza, evitando soluciones extremas y mejorando la diversificación de los portafolios. En este trabajo, el modelo de Black-Litterman se adopta como la base para la estimación de retornos, sobre la cual se construye la formulación completa del problema. De esta forma, los retornos esperados utilizados en la optimización corresponden a μ_{BL} , lo que permite incorporar de manera implícita tanto la información histórica como estructuras más estables provenientes del mercado.

En cuanto a la medición del riesgo, se adopta el Conditional Value at Risk (CVaR), el cual permite capturar la pérdida esperada en escenarios adversos. A diferencia de la varianza, el CVaR se enfoca en las colas de la distribución, lo que resulta consistente con la existencia de perfiles de riesgo diferenciados entre los inversionistas. En este contexto, se incorporan restricciones del tipo:

$$\text{CVaR}_\beta(w) \leq \alpha_p \quad (4.4)$$

donde α_p representa el nivel de pérdida tolerado. Si bien esta medida permite una mejor representación del riesgo, su implementación requiere trabajar con escenarios, lo que incrementa la dimensión del problema.

Para representar la incertidumbre en los retornos, se utiliza simulación de Monte Carlo, la cual permite generar múltiples escenarios futuros y evaluar el desempeño de los portafolios bajo distintas condiciones de mercado. Esta herramienta resulta especialmente útil para complementar el uso de CVaR. Sin embargo, su principal desventaja es el costo computacional, por lo que en este trabajo las simulaciones son precomputadas a partir de datos históricos, permitiendo cumplir con las restricciones de tiempo del sistema.

Adicionalmente, el modelo incorpora el comportamiento del cliente mediante funciones de probabilidad. En particular, la probabilidad de abandono se modela como:

$$P_1(x_1) = \frac{1}{1 + e^{-(x_1 - \hat{x}_1)}} \quad (4.5)$$

Donde x_1 corresponde a la pérdida actual y $\hat{x}_1$ corresponde a la máxima pérdida esperada, mientras que la probabilidad de aceptar una nueva recomendación se modela como:

$$P_2(x_2) = \frac{1}{1 + e^{-(x_2 - \hat{x}_2)}} \quad (4.6)$$

Donde x_2 corresponde a la tasa ofertada en escenario neutro y $\hat{x}_2$ corresponde a la máxima pérdida esperada. Estas funciones permiten capturar la toma de decisiones del cliente de forma probabilística. No obstante, su calibración depende de supuestos sobre el comportamiento del usuario, lo que introduce una fuente adicional de incertidumbre.

A partir del análisis anterior, se observa que ninguno de los modelos considerados permite abordar de manera completa el problema. En particular, los enfoques clásicos presentan limitaciones en la estimación de retornos y en la representación del riesgo, mientras que otros modelos incorporan mejoras parciales pero no capturan elementos clave como el comportamiento del cliente o la existencia de comisiones. En este contexto, se opta por un enfoque híbrido que integra distintas metodologías, aprovechando sus fortalezas y mitigando sus limitaciones.

En particular, el modelo propuesto combina el enfoque de Black-Litterman para la estimación de retornos con la estructura de optimización del modelo de media-varianza de Markowitz. De esta forma, los retornos esperados utilizados en la optimización corresponden a μ_{BL} , mientras que la asignación de los pesos del portafolio se determina resolviendo un problema de optimización del tipo:

$$\max_w w^\top \mu_{BL} - \lambda w^\top \Sigma w \quad (4.7)$$

Esto permite aprovechar la estabilidad en la estimación de retornos proporcionada por Black-Litterman junto con la capacidad de Markowitz para construir portafolios eficientes.

Para representar la incertidumbre en los retornos, se utiliza simulación de Monte Carlo, la cual permite generar múltiples escenarios futuros y construir una distribución de posibles resultados del portafolio. A diferencia de enfoques determinísticos, este método permite capturar de forma explícita la variabilidad del mercado.

A partir de esta distribución simulada, se definen escenarios representativos (desfavorable, neutro y favorable) mediante percentiles de la distribución de retornos, permitiendo evaluar el desempeño del portafolio bajo distintas condiciones de mercado. Este enfoque permite además estimar métricas de riesgo como el CVaR y analizar la toma de decisiones del cliente en función de los retornos proyectados.

Bajo este enfoque integrado, el problema se formula como una optimización multiobjetivo, en la cual se busca maximizar simultáneamente el retorno del cliente y la utilidad de la empresa. Este tipo de problemas se caracteriza por la existencia de objetivos en conflicto, lo que implica que no existe una única solución óptima, sino un conjunto de soluciones eficientes de Pareto (Deb, 2001). En la práctica, esta formulación se aborda mediante una función objetivo escalarizada:

$$\max_w \lambda f_1(w) + (1 - \lambda) f_2(w) \quad (4.8)$$

donde $f_1(w) = w^\top \mu_{BL}$ representa el retorno esperado del portafolio, mientras que $f_2(w)$ corresponde a la utilidad de la empresa, asociada a las comisiones generadas por las transacciones y al comportamiento del cliente, pudiendo representarse como:

$$f_2(w) \propto k \cdot P_2(x_2) \cdot (1 - P_1(x_1)) \quad (4.9)$$

Esta formulación permite representar explícitamente el trade-off entre el retorno del inversionista y la utilidad de la empresa, controlado mediante el parámetro λ , donde su elección es una decisión de diseño del modelo, ya que determina la importancia relativa de cada objetivo dentro del proceso de optimización. En conjunto, esta formulación permite integrar de manera coherente los distintos componentes del problema, combinando estimación robusta de retornos, optimización de portafolios, simulación de escenarios y modelación del comportamiento del cliente dentro de un único marco de decisión.

5. PASOS FUTUROS

Plan de Trabajo

El desarrollo del proyecto se estructura en cuatro fases secuenciales que abarcan desde la entrega del presente informe hasta el cierre del curso en junio de 2026. A continuación se describen las etapas planificadas, cuya distribución temporal se detalla en la Carta Gantt adjunta.

Fase 1: Definición y Modelamiento (completada)

Esta fase comprendió la comprensión del problema y la definición del alcance del sistema, la revisión bibliográfica sobre optimización de portafolios, la formalización de los perfiles de riesgo y las funciones de abandono y aceptación $P_1(x)$ y $P_2(x)$, y el diseño del modelo matemático base. Esta fase concluyó con la entrega del presente informe el 8 de abril de 2026.

Fase 2: Implementación Inicial (9 abril – 10 mayo)

La segunda fase contempla tres tareas paralelas que se desarrollarán a partir del 9 de abril. En primer lugar, se realizará la limpieza y análisis exploratorio de datos, que incluye el cálculo de estadísticas descriptivas, la detección de anomalías y la validación definitiva del universo de 636 acciones. Adicionalmente, se analizará la distribución estadística de los retornos históricos por acción y por sector, evaluando la presencia de asimetría y colas gruesas. Este análisis informará los supuestos distribucionales del modelo de simulación de Monte Carlo, permitiendo generar proyecciones de escenarios más realistas que los obtenidos bajo el supuesto de normalidad. Esta tarea tiene una duración estimada de 14 días.

En paralelo, se implementará el algoritmo de optimización Media-Varianza de Markowitz como modelo base, incorporando las restricciones de riesgo asociadas a cada uno de los cinco perfiles de cliente. Esta implementación servirá como punto de referencia para evaluar el desempeño del modelo Black-Litterman que se desarrollará a continuación.

A partir del 14 de abril se iniciará la implementación del modelo Black-Litterman con generación de escenarios mediante simulación de Monte Carlo precomputada. Esta es la etapa de mayor complejidad técnica del proyecto, pues requiere calibrar los parámetros τ y Ω , construir los *views* de mercado y garantizar que las consultas se resuelvan en menos de 10 segundos mediante el uso de caché.

La fase concluye con la Presentación 2 y la entrega del Informe 2 el 5 de mayo de 2026, instancia en que se espera contar con el modelo implementado y resultados preliminares.

Fase 3: Evaluación y Mejoras (12 mayo – 15 junio)

La tercera fase está orientada a la validación y refinamiento del sistema. Se llevará a cabo una evaluación comparativa del desempeño histórico del portafolio recomendado para cada perfil de riesgo, utilizando los KPIs definidos: Sharpe Ratio, tasa de pérdida excedida, tasa de cumplimiento del perfil y rentabilidad esperada.

Posteriormente, se incorporará la dinámica del cliente al sistema, implementando las probabilidades $P_1(x)$ y $P_2(x)$ que modelan el abandono de la plataforma y la aceptación de recomendaciones semanales, respectivamente. Las comisiones $k\%$ se integrarán como restricciones de rotación para penalizar cambios innecesarios de portafolio.

Finalmente, se realizará la optimización computacional del sistema completo, con el objetivo de garantizar tiempos de respuesta consistentemente inferiores a los 10 segundos requeridos por FinPUC.

Fase 4: Cierre y Entrega Final (13 – 26 junio)

La fase final contempla la preparación de la Presentación Final, la redacción del Informe Final y una ronda de revisión y correcciones. La entrega final del proyecto está programada para el 26 de junio de 2026.

La Figura 5.1 presenta una adaptación de la Carta Gantt con la planificación completa del proyecto.




Figure 5.1. Adaptación visual de la Carta Gantt del proyecto, generada con apoyo de inteligencia artificial a partir de los datos del plan de trabajo del equipo. La versión original no se incluye directamente en el informe debido a su extensión horizontal, que impide su visualización completa en una sola página.

6. CONCLUSIONES

En el informe se sentaron las bases metodológicas, bibliográficas y formales para el desarrollo del sistema recomendador de portafolios. A partir de la formulación del problema no lineal multiobjetivo estocástico, se pudo identificar elementos esenciales para su diseño; la decisión de la asignación del capital, los objetivos opuestos del máximo retorno para el cliente y la máxima utilidad para FinPUC, así como también las restricciones de riesgo diferenciadas según el perfil.

Mediante el proceso de filtrado del universo de acciones permitió una limpieza significativa para el posterior análisis de datos, reduciendo el conjunto de 1.406 tickers a un universo de 636 activos, aplicando criterios de liquidez, capitalización del mercado, historial y volatilidad razonable. Esto permite un sentido estadístico con menor sesgo en sus estimaciones, generando datos más representativos, los datos presentan una mediana de 26 años de historia y cobertura del 90% de la distribución de los dividendos. Tras el análisis sectoriales se revelaron patrones importantes para la diferenciación según el perfil de riesgo: en primer lugar los sectores como Utilities y Consumer Defensive son candidatos adecuados para perfiles conservadores, mientras que Technology, con el CAGR más alto pero también la mayor volatilidad, se orienta a perfiles más arriesgados. Estos datos facilitarán la construcción de sub-universos de activos candidatos según el perfil del cliente, reduciendo la dimensionalidad del problema de optimización.

Las bases bibliográficas obtenidas en la discusión nos permiten escoger finalmente, en primera instancia, el modelo híbrido que combina Black-Litterman para la estimación robusta de retornos, mientras que se generarán escenarios mediante simulación de Monte Carlo y se utilizará CvaR como medida de riesgo que se condice con los límites de tolerancia que esperan los clientes. Con esta combinación de métodos estadísticos y modelos de optimización se busca minimizar el sesgo o dificultades de cada uno por separado, obteniendo un enfoque más compacto.

Mediante la ayuda del visualizador interactivo desarrollado en Docker se pudo constituir una herramienta muy útil para el análisis exploratorio de la base de datos, permitiendo observar tendencias y comportamiento de las acciones. Se decidió revisar en mayor profundidad esto y se buscará implementar métodos como la estimación por Kernel (KDE) o el de Kolmogorov-Smirnov(KS) para estimar la distribución de las acciones y poder predecirlas bajo ciertas condiciones.

Los pasos siguientes contemplan la implementación del algoritmo de optimización, la validación histórica mediante los KPIs definidos para su implementación en el modelo, y la incorporación de la dinámica del cliente a través de las funciones de probabilidad $P_1(x)$ y $P_2(x)$. La restricción computacional de 10 segundos por recomendación seguirá siendo una condición de diseño central en todas las etapas de implementación.

REFERENCES

- D’Acunto, F., Prabhala, N., & Rossi, A. G. (2019). The promises and pitfalls of robo-advising. *Review of Financial Studies*, 32(5), 1983–2020. doi: [10.1093/rfs/hhz017](https://doi.org/10.1093/rfs/hhz017)
- Deb, K. (2001). *Multi-objective optimization using evolutionary algorithms*. Wiley.
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. doi: [10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5)
- Glasserman, P. (2004). *Monte carlo methods in financial engineering*. Springer. doi: [10.1007/978-0-387-21617-1](https://doi.org/10.1007/978-0-387-21617-1)
- He, G., & Litterman, R. (1999). *The intuition behind Black–Litterman model portfolios* (Tech. Rep.). Goldman Sachs Asset Management.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. doi: [10.1111/j.1540-6261.1952.tb01525.x](https://doi.org/10.1111/j.1540-6261.1952.tb01525.x)
- Myers, J. D. (2009). *Portfolio optimization with transaction costs and preconceived portfolio weights* (Master’s thesis, Massachusetts Institute of Technology). Retrieved from <https://dspace.mit.edu/bitstream/handle/1721.1/61296/702644615-MIT.pdf?sequence=2>
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41. doi: [10.21314/JOR.2000.038](https://doi.org/10.21314/JOR.2000.038)
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442. doi: [10.1111/j.1540-6261.1964.tb02865.x](https://doi.org/10.1111/j.1540-6261.1964.tb02865.x)