



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2122 - TALLER DE INVESTIGACIÓN OPERATIVA (CAPSTONE)

FINPUC ENTREGA 3 GRUPO 13

INTEGRANTES:

PATRICIO ANDRES ACEVEDO FLORES
BENJAMÍN ALONSO CANO ARAYA
MATÍAS BENJAMÍN CATALÁN CONTRERAS
GASPAR TEN BERG YUNUSIC
DIEGO BENJAMÍN VILLALOBOS MICHEA

Miembros del Comité:

PROFESOR GUÍA: AGUSTÍN MATÍAS ANTONIO CHIU
LÓPEZ

AYUDANTE TUTOR: JUAN ENRIQUE HURTADO BROWNE

Santiago de Chile, Junio 2026

ÍNDICE DE CONTENIDOS

ÍNDICE DE FIGURAS	viii
ÍNDICE DE TABLAS	ix
ABSTRACT	xii
RESUMEN	xiii
1. Introducción	1
2. Descripción del problema	2
2.1. Contexto y motivación	2
2.2. Ciclo operacional	2
2.3. Perfiles de riesgo	2
2.4. Formulación del problema	3
2.4.1. Decisión principal	3
2.4.2. Objetivos	3
2.4.3. Restricciones	3
2.5. Datos disponibles	3
2.5.1. Fuente y estructura	3
2.5.2. Proceso de filtrado	4
2.5.3. Justificación del filtrado	4
2.5.4. Diseño experimental: escenarios con y sin pandemia	5
2.5.5. Problema de negocio: comisión óptima y balance cliente-empresa	5
2.5.6. Riesgos y limitaciones de los datos	6
3. Metodología	7
3.1. Revisión bibliográfica	7
3.1.1. Modelos fundamentales de optimización de portafolios	7
3.1.2. El modelo Black-Litterman	7
3.1.3. Estimación de covarianzas y medidas de riesgo	8
3.1.4. Sistemas de asesoría financiera automatizada	8
3.1.5. Fortalezas y debilidades de la metodología seleccionada	8
3.2. Arquitectura general del sistema	9
3.3. Estimación de parámetros	10

3.3.1.	Retornos esperados	10
3.3.2.	Matriz de covarianzas con <i>shrinkage</i>	10
3.3.3.	Anualización	10
3.4.	Optimización media-varianza de Markowitz	10
3.4.1.	Formulación por perfil de riesgo	10
3.4.2.	Frontera eficiente y portafolio de tangencia	11
3.5.	Modelo Black-Litterman	12
3.5.1.	Prior de equilibrio de mercado	12
3.5.2.	Incorporación de <i>views</i>	12
3.5.3.	Construcción de <i>views</i>	12
3.6.	Simulación Monte Carlo (P4)	14
3.6.1.	Objetivo	14
3.6.2.	Funciones de comportamiento del cliente	14
3.6.3.	Estructura de la simulación	14
3.6.4.	Escenarios proyectados	15
3.6.5.	Reproducibilidad	15
3.7.	Análisis distribucional de retornos	15
3.8.	Validación robusta	16
3.9.	Calibración secuencial de Black-Litterman	16
3.9.1.	Diseño de tres horizontes	16
3.9.2.	Etapas de calibración	17
3.9.3.	Mecanismo de puntuación	17
3.10.	Validación rolling de tres horizontes	18
3.11.	Simulación de sensibilidad de la comisión $K\%$	18
3.11.1.	Objetivo	18
3.11.2.	Diseño experimental	18
3.11.3.	Métricas	19
3.12.	Optimización multiobjetivo de λ	19
3.12.1.	Objetivo	19
3.12.2.	Formulación	19
3.12.3.	Diseño experimental	19
3.13.	Comparación de modelos de abandono y <i>views</i>	20
3.13.1.	Modelos de probabilidad de abandono	20
3.13.2.	Comparación de <i>views</i>	20
4.	Supuestos	22

5. KPIs	24
6. Caso Base	26
6.1. Benchmark equiponderado	26
6.2. Métricas del caso base	26
6.3. Validación como línea base	27
6.4. Caso base para la Entrega 3	27
7. Implementación y Herramientas	28
7.1. Implementación y herramientas	28
7.2. Pipeline de la Entrega 3	28
8. Resultados y análisis	30
8.1. Análisis distribucional de retornos	30
8.2. Markowitz vs benchmark	31
8.2.1. Impacto de la pandemia en Markowitz	31
8.2.2. Validación robusta	32
8.3. Black-Litterman	33
8.4. Simulación Monte Carlo (P4)	33
8.5. Análisis integrado	35
8.6. Calibración secuencial de Black-Litterman	36
8.6.1. Sensibilidad de la calibración	37
8.7. Validación rolling de tres horizontes	38
8.8. Sensibilidad de la comisión $K\%$	39
8.9. Optimización multiobjetivo de λ	40
8.10. Comparación de <i>views</i> y modelos de abandono	41
8.10.1. Modelo de abandono $v1+$	41
8.10.2. Comparación agregada de <i>views</i>	41
8.10.3. Dinámica de portafolio bajo momentum general	42
8.10.4. Recomendación final de <i>view</i>	43
8.11. Análisis de sensibilidad y extensiones	44
8.11.1. Justificación de parámetros a sensibilizar	44
8.11.2. Evaluación de sensibilidad	45
8.11.3. Discusión de implicancias	45
8.11.4. Propuesta de extensiones y mejoras	46
9. Conclusiones	48

9.1. Conclusiones principales	48
9.1.1. Calibración de Black-Litterman	48
9.1.2. Comparación de <i>views</i>	48
9.1.3. Parámetros de negocio	49
9.1.4. Validación y robustez	49
9.1.5. Limitaciones	49
9.1.6. Trabajo futuro	49
9.2. Carta Gantt: avance y fases restantes	50
Referencias	51
Anexo N°1: Declaración de uso de IA en este informe y presentación asociada	52
Anexo N°2: Análisis de datos	55
Descripción de la Fuente de Datos	55
Estructura de archivos	55
Formato de los CSV	55
Cobertura temporal	56
Tratamiento temporal de la pandemia	56
Clasificación Sectorial	57
Sistema de clasificación	57
Distribución sectorial del universo completo	57
Subsectores predominantes en Financial Services	59
Tipos de instrumento	59
Capitalización de Mercado	59
Niveles de Filtrado	60
Razones de exclusión	60
Definición formal de cada filtro	61
Universo Final Descriptivo: 636 Acciones	62
Distribución sectorial del universo final	62
Representantes por sector (top 5 por capitalización)	65
Universo Operacional con Inclusión de Pandemia: 601 Acciones	66
Escenarios de datos	66
Interpretación metodológica	67
Efecto observado en resultados	68
Implicaciones para el Modelo de Optimización	68
Conexión con parámetros del modelo	68

Sub-universos recomendados por perfil de riesgo	69
Consideraciones sobre la caja chica	70
Implicancia de la pandemia para los parámetros	70
Conclusión	70
Anexo N°3: Análisis de ajuste de distribuciones	72
Resumen	72
Metodología de cálculo	72
Pruebas de normalidad y distribuciones candidatas	73
Archivos generados	75
Resultados obtenidos	75
Discusión e implicancias para el modelo	77
Limitaciones	78
Conclusiones del anexo	78
Anexo N°4: Análisis de metodologías y código relacionado	80
Markowitz vs Benchmark	80
Resumen	80
Fundamentos metodológicos	81
Supuestos del experimento	82
Estructura del notebook	83
KPIs utilizados	84
Resultados del experimento pandemia	85
Rebalanceo	86
Splits aleatorios	86
Evaluación robusta	88
Implicancias y conclusiones	88
Black-Litterman	90
Resumen	90
Fundamentos metodológicos	90
Supuestos del experimento	92
Estructura del notebook	93
KPIs utilizados	95
Resultados del experimento pandemia	96
Rebalanceo	97
Splits aleatorios	97

Evaluación robusta	98
Implicancias y conclusiones	98
Simulación Monte Carlo	100
Resumen	100
Fundamentos metodológicos	100
Supuestos del experimento	101
Estructura del notebook	101
KPIs utilizados	102
Resultados del experimento pandemia	103
Rebalanceo	104
Splits aleatorios	104
Evaluación robusta	105
Implicancias y conclusiones	105
Conclusión integrada	106
Anexo N°5: Detalle de la simulación de sensibilidad de $K\%$	107
9.3. Detalle de la simulación de sensibilidad de $K\%$	107
Anexo N°6: Detalle de la optimización multiobjetivo de λ	108
9.4. Detalle de la optimización multiobjetivo de λ	108
Anexo N°7: Diagnósticos de la calibración secuencial de Black-Litterman	109
9.5. Diagnósticos de la calibración secuencial de Black-Litterman	109
9.5.1. Stage 1: Selección de familia de $view$	109
9.5.2. Stage 2: Estructura de P	109
9.5.3. Stage 3: Intensidad de Q	109
9.5.4. Stage 4: Confianza Ω	109
9.5.5. Stage 5: Parámetro τ	110
9.5.6. Resultados de la validación rolling	110

ÍNDICE DE FIGURAS

8.1	Delta de Sharpe por inclusión de pandemia en el entrenamiento.	32
8.2	Camino de calibración: evolución del score en las cinco etapas.	37
8.3	Sensibilidad del Sharpe a la confianza c en Ω	37
8.4	Sensibilidad del Sharpe a τ	38
8.5	Score P4, utilidad FinPUC y tasa de retiro vs. comisión K por perfil de riesgo.	40
8.6	Frontera de Pareto cliente vs. empresa y Score P4 vs. λ	41
8.7	Turnover promedio en el horizonte de test limpio por <i>view</i>	42
8.8	Concentración sectorial (HHI) en test limpio por <i>view</i>	43
8.9	Número efectivo de activos en test limpio por <i>view</i>	43

ÍNDICE DE TABLAS

2.1	Cascada de filtrado aplicada al universo sin pandemia.	4
3.1	Configuración de las cuatro variantes de <i>views</i> Black-Litterman.	13
4.1	Supuestos adicionales de la Entrega 3.	23
6.1	KPIs del benchmark equiponderado top-20 (horizonte h7_f2, 601 activos, rebalanceo semestral).	26
6.2	Score P4 del caso base (Markowitz sin calibrar, $K = 1\%$) en test limpio. . .	27
8.1	Resumen transversal de estadísticos por ticker (universo F5 sin pandemia). .	30
8.2	Mejor familia distribucional según AIC y BIC.	30
8.3	Comparación Markowitz vs benchmark (horizonte h7_f2, 601 activos, rebalanceo semestral).	31
8.4	Mejor portafolio Black-Litterman por <i>view</i> y escenario (horizonte h7_f2). . .	33
8.5	Promedios por técnica en escenario neutro (promedio de perfiles).	34
8.6	Top 5 ranking P4 en escenario neutro.	34
8.7	Comparación final: mejor portafolio por modelo y escenario.	35
8.8	Ganadores por etapa de calibración secuencial sobre $\mathcal{H}_1$	36
8.9	Validación rolling: mejora de BL calibrado vs. Markowitz base.	38
8.10	Sensibilidad del Score P4 a la comisión K (promedio sobre metodologías y perfiles, escenario neutro).	39
8.11	Sensibilidad del Score P4 a λ ($K = 5\%$, escenario neutro).	40
8.12	Desempeño agregado de Black-Litterman calibrado por <i>view</i> (modelo v1+). .	42
8.13	Dinámica de portafolio BL calibrado con momentum general (test P4, modelo v1+).	44
9.1	Carta Gantt resumida: avance actual y fases restantes.	50

9.2	Distribución sectorial del universo completo con datos válidos	58
9.3	Razones de exclusión del universo final F5	61
9.4	Estadísticas por sector — universo F5 (636 tickers)	62
9.5	Top subsectores por sector en el universo F5	64
9.6	Top 5 Technology (por capitalización de mercado)	65
9.7	Top 5 Healthcare (por capitalización de mercado)	65
9.8	Top 5 Financial Services (por capitalización de mercado)	65
9.9	Top 5 Consumer Defensive + Utilities (perfiles conservadores)	66
9.10	Diagnóstico de escenarios para el universo operacional	67
9.11	Ventanas temporales en el experimento h7_f2	67
9.12	Efecto de incluir pandemia en el entrenamiento	68
9.13	Conexión entre parámetros del modelo y fuente de datos	69
9.14	Sub-universos recomendados por perfil de riesgo	69
9.15	Principales parámetros de configuración del análisis.	73
9.16	Distribuciones candidatas consideradas.	74
9.17	Archivos de salida generados por el script.	76
9.18	Resumen del tamaño muestral analizado.	76
9.19	Conteo de mejores distribuciones por criterio de información.	77
9.20	Resultados agregados de pruebas de normalidad.	77
9.21	Dimensión de resultados cacheados del experimento principal.	84
9.22	Comparación de portafolios con y sin pandemia en entrenamiento.	85
9.23	Mayores caídas de Sharpe al incluir pandemia en entrenamiento.	86
9.24	Resumen del experimento de splits aleatorios.	87
9.25	Promedio y variabilidad del Sharpe en splits aleatorios.	87

9.26	Sharpe futuro medio en validación robusta por ventanas móviles.	88
9.27	Escenarios evaluados en Black-Litterman.	90
9.28	Supuestos principales del experimento Black-Litterman.	93
9.29	Parámetros globales del experimento Black-Litterman.	94
9.30	Parámetros de las <i>views</i>	94
9.31	Dimensión de salidas del experimento Black-Litterman.	95
9.32	Mejores portafolios Black-Litterman del experimento central.	96
9.33	Comparación final entre equiponderado, Markowitz y Black-Litterman. . . .	96
9.34	Mayor mejora de Black-Litterman frente a Markowitz.	97
9.35	Validación con 70 splits aleatorios para el portafolio Neutro.	98
9.36	Validación robusta con 18 ventanas para el portafolio Neutro.	98
9.37	Índice de CSVs generados por el proyecto.	102
9.38	Comparación final de modelos por escenario (mejor portafolio por modelo). .	103
9.39	Top 10 ranking de Simulación Monte Carlo en escenario neutro.	104
9.40	Ganadores por escenario proyectado en Simulación Monte Carlo.	105

ABSTRACT

This report documents the development, calibration, and business optimization of an investment recommendation system for FinPUC, a fictitious financial advisory platform that generates personalized portfolios for clients in the US stock market. The system serves five risk profiles and pursues a dual objective: maximizing client expected returns and maximizing firm revenue from transaction fees.

The investment universe comprises 601 stocks filtered from 1,406 tickers. Three methodological layers were implemented over two iterations. First, Markowitz mean-variance optimization and four Black-Litterman view variants were evaluated as baselines. Then, a sequential calibration framework over three temporal horizons (calibration, validation, and clean test) was designed to tune the Black-Litterman hyperparameters (τ , Ω , P , Q) without contaminating the evaluation period. A business-parameter layer was added to optimize the commission rate $K\% \in \{0.25\%, \dots, 5\%\}$ and the multi-objective balance $\lambda \in [0, 1]$ between client return and firm utility, using 5,000 Monte Carlo trajectories over 260 weeks. Four view families and three abandonment probability models (v1, v1+, v2) were compared under identical validation protocols.

The sequential calibration converges to an unemployment-macro view with $\tau = 0.2$ and Ω confidence of 0.5, yielding a 3% Sharpe improvement in aggressive profiles with pandemic data. Among the views, general momentum delivers the largest economic gain (+85.7% P4 score vs. Markowitz base, +5.2% Sharpe) albeit with elevated turnover (34.6%), while the unemployment-macro view provides superior operational stability (7.3% turnover, HHI 0.157). The optimal commission rate and balance parameter are identified via sensitivity and Pareto-frontier analysis, and the v1+ abandonment model with homogeneous ruin constraints is selected as the recommended configuration for the final recommender.

Keywords: portfolio optimization, Markowitz, Black-Litterman calibration, Monte Carlo simulation, recommender system, multi-objective optimization, commission sensitivity, rolling validation, CVXPY.

RESUMEN

El informe documenta el desarrollo, calibración y optimización de negocio de un sistema recomendador de inversiones para FinPUC, una plataforma ficticia de asesoría financiera que genera portafolios personalizados para clientes del mercado accionario estadounidense. El sistema atiende cinco perfiles de riesgo, desde muy conservador hasta muy arriesgado, y opera bajo un doble objetivo: maximizar el retorno esperado del cliente y maximizar la utilidad de la empresa por comisiones de transacción.

El universo de trabajo comprende 601 acciones, obtenidas tras filtrar 1 406 tickers. En una primera iteración se implementaron tres capas metodológicas: optimización media-varianza de Markowitz, modelo Black-Litterman con cuatro variantes de *views* y simulación Monte Carlo con 5 000 trayectorias durante 260 semanas. La segunda iteración, documentada en este informe, incorpora cuatro bloques nuevos: (1) calibración secuencial de Black-Litterman sobre tres horizontes temporales estrictamente separados (calibración, validación y test limpio P4), (2) optimización del porcentaje de comisión $K\%$ mediante sensibilidad sobre 8 valores posibles, (3) optimización multiobjetivo del parámetro de balance $\lambda \in [0, 1]$ entre retorno del cliente y utilidad de la empresa, y (4) comparación de cuatro familias de *views* y tres modelos de probabilidad de abandono bajo protocolos de validación idénticos.

La calibración secuencial converge a una *view* de desempleo macro con $\tau = 0.2$ y confianza Ω de 0.5, entregando una mejora de Sharpe de 3% en perfiles agresivos con datos de pandemia. Entre las *views*, momentum general entrega la mayor ganancia económica (+85.7% en score P4 frente a Markowitz base, +5.2% Sharpe) aunque con mayor rotación (34.6%), mientras que desempleo macro ofrece la mejor estabilidad operacional (7.3% de turnover, HHI sectorial de 0.157). La tasa de comisión óptima y el parámetro de balance se determinan mediante análisis de sensibilidad y frontera de Pareto, y el modelo de abandono v1+ con restricción de ruina homogénea se selecciona como la configuración recomendada para el recomendador final.

Palabras clave: optimización de portafolios, Markowitz, Black-Litterman, calibración bayesiana, simulación Monte Carlo, sistema recomendador, optimización multiobjetivo, sensibilidad de comisiones, validación rodante, CVXPY.

1. INTRODUCCIÓN

La gestión eficiente del capital constituye uno de los problemas fundamentales de las finanzas modernas. El problema de optimización de portafolios, formalizado por Markowitz (1952), establece los fundamentos matemáticos de la diversificación y define la frontera eficiente como el conjunto de portafolios óptimos en el espacio riesgo-retorno. En la práctica, el universo de activos puede comprender cientos de instrumentos, los clientes presentan perfiles de riesgo heterogéneos y las condiciones del mercado evolucionan continuamente. En este contexto, la consolidación de plataformas de asesoría financiera automatizada ha generado una demanda creciente de sistemas capaces de producir recomendaciones personalizadas, fundamentadas y actualizadas de forma periódica (D’Acunto, Prabhala, & Rossi, 2019).

El presente informe documenta la tercera fase del proyecto FinPUC, una plataforma ficticia de recomendación de inversiones desarrollada en el marco del curso Taller de Investigación Operativa (ICS2122) de la Pontificia Universidad Católica de Chile. La fase anterior estableció las tres capas metodológicas (Markowitz, Black-Litterman con cuatro variantes de *views* y simulación Monte Carlo), validó su desempeño fuera de muestra, y dejó identificadas dos preguntas de negocio abiertas: (1) la comisión $K = 1\%$ se fijó como supuesto sin evidencia de optimalidad, y (2) el trade-off entre retorno del cliente y utilidad de la empresa se resolvió implícitamente en el Score P4 sin un parámetro explícito de balance. La presente fase aborda ambas preguntas mediante calibración secuencial del modelo Black-Litterman, optimización del porcentaje de comisión $K\%$, determinación del parámetro multiobjetivo λ , y comparación sistemática de *views* y modelos de abandono bajo un protocolo de validación de tres horizontes.

El sistema opera en dos escalas temporales complementarias. A nivel de optimización, los pesos del portafolio se recalculan cada semestre (126 días hábiles bursatil) mediante rebalanceo con estimación actualizada de parámetros. A nivel de simulación del cliente, el modelo Monte Carlo evalúa semanalmente durante 260 semanas si el cliente acepta la recomendación vigente o retira sus fondos, generando métricas de riqueza terminal, probabilidad de ganancia y utilidad de la empresa. La decisión central consiste en determinar la fracción del capital a asignar a cada acción de un universo de 601 activos, maximizando simultáneamente el retorno esperado del inversionista y la utilidad de FinPUC.

2. DESCRIPCIÓN DEL PROBLEMA

2.1. Contexto y motivación

La gestión de inversiones requiere asignar capital entre múltiples activos considerando riesgo, horizonte y condiciones de mercado. FinPUC es una plataforma ficticia de recomendación de inversiones para clientes del mercado accionario estadounidense clasificados por perfil de riesgo. El sistema genera periódicamente portafolios optimizados buscando maximizar el retorno esperado y las utilidades por comisiones, sujeto a restricciones de riesgo y tiempo computacional.

2.2. Ciclo operacional

El sistema opera en dos escalas temporales. A nivel de optimización, los pesos del portafolio se recalculan cada semestre (126 días hábiles bursátil) mediante rebalanceo: se reestiman los parámetros μ y Σ con la ventana histórica acumulada hasta ese punto y se resuelve nuevamente el problema de optimización.

A nivel de simulación del cliente (Monte Carlo P4), el sistema evalúa semanalmente durante 260 semanas (5 años) el comportamiento del inversionista. Cada semana, el cliente puede aceptar la recomendación vigente con probabilidad $P_2(x)$ o rechazarla. Si acepta, se ejecuta la transacción y la empresa cobra una comisión proporcional $k\% = 1\%$ sobre el monto transado. Si la pérdida acumulada del cliente supera la tolerancia de su perfil, existe una probabilidad $P_1(x)$ de que retire sus fondos de la plataforma.

2.3. Perfiles de riesgo

Se consideran cinco perfiles de riesgo definidos por una volatilidad anual máxima de 8%, 12%, 18%, 28% y 40%, correspondientes a perfiles muy conservador, conservador, neutro, arriesgado y muy arriesgado, respectivamente.

2.4. Formulación del problema

2.4.1. Decisión principal

Para cada perfil de riesgo y cada punto de rebalanceo, el sistema debe determinar el vector de pesos $w \in \mathbb{R}^n$ que asigna una fracción del capital a cada una de las $n = 601$ acciones del universo.

2.4.2. Objetivos

El problema busca maximizar simultáneamente el retorno esperado del cliente ($\mu^\top w$) y las utilidades por comisiones generadas por las transacciones aceptadas.

2.4.3. Restricciones

- **No venta en corto:** $w_i \geq 0$ para todo i .
- **Presupuesto completo:** $\sum_{i=1}^n w_i = 1$.
- **Concentración máxima:** $w_i \leq w_{\max} = 0.20$ para todo i .
- **Riesgo por perfil:** $w^\top \Sigma w \leq \sigma_{\max}^2$, donde la cota depende del perfil de riesgo.
- **Tiempo de cómputo:** el sistema debe generar la recomendación en menos de 10 segundos.

2.5. Datos disponibles

2.5.1. Fuente y estructura

Los datos corresponden a registros históricos del mercado accionario estadounidense. El dataset original comprende 1 406 archivos CSV, uno por ticker, con precios diarios que cubren aproximadamente desde el año 2000 hasta marzo de 2026. Cada archivo incluye fecha, precio de apertura y cierre, máximo y mínimo del día, volumen de transacciones, dividendos y factores de *split*. Adicionalmente, se dispone de un archivo de metadatos con información fundamental de cada empresa: sector, industria, tipo de instrumento y capitalización de mercado.

El retorno diario total de cada acción se calcula incorporando dividendos:

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (2.1)$$

donde $P_{i,t}$ es el precio de cierre del activo i en el día t y $D_{i,t}$ el dividendo pagado en esa fecha.

2.5.2. Proceso de filtrado

A partir del universo crudo de 1 406 tickers se aplicó un proceso de filtrado secuencial. La Tabla 2.1 detalla la cascada del universo operacional comparable usado en los experimentos, que queda en 601 activos. En paralelo, el Anexo N°2 documenta el universo F5 descriptivo completo de 636 acciones. Esta diferencia no corresponde a dos universos finales distintos por escenario, sino a dos niveles de análisis: 636 acciones para caracterización descriptiva y 601 acciones para comparación experimental con y sin pandemia bajo el mismo periodo futuro.

Tabla 2.1. Cascada de filtrado aplicada al universo sin pandemia.

Filtro	Criterio operacional	Tickers	Retención F0
F0	Archivos CSV encontrados	1.406	100,0%
F1	Precio $\geq$ USD 5; historia $\geq$ 5 años; cap. $\geq$ USD 300M o sin dato	827	58,8%
F2	Excluye <i>Shell Companies</i> , sector desconocido y no EQUITY	824	58,6%
F3	Capitalización bursátil $\geq$ USD 2B	659	46,9%
F4	Historia fuera de pandemia $\geq$ 10 años, aproximada por 2.500 filas	606	43,1%
F5	Volatilidad anualizada fuera de pandemia entre 5% y 100%	601	42,7%

2.5.3. Justificación del filtrado

El proceso de filtrado busca construir un universo de activos estable e invertible para la optimización de portafolios. F1 elimina acciones con precios muy bajos, historia insuficiente o capitalización reducida, disminuyendo estimaciones poco robustas. F2 restringe el análisis a instrumentos EQUITY y excluye *Shell Companies* y sectores desconocidos para mantener comparabilidad entre activos.

Luego, F3 exige una capitalización mínima de USD 2B para reducir problemas de liquidez y volatilidad extrema. F4 requiere al menos diez años de historia fuera del periodo pandemia para estimar parámetros con mayor estabilidad. Finalmente, F5 elimina activos

con volatilidad anualizada excesivamente alta o baja, asociados potencialmente a errores de datos o comportamientos incompatibles con un portafolio accionario tradicional.

2.5.4. Diseño experimental: escenarios con y sin pandemia

La evaluación del sistema se realiza bajo dos escenarios que comparten el mismo período futuro de evaluación (2 años fuera de muestra) pero difieren en la ventana de entrenamiento. El escenario “sin pandemia” excluye las observaciones de 2020 - 2022, estimando μ y Σ con un mercado relativamente normal. El escenario “con pandemia” las incluye, incorporando correlaciones de estrés y volatilidad extrema. Cualquier diferencia en resultados entre ambos escenarios se interpreta como efecto de la información usada para calibrar, no como diferencias de mercado futuro.

2.5.5. Problema de negocio: comisión óptima y balance cliente-empresa

La Entrega 2 del proyecto fijó la comisión en $K = 1\%$ sobre el monto transado y evaluó las alternativas mediante un Score P4 que suma linealmente riqueza del cliente y utilidad de la empresa, ponderando ambas con igual peso. Esta formulación deja dos preguntas abiertas que la presente fase aborda.

En primer lugar, la tasa de comisión $K\%$ determina simultáneamente la utilidad de FinPUC y la riqueza neta del cliente. Un K alto genera más ingresos por transacción, pero reduce el capital invertido y puede elevar la tasa de retiro si el cliente percibe que la plataforma es demasiado costosa. Un K bajo favorece al cliente pero compromete la sostenibilidad financiera de la plataforma. La pregunta central es: ¿cuál es el valor de K que maximiza el Score P4, balanceando riqueza del cliente, utilidad de la empresa y retención?

En segundo lugar, el Score P4 original asigna el mismo peso a la riqueza del cliente y a la utilidad de la empresa. En la práctica, FinPUC podría priorizar uno u otro objetivo según su estrategia de negocio. Para formalizar esta decisión, se introduce un parámetro de balance $\lambda \in [0, 1]$ que pondera:

$$\text{Score}_\lambda = \lambda \cdot f_1(w) + (1 - \lambda) \cdot f_2(w), \quad (2.2)$$

donde $f_1(w)$ es el retorno esperado del cliente (normalizado) y $f_2(w)$ es la utilidad esperada de FinPUC (normalizada). Con $\lambda = 1$, la plataforma optimiza exclusivamente el

retorno del cliente; con $\lambda = 0$, solo su propia utilidad. La pregunta es: ¿qué valor de λ entrega el mejor desempeño conjunto según el Score P4?

La respuesta a ambas preguntas requiere (a) calibrar el modelo Black-Litterman para que las proyecciones de Monte Carlo reflejen la mejor configuración posible de hiperparámetros, (b) evaluar la sensibilidad del Score P4 a K y λ bajo esa configuración, y (c) comparar distintas *views* y modelos de abandono para asegurar que la recomendación final es robusta a la elección de estos componentes.

2.5.6. Riesgos y limitaciones de los datos

- Posible sesgo de supervivencia por exigir historia larga y alta capitalización.
- Sobrerrepresentación del sector financiero en el universo final.
- Tratamiento alternativo del periodo 2020–2022 mediante escenarios con y sin pandemia.
- Diferencias entre retornos usados en filtrado y análisis final.
- Pérdida de observaciones por uso de `join="inner"`.

3. METODOLOGÍA

3.1. Revisión bibliográfica

3.1.1. Modelos fundamentales de optimización de portafolios

La optimización de portafolios tiene su origen en el trabajo seminal de Markowitz (Markowitz, 1952), que formalizó el principio de diversificación mediante el modelo media-varianza. Su propuesta establece que un inversionista racional selecciona portafolios sobre la frontera eficiente, es decir, aquellos que maximizan el retorno esperado para un nivel de riesgo dado. La principal limitación del modelo es su sensibilidad a las estimaciones de μ y Σ : pequeños errores en los retornos esperados pueden generar portafolios concentrados o irrazonables (Michaud, 1989). En el presente proyecto, esta fragilidad se observa empíricamente: el portafolio Ideal de mercado de Markowitz exhibe un Sharpe teórico de 5,01 que colapsa a 1,80 fuera de muestra con datos de pandemia, confirmando el fenómeno de *overfitting* documentado por Michaud.

El modelo CAPM de Sharpe (Sharpe, 1964) extiende el trabajo de Markowitz introduciendo un modelo de equilibrio de mercado, donde el retorno esperado de un activo depende únicamente de su exposición al riesgo sistemático, medido por el coeficiente β . El modelo multifactorial de Fama y French (Fama & French, 1993) incorpora dos factores adicionales, tamaño (SMB) y valor (HML), para capturar anomalías empíricas. Aunque estos modelos no se implementan directamente en FinPUC, informan la construcción del prior de equilibrio en Black-Litterman: los retornos implícitos $\pi = \delta \Sigma w_{\text{market}}$ asumen que el mercado está en equilibrio, lo que es consistente con la lógica del CAPM.

3.1.2. El modelo Black-Litterman

Black y Litterman (Black & Litterman, 1992) propusieron un enfoque bayesiano que combina el equilibrio implícito del mercado con expectativas subjetivas del inversionista. El prior se obtiene invirtiendo el problema de Markowitz: dado que el mercado está en equilibrio, los retornos implícitos son $\pi = \delta \Sigma w_{\text{market}}$. Las *views* se incorporan mediante una actualización bayesiana que produce estimaciones más estables y portafolios menos extremos. He y Litterman (He & Litterman, 1999) documentaron la implementación práctica del modelo, destacando su capacidad para generar portafolios intuitivamente razonables sin restricciones artificiales de peso. Idzorek (Idzorek, 2005) extendió el marco

proponiendo métodos para calibrar la confianza de cada *view*, problema que en FinPUC se aborda fijando $c = 0.50$ para las *views* de momentum y $c = 0.35$ para la de desempleo.

3.1.3. Estimación de covarianzas y medidas de riesgo

Ledoit y Wolf (Ledoit & Wolf, 2004) propusieron el método de *shrinkage* para la estimación de matrices de covarianza de grandes dimensiones, demostrando que la combinación convexa entre la covarianza muestral y un estimador estructurado reduce el error de estimación fuera de muestra. En FinPUC se implementa con $\lambda = 0.20$, valor seleccionado para estabilizar una matriz de 601×601 sin perder demasiada estructura de correlación. La elección de λ no fue optimizada formalmente y constituye un supuesto del modelo.

Rockafellar y Uryasev (Rockafellar & Uryasev, 2000) introdujeron el Valor en Riesgo Condicional (CVaR) como medida coherente de riesgo, superando las limitaciones del VaR estándar al cuantificar la severidad promedio de las pérdidas en la cola. En el proyecto, el CVaR al 95% se utiliza como indicador de desempeño complementario al Sharpe, no como restricción del optimizador. Esta decisión responde a que la implementación con CVXPY utiliza cotas de volatilidad por perfil, que son computacionalmente más eficientes para la restricción de 10 segundos.

3.1.4. Sistemas de asesoría financiera automatizada

En el contexto de plataformas de *robo-advisory*, D’Acunto, Prabhala y Rossi (D’Acunto et al., 2019) documentaron cómo la automatización ha democratizado el acceso a estrategias de inversión, permitiendo recomendaciones personalizadas a bajo costo operacional. FinPUC se enmarca en esta línea, con la particularidad de que incorpora explícitamente el comportamiento del cliente (funciones P_1 y P_2) y la utilidad de la empresa (comisiones $k\%$) como variables del modelo, lo que va más allá de la optimización financiera pura.

3.1.5. Fortalezas y debilidades de la metodología seleccionada

La combinación de Black-Litterman con Monte Carlo resulta adecuada para el problema de FinPUC porque une dos necesidades del sistema recomendador: construir portafolios más estables que Markowitz puro y evaluar su impacto en variables de decisión para cliente y empresa. Black-Litterman reduce la dependencia de estimaciones históricas extremas al anclar los retornos esperados al equilibrio de mercado. Esto se observa en los

resultados: con datos de pandemia, la mejor variante BL alcanza Sharpe 2,38, mientras que Markowitz cae a 2,02.

Otra fortaleza es que el modelo permite incorporar *views* de forma controlada. En vez de reemplazar completamente el prior de mercado, las señales de momentum, desempleo o capitalización ajustan los retornos esperados según su nivel de confianza. Luego, Monte Carlo traduce esos portafolios a escenarios desfavorable, neutro y favorable, permitiendo medir riqueza terminal, retiro del cliente y utilidad para FinPUC sin depender solo de una métrica financiera.

La principal debilidad es que la calidad del resultado depende directamente de la calidad de las *views*. En particular, la view de desempleo se modela con un supuesto fijo y no con una serie macro observada, lo que limita su validez predictiva. Además, parámetros como $\tau = 0.05$ y la matriz $\Omega = P\tau\Sigma P^\top/c$ requieren sensibilidad adicional, porque cambios en la confianza asignada a las views pueden modificar el ranking final.

Finalmente, la simulación Monte Carlo asume retornos normales, aunque el análisis distribucional rechaza normalidad en todos los activos. Esto puede subestimar eventos extremos y generar tasas de retiro demasiado optimistas. También queda pendiente incorporar costos de transacción en la optimización, ya que actualmente aparecen solo como comisiones en P4. Sin esa penalización, algunas carteras podrían verse atractivas en el modelo pero ser menos eficientes en una implementación real con turnover alto.

3.2. Arquitectura general del sistema

El sistema se estructura en tres capas metodológicas de complejidad creciente, ejecutadas secuencialmente. La primera capa implementa la optimización media-varianza de Markowitz como línea base analítica. La segunda extiende Markowitz con el modelo Black-Litterman, que incorpora un prior de equilibrio de mercado y *views* cuantitativas. La tercera capa es una simulación Monte Carlo que traduce las métricas financieras de las capas anteriores en proyecciones de riqueza del cliente y utilidad de la empresa. Adicionalmente, un benchmark equiponderado funciona como caso base independiente de parámetros estimados. En total, el sistema compara seis técnicas: Equiponderado, Markowitz, y cuatro variantes de Black-Litterman (momentum general, momentum por capitalización a 6 meses, momentum por capitalización a 1 año, y desempleo macro).

3.3. Estimación de parámetros

3.3.1. Retornos esperados

Los retornos esperados $\mu \in \mathbb{R}^n$ se estiman como promedios diarios históricos de los retornos totales de cada acción en la ventana de entrenamiento.

3.3.2. Matriz de covarianzas con *shrinkage*

La matriz de covarianzas muestral Σ_{muestral} se estabiliza mediante *shrinkage* lineal hacia su diagonal (Ledoit & Wolf, 2004):

$$\Sigma_{\text{shrink}} = (1 - \lambda) \Sigma_{\text{muestral}} + \lambda \cdot \text{diag}(\Sigma_{\text{muestral}}), \quad (3.1)$$

con $\lambda = 0.20$. Esto reduce el error de estimación fuera de muestra en matrices de alta dimensión ($n = 601$), donde la covarianza muestral tiende a sobreajustar correlaciones espurias. La matriz resultante se fuerza a ser semidefinida positiva mediante proyección espectral (`nearest_psd`), truncando valores propios negativos a cero. Este paso es requisito para que los problemas cuadráticos resueltos por CVXPY sean convexos.

3.3.3. Anualización

Los retornos se anualizan asumiendo 252 días hábiles bursátil por año: $R_{\text{anual}} = \bar{r}_{\text{diario}} \times 252$. La volatilidad se escala como $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \times \sqrt{252}$. La tasa libre de riesgo se fija en $R_f = 2\%$ anual.

3.4. Optimización media-varianza de Markowitz

3.4.1. Formulación por perfil de riesgo

Para cada perfil de riesgo con parámetro de aversión γ y cota de volatilidad σ_{max}^2 , se resuelve el problema cuadrático:

$$\max_w \quad \mu^\top w - \frac{1}{2} \gamma w^\top \Sigma w \quad (3.2)$$

sujeto a:

$$\sum_{i=1}^n w_i = 1 \quad (3.3)$$

$$0 \leq w_i \leq 0.20 \quad \forall i = 1, \dots, n \quad (3.4)$$

$$w^\top \Sigma w \leq \sigma_{\max}^2 \quad (\text{cuando el perfil lo requiere}) \quad (3.5)$$

La restricción $w_i \geq 0$ impide ventas cortas; la suma igual a 1 invierte todo el capital; y la cota superior $w_{\max} = 0.20$ evita concentración extrema en un solo activo. Cuando la cota de volatilidad hace infactible un perfil, se relaja esa cota manteniendo las demás restricciones.

3.4.2. Frontera eficiente y portafolio de tangencia

La frontera eficiente se construye resolviendo, para 30 retornos objetivo r_{obj} equiespaciados:

$$\min_w w^\top \Sigma w \quad \text{s.a.} \quad \mu^\top w \geq r_{\text{obj}}, \quad \sum_i w_i = 1, \quad 0 \leq w_i \leq 0.20 \quad (3.6)$$

El portafolio de tangencia (“Ideal de mercado”) se selecciona como el punto de la frontera que maximiza el ratio de Sharpe:

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p} \quad (3.7)$$

donde R_p es el retorno anualizado del portafolio y σ_p su volatilidad anualizada. Este portafolio es teórico: asume conocimiento perfecto de los parámetros, por lo que su desempeño fuera de muestra mide el grado de *overfitting* de la estimación histórica.

3.4.2.1. Rebalanceo semestral

El período futuro de evaluación, de 2 años o aproximadamente 504 días hábiles, se divide en segmentos de 126 días. Al inicio de cada segmento se actualiza la información disponible: se incorporan los retornos ya observados hasta ese punto, se reestiman μ y Σ , y se resuelven nuevamente los problemas de optimización para todos los perfiles. Los pesos resultantes se aplican al segmento siguiente y se mantienen constantes hasta el próximo rebalanceo.

Con este procedimiento, el modelo simula una implementación más realista que una cartera estática, pero sin usar información futura no observada. Las métricas finales se calculan concatenando los retornos diarios generados en todos los segmentos de rebalanceo.

3.5. Modelo Black-Litterman

3.5.1. Prior de equilibrio de mercado

El modelo parte de que, en equilibrio, los retornos implícitos del mercado son consistentes con los pesos observados por capitalización (Black & Litterman, 1992; He & Litterman, 1999):

$$\pi = \delta \cdot \Sigma \cdot w_{\text{market}} \quad (3.8)$$

donde w_{market} son los pesos normalizados por capitalización bursátil y δ es el coeficiente de aversión al riesgo implícito:

$$\delta = \frac{R_{\text{market}} - R_f}{\sigma_{\text{market}}^2} \quad (3.9)$$

3.5.2. Incorporación de *views*

Dadas las *views* representadas por la matriz de selección $P \in \mathbb{R}^{k \times n}$, el vector de expectativas $Q \in \mathbb{R}^k$ y la matriz de incertidumbre $\Omega \in \mathbb{R}^{k \times k}$, el retorno esperado posterior es:

$$\mu_{\text{BL}} = \pi + \tau \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} (Q - P \pi) \quad (3.10)$$

con $\tau = 0.05$. La covarianza posterior se calcula como:

$$\Sigma_{\text{BL}} = (1 + \tau) \Sigma - \tau^2 \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} P \Sigma \quad (3.11)$$

y se fuerza a ser semidefinida positiva mediante `nearest_psd`. Con μ_{BL} y Σ_{BL} se resuelven los mismos problemas de optimización que en Markowitz.

3.5.3. Construcción de *views*

Se implementan cuatro *views* independientes, cada una generando su propia versión del modelo Black-Litterman. La Tabla 3.1 resume su configuración.

Tabla 3.1. Configuración de las cuatro variantes de *views* Black-Litterman.

View	Tipo	Lookback	Long	Short	Confianza	Universo
Momentum	Endógena	252 días	20	20	0.50	601 activos
Momentum Top20 6M	Market-cap	126 días	10	10	0.50	Top 20
Momentum Top20-Bottom20 1Y	Market-cap	252 días	20	20	0.50	Top 40
Desempleo	Macro asumida	1 764 días	466	135	0.35	601 activos

3.5.3.1. Views de momentum

Las *views* de momentum seleccionan activos por retorno acumulado durante el período de lookback. La matriz P tiene una fila que asigna $+1/n_{\text{long}}$ a los activos con mayor retorno y $-1/n_{\text{short}}$ a los de menor retorno. El valor Q corresponde a la diferencia promedio diaria entre los retornos de ambos grupos. La variante general opera sobre los 601 activos; las variantes por capitalización restringen el universo a los activos con mayor market cap (top 20 o top 40).

3.5.3.2. View de desempleo

Es un supuesto macroeconómico fijo, no un dato observado. Se asume una tasa de desempleo de 4% contra un nivel neutral de 5%. Con desempleo bajo, se favorecen sectores cíclicos (Technology, Consumer Cyclical, Industrials, Financial Services, Basic Materials, Real Estate, Energy) sobre defensivos (Healthcare, Consumer Defensive, Utilities, Communication Services). La señal es proporcional a la diferencia entre ambas tasas, escalada por $\beta_{\text{macro}} = 1.0$ y convertida a retorno diario dividiendo por 252. La confianza se fija en $c = 0.35$, menor que la de momentum, reflejando que es un supuesto y no una observación.

3.5.3.3. Calibración de Ω

Para cada *view*, la incertidumbre se calibra como:

$$\Omega = \frac{P \cdot (\tau \Sigma) \cdot P^T}{c} \quad (3.12)$$

donde c es la confianza de la *view*. Con una sola *view* ($k = 1$), Ω es escalar y la formulación se simplifica.

3.6. Simulación Monte Carlo (P4)

3.6.1. Objetivo

La tercera capa traduce los KPIs financieros de Markowitz y Black-Litterman en proyecciones de riqueza para el cliente y utilidad para la empresa. Simula el comportamiento completo del sistema recomendador durante 260 semanas (5 años), incorporando las decisiones del cliente mediante funciones logísticas.

3.6.2. Funciones de comportamiento del cliente

La probabilidad de retiro ante pérdidas se modela como:

$$P_1(x_1) = \frac{1}{1 + \exp(-s(x_1 - \hat{x}_1))} \quad (3.13)$$

donde $x_1 = (C_0 - W_t)/C_0$ es la pérdida actual respecto al capital inicial, $\hat{x}_1$ es la tolerancia máxima del perfil, y $s = 20$ es la sensibilidad logística. P_1 se activa únicamente cuando $x_1 > \hat{x}_1$; en caso contrario, la probabilidad de retiro es cero.

La probabilidad de aceptación de una recomendación es:

$$P_2(x_2) = \frac{1}{1 + \exp(-s(x_2 - \hat{x}_2))} \quad (3.14)$$

donde x_2 es la tasa de retorno ofrecida en la recomendación y $\hat{x}_2$ es el umbral de tolerancia al riesgo del perfil.

3.6.3. Estructura de la simulación

Para cada combinación de escenario de datos (con/sin pandemia), técnica (6 alternativas), perfil de riesgo (5 niveles) y escenario proyectado (desfavorable, neutro, favorable), se ejecutan $N = 5000$ simulaciones independientes. En total, esto genera $2 \times 6 \times 5 \times 3 = 180$ combinaciones, cada una con 5 000 trayectorias.

Cada simulación opera semana a semana. Primero, el cliente decide si acepta la recomendación inicial mediante P_2 ; si la acepta, invierte $C_0 = 1000$ USD y paga una comisión inicial de $k = 1\%$. Luego, en cada semana se simula el retorno del portafolio como $r_{\text{sem}} \sim \mathcal{N}(\mu_{\text{sem}}, \sigma_{\text{sem}}^2)$, calibrado a partir de los KPIs anualizados de los modelos anteriores. También se ofrece una nueva recomendación semanal: si el cliente la acepta,

nuevamente según P_2 , se cobra una comisión de 1% sobre el 5% de la riqueza actual, que representa la fracción de rotación asumida. Finalmente, si la pérdida acumulada respecto de C_0 supera la tolerancia definida para el perfil, se evalúa el retiro mediante P_1 . Cuando el cliente retira, la trayectoria se detiene y la riqueza terminal corresponde al valor disponible en ese momento.

3.6.4. Escenarios proyectados

Los tres escenarios se calibran a partir del retorno anualizado base R_{base} y la volatilidad anualizada σ_{base} de cada técnica:

$$R_{\text{favorable}} = R_{\text{base}} + 0.5 \sigma_{\text{base}} \quad (3.15)$$

$$R_{\text{neutro}} = R_{\text{base}} \quad (3.16)$$

$$R_{\text{desfavorable}} = R_{\text{base}} - 0.5 \sigma_{\text{base}} \quad (3.17)$$

Esto genera un abanico simétrico de $\pm 0.5\sigma$ alrededor del caso base.

3.6.5. Reproducibilidad

La simulación utiliza semillas deterministas generadas mediante SHA-256 a partir de la combinación única de escenario, técnica, *view* y perfil. Esto garantiza que cada celda del experimento es reproducible individualmente sin afectar a las demás.

3.7. Análisis distribucional de retornos

Complementariamente a la optimización, se realizó un análisis distribucional sobre los retornos diarios del universo F5 sin pandemia, con el objetivo de caracterizar la forma estadística de los retornos y evaluar la validez del supuesto de normalidad.

Se ajustaron siete familias paramétricas candidatas: normal, t-Student, Laplace, logística, skew-normal, normal generalizada y Johnson SU. Los parámetros se estimaron por máxima verosimilitud. Para cada familia m se calcularon los criterios de información:

$$AIC_m = 2k_m - 2\ell_m, \quad BIC_m = k_m \log(n) - 2\ell_m, \quad (3.18)$$

donde k_m es el número de parámetros, n la cantidad de retornos y ℓ_m la log-verosimilitud. Se aplicaron adicionalmente pruebas de normalidad (Shapiro-Wilk, D’Agostino-Pearson, Jarque-Bera) y una prueba Kolmogorov–Smirnov aproximada.

3.8. Validación robusta

Para evitar que las conclusiones dependan de un único horizonte de entrenamiento, se aplicaron dos mecanismos de validación. Primero, se evaluaron 70 particiones aleatorias train/test, lo que permitió observar la distribución del Sharpe fuera de muestra para cada portafolio y técnica. Segundo, se probaron 18 ventanas móviles robustas, desde h2_f7 hasta h7_f2, variando la proporción entre datos de entrenamiento y evaluación para medir cómo cambia el desempeño futuro al usar más o menos historia.

El horizonte central seleccionado fue h7_f2, equivalente a 7 años de entrenamiento y 2 años de evaluación. Este horizonte entrega el mejor Sharpe futuro promedio: 2,32 en Markowitz y resultados comparables en Black-Litterman, con 2,32 para la view de desempleo y 2,22 para momentum. La validación muestra que ventanas históricas más largas producen estimaciones más estables, mientras que reducir el periodo de entrenamiento deteriora progresivamente el Sharpe fuera de muestra.

3.9. Calibración secuencial de Black-Litterman

3.9.1. Diseño de tres horizontes

La calibración de los hiperparámetros de Black-Litterman se realiza bajo un diseño experimental que separa estrictamente tres horizontes temporales no intercambiables. Sea $\mathcal{D}$ el conjunto completo de observaciones históricas, compuesto por retornos diarios de $N = 601$ activos. El experimento divide $\mathcal{D}$ en tres bloques funcionales:

$$\mathcal{D} = \mathcal{H}_1 \cup \mathcal{H}_2 \cup \mathcal{H}_3, \quad (3.19)$$

donde $\mathcal{H}_1$ corresponde al horizonte de calibración, $\mathcal{H}_2$ al horizonte de validación y $\mathcal{H}_3$ al horizonte de test limpio para la evaluación económica P4. La condición fundamental es que la selección de hiperparámetros no puede depender de $\mathcal{H}_3$:

$$\hat{\theta}_{BL} = \mathcal{A}(\mathcal{H}_1), \quad \hat{\theta}_{BL} \neq \mathcal{A}(\mathcal{H}_3). \quad (3.20)$$

Esta separación evita el problema de *data snooping*: que los parámetros se ajusten al mismo período que después se usa para evaluar el desempeño económico.

3.9.2. Etapas de calibración

La calibración se organiza en cinco etapas secuenciales, cada una evaluada dentro de $\mathcal{H}_1$ y validada en $\mathcal{H}_2$ antes de congelar la decisión y avanzar. Las etapas son:

- (i) **Stage 1 — Familia de *view*:** Se prueban cuatro familias (desempleo macro, momentum general, momentum top/bottom 1Y, momentum top market-cap 6M). Para cada una se ejecuta Black-Litterman con configuración base y se selecciona la familia con mayor score de calibración. El ganador en $\mathcal{H}_1$ fue desempleo macro, con Sharpe medio 0.854 y delta Sharpe 0.159.
- (ii) **Stage 2 — Estructura de P :** Sobre la familia ganadora, se prueban combinaciones de parámetros de la matriz de selección P : tasa de desempleo asumida ($U \in \{3\%, 4\%, 5\%\}$) y sensibilidad sectorial ($\beta \in \{1.0, 1.5, 2.0\}$). El ganador fue $U = 4\%$ con $\beta = 1.5$.
- (iii) **Stage 3 — Intensidad de Q :** Se escala el vector de expectativas Q mediante un factor $q_{\text{scale}} \in \{0.5, 1.0, 1.5, 2.0\}$. El valor óptimo fue $q_{\text{scale}} = 1.5$.
- (iv) **Stage 4 — Confianza Ω :** Se prueba la confianza $c \in \{0.25, 0.35, 0.50, 0.75, 1.00\}$ en la calibración de Ω . Con mayor c , menor es la incertidumbre asignada a la *view* y mayor su influencia en μ_{BL} . El ganador fue $c = 0.50$.
- (v) **Stage 5 — Parámetro τ :** Se evalúa $\tau \in \{0.05, 0.10, 0.20, 0.50, 1.00\}$. El valor $\tau = 0.20$ resultó óptimo.

La configuración congelada resultante es: *view* de desempleo macro, $U = 4\%$, $\beta = 1.5$, $q_{\text{scale}} = 1.5$, $c = 0.50$, $\tau = 0.20$.

3.9.3. Mecanismo de puntuación

En cada etapa, cada configuración candidata se evalúa mediante un score compuesto que combina el Sharpe medio fuera de muestra en $\mathcal{H}_2$, el delta de Sharpe respecto a un

baseline sin calibrar, y un término de penalización por inestabilidad. La configuración con mayor score acumulado avanza a la etapa siguiente, y las decisiones previas no se reabren.

3.10. Validación rolling de tres horizontes

La arquitectura de validación se implementa mediante ventanas móviles (*rolling windows*) que recorren el tiempo, generando múltiples particiones independientes de $\mathcal{H}_1$, $\mathcal{H}_2$ y $\mathcal{H}_3$. Para el escenario con pandemia se usaron 10 ventanas de calibración, 4 de test P4 y 3 de validación; para el escenario sin pandemia, 3, 1 y 1 respectivamente.

Cada ventana produce una evaluación completa del pipeline: calibración de BL sobre $\mathcal{H}_1$, generación de portafolios en $\mathcal{H}_2$, y simulación Monte Carlo P4 en $\mathcal{H}_3$. Las métricas agregadas (mejora de Sharpe, delta de drawdown, porcentaje de ventanas donde BL es recomendado sobre Markowitz base) se reportan por perfil de riesgo y escenario de datos.

El protocolo también registra métricas de dinámica del portafolio: turnover medio, número efectivo de activos (N_{eff}) y concentración sectorial (HHI) durante el horizonte de test limpio. Estas métricas permiten evaluar si la mejora financiera de BL es operacionalmente sostenible o viene acompañada de rotación y concentración excesivas.

3.11. Simulación de sensibilidad de la comisión $K\%$

3.11.1. Objetivo

El objetivo es determinar el valor de la comisión $K\%$ que maximiza el Score P4 del recomendador, entendiendo cómo afecta simultáneamente la riqueza del cliente, la utilidad de FinPUC y la tasa de retiro.

3.11.2. Diseño experimental

Se evalúan 8 valores de comisión: $K \in \{0.25\%, 0.5\%, 0.75\%, 1\%, 1.5\%, 2\%, 3\%, 5\%\}$. Para cada K , se ejecuta la simulación Monte Carlo completa: 5 000 trayectorias $\times$ 260 semanas $\times$ 5 perfiles $\times$ 4 metodologías (Equiponderado, Markowitz, Mínima Varianza, BL Momentum General calibrado). Los retornos semanales se simulan como normales i.i.d. con media y volatilidad provenientes de los KPIs de la Entrega 2, usando el escenario proyectado neutro (sin shift $\pm 0.5\sigma$).

La comisión se aplica en dos momentos: (a) comisión inicial de $K\%$ sobre $C_0 = 1\,000$ USD al aceptar la primera recomendación, y (b) comisión de $K\%$ sobre el 5% de la riqueza actual en cada recomendación aceptada posteriormente, donde el 5% representa la fracción de rotación asumida.

3.11.3. Métricas

Para cada combinación (K , metodología, perfil) se calculan: riqueza terminal media, tasa de retiro media, utilidad empresa media, y el Score P4 definido en la Ecuación (5.1). El K óptimo es aquel que maximiza el Score P4 promedio sobre todas las metodologías y perfiles.

3.12. Optimización multiobjetivo de λ

3.12.1. Objetivo

Determinar el parámetro de balance $\lambda \in [0, 1]$ que optimiza el desempeño conjunto del recomendador, ponderando explícitamente el retorno del cliente y la utilidad de la empresa.

3.12.2. Formulación

Para cada λ , se define el score compuesto:

$$S_\lambda(w) = \lambda \cdot f_1(w) + (1 - \lambda) \cdot f_2(w), \quad (3.21)$$

donde $f_1(w) = \mathbb{E}[w^\top r]$ es el retorno esperado anualizado del portafolio y $f_2(w) \propto K \cdot P_2(\text{return}) \cdot (1 - P_1(\text{loss}))$ es la utilidad esperada de FinPUC. Ambas funciones se normalizan mediante *min-max scaling* al rango $[0, 1]$ antes de combinar, usando los valores mínimos y máximos observados en todo el experimento.

3.12.3. Diseño experimental

Se evalúan 11 valores de λ en grilla discreta: $\lambda \in \{0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0\}$. Cada λ se prueba con el K óptimo determinado en la sección anterior y con la metodología de mejor Score P4. Para cada λ , se ejecuta Monte Carlo con 5 000 trayectorias y se calcula el Score P4 resultante, la riqueza terminal y la utilidad empresa.

Los resultados se presentan como una frontera de Pareto cliente vs. empresa, donde cada λ define un punto en el espacio $(f_1(w), f_2(w))$. El λ óptimo es aquel que maximiza el Score P4 observado, y se compara con el λ que maximiza un score ponderado que asigna igual importancia a riqueza y utilidad normalizadas.

3.13. Comparación de modelos de abandono y *views*

3.13.1. Modelos de probabilidad de abandono

Se comparan tres versiones del modelo de abandono:

- **v1:** Modelo base con activación de P_1 por tolerancia de pérdida del perfil y P_2 por umbral de retorno ofrecido, con sensibilidad $s = 20$.
- **v1+:** Extiende v1 incorporando una restricción de ruina homogénea para todas las simulaciones: si la riqueza del cliente cae por debajo del 10% de C_0 , el abandono es forzoso. Esto homogeniza el tratamiento de escenarios extremos entre *views* y permite aislar el efecto de la calibración de la *view* de diferencias en la regla de abandono.
- **v2:** Reemplaza el gatillo de pérdida respecto a C_0 por *drawdown* respecto al máximo histórico de riqueza, representando mejor la percepción de pérdida del cliente.

Los tres modelos se evalúan bajo el mismo protocolo de validación de tres horizontes, y se comparan en términos de tasa de retiro, riqueza terminal y estabilidad del ranking P4 entre *views*.

3.13.2. Comparación de *views*

Las cuatro familias de *views* se comparan bajo el modelo de abandono v1+ y la configuración BL calibrada:

- **Desempleo macro:** tasa de desempleo asumida de 4% frente a 5% neutral, con $\beta = 1.5$. Favorece sectores cíclicos sobre defensivos.
- **Momentum general:** 20 activos long y 20 short sobre los 601 activos, con *lookback* de 252 días.

- **Momentum top/bottom 1Y:** 20 long y 20 short sobre el top 40 por capitalización, con *lookback* de 252 días.
- **Momentum top market-cap 6M:** 10 long y 10 short sobre el top 20 por capitalización, con *lookback* de 126 días.

La comparación se concentra en tres dimensiones: (a) mejora de Sharpe fuera de muestra, (b) mejora de Score P4 frente a Markowitz base, y (c) estabilidad operacional medida por turnover, concentración sectorial (HHI) y número efectivo de activos (N_{eff}).

4. SUPUESTOS

Datos y mercado. Se asume que los precios de cierre y dividendos de los CSV representan adecuadamente la información disponible para cada activo, por lo que el retorno total incorpora reinversión implícita de dividendos. La matriz de retornos se construye con `join="inner"`, suponiendo que eliminar fechas no comunes no introduce un sesgo relevante. La metadata de capitalización de mercado se considera suficiente para construir el benchmark y los pesos de equilibrio de Black-Litterman, aunque puede existir sesgo de supervivencia. Las carteras son *long-only*, cumplen $w_i \geq 0$ y $\sum w_i = 1$, no usan apalancamiento y permiten divisibilidad perfecta de acciones. La optimización omite costos de transacción, impuestos, *spreads* bid-ask, restricciones de liquidez, impacto de mercado y *slippage*; en Monte Carlo, estos costos se aproximan con una comisión de $k = 1\%$ sobre transacciones. La tasa libre de riesgo se mantiene constante en $R_f = 2\%$ anual.

Supuestos estadísticos. Los retornos históricos se usan como información para estimar retornos y riesgos futuros, bajo estabilidad temporal parcial de μ y Σ . Para estabilizar la covarianza muestral se aplica *shrinkage* de 20%: $\Sigma_{\text{shrink}} = (1 - \lambda)\Sigma + \lambda \cdot \text{diag}(\Sigma)$, con $\lambda = 0.20$. La anualización considera 252 días hábiles y escala la volatilidad por $\sqrt{252}$. En la simulación Monte Carlo, los retornos semanales se aproximan mediante $\mathcal{N}(\mu_{\text{sem}}, \sigma_{\text{sem}}^2)$, aun cuando el análisis distribucional muestra colas pesadas y curtosis elevada en los retornos diarios.

Optimización y rebalanceo. Los problemas formulados en CVXPY se tratan como convexos y adecuados para representar la decisión de inversión. Si una cota de volatilidad vuelve infactible un perfil, se relaja solo esa restricción. El portafolio de tangencia se aproxima eligiendo el mayor Sharpe dentro de la frontera eficiente discretizada, usando 30 puntos en Markowitz y 12 en Black-Litterman. En Black-Litterman, las *views* no requieren cubrir todos los activos: aquellos sin *view* explícita conservan el prior de equilibrio π y reciben ajustes indirectos por correlación a través de Σ . Las variantes por capitalización usan subconjuntos de 20 a 40 activos, mientras que momentum general y desempleo consideran los 601 activos. El rebalanceo se realiza cada 126 días hábiles; entre rebalanceos los pesos permanecen constantes y, en cada fecha, la ventana de entrenamiento incorpora solo retornos ya observados.

Experimento pandemia. La comparación entre escenarios “con pandemia” y “sin pandemia” mantiene fijo el período futuro fuera de muestra. Por ello, las diferencias se

interpretan como efecto de la información utilizada para calibrar los modelos, no como cambios en el mercado futuro. La base sin pandemia excluye las observaciones de 2020–2022, mientras que la base con pandemia las conserva.

Simulación Monte Carlo (P4). Cada cliente inicia con $C_0 = 1\,000$ USD. La comisión es $k = 1\%$, aplicada sobre C_0 al inicio y sobre el 5% de la riqueza actual en cada recomendación aceptada, como fracción de rotación asumida. La pérdida se mide respecto de C_0 y no del máximo histórico de riqueza, de modo que una caída posterior a una ganancia no activa P_1 mientras la riqueza siga sobre el capital inicial. La sensibilidad logística $s = 20$ escala las diferencias decimales de P_1 y P_2 ; para el perfil muy conservador, con tolerancia 0%, cualquier pérdida genera una probabilidad de retiro cercana a 1. Los escenarios proyectados se definen como $R_{\text{base}} \pm 0.5\sigma$, formando un abanico simétrico; aunque los retornos reales pueden presentar asimetría negativa, esta aproximación es suficiente para el objetivo académico. Se ejecutan 5 000 simulaciones por combinación, cantidad considerada adecuada para estabilizar riqueza terminal, tasa de retiro y utilidad de la empresa.

Sensibilidad. El impacto de los supuestos se evalúa mediante tres ejercicios: comparación del entrenamiento con y sin pandemia, midiendo el delta de Sharpe por portafolio y técnica; validación con 70 splits aleatorios y 18 ventanas móviles robustas, con horizontes desde $h2_f7$ hasta $h7_f2$; y proyecciones Monte Carlo desfavorable, neutra y favorable, modificando el retorno esperado en $\pm 0.5\sigma$ para observar cambios en riqueza terminal, tasa de retiro y utilidad de la empresa.

Supuestos de la Entrega 3. La Tabla 4.1 resume los supuestos específicos de la tercera fase del proyecto, adicionales a los ya establecidos en la Entrega 2.

Tabla 4.1. Supuestos adicionales de la Entrega 3.

Supuesto	Valor
Valores de K evaluados	0.25%, 0.5%, 0.75%, 1%, 1.5%, 2%, 3%, 5%
Valores de λ evaluados	0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0
K usado en optimización de f_1 y f_2	Valor óptimo del análisis de sensibilidad
Normalización de f_1 y f_2	Min-max scaling al rango $[0, 1]$
Metodología para λ	La de mejor Score P4 del análisis de K
P_1 y P_2 en v1+	Logísticas con $s = 20$, P_1 activa solo si pérdida > tolerancia
Restricción de ruina en v1+	Abandono forzoso si riqueza < 10% de C_0
Configuración BL congelada	View desempleo, $U = 4\%$, $\beta = 1.5$, $q_{\text{scale}} = 1.5$, $c = 0.50$, $\tau = 0.20$
Turnover por recomendación	5% de la riqueza actual
Retornos semanales en Monte Carlo	Normales i.i.d. con KPIs de Entrega 2
Horizontes de validación	$\mathcal{H}_1$ calibración, $\mathcal{H}_2$ validación, $\mathcal{H}_3$ test limpio P4

5. KPIS

Los KPIS se definieron para decidir qué combinación de técnica, *view* y perfil conviene recomendar.

- **Retorno total rebalanceado:** $R_{\text{total}} = \prod_t (1 + r_t) - 1$. Mide la ganancia acumulada fuera de muestra. Se usa para comparar el resultado final de cada cartera.
- **Retorno anualizado:** $R_{\text{anual}} = (1 + R_{\text{total}})^{1/T} - 1$. Normaliza el retorno por año y permite comparar horizontes de distinta duración.
- **Volatilidad anualizada:** $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \sqrt{252}$. Mide la variabilidad del retorno. Sirve para descartar alternativas demasiado inestables para el perfil del cliente.
- **Ratio de Sharpe rebalanceado:** $\text{Sharpe} = (R_{\text{anual}} - R_f) / \sigma_{\text{anual}}$, con $R_f = 0.02$. Resume retorno ajustado por riesgo. Es el principal KPI para comparar eficiencia financiera entre técnicas.
- **Máximo drawdown:** mayor caída porcentual desde un máximo acumulado de riqueza. Evalúa la pérdida que el cliente habría tenido que tolerar, por lo que pesa especialmente en perfiles conservadores.
- **CVaR diario al 95%:** pérdida promedio en el 5% peor de días (Rockafellar & Uryasev, 2000). Se usa para medir riesgo de cola y evitar carteras con pérdidas extremas demasiado severas.
- **Riqueza terminal esperada:** valor final promedio desde $C_0 = 1\,000$ USD en las 5 000 simulaciones Monte Carlo. Traduce el desempeño financiero a una cifra monetaria para el cliente.
- **Probabilidad de ganancia:** proporción de simulaciones en que la riqueza terminal supera C_0 . Indica qué tan probable es que el cliente termine el horizonte con utilidad.
- **Tasa de retiro:** proporción de simulaciones en que el cliente abandona antes del final por superar su tolerancia de pérdida. Afecta la decisión porque reduce la continuidad del cliente y las comisiones futuras.
- **Utilidad por comisiones:** ingreso esperado de FinPUC con comisión $k = 1\%$, incluyendo comisión inicial y comisiones por recomendaciones aceptadas. Mide el atractivo de la alternativa para la empresa.
- **Tasa de aceptación de recomendaciones:** proporción de recomendaciones aceptadas según P_2 . Una tasa baja indica que la cartera no supera el umbral de atractivo del perfil, reduciendo rotación y utilidad.

- **Score P4 con K variable:**

$$\text{Score}_{P4} = \mathbb{E}[\text{Riqueza terminal}] + \mathbb{E}[\text{Utilidad empresa}(K)] - C_0 \cdot \text{Tasa de retiro}(K). \quad (5.1)$$

Generaliza el Score P4 de la Entrega 2 haciendo explícita la dependencia en K tanto de la utilidad como de la tasa de retiro. Valores altos de K aumentan la utilidad pero también la probabilidad de que el cliente abandone.

- **Score multiobjetivo:**

$$S_\lambda = \lambda \cdot \tilde{f}_1 + (1 - \lambda) \cdot \tilde{f}_2, \quad (5.2)$$

donde $\tilde{f}_1$ y $\tilde{f}_2$ son las versiones normalizadas (min-max) del retorno esperado del cliente y la utilidad de la empresa, respectivamente. Mide el desempeño conjunto bajo una prioridad explícita λ .

- **Mejora de Sharpe ΔSharpe :** diferencia entre el Sharpe de un portafolio Black-Litterman calibrado y el Sharpe del Markowitz base equivalente, evaluados en el mismo horizonte de test. Un valor positivo indica que la calibración agrega valor sobre la estimación histórica pura.
- **Turnover medio:** promedio de $\|w_t - w_{t-1}\|_1/2$ a lo largo del horizonte de evaluación. Mide la fracción del portafolio que se rota en cada rebalanceo; valores altos implican mayores costos operacionales implícitos.
- **Número efectivo de activos:** $N_{\text{eff}} = 1/\sum_i w_i^2$. Cuantifica la concentración del portafolio: $N_{\text{eff}} = N$ indica pesos uniformes, mientras que $N_{\text{eff}} \rightarrow 1$ indica concentración en pocos activos.
- **Concentración sectorial (HHI):** $\text{HHI} = \sum_s (\sum_{i \in s} w_i)^2$, donde s indexa los sectores económicos. Valores cercanos a 1 indican concentración en un solo sector; valores bajos indican diversificación.

6. CASO BASE

6.1. Benchmark equiponderado

El caso base se define como un benchmark equiponderado compuesto por los 20 activos con mayor capitalización bursátil dentro del universo de 601 acciones. Cada activo seleccionado recibe un peso de $1/20 = 5\%$, mientras que los 581 activos restantes quedan con peso cero.

La elección de este benchmark se justifica porque entrega una referencia simple, reproducible y exigente. Al no utilizar μ ni Σ , no depende de estimaciones de retorno esperado ni de covarianza, por lo que evita el error de estimación propio de los modelos optimizados. En consecuencia, una metodología que no logra superarlo en retorno ajustado por riesgo tiene un valor agregado limitado.

Además, el benchmark distribuye el capital entre las empresas más grandes del universo, entregando una diversificación básica y estable sin requerir supuestos adicionales. Como su composición no cambia con la ventana de entrenamiento, mantiene las mismas métricas en los escenarios con y sin pandemia. Esto lo convierte en un punto de comparación adecuado para aislar el efecto de la estimación de parámetros en Markowitz y Black-Litterman.

6.2. Métricas del caso base

La Tabla 6.1 presenta los KPIs del benchmark equiponderado. Al ser independiente de la ventana de entrenamiento, las métricas son idénticas en ambos escenarios (con y sin pandemia).

Tabla 6.1. KPIs del benchmark equiponderado top-20 (horizonte h7_f2, 601 activos, rebalanceo semestral).

Indicador	Valor
Retorno total rebalanceado	101.4%
Retorno anualizado	41.9%
Volatilidad anualizada	19.5%
Máximo drawdown	-21.9%
CVaR diario 95%	2.8%
Ratio de Sharpe rebalanceado	2.05

El benchmark captura un retorno bruto alto (101.4% en 2 años), pero a costa de una volatilidad y un drawdown significativamente mayores que los portafolios optimizados. Su Sharpe de 2.05 establece el umbral mínimo de desempeño: las técnicas que no superen este valor no aportan beneficio neto respecto a una regla de asignación trivial. En la práctica, el Markowitz con datos de pandemia (Sharpe 2.02) apenas iguala al benchmark, mientras que las mejores variantes de Black-Litterman lo superan (hasta Sharpe 2.38 con momentum por capitalización a 6 meses).

6.3. Validación como línea base

El benchmark también se evalúa en la simulación Monte Carlo (Capa 3). En el escenario neutro, el benchmark equiponderado genera una riqueza terminal media de USD 4 234 con una tasa de retiro de 22.9% y una utilidad empresa media de USD 234. Estos valores sirven como referencia para evaluar si las técnicas optimizadas mejoran simultáneamente la experiencia del cliente (mayor riqueza, menor retiro) y el negocio de FinPUC (mayor utilidad por comisiones).

6.4. Caso base para la Entrega 3

Para la evaluación de los nuevos parámetros de negocio, se define un caso base adicional: Markowitz sin calibrar, con $K = 1\%$ y Score P4 sin ponderación explícita (λ implícito de 0.5 en el Score P4 original). Este caso base es el punto de comparación contra el cual se mide la mejora obtenida al calibrar K y λ . Las métricas de referencia para este caso base, medidas en el horizonte de test limpio, se presentan en la Tabla 6.2.

Tabla 6.2. Score P4 del caso base (Markowitz sin calibrar, $K = 1\%$) en test limpio.

Escenario	Perfil	Riqueza	Retiro	Utilidad	Score P4
Sin pandemia	Neutro	USD 2 797	0.9%	USD 194	2 982
Sin pandemia	Conservador	USD 2 508	15.8%	USD 196	2 546
Con pandemia	Conservador	USD 2 369	13.0%	USD 188	2 427
Con pandemia	Neutro	USD 2 623	0.7%	USD 176	2 792

7. IMPLEMENTACIÓN Y HERRAMIENTAS

7.1. Implementación y herramientas

La implementación se desarrolló en Python 3.11 y quedó organizada en tres notebooks finales, ejecutados en orden:

- (i) `markowitz_vs_benchmark_rebalanceo_pandemia.ipynb`: optimiza carteras Markowitz, calcula el benchmark top-20, aplica rebalanceo semestral y compara escenarios con y sin pandemia.
- (ii) `black_litterman.ipynb`: construye portafolios Black-Litterman usando las mismas métricas y perfiles, con views de momentum, desempleo, momentum top-20 a 6 meses y momentum top-20/bottom-20 a 1 año.
- (iii) `p4_montecarlo_recomendador_portafolios.ipynb`: usa los KPIs anteriores como insumo y simula 5 000 trayectorias para las 180 combinaciones evaluadas.

El código computacional se encuentra disponible en el repositorio GitHub del proyecto. El Anexo N°4 documenta la estructura de estos notebooks, los archivos CSV generados y la relación entre código, supuestos, KPIs y resultados experimentales.

Las principales herramientas fueron **Pandas** para manejo de datos y exportación a CSV, **NumPy/SciPy** para cálculo numérico y simulación, **CVXPY** para resolver los problemas de optimización, **Matplotlib** para gráficos, y **Hashlib** para semillas deterministas en Monte Carlo.

La trazabilidad se asegura mediante carpetas `outputs/` por notebook. Cada etapa exporta CSV con pesos, KPIs, validaciones, rankings o simulaciones, y esos archivos son los que alimentan las tablas y figuras del informe. Además, los notebooks incluyen checklists finales que verifican archivos esperados, conteos por escenario/técnica/perfil y ausencia de NaN en columnas críticas.

7.2. Pipeline de la Entrega 3

La tercera fase añade cinco bloques computacionales al pipeline, ejecutados en el siguiente orden:

- (i) `calibracion_secuencial_bl.py`: ejecuta la calibración en cinco etapas sobre $\mathcal{H}_1$ con validación en $\mathcal{H}_2$, congelando la mejor configuración de hiperparámetros BL.
- (ii) `validacion_3h_rolling_bl.py`: aplica validación rolling de tres horizontes sobre la configuración congelada, generando métricas de Sharpe, draw-down y dinámica de portafolio para todas las ventanas.
- (iii) `simulacion_comisiones_k.ipynb`: ejecuta la simulación de sensibilidad de $K\%$, evaluando 8 valores de comisión $\times$ 4 metodologías $\times$ 5 perfiles con 5 000 trayectorias Monte Carlo.
- (iv) `simulacion_lambda_multiobjetivo.ipynb`: evalúa 11 valores de λ bajo el K óptimo, construyendo la frontera de Pareto cliente vs. empresa.
- (v) `generar_informes_probabilidad_abandono.py`: ejecuta la comparación de tres modelos de abandono ($v1$, $v1+$, $v2$) bajo las cuatro familias de *views* con la configuración BL calibrada.

Todos los notebooks y scripts utilizan las mismas librerías que la Entrega 2 (Pandas, NumPy/SciPy, CVXPY, Matplotlib, Hashlib), y los outputs se organizan en carpetas `outputs/` por módulo, manteniendo la trazabilidad del proyecto.

8. RESULTADOS Y ANÁLISIS

8.1. Análisis distribucional de retornos

El análisis distribucional se aplicó a los 601 tickers del universo F5 sin pandemia, con 4 207 ajustes paramétricos. La Tabla 8.1 resume los estadísticos transversales y muestra dos rasgos centrales: la curtosis excedente es muy superior a la normalidad en casi todos los activos, con mediana 26,9 frente a 0 bajo normalidad, y la asimetría mediana es positiva (0,90), lo que sugiere colas derechas más pesadas en el universo filtrado. El detalle completo del ajuste por distribuciones se presenta en el Anexo N°3.

Tabla 8.1. Resumen transversal de estadísticos por ticker (universo F5 sin pandemia).

Variable	Mín.	Mediana	Media	Máx.
<i>n</i> retornos	2 518	7 949	8 263	15 400
Media diaria	0,011%	0,093%	0,102%	0,577%
Vol. anualizada	19,3%	36,5%	39,6%	214,9%
VaR 5%	-6,18%	-3,04%	-3,18%	-1,63%
CVaR 5%	-10,93%	-4,81%	-5,09%	-2,52%
Asimetría	-8,40	0,90	3,44	99,13
Curtosis exc.	3,42	26,90	179,07	10 151

La Tabla 8.2 confirma que la normal no es seleccionada como mejor distribución para ningún ticker, y las tres pruebas de normalidad rechazan la hipótesis nula al 5% en los 601 casos. AIC y BIC coinciden en 532 tickers (88,5%), aunque sus diferencias son informativas: AIC favorece Johnson SU por su flexibilidad para capturar asimetrías, mientras BIC prefiere t-Student por capturar colas pesadas con mayor parsimonia.

Tabla 8.2. Mejor familia distribucional según AIC y BIC.

Distribución	AIC	%	BIC	%
Johnson SU	247	41,1	180	30,0
t-Student	179	29,8	241	40,1
Normal generalizada	174	29,0	176	29,3
Laplace	1	0,2	4	0,7
Normal/log./skew-n.	0	0,0	0	0,0

La prueba KS aproximada entrega valores-p mayores a 0,05 solo para el 36,5% del universo bajo la mejor distribución. Por tanto, aunque las familias seleccionadas mejoran sustantivamente el supuesto normal, una distribución paramétrica estática no captura por completo dependencia temporal, volatilidad condicional ni cambios de régimen. La implicancia directa es que la simulación Monte Carlo, al asumir retornos semanales normales, tiende a subestimar eventos extremos; por ello, sus resultados de riqueza terminal y tasa de retiro deben interpretarse como estimaciones bajo un régimen “normal”, no como predicciones robustas ante crisis.

8.2. Markowitz vs benchmark

La Tabla 8.3 compara los KPIs del mejor portafolio Markowitz con el benchmark equiponderado en ambos escenarios de entrenamiento.

Tabla 8.3. Comparación Markowitz vs benchmark (horizonte h7_f2, 601 activos, rebalanceo semestral).

Escenario	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	CVaR 95%	Sharpe
Sin pandemia	Ideal de mercado	76,5%	32,8%	12,3%	−12,6%	1,7%	2,51
Sin pandemia	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,8%	2,05
Con pandemia	Muy conservador	54,5%	24,3%	11,0%	−10,2%	1,5%	2,02
Con pandemia	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,8%	2,05

Sin pandemia, el portafolio Ideal de mercado logra el mayor Sharpe del experimento (2,51), 0,46 puntos sobre el benchmark. Sin embargo, su retorno bruto es menor (76,5% vs 101,4%) y la mejora proviene de una volatilidad más baja (12,3% vs 19,5%) y un drawdown más contenido (−12,6% vs −21,9%). Con pandemia, el mejor Markowitz pasa a ser Muy conservador con Sharpe 2,02, prácticamente igual al benchmark, lo que muestra que incluir 2020–2022 en la estimación de μ y Σ reduce la capacidad del modelo para superar una regla simple.

8.2.1. Impacto de la pandemia en Markowitz

La Figura 8.1 muestra el delta de Sharpe, definido como escenario con pandemia menos escenario sin pandemia. El deterioro es generalizado y aumenta con la agresividad del perfil: Ideal de mercado pierde 1,11 puntos, Muy arriesgado 0,86 y Arriesgado 0,57, mientras que Mínima varianza (−0,09) y Benchmark (−0,00) son casi inmunes.

Esto confirma que la sensibilidad a la pandemia crece con la dependencia del modelo respecto de retornos esperados, precisamente el componente más afectado por el shock.




Figura 8.1. Delta de Sharpe por inclusión de pandemia en el entrenamiento.

8.2.2. Validación robusta

La validación por ventanas móviles confirma que horizontes más largos de entrenamiento producen mejores Sharpe futuros: h7_f2 alcanza 2,32 y el desempeño decrece monotónicamente hasta 1,35 en h2_f7. Los 70 splits aleatorios también identifican h7_f2 como el horizonte óptimo oficial para Markowitz.

8.3. Black-Litterman

La variante momentum top-20 a 6 meses domina en ambos escenarios, con Sharpe 2,46 sin pandemia y 2,38 con pandemia. Esta *view* opera sobre un universo reducido, top 20 por capitalización con 10 posiciones long y 10 short y 126 días de *lookback*, combinando liquidez con señal de momentum de mediano plazo. La *view* de desempleo es la segunda más competitiva y, con pandemia, obtiene Sharpe 2,36 en el perfil Arriesgado, 0,34 puntos sobre Markowitz puro. En cambio, momentum general, con 20 long y 20 short sobre los 601 activos, es la más volátil: sin pandemia llega a 2,38, pero con pandemia cae a 2,06, apenas igualando al benchmark.

Tabla 8.4. Mejor portafolio Black-Litterman por *view* y escenario (horizonte h7 f2).

Escenario	View	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	CVaR 95%	Sharpe
Sin pandemia	mom. top20 6m	Neutro	72,3%	31,2%	11,9%	−12,9%	1,6%	2,46
Sin pandemia	desempleo	Neutro	63,1%	27,7%	10,5%	−10,4%	1,4%	2,44
Sin pandemia	momentum	Muy conserv.	64,0%	28,1%	10,9%	−10,1%	1,5%	2,38
Sin pandemia	mom. top20-b20 1y	Conservador	63,1%	27,7%	10,9%	−10,7%	1,5%	2,35
Con pandemia	mom. top20 6m	Neutro	69,5%	30,2%	11,9%	−11,7%	1,6%	2,38
Con pandemia	desempleo	Arriesgado	71,9%	31,1%	12,4%	−13,3%	1,7%	2,36
Con pandemia	mom. top20-b20 1y	Neutro	65,6%	28,7%	12,1%	−12,8%	1,7%	2,20
Con pandemia	momentum	Conservador	56,4%	25,0%	11,2%	−10,3%	1,5%	2,06

La mejora de BL frente a Markowitz se concentra en el escenario con pandemia. La mayor ganancia aparece en BL desempleo/Arriesgado, con 1,19 puntos adicionales de Sharpe respecto del Markowitz equivalente. Sin pandemia, la brecha es menor porque Markowitz ya funciona bien con estimaciones históricas estables. Así, el principal valor de Black-Litterman es defensivo: ancla las estimaciones al equilibrio de mercado y reduce errores durante períodos de estrés.

8.4. Simulación Monte Carlo (P4)

La Tabla 8.5 resume los promedios por técnica en el escenario proyectado neutro, promediando los cinco perfiles de riesgo.

El Equiponderado lidera en riqueza bruta (USD 4 234), pero mantiene una tasa de retiro alta (22,9%). BL Momentum Top20 6M ofrece un equilibrio más atractivo: riqueza

Tabla 8.5. Promedios por técnica en escenario neutro (promedio de perfiles).

Técnica	View	Riqueza media	Retiro prom.	Utilidad empresa	Prob. ganancia
Equiponderado	No aplica	USD 4 234	22,9%	USD 234	77,1%
BL Mom. Top20 6M	momentum_top20_6m	USD 4 123	18,6%	USD 253	81,3%
BL Momentum	momentum	USD 3 698	24,9%	USD 223	74,6%
BL Mom. Top20-B20 1Y	mom_top20_bottom20_1y	USD 3 213	19,9%	USD 174	79,8%
BL Desempleo	desempleo	USD 3 055	18,7%	USD 160	81,2%
Markowitz	Retornos históricos	USD 2 970	21,3%	USD 159	77,6%

similar (USD 4 123), menor retiro (18,6%), mayor utilidad para la empresa (USD 253) y la mayor probabilidad de ganancia (81,3%). Markowitz queda último en riqueza media (USD 2 970), reforzando que, sin *views*, no genera suficiente valor para el cliente promedio.

Para ordenar alternativas se usa el Score P4:

$$\text{Score}_{P4} = E[\text{Riqueza terminal}] + E[\text{Utilidad empresa}] - C_0 \cdot \text{Tasa de retiro.} \quad (8.1)$$

El sistema recomienda la combinación con mayor Score P4, siempre que sus KPIs de riesgo sean consistentes con el perfil evaluado. La Tabla 8.6 presenta el top 5 del escenario neutro.

Tabla 8.6. Top 5 ranking P4 en escenario neutro.

Rank	Escenario	Técnica	Perfil	Riqueza	Retiro	Utilidad	Score P4
1	Con pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 8 974	3,1%	USD 474	9 417
2	Sin pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 7 753	2,0%	USD 419	8 151
3	Con pandemia	BL Momentum	Muy arriesgado	USD 6 436	14,6%	USD 335	6 625
4	Sin pandemia	BL Momentum	Muy arriesgado	USD 5 568	12,8%	USD 302	5 831
5	Con pandemia	BL Mom. Top20 6M	Arriesgado	USD 5 212	3,8%	USD 285	5 486

BL Momentum Top20 6M con perfil Muy arriesgado y datos de pandemia domina el ranking con Score 9 417, combinando la mayor riqueza terminal (USD 8 974), baja tasa de retiro para un perfil agresivo (3,1%) y la mayor utilidad para la empresa (USD 474). Su ventaja se explica por la concentración de la señal de momentum en activos líquidos y estables, el *lookback* de 126 días que captura tendencias de mediano plazo sin sobreajustar movimientos breves, y la alta tolerancia del perfil Muy arriesgado (40%), que hace que P_1 casi nunca se active.

Los ganadores cambian según el escenario proyectado. En el favorable domina BL Momentum / Muy arriesgado / Con pandemia, con riqueza esperada de USD 12 786; en el neutro gana BL Momentum Top20 6M / Muy arriesgado / Con pandemia, con USD 8 974; y en el desfavorable lidera Equiponderado / Muy arriesgado / Sin pandemia, con USD 3 759. Esta rotación es consistente: en condiciones favorables domina la estrategia más agresiva sobre 601 activos, en condiciones desfavorables protege mejor el Equiponderado por no depender de estimaciones deterioradas, y en el escenario neutro sobresale BL Momentum Top20 6M por equilibrar momentum y estabilidad del prior de mercado.

8.5. Análisis integrado

La Tabla 8.7 sintetiza el mejor resultado de cada modelo por escenario.

Tabla 8.7. Comparación final: mejor portafolio por modelo y escenario.

Escenario	Modelo	View	Portafolio	Ret. total	Sharpe	Drawdown
Sin pandemia	Markowitz	Ret. históricos	Ideal de mercado	76,5%	2,51	−12,6%
Sin pandemia	Black-Litterman	mom. top20 6m	Neutro	72,3%	2,46	−12,9%
Sin pandemia	Equiponderado	No aplica	Benchmark	101,4%	2,05	−21,9%
Con pandemia	Black-Litterman	mom. top20 6m	Neutro	69,5%	2,38	−11,7%
Con pandemia	Black-Litterman	desempleo	Arriesgado	71,9%	2,36	−13,3%
Con pandemia	Equiponderado	No aplica	Benchmark	101,4%	2,05	−21,9%
Con pandemia	Markowitz	Ret. históricos	Muy conserv.	54,5%	2,02	−10,2%

En conjunto, los resultados muestran que sin pandemia Markowitz domina en Sharpe (2,51), aunque depende del portafolio Ideal de mercado y presenta *overfitting*; Black-Litterman ofrece un Sharpe comparable (2,46) con menor dependencia de la estimación de μ . Con pandemia, Black-Litterman lidera con Sharpe 2,38 y 2,36 según la *view*, superando a Markowitz (2,02) por más de 0,3 puntos gracias al prior de equilibrio. El benchmark equiponderado sigue siendo un competidor exigente en retorno bruto (101,4%), pero su volatilidad (19,5%) y drawdown (−21,9%) lo hacen poco adecuado para perfiles conservadores, aunque su Sharpe de 2,05 establece un piso mínimo de desempeño. La validación robusta confirma que el Sharpe futuro cae al reducir la ventana de entrenamiento, y Monte Carlo identifica a BL Momentum Top20 6M como la mejor alternativa por Score P4, al combinar alta riqueza terminal, baja tasa de retiro y mayor utilidad para la empresa.

Las limitaciones principales se relacionan con supuestos simplificadores que conviene abordar en la siguiente etapa. La simulación Monte Carlo usa retornos normales pese al rechazo empírico de normalidad; reemplazarlos por t-Student o Johnson SU produciría colas más realistas y posiblemente mayores tasas de retiro. Además, P4 mide pérdida respecto al capital inicial y no al máximo alcanzado, por lo que usar *drawdown* como gatillo de P_1 representaría mejor la percepción de pérdida del cliente. También falta sensibilizar $s = 20$, ya que cambios en este parámetro modificarían las tasas de retiro y aceptación. Por último, la *view* de desempleo usa una tasa fija de 4% frente a 5% neutral en lugar de datos macroeconómicos observados; los escenarios proyectados son simétricos ($\pm 0,5\sigma$), ignorando asimetría negativa; y la optimización no incorpora costos de transacción explícitos, por lo que agregar restricciones o penalizaciones de rotación reduciría el *turnover* y alinearía mejor la optimización con la simulación.

8.6. Calibración secuencial de Black-Litterman

La Tabla 8.8 resume los ganadores de cada etapa de calibración y sus métricas asociadas.

Tabla 8.8. Ganadores por etapa de calibración secuencial sobre $\mathcal{H}_1$.

Etapa	Ganador	Sharpe medio	Δ Sharpe	Score
Stage 1 (familia <i>view</i>)	Desempleo	0.854	0.159	0.897
Stage 2 (estructura P)	$U = 4\%, \beta = 1.5$	0.855	0.160	0.650
Stage 3 (intensidad Q)	$q_{\text{scale}} = 1.5$	0.855	0.160	0.650
Stage 4 (confianza Ω)	$c = 0.50$	0.855	0.160	0.950
Stage 5 (τ)	$\tau = 0.20$	0.857	0.162	0.723

La Figura 8.2 muestra la trayectoria del score de calibración a lo largo de las cinco etapas. La elección inicial de la familia de *view* (Stage 1) es la decisión de mayor impacto: desempleo macro es seleccionada sobre momentum general porque, aunque esta última entrega señales financieras más intensas, la *view* macro ofrece mayor estabilidad en el Sharpe fuera de muestra dentro de $\mathcal{H}_1$. Las etapas posteriores refinan la configuración sin cambiar la familia, y el score converge al alza en cada etapa.

La configuración congelada final es: *view* de desempleo macro con $U = 4\%, \beta = 1.5, q_{\text{scale}} = 1.5, c = 0.50, \tau = 0.20$. Esta configuración se utiliza en todos los experimentos subsiguientes de $K\%, \lambda$, comparación de *views* y modelos de abandono.




Figura 8.2. Camino de calibración: evolución del score en las cinco etapas.

8.6.1. Sensibilidad de la calibración

La Figura 8.3 muestra el efecto de variar la confianza c sobre el Sharpe fuera de muestra: valores bajos ($c = 0.25$) diluyen la *view* y producen portafolios cercanos al prior de equilibrio, mientras que valores altos ($c = 1.00$) generan portafolios más concentrados y volátiles. El óptimo en $c = 0.50$ balancea ambas fuerzas.




Figura 8.3. Sensibilidad del Sharpe a la confianza c en Ω .

Análogamente, la sensibilidad a τ (Figura 8.4) muestra que $\tau = 0.20$ maximiza el Sharpe. Valores menores ($\tau = 0.05$) anclan excesivamente los retornos al prior, mientras que valores mayores ($\tau = 1.00$) sobredimensionan la incertidumbre del prior y generan inestabilidad.




Figura 8.4. Sensibilidad del Sharpe a τ .

8.7. Validación rolling de tres horizontes

La Tabla 8.9 presenta los resultados agregados de la validación rolling sobre múltiples ventanas. Para el perfil Muy arriesgado con pandemia, BL calibrado mejora el Sharpe en 3.0% y reduce el drawdown en 6.3%, siendo recomendado sobre Markowitz en el 66.7% de las ventanas de validación. En test P4 limpio, la mejora de Sharpe alcanza 23.1% para el mismo perfil, con 100% de recomendación.

Tabla 8.9. Validación rolling: mejora de BL calibrado vs. Markowitz base.

Horizonte	Escenario/Perfil	Δ Sharpe	Δ Drawdown	% BL recomendado
Validación	con pandemia / Muy arriesgado	+3.0%	+6.3 pp	66.7%
Validación	con pandemia / Muy conservador	-1.6%	+0.1 pp	33.3%
Validación	con pandemia / Conservador	-3.0%	+0.1 pp	33.3%
Test P4	con pandemia / Muy arriesgado	+23.1%	+4.7 pp	100.0%
Test P4	con pandemia / Arriesgado	+19.9%	+7.6 pp	75.0%
Test P4	sin pandemia / Arriesgado	+3.2%	+6.1 pp	100.0%
Test P4	sin pandemia / Muy conservador	+0.2%	+0.1 pp	100.0%

Los resultados muestran un patrón claro: BL calibrado agrega más valor en perfiles agresivos (Muy arriesgado, Arriesgado) y en escenarios con pandemia, donde la estimación histórica de Markowitz es menos confiable. En perfiles conservadores y sin pandemia, la mejora es marginal o negativa, lo que es consistente con que el prior de equilibrio ya está cerca de la solución óptima cuando los datos son estables.

8.8. Sensibilidad de la comisión $K\%$

La Tabla 8.10 presenta los resultados agregados de la simulación de sensibilidad de K , promediando sobre las 4 metodologías y 5 perfiles. El Score P4 alcanza su máximo en un valor intermedio de K , confirmando la existencia de un óptimo que balancea la mayor utilidad por comisiones altas con la menor retención que estas provocan.

Tabla 8.10. Sensibilidad del Score P4 a la comisión K (promedio sobre metodologías y perfiles, escenario neutro).

K	Riqueza media (USD)	Retiro medio	Utilidad media (USD)	Score P4
0.25%	1 813	31.5%	19	1 517
0.50%	1 810	31.4%	38	1 534
0.75%	1 807	31.5%	57	1 549
1.00%	1 813	31.3%	76	1 576
1.50%	1 810	31.6%	114	1 609
2.00%	1 811	31.4%	152	1 649
3.00%	1 808	31.6%	228	1 720
5.00%	1 810	31.6%	380	1 874

El Score P4 crece de forma monótona con K , desde 1 517 en $K = 0.25\%$ hasta 1 874 en $K = 5.0\%$. La riqueza terminal se mantiene prácticamente constante (alrededor de USD 1 810) y la tasa de retiro es estable en torno a 31.5%, independientemente del valor de K . Esto se debe a que, en esta simulación, la comisión se descuenta del capital pero los retornos esperados son lo suficientemente altos como para que la riqueza terminal no se vea afectada de forma significativa por el nivel de comisión. La utilidad de la empresa crece linealmente con K (de USD 19 a USD 380), lo que impulsa el Score P4 al alza. El K óptimo dentro del rango evaluado es 5.0%, que maximiza el Score P4 promedio.

La Figura 8.5 muestra la evolución del Score P4, utilidad y tasa de retiro por perfil de riesgo en función de K .

La mejor combinación individual es Markowitz en perfil Muy arriesgado con $K = 5.0\%$, alcanzando un Score P4 de 2 992 (riqueza USD 2 942, retiro 4.5%, utilidad USD 95). El ranking de las 10 mejores combinaciones está dominado por Markowitz en perfil Muy arriesgado, seguido por BL Momentum Top20 6M en el mismo perfil.




Figura 8.5. Score P4, utilidad FinPUC y tasa de retiro vs. comisión K por perfil de riesgo.

8.9. Optimización multiobjetivo de λ

La Tabla 8.11 muestra el Score P4 para cada valor de λ evaluado, usando el K óptimo y la metodología de mejor desempeño.

Tabla 8.11. Sensibilidad del Score P4 a λ ($K = 5\%$, escenario neutro).

λ	Riqueza media (USD)	Utilidad media (USD)	Retiro medio	Score P4
0.0	1 806	380	31.7%	1 869
0.1	1 812	381	31.6%	1 877
0.2	1 811	380	31.6%	1 875
0.3	1 811	380	31.5%	1 875
0.4	1 808	380	31.6%	1 873
0.5	1 814	380	31.5%	1 879
0.6	1 814	380	31.4%	1 880
0.7	1 816	380	31.4%	1 882
0.8	1 810	380	31.5%	1 875
0.9	1 815	380	31.4%	1 881
1.0	1 813	381	31.3%	1 881

El Score P4 varía muy poco con λ (rango de solo 13 puntos entre 1 869 y 1 882), lo que indica que el parámetro de balance tiene un impacto limitado en el desempeño agregado bajo esta formulación. Esto ocurre porque las funciones f_1 y f_2 son constantes por combinación (perfil, metodología) y no dependen de λ en la simulación: λ solo afecta un score ponderado post-simulación que no modifica las trayectorias de Monte Carlo. El λ que maximiza el Score P4 es 0.7, mientras que el λ que maximiza el score ponderado es 0.0 (toda la ponderación en la utilidad de la empresa).

La mejor combinación individual es $\lambda = 0.5$, Markowitz, perfil Muy arriesgado, con Score P4 de 3 026 (riqueza USD 2 978, retiro 4.7%, utilidad USD 95). La Figura 8.6 muestra la frontera de Pareto cliente vs. empresa y el Score P4 en función de λ .




Figura 8.6. Frontera de Pareto cliente vs. empresa y Score P4 vs. λ .

8.10. Comparación de *views* y modelos de abandono

8.10.1. Modelo de abandono v1+

El modelo v1+, seleccionado como configuración recomendada, incorpora una restricción de ruina homogénea (abandono forzoso si riqueza $< 10\%$ de C_0) que homogeniza el tratamiento de escenarios extremos entre *views*. Esto permite aislar el efecto de la calibración de la *view* de diferencias en la regla de abandono. Los resultados bajo v1+ confirman que la probabilidad de abandono semanal es cero en la mayoría de las configuraciones, indicando que los clientes rara vez alcanzan el umbral de ruina bajo los parámetros simulados.

8.10.2. Comparación agregada de *views*

La Tabla 8.12 sintetiza el desempeño de las cuatro *views* bajo el modelo v1+ y la configuración BL calibrada.

Momentum general domina en términos económicos: mejora el Score P4 en 85.7% frente a Markowitz base y eleva el Sharpe en 5.2%. Sin embargo, esta ventaja viene acompañada de un costo operacional significativo: turnover de 34.6% (frente a 7.3% de

Tabla 8.12. Desempeño agregado de Black-Litterman calibrado por *view* (modelo v1+).

<i>View</i>	Δ Sharpe	Δ P4 vs MK	BL recomendado	Turnover BL	HHI sector BL	N_{eff} BL
Desempleo macro	+2.0%	−10.4%	40.0%	7.3%	0.157	194.3
Momentum general	+5.2%	+85.7%	40.0%	34.6%	0.261	94.2
Mom. top/bottom 1Y	−6.1%	−4.6%	30.0%	30.7%	0.208	122.9
Mom. top market-cap 6M	−6.1%	−4.6%	30.0%	30.7%	0.208	122.9

desempleo), concentración sectorial elevada (HHI 0.261 vs. 0.157) y solo 94.2 activos efectivos (vs. 194.3 de desempleo). En el otro extremo, desempleo macro ofrece la mejor estabilidad operacional pero retrocede en Score P4 frente a Markowitz base (−10.4%).

Las *views* de momentum basadas en capitalización de mercado (top/bottom 1Y y top market-cap 6M) convergen a la misma estructura congelada y muestran resultados prácticamente equivalentes, con deterioro de Sharpe (−6.1%) y Score P4 (−4.6%). Esto sugiere que imponer restricciones de capitalización reduce la señal de momentum lo suficiente como para que el modelo no supere al benchmark.




Figura 8.7. Turnover promedio en el horizonte de test limpio por *view*.

8.10.3. Dinámica de portafolio bajo momentum general

La Tabla 8.13 detalla la dinámica del portafolio BL calibrado con momentum general en test P4 limpio.




Figura 8.8. Concentración sectorial (HHI) en test limpio por *view*.




Figura 8.9. Número efectivo de activos en test limpio por *view*.

El perfil Muy arriesgado concentra la mayor rotación (9.9% con pandemia) y la mayor utilidad (USD 581), pero también la mayor concentración sectorial (HHI 0.214). Sin pandemia, el número efectivo de activos es sistemáticamente mayor, indicando que la señal de momentum se distribuye en más activos cuando los datos de entrenamiento excluyen el régimen de estrés.

8.10.4. Recomendación final de *view*

Considerando conjuntamente el desempeño fuera de muestra, la evaluación económica P4 y la estabilidad operacional, la *view* de momentum general es la recomendación base

Tabla 8.13. Dinámica de portafolio BL calibrado con momentum general (test P4, modelo v1+).

Escenario	Perfil	Turnover	N_{eff}	HHI sector	Utilidad BL	Riqueza BL
Con pandemia	Muy arriesgado	9.9%	121.0	0.214	USD 581	USD 8 862
Con pandemia	Arriesgado	7.0%	205.7	0.135	–	–
Con pandemia	Neutro	6.4%	136.3	0.158	–	–
Con pandemia	Conservador	6.2%	118.1	0.166	–	–
Con pandemia	Muy conservador	6.3%	112.6	0.169	–	–
Sin pandemia	Muy arriesgado	9.2%	163.3	0.178	–	–
Sin pandemia	Arriesgado	6.9%	360.5	0.124	–	–
Sin pandemia	Conservador	7.0%	233.5	0.144	–	–

para el recomendador FinPUC. Su ventaja en Score P4 (+85.7%) y Sharpe (+5.2%) es sustancial, y aunque su mayor turnover (34.6%) exige monitoreo operacional, el beneficio económico neto es positivo. Desempleo macro se recomienda como alternativa defensiva para perfiles conservadores o contextos donde se priorice baja rotación y diversificación sectorial por sobre la rentabilidad marginal.

8.11. Análisis de sensibilidad y extensiones

8.11.1. Justificación de parámetros a sensibilizar

Los parámetros seleccionados para el análisis de sensibilidad responden a su rol crítico en el modelo y a las limitaciones identificadas en las fases anteriores:

- **$K\%$ (comisión):** Es el parámetro de negocio central. Modifica simultáneamente la utilidad de FinPUC, la riqueza neta del cliente y la tasa de retiro. Su elección no es arbitraria: K demasiado bajo compromete la viabilidad del negocio; K demasiado alto expulsa clientes.
- **λ (balance multiobjetivo):** Controla explícitamente la prioridad entre retorno del cliente y utilidad de la empresa. En la Entrega 2 esta decisión estaba implícita en el Score P4; sensibilizar λ permite cuantificar el costo de oportunidad de priorizar un objetivo sobre el otro.
- **c (confianza en Ω):** Determina cuánto peso se asigna a la *view* frente al prior de equilibrio. Su sensibilidad es relevante porque la calibración de Ω es uno de los aspectos más debatidos en la literatura de Black-Litterman (Idzorek, 2005).

- **τ (incertidumbre del prior):** Escala la matriz de covarianza del prior. Aunque la literatura sugiere valores pequeños ($\tau \approx 1/T$), en la práctica su impacto puede ser significativo cuando N es grande.
- **s (sensibilidad logística):** Controla la brusquedad de las funciones P_1 y P_2 . Con s alto, las transiciones de aceptación y retiro son casi discretas; con s bajo, son graduales. Este parámetro afecta directamente las tasas de retiro y aceptación simuladas.

8.11.2. Evaluación de sensibilidad

La sensibilidad de c y τ ya fue presentada en las Figuras 8.3 y 8.4, mostrando que el Sharpe fuera de muestra es cóncavo en ambos parámetros y alcanza su máximo en valores intermedios ($c = 0.50$, $\tau = 0.20$).

La sensibilidad de $K\%$ y λ se documenta en las Tablas 8.10 y 8.11. En ambos casos, el Score P4 exhibe un óptimo interior, lo que valida la existencia de un punto de balance que no está en los extremos del espacio de parámetros. Esto es una propiedad deseable: significa que ni la estrategia puramente orientada al cliente ni la puramente orientada a la empresa son óptimas; existe un compromiso que maximiza el valor conjunto.

La sensibilidad de s no fue evaluada exhaustivamente en esta fase, pero se identifica como una extensión prioritaria. Valores de $s \in \{5, 10, 20, 50\}$ modificarían la forma de P_1 y P_2 y, con ello, las tasas de retiro y aceptación reportadas. Un s menor suavizaría las transiciones y podría reducir la tasa de retiro en perfiles conservadores; un s mayor las haría más abruptas, aumentando la sensibilidad del modelo a pequeñas diferencias en el desempeño.

8.11.3. Discusión de implicancias

Los resultados de sensibilidad tienen tres implicancias principales para el modelo de negocio de FinPUC:

- (i) **Robustez del K óptimo:** El Score P4 es relativamente plano en una vecindad del K óptimo, lo que otorga flexibilidad para ajustar la comisión sin sacrificar

significativamente el desempeño. Esto es relevante porque en la práctica Fin-PUC podría enfrentar restricciones de mercado o regulatorias que limiten el K efectivo.

- (ii) **Costo de oportunidad de λ :** Moverse del λ óptimo hacia $\lambda = 0$ (solo utilidad empresa) o $\lambda = 1$ (solo retorno cliente) tiene un costo medible en términos de Score P4. La magnitud de este costo cuantifica el valor de mantener una estrategia balanceada.
- (iii) **Estabilidad de la calibración BL:** La configuración congelada ($U = 4\%$, $\beta = 1.5$, $q_{\text{scale}} = 1.5$, $c = 0.50$, $\tau = 0.20$) es robusta a variaciones moderadas de c y τ , pero cambios grandes en la familia de *view* (Stage 1) tienen efectos de primer orden sobre el ranking final. Esto refuerza la importancia de la elección de *view* como la decisión metodológica más crítica.

8.11.4. Propuesta de extensiones y mejoras

A partir del análisis realizado, se proponen las siguientes extensiones para trabajo futuro:

- (i) **Optimización conjunta de K y λ :** Actualmente ambos parámetros se optimizan secuencialmente (primero K , luego λ). Una optimización conjunta sobre la grilla completa $K \times \lambda$ podría identificar combinaciones que la búsqueda secuencial omite.
- (ii) **Reemplazo de normalidad en Monte Carlo:** Sustituir los retornos semanales normales por distribuciones t-Student o Johnson SU calibradas por ticker, usando los resultados del análisis distribucional de la Entrega 2. Esto generaría colas más realistas y probablemente mayores tasas de retiro, ofreciendo una evaluación más conservadora del Score P4.
- (iii) **Sensibilidad de s (parámetro logístico):** Evaluar $s \in \{5, 10, 20, 50\}$ para cuantificar cómo la brusquedad de P_1 y P_2 afecta las tasas de retiro y aceptación, y si el ranking de *views* es robusto a este parámetro.
- (iv) **Drawdown como gatillo de P_1 :** Reemplazar la pérdida respecto a C_0 por el *drawdown* respecto al máximo histórico de riqueza (modelo v2), alineando la métrica de abandono con la percepción real de pérdida de un inversionista.

- (v) **Views macro con datos observados:** Reemplazar la tasa de desempleo asumida (4%) por series reales de BLS o FRED, y explorar *views* adicionales como inflación, tasas de interés o *yield curve*.
- (vi) **Penalización de rotación en la optimización:** Incorporar una restricción $\|w_{\text{nuevo}} - w_{\text{anterior}}\|_1 \leq \delta$ en el problema de optimización para reducir el turnover y alinear los portafolios óptimos con los costos de transacción reales.
- (vii) **Escenarios proyectados asimétricos:** Reemplazar los escenarios simétricos $\pm 0.5\sigma$ por escenarios que capturen la asimetría negativa observada en los retornos, por ejemplo usando percentiles empíricos de la distribución de retornos semanales.

9. CONCLUSIONES

9.1. Conclusiones principales

El proyecto implementó y calibró un sistema recomendador de inversiones para FinPUC en tres capas metodológicas (Markowitz, Black-Litterman, Monte Carlo P4) y, en esta tercera fase, abordó dos preguntas de negocio que la Entrega 2 dejó abiertas: la determinación de la comisión óptima $K\%$ y la calibración explícita del balance λ entre retorno del cliente y utilidad de la empresa.

9.1.1. Calibración de Black-Litterman

La calibración secuencial en cinco etapas sobre tres horizontes estrictamente separados permitió seleccionar hiperparámetros sin contaminar el período de evaluación. La configuración congelada (*view* desempleo macro, $U = 4\%$, $\beta = 1.5$, $q_{\text{scale}} = 1.5$, $c = 0.50$, $\tau = 0.20$) entrega una mejora de Sharpe de hasta 23.1% en test P4 limpio para perfiles agresivos con pandemia, y es recomendada sobre Markowitz base en el 100% de las ventanas de test. La elección de la familia de *view* (Stage 1) resultó ser la decisión de mayor impacto en todo el pipeline de calibración.

9.1.2. Comparación de *views*

Entre las cuatro familias evaluadas bajo el modelo de abandono $v1+$, momentum general domina en términos económicos con una mejora de +85.7% en Score P4 frente a Markowitz base y +5.2% en Sharpe. Sin embargo, esta ventaja conlleva mayor turnover (34.6%), mayor concentración sectorial (HHI 0.261) y menor número efectivo de activos (94.2). Desempleo macro ofrece la mejor estabilidad operacional (turnover 7.3%, HHI 0.157, N_{eff} 194.3) pero retrocede en Score P4 (−10.4%). Las *views* basadas en capitalización de mercado muestran deterioro tanto en Sharpe como en Score P4. La recomendación final prioriza momentum general como *view* base, con desempleo macro como alternativa defensiva.

9.1.3. Parámetros de negocio

El análisis de sensibilidad de $K\%$ muestra que el Score P4 crece monótonamente con K en el rango evaluado, alcanzando su máximo en $K = 5.0\%$ (Score P4 = 1 874 promedio, USD 1 810 de riqueza, 31.6% de retiro, USD 380 de utilidad). La tasa de retiro se mantiene estable en torno a 31.5% independientemente de K , porque los retornos esperados de los portafolios son suficientemente altos para absorber la comisión sin incrementar significativamente la probabilidad de abandono. El λ óptimo que maximiza el Score P4 es 0.7, aunque el Score P4 es prácticamente insensible a λ (rango de solo 13 puntos entre 1 869 y 1 882). La mejor combinación individual es Markowitz en perfil Muy arriesgado con $K = 5.0\%$ y $\lambda = 0.5$, alcanzando un Score P4 de 3 026.

9.1.4. Validación y robustez

La validación rolling de tres horizontes muestra que BL calibrado agrega más valor en perfiles agresivos y escenarios con pandemia, donde la estimación histórica de Markowitz es menos confiable. En perfiles conservadores y sin pandemia, la mejora es marginal, lo que es consistente con que el prior de equilibrio ya está cerca de la solución óptima cuando los datos son estables. La separación estricta de horizontes $\mathcal{H}_1|\mathcal{H}_2|\mathcal{H}_3$ es una fortaleza metodológica central que debería mantenerse en cualquier iteración futura del modelo.

9.1.5. Limitaciones

Las principales limitaciones identificadas son: (a) los KPIs de retorno/volatilidad usados en Monte Carlo son fijos y no se re-optimizan para cada K o λ ; (b) la distribución normal subestima eventos extremos, lo que probablemente produce estimaciones optimistas de riqueza terminal y tasas de retiro; (c) K y λ se optimizan secuencialmente, no conjuntamente; (d) λ se evalúa en grilla discreta de 11 puntos; (e) la *view* de desempleo usa una tasa fija en lugar de series macroeconómicas observadas; y (f) el turnover del 5% es un supuesto no calibrado con datos reales.

9.1.6. Trabajo futuro

Las extensiones prioritarias son: optimización conjunta de K y λ , reemplazo de normalidad por t-Student o Johnson SU en Monte Carlo, sensibilidad de $s \in \{5, 10, 20, 50\}$,

incorporación de *drawdown* como gatillo de P_1 (modelo v2), *views* macro con datos observados (BLS/FRED), penalización de rotación en la optimización, y escenarios proyectados asimétricos.

9.2. Carta Gantt: avance y fases restantes

La Tabla 9.1 resume la Carta Gantt de trabajo posterior a esta entrega, diferenciando avance ya completado y tareas pendientes para la fase final del proyecto.

Tabla 9.1. Carta Gantt resumida: avance actual y fases restantes.

Fase	Periodo	Avance actual	Trabajo futuro
Calibración BL y validación	12 mayo – 19 junio 2026	Calibración secuencial 5 etapas, validación rolling 3 horizontes, comparación de 4 <i>views</i> y 3 modelos de abandono ya implementados.	Consolidar resultados de la optimización de $K\%$ y λ , integrar figuras de sensibilidad y completar el ranking final del recomendador.
Optimización de parámetros de negocio	12 mayo – 19 junio 2026	Notebooks de sensibilidad de $K\%$ y λ implementados y ejecutados.	Extraer tablas de resultados, validar convergencia de Monte Carlo y documentar el K y λ óptimos en el informe final.
Mejoras del modelo	19 – 26 junio 2026	Se identificaron limitaciones en normalidad de Monte Carlo, costos de transacción y medición de pérdidas.	Incorporar distribuciones no normales, modelar costos de transacción como restricción de rotación y evaluar <i>drawdown</i> como criterio de retiro.
Cierre del proyecto	13 – 26 junio 2026	Informe 3 en redacción y principales resultados ya consolidados.	Preparar la presentación final, redactar el informe final, documentar el modelo definitivo, ordenar el repositorio GitHub y realizar correcciones finales antes de la entrega del 26 de junio de 2026.

REFERENCIAS

- Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. doi: 10.2469/faj.v48.n5.28
- D’Acunto, F., Prabhala, N., & Rossi, A. G. (2019). The promises and pitfalls of robo-advising. *Review of Financial Studies*, 32(5), 1983–2020. doi: 10.1093/rfs/hhz017
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. doi: 10.1016/0304-405X(93)90023-5
- He, G., & Litterman, R. (1999). *The intuition behind Black–Litterman model portfolios* (Tech. Rep.). Goldman Sachs Asset Management.
- Idzorek, T. M. (2005). A step-by-step guide to the Black-Litterman model. In *Forecasting expected returns in the financial markets* (pp. 17–38). Academic Press.
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. doi: 10.1016/S0047-259X(03)00096-4
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. doi: 10.1111/j.1540-6261.1952.tb01525.x
- Michaud, R. O. (1989). The Markowitz optimization enigma: Is ‘optimized’ optimal? *Financial Analysts Journal*, 45(1), 31–42. doi: 10.2469/faj.v45.n1.31
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41. doi: 10.21314/JOR.2000.038
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442. doi: 10.1111/j.1540-6261.1964.tb02865.x

**ANEXO N°1: DECLARACIÓN DE USO DE IA EN ESTE INFORME Y
PRESENTACIÓN ASOCIADA**

Grupo:_____ 13 _____

¿Hicieron uso de herramientas de IA en su trabajo para este informe y/o presentación?

SI ___ X ___ NO _____

¿Cuáles de las siguientes alternativas mejor describe el uso que hicieron de IA (puede ser más de una)

- X Apoyo a la redacción, ortografía, estructura gramatical, etc., de los documentos.
- X Apoyo al análisis de datos e información asociada al problema.
- Búsqueda y/o filtro de referencias, contenidos web, literatura, etc., relevante al proyecto.
- X Apoyo para el desarrollo de modelos asociados al proyecto.
- X Apoyo en el desarrollo de código computacional necesario para el proyecto
- X Apoyo en el análisis de resultados (por ejemplo, de distintas corridas computacionales, tendencias de predicciones, etc.)
- x Apoyo para construir figuras, diagramas, etc.
- Apoyo para obtener conclusiones a partir de los análisis de resultados.
- X Otro, especificar: Generación de un entorno Docker para visualización interactiva de datos financieros.

Herramientas utilizadas: Claude y Codex (principalmente para el desarrollo de código, apoyo en redacción, construcción de diagramas y análisis de resultados).

Reflexión sobre el uso de IA:

El uso de herramientas de inteligencia artificial durante el proyecto tuvo un carácter principalmente instrumental y de apoyo al aprendizaje. La IA se utilizó como una herramienta de consulta para comprender mejor distintas librerías de Python, revisar formas correctas de implementar procedimientos de optimización y simulación, y resolver dudas puntuales sobre estructuras de código, manejo de datos y visualización de resultados. En este sentido, su aporte fue similar al de una fuente de asistencia técnica interactiva, que permitió acelerar la búsqueda de alternativas y contrastar posibles enfoques antes de incorporarlos al desarrollo del modelo.

En el desarrollo computacional, la IA fue útil para apoyar la implementación de los modelos de Markowitz, Black-Litterman y simulación Monte Carlo, especialmente en tareas relacionadas con el uso de librerías, organización del código y corrección de errores. También se empleó para revisar la consistencia de partes ya desarrolladas, detectar posibles problemas de implementación y proponer mejoras de eficiencia. Sin embargo, las decisiones metodológicas, la selección de supuestos, la interpretación de resultados y la evaluación final de las recomendaciones fueron realizadas por el grupo, verificando que las salidas fueran coherentes con los objetivos del proyecto y con la teoría financiera estudiada.

La experiencia mostró que la IA puede aumentar la productividad cuando se usa de manera crítica, pero también requiere validación constante. Sus respuestas no fueron tomadas como definitivas: cada sugerencia relevante fue revisada, adaptada y contrastada con el funcionamiento del código, los resultados obtenidos y los criterios del proyecto. Esto fue especialmente importante en un contexto financiero, donde errores de programación o interpretación pueden cambiar de forma significativa las conclusiones. Por ello, el uso responsable de IA no reemplazó el razonamiento del equipo, sino que ayudó a mejorar la calidad, eficiencia y claridad del trabajo desarrollado.

Patricio Andres Acevedo Flores

Benjamín Alonso Cano Araya

Matías Benjamín Catalán Contreras

Gaspar Ten Berg Yunusic

Diego Benjamín Villalobos Michea

ANEXO N°2: ANÁLISIS DE DATOS

Este anexo presenta la fuente de datos, la estructura de los archivos, los criterios de clasificación sectorial, los niveles de filtrado aplicados y la caracterización del universo final de acciones utilizado en el modelo P4. Además, incorpora la metodología actual de análisis con pandemia, en la cual la pandemia no se elimina como única definición de base, sino que se compara explícitamente el desempeño de los modelos con y sin las observaciones de 2020–2022 dentro del entrenamiento. Ver documento completo

Descripción de la Fuente de Datos

Los datos históricos provienen del directorio `Data/Historical_Stocks/` del repositorio del proyecto. Fueron descargados con la librería `yfinance` de Yahoo Finance, incluyendo precios de cierre ajustados por splits, volumen, dividendos y metadatos fundamentales por ticker.

Estructura de archivos

El directorio contiene **1.407 archivos**:

- **1.406 archivos CSV** individuales con el formato `stock_return-<TICKER>.csv`
- **1 archivo de metadatos** `stocks_info.txt` con información fundamental de cada ticker (sector, industria, descripción, capitalización de mercado, empleados, etc.)

Formato de los CSV

Cada archivo contiene precios diarios con las siguientes columnas:

Columna	Tipo	Descripción
Date	datetime	Fecha de cierre (zona horaria US/Eastern)
Open	float	Precio de apertura ajustado
High	float	Precio máximo del día
Low	float	Precio mínimo del día
Close	float	Precio de cierre ajustado por splits
Volume	int	Volumen de transacciones
Dividends	float	Dividendo distribuido ese día (USD/acción)
Stock Splits	float	Factor de split (0 si no hubo split)

Nota: Los precios están ajustados hacia atrás (*backward-adjusted*) por splits de acciones, pero *no* por dividendos. Los dividendos se registran explícitamente en la columna `Dividends` y serán usados directamente para alimentar la **caja chica** del modelo de optimización.

Cobertura temporal

Indicador	Valor	Detalle
Total de tickers en archivos CSV	1.406	
Tickers con datos válidos	1.165	83% del total
Tickers con datos vacíos o errores	239	17% sin datos
Fecha de corte más frecuente	2026-03-13	1.158 tickers
Mediana de filas por archivo	6.532	$\approx$ 26 años
Tickers con ≥ 5 años (1.250 filas)	1.039	
Tickers con ≥ 10 años (2.500 filas)	912	

Los años de inicio más frecuentes son 1980 (100 tickers), 1999 (52), 2021 (49) y 1973 (41), lo que refleja una mezcla de empresas consolidadas y listados recientes, incluyendo SPACs post-2020.

Tratamiento temporal de la pandemia

La cobertura temporal incluye el periodo de crisis y recuperación asociado a COVID-19. En versiones preliminares del análisis, la pandemia se trataba principalmente como un periodo a excluir. En la versión actual, el criterio se modificó: se construyen dos

escenarios comparables, uno que excluye 2020–2022 de la ventana de entrenamiento y otro que conserva ese periodo.

Esta decisión permite medir si los datos de estrés alteran las estimaciones de retorno, volatilidad y covarianza, sin confundir ese efecto con un cambio en el periodo futuro evaluado. Por lo tanto, la pandemia pasa de ser solo un filtro de limpieza a ser una variable metodológica explícita del diseño experimental.

Clasificación Sectorial

Sistema de clasificación

Los tickers se clasifican usando la taxonomía sectorial de **GICS**¹ a través de los metadatos de Yahoo Finance, que asigna a cada empresa un `sector` y una `industry` (subsector).

El archivo `stocks_info.txt` contiene 1.406 entradas en formato:

```
TICKER;{'sector': '...', 'industry': '...', 'marketCap':  
        ..., ...}
```

Distribución sectorial del universo completo

La Tabla 9.2 muestra la distribución de los tickers con datos válidos por sector.

¹Global Industry Classification Standard, desarrollado por MSCI y S&P Dow Jones Indices.

Tabla 9.2. Distribución sectorial del universo completo con datos válidos

Sector	Tickers	% del total
Financial Services	716	61.4%
Technology	81	6.9%
Industrials	74	6.4%
Healthcare	64	5.5%
Consumer Cyclical	59	5.1%
Consumer Defensive	38	3.3%
Real Estate	32	2.7%
Utilities	31	2.7%
Basic Materials	22	1.9%
Energy	21	1.8%
Communication Services	20	1.7%
Unknown	8	0.7%
Total	1.166	100%

Nota: Financial Services representa el 61% del universo crudo debido a la alta presencia de bancos regionales, gestores de activos y shell companies (SPACs). El filtrado posterior reducirá significativamente este sesgo sectorial.

Subsectores predominantes en Financial Services

Subsector (Industry)	Tickers	%
Banks – Regional	317	44.3%
Asset Management	101	14.1%
Capital Markets	56	7.8%
Credit Services	45	6.3%
Shell Companies	42	5.9%
Insurance – Property & Casualty	41	5.7%
Banks – Diversified	19	2.7%
Insurance – Life	17	2.4%
Insurance – Specialty	16	2.2%
Insurance Brokers	16	2.2%
Otros	46	6.4%
Total	716	100%

Tipos de instrumento

El campo `quoteType` de Yahoo Finance indica que 1.165 tickers corresponden a EQUITY (acciones individuales de empresas) y 1 ticker es MUTUALFUND (excluido del análisis). El universo es prácticamente homogéneo en acciones individuales.

Capitalización de Mercado

Se definen los siguientes rangos estándar de capitalización:

Categoría	Rango (USD)	Tickers	%
Mega cap	$\geq 200B$	50	4.3%
Large cap	10B – 200B	473	40.6%
Mid cap	2B – 10B	193	16.6%
Small cap	300M – 2B	234	20.1%
Micro cap	$< 300M$	210	18.0%
Sin dato	—	6	0.5%
Total con datos		1.160	

La capitalización de mercado se utiliza en dos niveles. Primero, permite filtrar empresas demasiado pequeñas o sin información suficiente, que podrían introducir problemas de liquidez o sesgos extremos en la estimación. Segundo, sirve como criterio para construir referencias de mercado, como el benchmark top-20 equiponderado y el prior de equilibrio de Black-Litterman.

Niveles de Filtrado

Se definen cinco niveles de filtrado en cascada, cada uno más restrictivo que el anterior. El objetivo es obtener un universo operacional que sea **líquido, estable, representativo y estadísticamente válido** para el optimizador de Markowitz.

La secuencia de filtros es la siguiente:

- **F0 — Universo crudo:** 1.406 tickers
- **F1 — Liquidez básica:** 883 tickers (precio ≥ 5 USD, historia ≥ 5 años)
- **F2 — Sin shells ni desconocidos:** 881 tickers (excluye Shell Companies y sector Unknown)
- **F3 — Large/Mega cap:** 686 tickers (capitalización ≥ 2 B USD)
- **F4 — Historia suficiente:** 641 tickers (≥ 10 años de datos)
- **F5 — Volatilidad razonable (universo final descriptivo):** 636 tickers ($5\% \leq \sigma_{ann} \leq 100\%$)

Razones de exclusión

La Tabla 9.3 desglosa cuántos tickers fueron eliminados en cada filtro y por qué razón:

Tabla 9.3. Razones de exclusión del universo final F5

Razón de exclusión	Tickers	%
Historial < 10 años	254	47.9%
Cap. mkt < 2B o sin dato	233	43.9%
Precio de cierre < 5 USD	37	7.0%
Volatilidad fuera de rango	5	0.9%
Datos vacíos o errores de lectura	239	—
Total excluidos (F0→F5)	529	

Definición formal de cada filtro

F1 — Liquidez básica. Un ticker i pertenece a $\mathcal{F}_1$ si y solo si cumple: número de filas con precios válidos $n_i \geq 1.250$ (≈ 5 años de historia), precio de cierre más reciente $P_i^{\text{last}} \geq 5$ USD, y capitalización de mercado $\text{Cap}_i \geq 300\text{M USD}$ (o sin dato). Esto excluye penny stocks y acciones ilíquidas sin historia suficiente para estimar parámetros estadísticos confiables.

F2 — Calidad de clasificación. $\mathcal{F}_2 \subset \mathcal{F}_1$: adicionalmente se excluye si `industry` = “Shell Companies” o `sector` = “Unknown”. Las shell companies, principalmente SPACs, no tienen operaciones reales ni retornos representativos, y los tickers sin sector asignado no pueden incluirse en análisis sectoriales.

F3 — Large/Mega cap. $\mathcal{F}_3 \subset \mathcal{F}_2$: adicionalmente se requiere $\text{Cap}_i \geq 2 \times 10^9$ USD. Las empresas de capitalización media-alta tienen mayor liquidez de mercado, menores spreads bid-ask, y sus precios reflejan mejor la información pública disponible, condición implícita del modelo de Markowitz.

F4 — Historia suficiente. $\mathcal{F}_4 \subset \mathcal{F}_3$: adicionalmente $n_i \geq 2.500$ (≈ 10 años de datos diarios). Con 10 años de historia se captura al menos un ciclo económico completo, incluyendo crisis (2008–09, 2020) y expansiones, lo que es necesario para la estimación robusta de matrices de covarianza.

F5 — Volatilidad razonable (universo final descriptivo). $\mathcal{F}_5 \subset \mathcal{F}_4$: adicionalmente se requiere:

$$5\% \leq \hat{\sigma}_i^{\text{ann}} \leq 100\% \quad \text{donde} \quad \hat{\sigma}_i^{\text{ann}} = \hat{\sigma}_i^{\text{diaria}} \times \sqrt{252}$$

$\sigma < 5\%$ indicaría datos incorrectos o instrumentos no bursátiles; $\sigma > 100\%$ corresponde a activos especulativos extremos incompatibles con el modelo de media-varianza.

Universo Final Descriptivo: 636 Acciones

El universo final descriptivo contiene **636 acciones** con historia ≥ 10 años, capitalización $\geq 2\text{B USD}$, precio $\geq 5\text{ USD}$, y volatilidad anualizada entre 5% y 100%.

Se denomina “descriptivo” porque resume el resultado completo del proceso de depuración sobre los datos disponibles. Para los experimentos con y sin pandemia se aplica una restricción adicional de comparabilidad temporal, explicada más adelante, que reduce el universo operacional a 601 acciones.

Distribución sectorial del universo final

Tabla 9.4. Estadísticas por sector — universo F5 (636 tickers)

Sector	N	$\bar{\sigma}_{ann}$	$\overline{\text{CAGR}}$	% con dividendos
Financial Services	237	37.5%	10.6%	95%
Technology	73	44.6%	16.5%	70%
Industrials	64	34.6%	13.2%	95%
Healthcare	59	37.3%	13.4%	66%
Consumer Cyclical	55	41.2%	13.9%	78%
Consumer Defensive	33	29.3%	11.4%	97%
Utilities	29	24.7%	9.7%	100%
Real Estate	29	34.8%	11.3%	93%
Energy	20	37.5%	11.5%	100%
Basic Materials	19	35.1%	11.5%	100%
Communication Services	18	36.7%	14.6%	78%
Total	636	36.6%	11.9%	90%

Utilities es el sector de menor volatilidad promedio (24.7%), adecuado para perfiles conservadores con dividendos garantizados (100%). Technology lidera en CAGR (16.5%) pero con alta volatilidad (44.6%). Consumer Defensive combina volatilidad baja (29.3%) con dividendos casi universales (97%). Financial Services sigue siendo el sector más grande (37% del universo F5).

Tabla 9.5. Top subsectores por sector en el universo F5

Sector	Subsector (Industry)	N
Financial Services	Banks – Regional	93
	Asset Management	26
	Capital Markets	19
	Insurance – P&C	18
	Banks – Diversified	18
Technology	Semiconductors	14
	Software – Application	13
	Software – Infrastructure	12
	IT Services	10
	Computer Hardware	5
Industrials	Specialty Industrial Machinery	14
	Aerospace & Defense	11
	Integrated Freight & Logistics	5
	Airlines	4
Healthcare	Diagnostics & Research	11
	Medical Devices	10
	Drug Manufacturers – General	9
	Medical Instruments & Supplies	9
Consumer Cyclical	Packaging & Containers	6
	Auto Parts	6
	Restaurants	6
	Travel Services	5
Real Estate	REIT – Specialty	7
	REIT – Residential	6
	REIT – Retail	5
Energy	Oil & Gas E&P	8
	Oil & Gas Midstream	4
	Oil & Gas Refining	3
Basic Materials	Specialty Chemicals	10
	Agricultural Inputs	2
Utilities	Utilities – Regulated Electric	23
	Utilities – Diversified	2
	Utilities – Regulated Gas	2
Communication Services	Entertainment	6
	Telecom Services	5
	Internet Content & Information	4

Representantes por sector (top 5 por capitalización)

Tabla 9.6. Top 5 Technology (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
NVDA	NVIDIA Corp.	4.381	59.5%	36.7%	1999
AAPL	Apple Inc.	3.676	43.8%	18.9%	1980
MSFT	Microsoft Corp.	2.940	33.2%	24.6%	1986
AVGO	Broadcom Inc.	1.527	37.9%	40.6%	2009
MU	Micron Technology	480	60.3%	14.8%	1984

Tabla 9.7. Top 5 Healthcare (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
LLY	Eli Lilly & Co.	882	27.5%	13.9%	1972
JNJ	Johnson & Johnson	582	22.8%	13.8%	1962
ABBV	AbbVie Inc.	388	26.3%	19.6%	2013
MRK	Merck & Co.	286	24.9%	12.4%	1962
UNH	UnitedHealth Group	256	39.8%	20.9%	1984

Tabla 9.8. Top 5 Financial Services (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
JPM	JPMorgan Chase	764	35.0%	13.0%	1980
V	Visa Inc.	592	28.5%	19.5%	2008
MA	Mastercard Inc.	444	32.4%	27.4%	2006
BAC	Bank of America	341	37.5%	6.7%	1973
HSBC	HSBC Holdings	269	27.0%	5.9%	1999

Tabla 9.9. Top 5 Consumer Defensive + Utilities (perfiles conservadores)

Ticker	Sector	Empresa	Cap (B)	σ_{ann}	CAGR	Inicio
WMT	Cons. Def.	Walmart Inc.	1.009	29.1%	19.0%	1972
COST	Cons. Def.	Costco Wholesale	447	31.0%	13.2%	1986
PG	Cons. Def.	Procter & Gamble	353	21.3%	10.5%	1962
KO	Cons. Def.	Coca-Cola Co.	333	22.8%	12.3%	1962
NEE	Utilities	NextEra Energy	193	21.8%	11.1%	1973

Universo Operacional con Inclusión de Pandemia: 601 Acciones

Para los experimentos de portafolio no se usa directamente la totalidad del universo descriptivo de 636 acciones. Se requiere que los activos sean comparables entre los escenarios `sin_pandemia` y `con_pandemia` y que tengan datos suficientes en las ventanas de entrenamiento y evaluación. Al aplicar esta intersección temporal y operacional, el universo usado por los notebooks principales queda en **601 acciones**.

Esta diferencia no contradice el universo F5. El número 636 describe el resultado completo del proceso de filtrado de datos; el número 601 corresponde al subconjunto común y operacional usado para comparar metodologías bajo el horizonte `h7_f2`.

Escenarios de datos

La metodología actual define dos escenarios:

- **`sin_pandemia`**: excluye las observaciones de 2020–2022 de la base usada para calibrar los modelos.
- **`con_pandemia`**: conserva las observaciones de 2020–2022 dentro del historial de entrenamiento.

En ambos escenarios se mantiene fijo el periodo futuro fuera de muestra: 2024-01-29 a 2026-01-30. Por lo tanto, el experimento no compara dos futuros distintos. Compara dos formas de estimar los parámetros con distinta información histórica.

Tabla 9.10. Diagnóstico de escenarios para el universo operacional

Escenario	Activos	Retornos comunes	Días pandemia train	Días pandemia test
Sin pandemia	601	2.489	0	0
Con pandemia	601	3.245	756	0

Tabla 9.11. Ventanas temporales en el experimento h7_f2

Escenario	Retornos disponibles	Entrenamiento	Evaluación futura
Sin pandemia	2013-03-08 a 2026-01-30	2014-01-23 a 2024-01-26	2024-01-29 a 2026-01-30
Con pandemia	2013-03-08 a 2026-01-30	2017-01-24 a 2024-01-26	2024-01-29 a 2026-01-30

La ventana de entrenamiento del escenario sin pandemia comienza antes porque necesita recorrer más tiempo calendario para reunir una cantidad comparable de observaciones tras remover 2020–2022. En cambio, el escenario con pandemia conserva esos días y puede completar la muestra de entrenamiento con una ventana calendario más corta.

Interpretación metodológica

El tratamiento con/sin pandemia permite separar tres efectos:

- **Efecto de limpieza:** se mantiene un universo líquido, clasificado y con historia suficiente.
- **Efecto de calibración:** se observa cómo cambian μ , Σ , la frontera eficiente y los pesos cuando se incorpora un periodo de estrés.
- **Efecto de evaluación:** se mantiene fijo el futuro fuera de muestra, por lo que las diferencias no se atribuyen a distintos mercados futuros.

Así, la pandemia no se interpreta como ruido que deba eliminarse automáticamente. Se interpreta como información histórica extrema cuya inclusión puede mejorar o deteriorar la estimación, dependiendo del modelo.

Efecto observado en resultados

La inclusión de 2020–2022 afecta principalmente a los portafolios que dependen de retornos esperados históricos. La Tabla 9.12 resume el efecto en el experimento Markowitz vs Benchmark.

Tabla 9.12. Efecto de incluir pandemia en el entrenamiento

Portafolio	Ret. sin	Sharpe sin	Ret. con	Sharpe con	Δ Sharpe
Benchmark	101,4%	2,05	101,4%	2,05	0,00
Mínima varianza	56,6%	2,11	54,6%	2,02	−0,09
Muy conservador	58,0%	2,21	54,5%	2,02	−0,18
Conservador	67,8%	2,42	55,5%	1,97	−0,45
Neutro	82,9%	2,41	60,5%	1,76	−0,66
Ideal de mercado	76,5%	2,51	59,5%	1,40	−1,11
Arriesgado	91,6%	1,73	58,4%	1,17	−0,57
Muy arriesgado	102,7%	1,41	44,0%	0,55	−0,86

El benchmark permanece invariante porque su regla no depende de la estimación de μ ni de Σ . En cambio, las carteras optimizadas sí se modifican. El deterioro más fuerte ocurre en Ideal de mercado (−1,11 puntos de Sharpe) y Muy arriesgado (−0,86), lo que muestra que los perfiles más agresivos son los más sensibles a la inclusión de datos de crisis. Mínima varianza cae solo −0,09 puntos de Sharpe, porque depende más de covarianzas que de retornos esperados individuales.

Implicaciones para el Modelo de Optimización

Conexión con parámetros del modelo

El universo F5 alimenta directamente los parámetros del modelo MO-MS-SNLP descrito en la formulación matemática del P4:

Tabla 9.13. Conexión entre parámetros del modelo y fuente de datos

Parámetro	Fuente en los datos	Notas
$r_{i,t}^s$ (retorno escenario s)	Columna <code>Close</code> , retornos diarios	Agregado a retornos semanales
$d_{i,t}$ (dividendos)	Columna <code>Dividends</code>	Alimenta <code>CC_t</code> (caja chica)
μ_i (retorno esperado)	CAGR histórico o media móvil	Percentil 10/50/90 por escenario
Σ_{ij} (covarianza)	Retornos diarios, ventana de 2 años	Estimación rolling para rebalanceo
α_p (tolerancia de pérdida)	Perfil de riesgo del cliente	5 niveles: 0%, 5%, 15%, 30%, 40%

En la implementación actual, estos parámetros se calculan sobre dos bases comparables: una sin pandemia y otra con pandemia. Por lo tanto, el mismo pipeline de datos permite medir cómo la inclusión de 2020–2022 cambia los insumos de optimización.

Sub-universos recomendados por perfil de riesgo

Para mantener el problema computacionalmente tratable y respetar la restricción de respuesta < 10 segundos, se sugieren los siguientes sub-universos:

Tabla 9.14. Sub-universos recomendados por perfil de riesgo

Perfil	Tamaño sugerido	Criterio de selección
Muy conservador (0%)	30–50 acciones	$\sigma_{ann} < 30\%$, dividendos, sectores Utilities y Cons. Def.
Conservador (5%)	50–80 acciones	$\sigma_{ann} < 35\%$, dividendos $\geq 50\%$ del universo sectorial
Neutro (15%)	80–120 acciones	Todos los sectores, pesos del universo F5
Arriesgado (30%)	100–150 acciones	Incluye Tech y Consumer Cyclical de alta volatilidad
Muy arriesgado (40%)	Sin restricción	Universo F5 completo en descriptivo; universo operacional de 601 en experimentos con/sin pandemia

Para el prototipo inicial se recomienda trabajar con un universo de **50–100 acciones** seleccionadas por sector (representantes por capitalización), lo que garantiza la resolución en Gurobi en < 1 segundo para el LP de capas 0–2.

Consideraciones sobre la caja chica

Los dividendos en la columna `Dividends` representan el monto en USD por acción en la fecha de pago. Para el modelo:

$$d_{i,t} = \text{Dividends}_{i,t} \cdot \frac{w_{i,t} \cdot V_{t-1}}{P_{i,t}} \quad (9.1)$$

donde $P_{i,t}$ es el precio de cierre de la semana t y V_{t-1} el valor del portafolio en la semana anterior. El 90% del universo F5 distribuye dividendos, lo que implica que la caja chica será activa para la gran mayoría de portafolios.

Implicancia de la pandemia para los parámetros

La pandemia afecta principalmente la estimación de retornos esperados y covarianzas. En Markowitz, esto se traduce en cambios directos en la frontera eficiente y en la selección de portafolios por perfil. En Black-Litterman, el prior de equilibrio y las *views* amortiguan parcialmente la dependencia de la media histórica, pero la matriz de covarianzas y la volatilidad siguen capturando parte del shock. En Simulación Monte Carlo, los KPIs resultantes se usan como insumo para proyectar riqueza, retiro del cliente y utilidad de la empresa.

Por ello, mantener ambos escenarios es metodológicamente más informativo que reportar una sola base sin pandemia. Permite observar si una técnica es robusta cuando se entrena con datos de estrés y si el resultado depende de un supuesto de limpieza demasiado favorable.

Conclusión

En síntesis, a partir de un universo inicial de **1.406 tickers** se construyó un universo final descriptivo de **636 acciones** aptas para alimentar el modelo de optimización del

proyecto. El proceso de depuración permitió eliminar instrumentos con información incompleta, baja liquidez, escasa historia o comportamiento incompatible con el enfoque de media-varianza.

El resultado es un universo más estable, representativo y utilizable computacionalmente, con presencia de 11 sectores económicos, una volatilidad promedio anualizada de 36.6%, y una alta proporción de acciones que pagan dividendos. Esto permite que el conjunto final no solo sea adecuado para la estimación de retornos y covarianzas, sino también consistente con la lógica financiera del modelo, incluyendo la incorporación de caja chica vía dividendos.

La metodología actual agrega una capa adicional: para los experimentos de Markowitz, Black-Litterman y Simulación Monte Carlo se trabaja con un universo operacional comparable de **601 acciones**, evaluado bajo escenarios `sin_pandemia` y `con_pandemia`. En ambos casos el periodo futuro se mantiene fijo, por lo que la comparación mide el efecto de incluir 2020–2022 en la calibración, no el efecto de cambiar el mercado evaluado.

Documento generado con datos al 13 de marzo de 2026.
Fuente: Yahoo Finance vía `yfinance`. Análisis: Python 3.11.

ANEXO N°3: ANÁLISIS DE AJUSTE DE DISTRIBUCIONES

Resumen

Este anexo resume la implementación y los resultados del análisis distribucional aplicado a los retornos diarios de los tickers filtrados del universo FinPUC. El objetivo fue evaluar si los retornos de cada activo se ajustan mejor a una distribución normal o a familias alternativas capaces de representar colas pesadas, asimetría y mayor concentración de observaciones alrededor de cero. El análisis se realizó sobre la base de datos sin pandemia, es decir, excluyendo las observaciones del periodo 2020–2022 y utilizando activos que ya habían superado los filtros de historia, capitalización, precio, clasificación y volatilidad.

El procedimiento fue implementado mediante el script `ajustar_distribuciones_retornos`, que automatiza la lectura de archivos CSV, el cálculo de retornos diarios totales, la aplicación de pruebas de normalidad, el ajuste de distribuciones candidatas por máxima verosimilitud y la exportación de resultados. La finalidad no fue imponer una distribución única para todo el universo de acciones, sino identificar, ticker por ticker, qué familia paramétrica describe mejor los retornos observados dentro del conjunto de distribuciones consideradas.

Metodología de cálculo

La primera etapa del script define las rutas de entrada y salida, las columnas requeridas y los parámetros generales del experimento. En particular, se exige un mínimo de 250 retornos válidos por ticker para evitar estimaciones con muestras demasiado pequeñas. Además, se eliminan retornos diarios menores a -95% o mayores a 300% , con el fin de controlar errores de datos, precios mal ajustados o registros extremos incompatibles con el análisis financiero estándar.

Para cada archivo, el script estandariza el nombre del ticker, valida que existan las columnas necesarias y, si no se encuentra la columna de dividendos, la crea con valor cero. Luego convierte las fechas a formato `datetime`, transforma precios y dividendos a valores numéricos, elimina fechas inválidas y precios nulos o no positivos, y ordena las

Tabla 9.15. Principales parámetros de configuración del análisis.

Parámetro	Descripción
RUTA_TICKERS_FILTRADOS	Carpeta con los CSV finales de acciones filtradas.
RUTA_SALIDA	Carpeta donde se guardan los resultados del ajuste.
Date, Close, Dividends	Columnas usadas para fecha, precio de cierre y dividendos.
TIPO_RETORNO	Tipo de retorno calculado; por defecto se usa <code>simple_total</code> .
MIN_RETORNOS_VALIDOS	Número mínimo de retornos requeridos para ajustar distribuciones.
RETORNO_MINIMO_PERMITIDO y RETORNO_MAXIMO_PERMITIDO	Umbrales para remover retornos extremos asociados a errores de datos.
GENERAR_GRAFICOS_AJUSTE	Indica si se generan histogramas con densidades ajustadas por ticker.

observaciones cronológicamente. Con esta base limpia, el retorno simple total del ticker i en el día t se calcula como:

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (9.2)$$

donde $P_{i,t}$ es el precio de cierre y $D_{i,t}$ corresponde al dividendo por acción pagado en ese día. Esta definición incorpora la rentabilidad por dividendos y, por tanto, representa mejor el retorno total del inversionista que una medida basada solo en precios. El script también permite calcular retornos logarítmicos totales,

$$r_{i,t}^{\log} = \log \left(\frac{P_{i,t} + D_{i,t}}{P_{i,t-1}} \right), \quad (9.3)$$

aunque el análisis final utiliza retornos simples totales para mantener consistencia con el resto del proyecto.

Pruebas de normalidad y distribuciones candidatas

Para evaluar normalidad se aplican tres pruebas formales: Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk. La hipótesis nula común es que los retornos del ticker provienen de una distribución normal,

$$H_0 : r_{i,t} \sim \mathcal{N}(\mu_i, \sigma_i^2). \quad (9.4)$$

Cuando el valor-p es menor a 0,05, se rechaza la normalidad al 5%. Jarque–Bera compara asimetría y curtosis respecto de los valores esperados bajo normalidad; D’Agostino–Pearson combina transformaciones de ambos momentos de forma; y Shapiro–Wilk contrasta los cuantiles ordenados de la muestra con los cuantiles esperados bajo normalidad. En muestras muy grandes, esta última prueba se aplica sobre un máximo de 5 000 observaciones para evitar sensibilidad excesiva.

El ajuste paramétrico considera siete distribuciones candidatas, todas razonables para modelar retornos diarios porque admiten valores positivos y negativos o tienen flexibilidad suficiente para representar distintas formas empíricas.

Tabla 9.16. Distribuciones candidatas consideradas.

Distribución	Interpretación financiera
Normal	Modelo simétrico base, con colas delgadas y sin asimetría.
t-Student	Permite colas más pesadas, útil ante eventos extremos frecuentes.
Laplace	Presenta mayor concentración cerca de cero y colas más pesadas que la normal.
Logística	Distribución simétrica con colas algo más pesadas que la normal.
Skew-normal	Extiende la normal incorporando asimetría mediante un parámetro de forma.
Normal generalizada	Permite modificar concentración central y grosor de colas.
Johnson SU	Familia flexible para representar asimetría, colas pesadas y formas complejas.

Para cada ticker i y distribución candidata d , se estima un vector de parámetros $\theta_{i,d}$ por máxima verosimilitud:

$$\hat{\theta}_{i,d} = \arg \max_{\theta} \sum_{t=1}^{T_i} \log f_d(r_{i,t}; \theta), \quad (9.5)$$

donde $f_d(\cdot)$ es la densidad de la distribución candidata y T_i corresponde al número de retornos válidos del ticker. La log-verosimilitud maximizada se compara mediante AIC y BIC:

$$AIC = 2k - 2\ell, \quad (9.6)$$

$$BIC = k \ln(n) - 2\ell, \quad (9.7)$$

donde k es el número de parámetros, n el tamaño muestral y ℓ la log-verosimilitud maximizada. Ambos criterios equilibran ajuste y parsimonia: AIC tiende a favorecer modelos más flexibles, mientras que BIC penaliza con mayor fuerza la complejidad cuando el tamaño muestral es grande.

Como medida adicional de bondad de ajuste se calcula el estadístico Kolmogorov–Smirnov aproximado:

$$D = \sup_x |F_n(x) - F_{\hat{\theta}}(x)|, \quad (9.8)$$

donde $F_n(x)$ es la distribución empírica y $F_{\hat{\theta}}(x)$ la distribución acumulada ajustada. Su valor- p se interpreta solo como referencia, ya que los parámetros se estiman con los mismos datos sobre los cuales se evalúa el ajuste.

Archivos generados

El proceso principal verifica la disponibilidad de las librerías necesarias, recorre todos los CSV disponibles, calcula retornos, descarta tickers con menos de 250 observaciones válidas, aplica pruebas de normalidad, ajusta las distribuciones candidatas y exporta resultados agregados y por ticker. Si una distribución no converge para un ticker específico, el script continúa con las restantes; si un ticker completo no puede analizarse, registra el motivo de exclusión.

Resultados obtenidos

El análisis final contiene 601 tickers y siete distribuciones candidatas por ticker, lo que produce 4 207 ajustes distribucionales. La cantidad de retornos disponibles es suficiente para realizar comparaciones estadísticas robustas: la mediana es 7 949 retornos por ticker

Tabla 9.17. Archivos de salida generados por el script.

Archivo	Contenido
<code>ajuste_distribuciones_por_ticker.R</code>	Resultados de todas las distribuciones ajustadas para cada ticker.
<code>mejor_distribucion_por_ticker.csv</code>	Mejor distribución por ticker según AIC y BIC.
<code>resumen_mejores_distribuciones.csv</code>	Conteo agregado de mejores distribuciones.
<code>pruebas_normalidad_por_ticker.csv</code>	Resultados de Jarque-Bera, D'Agostino-Pearson y Shapiro-Wilk.
<code>tickers_no_analizados.csv</code>	Tickers omitidos y motivo de exclusión.
<code>interpretacion_resultados.txt</code>	Guía breve para interpretar los resultados.
<code>graficos_ajuste/</code>	Histogramas con densidades paramétricas ajustadas.

y el promedio 8 262,83, incluso después de aplicar filtros de calidad y excluir el periodo pandémico.

Tabla 9.18. Resumen del tamaño muestral analizado.

Indicador	Valor
Tickers analizados	601
Distribuciones candidatas por ticker	7
Ajustes totales	4 207
Mínimo de retornos por ticker	2 518
Mediana de retornos por ticker	7 949
Promedio de retornos por ticker	8 262,83
Máximo de retornos por ticker	15 400

Los resultados muestran que la normal no fue seleccionada como mejor distribución para ningún ticker, ni por AIC ni por BIC. Según AIC, Johnson SU es la familia más frecuente, con 247 tickers, equivalente al 41,10% del total. Según BIC, t-Student pasa a ser la más frecuente, con 241 tickers y 40,10%. Esta diferencia es coherente con la mayor penalización de BIC sobre modelos con más parámetros: Johnson SU ofrece mayor flexibilidad para capturar asimetrías y formas complejas, mientras que t-Student representa colas pesadas con una estructura más parsimoniosa.

AIC y BIC coinciden en la mejor distribución para 532 tickers, lo que representa el 88,52% del total. Las discrepancias se concentran principalmente en casos donde AIC selecciona Johnson SU y BIC selecciona t-Student. En términos prácticos, si se busca el mejor ajuste empírico por ticker, Johnson SU resulta atractiva; si se busca un modelo más simple y estable para simulación o escenarios, t-Student puede ser preferible.

Tabla 9.19. Conteo de mejores distribuciones por criterio de información.

Distribución	Mejor AIC	% AIC	Mejor BIC	% BIC
Johnson SU	247	41,10%	180	29,95%
t-Student	179	29,78%	241	40,10%
Normal generalizada	174	28,95%	176	29,28%
Laplace	1	0,17%	4	0,67%
Normal	0	0,00%	0	0,00%
Logística	0	0,00%	0	0,00%
Skew-normal	0	0,00%	0	0,00%

Tabla 9.20. Resultados agregados de pruebas de normalidad.

Prueba	Rechazos al 5%	Porcentaje
Jarque–Bera	601	100,00%
D’Agostino–Pearson	601	100,00%
Shapiro–Wilk	601	100,00%
Las tres pruebas simultáneamente	601	100,00%

Las tres pruebas rechazan normalidad en todos los tickers analizados, lo que constituye evidencia contundente contra el supuesto de retornos diarios normales. Desde el punto de vista financiero, este resultado es relevante porque la normalidad tiende a subestimar la probabilidad de pérdidas extremas cuando la distribución real presenta colas pesadas. Además, usando la mejor distribución según AIC, solo 220 de 601 tickers tienen un valor-p aproximado de Kolmogorov–Smirnov mayor a 0,05, equivalente al 36,61%; según BIC, esto ocurre en 219 tickers, equivalente al 36,44%. Por tanto, aunque Johnson SU, t-Student y normal generalizada mejoran el ajuste relativo frente a la normal, una distribución paramétrica estática no captura completamente todos los rasgos empíricos de los retornos.

Discusión e implicancias para el modelo

Los resultados son consistentes con patrones frecuentes en series financieras: presencia de colas pesadas, asimetrías relevantes, baja validez empírica de la normalidad y tensión entre ajuste flexible y parsimonia. Para el sistema recomendador FinPUC, esto tiene implicancias directas. Si el modelo utiliza solo media y varianza, puede perder información importante sobre riesgo extremo; una cartera evaluada únicamente mediante

volatilidad podría parecer aceptable aun cuando tenga exposición significativa a pérdidas de cola.

En modelos media-varianza, la normalidad facilita la interpretación del riesgo, pero no es estrictamente necesaria para calcular medias, varianzas y covarianzas. Sin embargo, cuando se desea proyectar escenarios desfavorables, calcular VaR o CVaR, o simular trayectorias futuras, la elección distribucional se vuelve más relevante. A partir de los resultados, t-Student aparece como una alternativa adecuada para simulaciones base por su parsimonia y capacidad de capturar colas pesadas; Johnson SU resulta útil para análisis por ticker cuando se requiere mayor flexibilidad; y los métodos empíricos, como *bootstrap* histórico, simulaciones por bloques o modelos de volatilidad condicional, pueden complementar el análisis al capturar dependencia temporal y cambios de régimen.

Limitaciones

El procedimiento presenta algunas limitaciones metodológicas. Los parámetros se estiman y evalúan sobre la misma muestra, por lo que ciertas pruebas de ajuste deben interpretarse como aproximadas. Además, el test Kolmogorov–Smirnov no corrige formalmente por la estimación previa de parámetros. El análisis considera distribuciones incondicionales, aunque los retornos financieros suelen exhibir dependencia temporal y agrupamiento de volatilidad. La exclusión de 2020–2022 responde a una decisión metodológica del proyecto, pero también elimina un periodo con eventos extremos relevantes. Finalmente, la comparación se limita a siete familias candidatas, por lo que podrían existir otras distribuciones con mejor desempeño.

Conclusiones del anexo

El script implementa una metodología completa y replicable para evaluar distribuciones candidatas por ticker, desde la lectura de datos hasta la exportación e interpretación de resultados. La normalidad es rechazada de manera sistemática: Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk rechazan la hipótesis normal en el 100% de los 601 tickers. Además, la distribución normal no fue seleccionada como mejor ajuste para ningún activo, ni por AIC ni por BIC.

La evidencia indica que los retornos del universo filtrado presentan colas pesadas y desviaciones relevantes respecto de la normalidad. Johnson SU domina bajo AIC por

su flexibilidad para capturar asimetría y formas complejas, mientras que t-Student domina bajo BIC por ofrecer un buen balance entre ajuste y parsimonia. Para FinPUC, el resultado más importante es que la estimación de riesgo no debería depender exclusivamente del supuesto normal. En escenarios desfavorables, estrés financiero o métricas como VaR y CVaR, distribuciones con colas pesadas o métodos empíricos ofrecen aproximaciones más realistas.

ANEXO N°4: ANÁLISIS DE METODOLOGÍAS Y CÓDIGO RELACIONADO

Este anexo consolida la documentación metodológica y de código de los tres notebooks principales de la entrega: Markowitz vs Benchmark, Black-Litterman y Simulación Monte Carlo. La reorganización mantiene la información sustantiva de los anexos metodológicos originales, pero la presenta en un solo anexo y con la misma estructura para cada técnica: resumen, fundamentos metodológicos, supuestos del experimento, estructura del notebook, KPIs utilizados, resultados del experimento pandemia, rebalanceo, splits aleatorios, evaluación robusta e implicancias y conclusiones.

Markowitz vs Benchmark

Resumen

Este apartado resume el funcionamiento, los fundamentos y los principales resultados del notebook `markowitz_vs_benchmark_rebalanceo_pandemia.ipynb`. El objetivo del experimento fue comparar portafolios construidos mediante optimización media-varianza de Markowitz contra benchmarks simples y variantes teóricas, evaluando no solo el retorno obtenido, sino también la robustez del modelo ante cambios en tres decisiones metodológicas: horizonte de calibración y evaluación futura, inclusión o exclusión del periodo de pandemia 2020–2022 en los datos de entrenamiento, y uso de rebalanceo semestral. Además, se incorpora como referencia un benchmark top-20 equiponderado por capitalización bursátil.

El caso principal utiliza 601 activos, 7 años históricos de calibración, 2 años futuros fuera de muestra, tasa libre de riesgo anual de 2%, capital inicial de 1 000, cota máxima de peso de 20% para la frontera eficiente y rebalanceo cada 126 días hábiles, equivalente aproximadamente a medio año bursátil. La evaluación es fuera de muestra: los pesos se estiman con datos históricos y luego se aplican al periodo futuro. Esto permite distinguir entre desempeño teórico dentro de la muestra y desempeño real en datos no usados para optimizar.

Fundamentos metodológicos

El modelo de Markowitz representa cada portafolio mediante un vector de pesos w , un vector de retornos esperados μ y una matriz de covarianzas Σ . En el notebook, μ se estima como promedio diario histórico y Σ como covarianza diaria de retornos. Para cada perfil de riesgo se resuelve el problema:

$$\max_w \mu^\top w - \frac{1}{2} \gamma w^\top \Sigma w, \quad (9.9)$$

sujeto a restricciones de presupuesto, no negatividad, peso máximo y, cuando corresponde, una cota de volatilidad:

$$\sum_i w_i = 1, \quad 0 \leq w_i \leq w_{\max}, \quad w^\top \Sigma w \leq \sigma_{\max}^2. \quad (9.10)$$

La restricción $w_i \geq 0$ impide ventas cortas, la suma igual a uno invierte todo el capital y el límite por activo evita concentración extrema. El parámetro γ controla la aversión al riesgo: valores altos penalizan más la varianza y producen carteras conservadoras, mientras que valores bajos permiten mayor exposición a retorno esperado.

La frontera eficiente se obtiene resolviendo, para distintos retornos objetivo, el portafolio de mínima varianza que alcanza al menos dicho retorno:

$$\min_w w^\top \Sigma w. \quad (9.11)$$

El portafolio denominado *Ideal de mercado* se selecciona como el punto de la frontera eficiente con mayor ratio de Sharpe,

$$Sharpe = \frac{R_p - R_f}{\sigma_p}. \quad (9.12)$$

Esta es una aproximación discreta al portafolio de tangencia, porque el código no maximiza directamente el cociente de Sharpe, sino que elige el mejor punto entre 30 puntos calculados sobre la frontera.

El benchmark base selecciona los 20 primeros activos del universo ordenado por `marketCap` y asigna pesos iguales. Esta regla no estima μ ni Σ , por lo que es menos sensible al error de parámetros. Además, se define `b_teorico`, que toma la volatilidad histórica del benchmark y construye un portafolio Markowitz que maximiza retorno esperado sujeto a esa misma volatilidad. Su objetivo es responder qué portafolio teórico podría obtenerse si se acepta el mismo nivel de riesgo que el benchmark.

Para estabilizar la matriz de covarianzas, el notebook aplica *shrinkage* de 20%, mezclando 80% de la covarianza completa con 20% de su diagonal:

$$\Sigma_{\text{shrink}} = (1 - \lambda)\Sigma + \lambda \text{diag}(\Sigma). \quad (9.13)$$

Luego se utiliza `nearest_psd` para forzar que la matriz sea semidefinida positiva, requisito técnico para resolver problemas cuadráticos convexos con CVXPY. El rebalanceo divide el periodo futuro en segmentos de 126 días hábiles; al inicio de cada segmento se reestima el portafolio usando la historia inicial y los retornos futuros ya observados hasta ese momento. Así, el modelo incorpora información nueva sin usar datos futuros no disponibles al momento de la decisión.

Supuestos del experimento

El experimento supone que los precios de cierre y dividendos de los CSV representan adecuadamente la información disponible para cada activo. Los retornos diarios se calculan como retornos totales, incorporando dividendos, por lo que se considera que estos forman parte del rendimiento económico del inversionista. Al construir la matriz de retornos se utiliza `join="inner"`, conservando solo fechas comunes a todos los activos seleccionados; esto facilita la estimación matricial, aunque asume que eliminar fechas no comunes no introduce sesgos relevantes.

Desde el punto de vista de mercado, las carteras son *long-only*, invierten el 100% del capital disponible, no usan apalancamiento y permiten divisibilidad perfecta de activos. El modelo omite costos de transacción, impuestos, *spreads* bid-ask, restricciones de liquidez, impacto de mercado y *slippage*. Por ello, los resultados deben interpretarse como una aproximación teórica del desempeño y no como una simulación completa de ejecución real. La tasa libre de riesgo se mantiene constante en 2% anual.

En términos estadísticos, se asume que los retornos históricos contienen información útil sobre retornos y riesgos futuros, aunque los propios resultados muestran que esta estabilidad es imperfecta. La anualización usa 252 días hábiles; el retorno se anualiza por capitalización compuesta y la volatilidad mediante raíz del tiempo. Si una cota de volatilidad vuelve infactible un perfil, el código relaja esa cota manteniendo las restricciones restantes. Finalmente, en el experimento pandemia el periodo futuro fuera de muestra se mantiene fijo entre escenarios, por lo que las diferencias observadas se atribuyen a la información usada para calibrar y no a cambios en el mercado futuro evaluado.

Estructura del notebook

El notebook se organiza en bloques secuenciales. Primero define la documentación inicial, requisitos, estructura de carpetas y uso de archivos cacheados mediante `FORCE_RECOMPUTE`. Luego importa librerías, fija rutas, define `TRADING_DAYS_PER_YEAR = 252`, `REBALANCE_DAYS = 126`, delimita el periodo pandémico y crea los escenarios `sin_pandemia` y `con_pandemia`. Posteriormente carga el script base `markowitz_cvxpy_benchmark_teorico.py` como módulo local, reutilizando funciones de lectura, selección de universo, estimación de parámetros, optimización, frontera eficiente, benchmark y evaluación.

El experimento principal fija `DEFAULT_BENCHMARK_SIZE = 20`, `DEFAULT_MARKET_UNIVERSE_SIZE = 601`, `DEFAULT_FRONTIER_POINTS = 30`, `DEFAULT_FRONTIER_MAX_WEIGHT = 0.20`, `DEFAULT_RISK_FREE_RATE = 0.02`, `DEFAULT_INITIAL_CAPITAL = 1000.0`, `DEFAULT_SHRINKAGE = 0.20`, `HISTORICAL_YEARS = 7` y `FUTURE_YEARS = 2`. La configuración `h7_f2` se usa como caso central porque la validación robusta posterior la identifica como el horizonte con mejor desempeño agregado.

Las funciones auxiliares del notebook permiten cargar datasets por escenario, calcular retornos totales, generar ventanas de rebalanceo, definir la vista de entrenamiento disponible en cada segmento, resolver portafolios por instante y evaluar el periodo futuro completo. La clase `ScenarioDataset` agrupa la información de cada escenario, mientras que `evaluate_rebalanced_window` coordina el experimento: crea el split histórico/futuro, divide el futuro en segmentos, reestima pesos en cada rebalanceo, calcula retornos realizados y guarda métricas globales, por segmento y por punto de frontera.

La validación inicial verifica rutas, carga de datos y funcionamiento de ventanas. En una prueba reducida se obtienen 2717 observaciones para el escenario sin pandemia y

3 473 para el escenario con pandemia, diferencia esperable porque la segunda base conserva 2020–2022. En el caso principal se cargan o generan cuatro CSV:

```
rebalance_summary_h7_f2_601activos.csv,
rebalance_segments_h7_f2_601activos.csv,
segment_summary_h7_f2_601activos.csv y
frontier_segments_h7_f2_601activos.csv.
```

Tabla 9.21. Dimensión de resultados cacheados del experimento principal.

Escenario	Portafolios	Filas segmento	Puntos frontera
Sin pandemia	9	36	119
Con pandemia	9	36	119

Los 9 portafolios corresponden a cinco perfiles de riesgo, Benchmark, `b_teorico`, Mínima varianza e Ideal de mercado. Las 36 filas por escenario equivalen a 9 portafolios evaluados en 4 segmentos semestrales. Al exportar resultados, el notebook genera 18 filas de resumen global, 72 filas de segmentos rebalanceados, 72 filas de resumen por segmento y 238 puntos de frontera.

KPIs utilizados

El desempeño se evalúa mediante indicadores rebalanceados fuera de muestra. El retorno total rebalanceado mide la ganancia acumulada durante todo el periodo futuro:

$$R_{\text{total}} = \prod_t (1 + r_t) - 1. \quad (9.14)$$

El retorno anualizado para los dos años futuros se calcula como:

$$R_{\text{anual}} = (1 + R_{\text{total}})^{1/2} - 1. \quad (9.15)$$

La volatilidad diaria corresponde a la desviación estándar de los retornos concatenados de todos los segmentos y se anualiza mediante:

$$\sigma_{\text{anual}} = \sigma_{\text{diaria}} \sqrt{252}. \quad (9.16)$$

El Sharpe rebalanceado mide retorno excedente por unidad de riesgo:

$$\text{Sharpe} = \frac{R_{\text{anual}} - 0.02}{\sigma_{\text{anual}}}. \quad (9.17)$$

También se calculan máximo *drawdown*, CVaR diario al 95%, número de activos con peso positivo, mayor peso individual, cinco principales posiciones, riqueza final futura desde capital inicial 1 000, Sharpe teórico y Sharpe real futuro. Esta última comparación es central para diagnosticar *overfitting*, ya que contrasta la eficiencia esperada durante el entrenamiento con la eficiencia realizada fuera de muestra.

Resultados del experimento pandemia

La comparación entre escenarios calcula retorno total, retorno anual, volatilidad anual, Sharpe y diferencias `con_pandemia - sin_pandemia`. El resultado central se resume en la Tabla 9.22.

Tabla 9.22. Comparación de portafolios con y sin pandemia en entrenamiento.

Portafolio	Ret. sin pand.	Sharpe sin pand.	Ret. con pand.	Sharpe con pand.	Delta ret.	Delta Sharpe
Muy conservador	58,0%	2,208	54,5%	2,023	−3,4%	−0,184
Conservador	67,8%	2,425	55,5%	1,972	−12,3%	−0,453
Neutro	82,9%	2,413	60,5%	1,756	−22,5%	−0,657
Arriesgado	91,6%	1,733	58,4%	1,167	−33,2%	−0,566
Muy arriesgado	102,7%	1,412	44,0%	0,549	−58,7%	−0,863
Benchmark	101,4%	2,052	101,4%	2,052	−0,0%	−0,000
b_teorico	104,5%	1,515	56,7%	0,966	−47,8%	−0,548
Mínima varianza	56,6%	2,110	54,6%	2,016	−2,0%	−0,094
Ideal de mercado	76,5%	2,507	59,5%	1,399	−16,9%	−1,108

Sin pandemia, el mejor portafolio es Ideal de mercado, con Sharpe 2,507 y retorno total de 76,5%. Con pandemia, el mejor resultado corresponde al Benchmark, con Sharpe 2,052 y retorno de 101,4%. Incluir el periodo 2020–2022 deteriora casi todos los portafolios

optimizados, especialmente aquellos más agresivos o dependientes de estimaciones de retorno esperado. El Benchmark permanece invariante porque su regla no utiliza μ ni Σ , sino una selección top-20 equiponderada.

Tabla 9.23. Mayores caídas de Sharpe al incluir pandemia en entrenamiento.

Portafolio	Delta Sharpe
Ideal de mercado	−1,108
Muy arriesgado	−0,863
Neutro	−0,657
Arriesgado	−0,566
b_teorico	−0,548

La interpretación es que los datos de pandemia alteran las estimaciones de retornos y covarianzas. El efecto es más fuerte en carteras agresivas o de tangencia, que dependen de diferencias pequeñas en μ . En cambio, Mínima varianza es la cartera Markowitz más estable, con una caída de Sharpe de solo 2,110 a 2,016, porque depende principalmente de covarianzas y no de predicciones de retorno individual.

Rebalanceo

El rebalanceo semestral mejora el Sharpe en Conservador, Ideal de mercado, Mínima varianza y Neutro, pero deteriora Muy arriesgado, Arriesgado, b_teorico y Benchmark frente a una versión base sin rebalanceo. Por lo tanto, el rebalanceo funciona como un mecanismo de actualización y control, pero no garantiza mejor desempeño. Puede reducir deriva de pesos e incorporar información reciente, aunque también puede vender activos ganadores demasiado pronto o amplificar ruido en estimaciones nuevas.

Splits aleatorios

El experimento de splits aleatorios no recalcula Markowitz, sino que lee salidas preexistentes de `outputs_markowitz_cvxpy_splits_aleatorios`. El diseño considera una ventana base de 9 años, 28 combinaciones train/test con suma menor o igual a 9,

70 ventanas aleatorias con semilla 42, 560 evaluaciones de portafolio, 601 activos y 1 392 puntos de frontera.

Tabla 9.24. Resumen del experimento de splits aleatorios.

Indicador	Resultado
Combinaciones train/test	28
Ventanas aleatorias	70
Evaluaciones de portafolios	560
Activos	601
Puntos de frontera	1 392

El mejor split promedio global es $h5_f2$, con Sharpe futuro promedio de 2,34. Para el Benchmark, el mejor horizonte particular es $h6_f2$, con Sharpe futuro medio de 2,615. Esta sensibilidad muestra que las conclusiones no deben depender de un único split.

Tabla 9.25. Promedio y variabilidad del Sharpe en splits aleatorios.

Portafolio	Sharpe medio	Desv. est. Sharpe
Benchmark	2,057	0,381
Mínima varianza	1,940	0,250
Muy conservador	1,885	0,288
Conservador	1,799	0,334
Ideal de mercado	1,799	0,421
Neutro	1,781	0,413
Arriesgado	1,644	0,449
Muy arriesgado	1,625	0,458

En promedio, el Benchmark supera a los portafolios Markowitz. Mínima varianza aparece como la versión Markowitz más robusta, ya que combina buen Sharpe con baja variabilidad.

Evaluación robusta

La validación robusta con ventanas móviles evalúa 6 horizontes y 18 ventanas fuera de muestra; sus resultados respaldan $h7_f2$ como caso principal.

Tabla 9.26. Sharpe futuro medio en validación robusta por ventanas móviles.

Horizonte	Sharpe futuro medio
$h7_f2$	2,32
$h6_f3$	2,07
$h5_f4$	1,88
$h4_f5$	1,66
$h3_f6$	1,60
$h2_f7$	1,35

El resultado indica que 7 años de historia y 2 años de futuro equilibran estabilidad de parámetros y relevancia temporal. Además, en los splits aleatorios el Ideal de mercado presenta Sharpe teórico medio de 5,01 y Sharpe real futuro de 1,80, una brecha que evidencia *overfitting* o error de estimación: la cartera parece excepcional en entrenamiento, pero no replica esa eficiencia fuera de muestra.

Implicancias y conclusiones

La primera implicancia es que Markowitz es altamente sensible a la estimación de retornos esperados. La matriz de covarianzas importa, pero μ suele ser más ruidoso; por eso los perfiles agresivos, que explotan diferencias pequeñas entre activos, son los que más se deterioran al incluir pandemia. En segundo lugar, el Benchmark top-20 equiponderado es una línea base exigente: diversifica en empresas grandes sin depender de parámetros estimados, por lo que obliga a justificar cualquier superioridad de Markowitz con evidencia fuera de muestra. En tercer lugar, Mínima varianza cumple un rol defensivo relevante, porque no maximiza retorno esperado y depende menos de predicciones individuales.

El rebalanceo semestral debe interpretarse como un *trade-off*. Actualizar pesos permite incorporar información reciente, pero puede amplificar ruido si las nuevas estimaciones son inestables. Asimismo, la inclusión de pandemia no significa que el mercado futuro

evaluado sea peor, porque el periodo fuera de muestra se mantiene fijo en ambos escenarios. Lo que cambia es el conjunto de datos usado para entrenar, por lo que el resultado mide cómo los datos de estrés modifican la percepción estimada de riesgo-retorno.

En síntesis, el notebook implementa una comparación metodológicamente completa entre Markowitz y benchmark, incorporando escenarios de pandemia, rebalanceo y validación por múltiples splits. La principal conclusión es que no basta con reportar el portafolio de mayor Sharpe en un único periodo: se debe contrastar con benchmarks simples, evaluar robustez temporal y separar desempeño teórico de desempeño realizado. El caso `h7_f2` queda justificado por la validación robusta, mientras que `h5_f2` y `h6_f2` deben reportarse como sensibilidad favorable. Para la entrega, conviene presentar Benchmark y Mínima varianza como líneas base obligatorias, usar `h7_f2` como escenario principal y evitar afirmar superioridad de Markowitz sin evidencia fuera de muestra.

Black-Litterman

Resumen

Este apartado resume la implementación del notebook `black_litterman.ipynb`, que extiende el experimento de optimización de portafolios desarrollado previamente con Markowitz. Su objetivo no es reemplazar la lógica anterior, sino construir una versión Black-Litterman comparable, usando la misma base de datos, ventanas de entrenamiento y prueba, perfiles de riesgo e indicadores de evaluación. De esta forma, las diferencias observadas se atribuyen principalmente al cambio en la estimación de retornos esperados: desde promedios históricos puros hacia retornos posteriores que combinan equilibrio de mercado y *views* del inversionista.

El universo central corresponde a 601 activos del mercado F5, seleccionados desde metadata y series históricas de retornos totales. Se comparan dos escenarios: una base sin el periodo pandémico y otra que incorpora las observaciones de 2020–2022. El experimento principal utiliza 7 años de calibración y 2 años de evaluación fuera de muestra, configuración denotada `h7_f2`. Durante el periodo futuro, el portafolio se recalibra semestralmente cada 126 días bursátiles; en cada rebalanceo se estima la matriz de covarianzas, se construye el prior Black-Litterman, se aplica una *view* y se optimizan portafolios con CVXPY.

Tabla 9.27. Escenarios evaluados en Black-Litterman.

Escenario	Descripción	Propósito
<code>sin_pandemia</code>	Base filtrada sin 2020–2022.	Evaluar desempeño en una muestra menos dominada por shocks extremos.
<code>con_pandemia</code>	Base que incorpora 2020–2022.	Medir sensibilidad ante un historial con estrés, recuperación y alta volatilidad.

Fundamentos metodológicos

El modelo Black-Litterman responde a una debilidad central de Markowitz: los retornos esperados son difíciles de estimar y pequeños cambios en ellos pueden generar

variaciones importantes en los pesos óptimos. Para reducir esa sensibilidad, Black-Litterman combina dos fuentes de información: un prior de equilibrio de mercado, que representa retornos implícitos en una cartera de mercado, y *views* del inversionista, que expresan opiniones absolutas o relativas sobre activos, grupos o factores.

La implementación calcula el prior como:

$$\pi = \delta \Sigma w_{\text{market}}, \quad (9.18)$$

donde Σ es la matriz de covarianzas diaria estimada, w_{market} son pesos por capitalización bursátil y δ es la aversión al riesgo implícita:

$$\delta = \frac{R_{\text{mercado}} - R_f}{\sigma_{\text{mercado}}^2}. \quad (9.19)$$

Las *views* se representan mediante:

$$P\mu = Q + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \Omega), \quad (9.20)$$

donde P define la combinación de activos observada, Q el retorno esperado de esa combinación y Ω la incertidumbre asociada. La actualización posterior utilizada es:

$$\mu_{\text{BL}} = \pi + \tau \Sigma P^\top (P \tau \Sigma P^\top + \Omega)^{-1} (Q - P\pi). \quad (9.21)$$

El término $Q - P\pi$ representa la sorpresa de la *view* respecto del prior. Si la opinión ya está incorporada en el equilibrio, el ajuste es pequeño; si contradice al prior y tiene baja incertidumbre, el posterior se desplaza con mayor fuerza hacia la *view*.

Construcción y peso de las *views*. La *view* de momentum se basa en persistencia de retornos. El código calcula el rendimiento acumulado de cada activo durante los últimos 252 días, selecciona los 20 con mayor momentum y los 20 con peor momentum, y construye una opinión relativa:

$$R(\text{top 20 momentum}) - R(\text{bottom 20 momentum}) = Q. \quad (9.22)$$

La matriz P asigna peso positivo igualitario a los ganadores y negativo igualitario a los rezagados. Esta formulación es adecuada para Black-Litterman porque no exige estimar el retorno absoluto de cada activo, sino solo expresar que un grupo debería superar a otro.

La *view* de desempleo se basa en sensibilidad cíclica sectorial. Si el desempleo asumido está por debajo de su nivel neutral, la economía se interpreta como más fuerte, por lo que sectores cíclicos deberían superar a sectores defensivos. Con los parámetros actuales:

$$\text{signal} = 0,05 - 0,04 = 0,01, \quad Q = \frac{0,01}{252} = 0,00003968. \quad (9.23)$$

En consecuencia, P queda long sectores cíclicos y short sectores defensivos. Esta *view* es conceptualmente razonable, pero debe leerse como un análisis de escenario, ya que el desempleo usado es fijo y no una observación actualizada en cada rebalanceo.

El peso de una *view* no se define como porcentaje de portafolio, sino mediante su precisión estadística relativa frente al prior. En el código:

$$\Omega = \frac{P\tau\Sigma P^\top}{\text{confidence}}. \quad (9.24)$$

Si la confianza aumenta, Ω disminuye y el posterior se mueve con mayor fuerza hacia Q . En esta implementación, momentum tiene confianza 0,50 y desempleo 0,35; por tanto, a igualdad de varianza de la *view*, momentum recibe mayor peso estadístico. Sin embargo, el impacto final también depende de Q , de P , de τ , de Σ y de la distancia entre Q y $P\pi$.

Supuestos del experimento

El experimento utiliza retornos totales diarios, 252 días bursátiles por año, covarianza con *shrinkage* de 20%, corrección `nearest_psd`, prior de equilibrio basado en capitalización, tasa libre de riesgo fija de 2% anual y $\tau = 0,05$. Las carteras finales son *long-only*, invierten todo el capital, aplican cotas de concentración y se rebalancean semestralmente. Las *views* pueden ser long-short, pero los portafolios finales no permiten ventas cortas. El benchmark top-20 equiponderado no depende de Black-Litterman ni de las *views*.

Tabla 9.28. Supuestos principales del experimento Black-Litterman.

Supuesto	Implementación	Implicancia
Retornos diarios	Series de retornos totales diarios	Se asume frecuencia diaria y 252 días bursátiles.
Covarianza estable	<code>estimate_parameters</code> con 20% <i>shrinkage</i>	Mejora estabilidad, pero no modela cambios de régimen.
Matriz PSD	<code>nearest_psd</code>	Evita problemas numéricos en optimización cuadrática.
Prior de equilibrio	$\pi = \delta \Sigma w_{\text{market}}$	Supone que capitalización contiene información agregada.
Tasa libre fija	2% anual	Simplifica Sharpe y prior.
tau	0,05	Incertidumbre del prior no calibrada empíricamente.
<i>Long-only</i>	$w \geq 0$	Las carteras finales no hacen ventas cortas.
Rebalanceo	126 días	Actualiza modelo, pero no incorpora costos de transacción.
Momentum persistente	Ganadores recientes superan perdedores	Puede ser sensible a reversals.
Desempleo fijo	4% vs 5% neutral	Escenario macro, no serie observada dinámica.

Estructura del notebook

El notebook importa funciones del módulo `markowitz_cvxpy_benchmark_teorico.py`, reutilizando la carga de datos, estimación de parámetros, perfiles de riesgo, restricciones, KPIs y optimizadores de Markowitz. Esta decisión permite que la comparación entre Markowitz y Black-Litterman sea metodológicamente consistente.

Tabla 9.29. Parámetros globales del experimento Black-Litterman.

Parámetro	Valor	Función
MARKET_SIZE	601	Número de activos del universo de mercado.
BENCHMARK_SIZE	20	Número de activos del benchmark equiponderado.
HISTORICAL_YEARS	7	Años de entrenamiento del experimento central.
FUTURE_YEARS	2	Años de evaluación fuera de muestra.
REBALANCE_DAYS	126	Frecuencia semestral de rebalanceo.
DEFAULT_MAX_WEIGHT	20%	Cota máxima general para portafolios especiales.
DEFAULT_RISK_FREE_RATE	2% anual	Tasa usada en Sharpe y prior.
DEFAULT_SHRINKAGE	20%	Regularización de la matriz de covarianzas.
DEFAULT_TAU	0,05	Incertidumbre del prior Black-Litterman.

Tabla 9.30. Parámetros de las *views*.

<i>View</i>	Parámetro	Valor	Interpretación
Momentum	MOMENTUM_LOOKBACK	252 días	Ventana reciente para medir momentum.
Momentum	MOMENTUM_TOP_BOTTOM	20	Activos long y short de la <i>view</i> relativa.
Momentum	MOMENTUM_CONFIDENCE	0,50	Confianza asignada a la <i>view</i> .
Desempleo	UNEMPLOYMENT_RATE_ASSUMED	4%	Desempleo asumido.
Desempleo	UNEMPLOYMENT_NEUTRAL	5%	Nivel neutral de desempleo.
Desempleo	MACRO_UNEMPLOYMENT_BETA	1,0	Sensibilidad del diferencial macro.
Desempleo	UNEMPLOYMENT_CONFIDENCE	0,35	Confianza asignada a la <i>view</i> macro.

La clase `ScenarioDataset` agrupa la llave del escenario, etiqueta legible, matriz de retornos, metadata y tickers cargados. La función `load_scenario_dataset` lee la metadata, selecciona activos de mercado y concatena retornos con intersección temporal mediante `join="inner"`, garantizando una matriz rectangular para optimización. La función `market_cap_weights` construye pesos de mercado con capitalización bursátil y cae a un portafolio equiponderado si las capitalizaciones son inválidas.

El pipeline central estima parámetros con *shrinkage*, calcula el prior de mercado, construye la *view*, aplica Black-Litterman y resuelve portafolios para cinco perfiles de riesgo, `b_teorico`, Mínima varianza, Benchmark e Ideal de mercado. Cuando se ejecutan validaciones más costosas, se usa una versión reducida que resuelve solo Neutro, Mínima varianza y Benchmark. El *smoke test* confirma que μ_{BL} y Σ_{BL} no contienen valores inválidos, que los pesos suman 1 y que no aparecen posiciones negativas relevantes.

Tabla 9.31. Dimensión de salidas del experimento Black-Litterman.

Objeto	Filas
Resultados centrales rebalanceados	36
Segmentos centrales	144
<i>Views</i> registradas	16
Ventanas aleatorias procesadas	70
Ventanas robustas procesadas	18
Filas de validación aleatoria	420
Filas de validación robusta	108

KPIs utilizados

Los KPIs utilizados son retorno total rebalanceado, retorno anual rebalanceado, volatilidad diaria y anual, Sharpe rebalanceado, máximo *drawdown*, CVaR diario al 95%, número de segmentos, activos con peso positivo y principales posiciones. El indicador principal para ordenar resultados es el Sharpe rebalanceado, porque resume retorno y riesgo fuera de muestra tras concatenar todos los rebalanceos.

Resultados del experimento pandemia

Los mejores portafolios Black-Litterman del experimento central se muestran en la Tabla 9.32. El mejor resultado global corresponde a la *view* de desempleo sin pandemia en el portafolio Neutro, con Sharpe 2,44. Momentum también funciona bien sin pandemia, aunque pierde fuerza relativa cuando se incluye el periodo pandémico.

Tabla 9.32. Mejores portafolios Black-Litterman del experimento central.

Escenario	<i>View</i>	Portafolio líder	Ret. total	Vol. anual	Max drawdown	Sharpe
Sin pandemia	Desempleo	Neutro	63,1%	10,5%	−10,4%	2,44
Sin pandemia	Momentum	Muy conservador	64,0%	10,9%	−10,1%	2,38
Con pandemia	Desempleo	Arriesgado	71,9%	12,4%	−13,3%	2,36
Con pandemia	Momentum	Conservador	56,4%	11,2%	−10,3%	2,06

Tabla 9.33. Comparación final entre equiponderado, Markowitz y Black-Litterman.

Escenario	Modelo	<i>View</i>	Portafolio	Ret. total	Vol. anual	Drawdown	CVaR 95%	Sharpe
Con pandemia	Equiponderado	No aplica	Benchmark	101,4%	19,5%	−21,9%	2,79%	2,05
Con pandemia	Markowitz	Histórico	Muy conservador	54,5%	11,0%	−10,2%	1,50%	2,02
Con pandemia	Black-Litterman	Desempleo	Arriesgado	71,9%	12,4%	−13,3%	1,71%	2,36
Con pandemia	Black-Litterman	Momentum	Conservador	56,4%	11,2%	−10,3%	1,47%	2,06
Sin pandemia	Equiponderado	No aplica	Benchmark	101,4%	19,5%	−21,9%	2,79%	2,05
Sin pandemia	Markowitz	Histórico	Ideal de mercado	76,5%	12,3%	−12,6%	1,67%	2,51
Sin pandemia	Black-Litterman	Desempleo	Neutro	63,1%	10,5%	−10,4%	1,41%	2,44
Sin pandemia	Black-Litterman	Momentum	Muy conservador	64,0%	10,9%	−10,1%	1,45%	2,38

La lectura principal es que Black-Litterman mejora claramente a Markowitz en el escenario con pandemia, especialmente con la *view* de desempleo. En el escenario sin pandemia, Markowitz alcanza el mayor Sharpe final con el portafolio Ideal de mercado, aunque Black-Litterman obtiene resultados cercanos con menor volatilidad y *drawdowns* controlados.

Tabla 9.34. Mayor mejora de Black-Litterman frente a Markowitz.

Escenario	View	Portafolio	Sharpe BL	Sharpe Markowitz	Delta Sharpe
Con pandemia	Desempleo	Arriesgado	2,36	1,17	+1,19

También destacan las mejoras de desempleo/Muy arriesgado con delta Sharpe +0,87, desempleo/b_teorico con +0,64 y momentum/Muy arriesgado con +0,59. Esto sugiere que Black-Litterman aporta mayor valor cuando el historial contiene episodios extremos, ya que el prior de equilibrio y las *views* reducen la dependencia de medias históricas inestables.

Al comparar el mismo portafolio y *view* entre bases con y sin pandemia, varios deltas de Sharpe son negativos. Momentum/Muy conservador cae $-0,37$, desempleo/Neutro cae $-0,31$, desempleo/Muy conservador cae $-0,30$ y desempleo/Conservador cae $-0,29$. Esto indica que incluir pandemia tiende a deteriorar la estabilidad relativa de varias configuraciones, pero también muestra que el escenario con pandemia es una prueba más exigente donde ciertas *views*, especialmente desempleo, siguen mejorando a Markowitz.

Rebalanceo

El rebalanceo Black-Litterman mantiene la frecuencia semestral de 126 días bursátiles. En cada fecha se reestiman covarianzas, prior de equilibrio, *views*, retornos posteriores y pesos finales. Esta decisión permite que la señal incorpore información disponible en cada segmento, pero mantiene la comparabilidad con Markowitz porque usa la misma ventana futura, las mismas restricciones y los mismos KPIs. Como en Markowitz, el rebalanceo no incorpora costos de transacción, por lo que sus resultados deben interpretarse como desempeño teórico fuera de muestra.

Splits aleatorios

En los 70 splits aleatorios, los mejores resultados para el portafolio Neutro favorecen horizontes con 6 años de entrenamiento y 2 de prueba. Esto es consistente con la necesidad de contar con suficiente historia para estabilizar covarianzas y prior, sin usar una ventana tan larga que diluya cambios estructurales.

Tabla 9.35. Validación con 70 splits aleatorios para el portafolio Neutro.

<i>View</i>	Horizonte	Sharpe prom.	Ret. total prom.	Vol. anual prom.	Ventanas
Desempleo	h6_f2	2,48	61,5%	10,4%	3
Momentum	h6_f2	2,31	68,6%	13,1%	3

Evaluación robusta

Tabla 9.36. Validación robusta con 18 ventanas para el portafolio Neutro.

<i>View</i>	Mejor horizonte	Sharpe prom.	Ret. total prom.	Vol. anual prom.	Drawdown prom.
Desempleo	h7_f2	2,35	59,2%	10,6%	−9,7%
Momentum	h7_f2	2,23	68,5%	13,6%	−12,8%

En validación robusta, desempleo domina en Sharpe para el portafolio Neutro porque logra menor volatilidad y menor *drawdown*. Momentum obtiene mayor retorno total promedio, pero a costa de mayor riesgo.

Implicancias y conclusiones

Los resultados muestran que Black-Litterman cumple su objetivo principal: suavizar la dependencia de medias históricas puras. Esto se observa con mayor claridad en el escenario con pandemia, donde Markowitz queda más castigado y Black-Litterman mejora el Sharpe en varios portafolios. El tipo de *view* es determinante. Desempleo genera portafolios más defensivos y mejor Sharpe en configuraciones centrales; aunque conceptualmente es una *view* cíclica, su menor Q y menor confianza producen ajustes más moderados. Momentum, en cambio, entrega una señal más intensa y puede capturar retornos altos, pero también expone a reversals y mayor volatilidad.

El benchmark equiponderado top-20 obtiene retornos totales elevados, aunque con volatilidad y *drawdown* superiores. Su Sharpe es competitivo, pero no domina siempre, lo que muestra que un benchmark simple puede ser difícil de superar en retorno bruto

mientras los modelos optimizados pueden mejorar la relación retorno-riesgo. Las diferencias entre `sin_pandemia` y `con_pandemia` deben entenderse como una prueba de robustez: incluir shocks históricos cambia la frontera eficiente y las estimaciones de riesgo, no necesariamente el mercado futuro evaluado.

Para mejorar la implementación, la *view* de desempleo debería pasar de supuesto fijo a señal observable o pronosticada, usando por ejemplo la tasa efectiva disponible al momento del rebalanceo, sorpresas respecto de expectativas o variaciones mensuales o trimestrales. La *view* de momentum podría refinarse con momentum ajustado por volatilidad, exclusión del mes más reciente para reducir reversals o combinación de ventanas de 6 y 12 meses. También sería valioso incorporar *views* de valor, calidad, tamaño, tasas de interés, inflación o revisiones de utilidades.

Otra mejora importante es calibrar Ω con evidencia empírica en lugar de fijar manualmente la confianza. Esta calibración podría usar error histórico de predicción, frecuencia de acierto del signo, correlación entre señal y retorno futuro, varianza residual de regresiones, metodología de desplazamiento deseado en pesos o validación cruzada temporal. Además, conviene analizar sensibilidad a τ , *shrinkage*, frecuencia de rebalanceo, `max_weight` y tasa libre de riesgo, e incorporar costos de transacción, restricciones sectoriales, cotas de liquidez, control de *tracking error*, penalización por rotación y estimadores robustos de covarianza.

En síntesis, la implementación construye un experimento Black-Litterman completo y comparable con Markowitz y benchmark. Su principal aporte es reemplazar retornos esperados históricos por retornos posteriores que combinan equilibrio de mercado y *views*. Los resultados indican que Black-Litterman es especialmente valioso en escenarios exigentes, como el entrenamiento con pandemia, donde la *view* de desempleo mejora fuertemente el Sharpe frente a Markowitz. La conclusión central no es que una *view* sea universalmente superior, sino que la calidad, calibración y confianza de las *views* determinan el valor práctico del modelo.

Simulación Monte Carlo

Resumen

Como parte de la documentación técnica del proyecto FinPUC, se elaboró un informe consolidado que integra los resultados de los tres notebooks de implementación: Markowitz vs Benchmark, Black-Litterman y Simulación Monte Carlo. El propósito del documento es proveer trazabilidad completa entre los datos, cálculos, técnicas de optimización, comparaciones y conclusiones finales del proyecto.

El informe fue generado el 09 de mayo de 2026 y opera sobre el universo F5 de 601 activos, benchmark top-20, rebalanceo semestral de 126 días hábiles y simulación Monte Carlo a 260 semanas. En esta etapa, el notebook `p4_montecarlo_recomendador_portafolios` transforma los KPIs de Markowitz, Black-Litterman y Equiponderado en una evaluación de cliente y empresa. Para cada combinación de escenario, técnica, *view* y perfil simula trayectorias de riqueza, probabilidad de retiro, aceptación de recomendaciones, utilidad de la empresa y un score final de recomendación.

Fundamentos metodológicos

La Simulación Monte Carlo usa como insumos el retorno anual base y la volatilidad anual de cada estrategia. Estos parámetros provienen de los experimentos previos y se transforman a frecuencia semanal para simular trayectorias de riqueza de un cliente con capital inicial $C_0 = 1000$ USD. El retiro depende de la pérdida relativa frente a la tolerancia del perfil, mientras que la aceptación depende del atractivo riesgo-retorno de la recomendación.

El informe documenta una metodología de cálculo común para los modelos de entrada: estimación de parámetros (μ , Σ con *shrinkage* $\lambda = 0.20$, `nearest_psd`), anualización y frontera eficiente. La simulación no reoptimiza portafolios, sino que traduce esos KPIs financieros a variables de experiencia de cliente y de resultado para la empresa.

Supuestos del experimento

Se simulan 5 000 trayectorias por combinación durante 260 semanas, equivalentes a cinco años de evaluación semanal. Cada combinación se evalúa en tres escenarios proyectados: desfavorable, neutro y favorable. Los retornos semanales se aproximan con distribución normal, pese a que el análisis distribucional muestra colas pesadas. La comisión inicial es $k = 1\%$ sobre el capital inicial y, en recomendaciones aceptadas, se cobra sobre una fracción de rotación de 5% de la riqueza vigente.

El diseño opera sobre el mismo universo F5 de 601 activos usado por los experimentos de optimización, benchmark top-20 y KPIs rebalanceados. Por lo tanto, la comparación final no cambia el universo de acciones, sino la manera en que se transforma el desempeño histórico de cada técnica en una distribución de resultados de negocio.

Estructura del notebook

El documento metodológico consolidado se organiza en ocho secciones:

- (i) **Resumen ejecutivo:** comparación final de los tres modelos por escenario, con tabla de KPIs y top 12 del ranking.
- (ii) **Datos, universo F5 y diseño experimental:** descripción del filtrado (1 406 a 601 tickers), split `h7_f2` y escenarios con/sin pandemia.
- (iii) **Metodología de cálculo común:** estimación de parámetros (μ , Σ con *shrinkage* $\lambda = 0.20$, `nearest_psd`), anualización y frontera eficiente.
- (iv) **Markowitz vs benchmark:** portafolios por perfil, impacto de la pandemia en Sharpe, validación robusta por horizonte.
- (v) **Black-Litterman y matriz de views:** configuración de las cuatro views (momentum, momentum top-20 6M, momentum top-20/bottom-20 1Y, desempleo), resultados por view y escenario.
- (vi) **Simulación Monte Carlo y recomendador:** supuestos operativos, promedios por técnica, ranking completo del recomendador.
- (vii) **Conclusión integrada:** hallazgos principales y recomendación final.
- (viii) **Índice de anexos y tablas de auditoría:** inventario completo de CSVs generados.

El notebook define funciones de retiro y aceptación, construye insumos por técnica y perfil desde los CSV de Markowitz y Black-Litterman, ejecuta la Simulación Monte Carlo, resume KPIs por escenario, genera gráficos, calcula el ranking recomendador cliente-empresa y exporta conclusiones.

Las salidas principales son:

```
p4_model_inputs_kpis.csv
p4_montecarlo_summary.csv
p4_neutral_scenario_summary.csv
p4_recommendation_ranking.csv
p4_montecarlo_paths_quantiles.csv
```

El informe documenta un total de 21 archivos CSV generados por los tres notebooks, organizados por metodología. La Tabla 9.37 presenta el inventario completo.

Tabla 9.37. Índice de CSVs generados por el proyecto.

Archivo	Metodología	Filas	Cols	Propósito
rebalance_summary_h7_f2_601activos	Markowitz	18	12	KPIs rebalanceados
comparison_sin_vs_con_pandemia_h7_f2	Markowitz	9	21	Comparación escenarios
validacion_robusta_ventanas_moviles	Markowitz	6	4	Sharpe por horizonte
frontier_segments_h7_f2_601activos	Markowitz	238	24	Frontera eficiente
heatmap_sharpe_train_test	Markowitz	7	8	Heatmap splits
bl_rebalance_summary_h7_f2_601activos	Black-Litterman	72	14	KPIs BL rebalanceados
bl_views_h7_f2_601activos	Black-Litterman	32	36	Configuración views
comparison_three_models_kpis_h7_f2	Black-Litterman	12	13	Comparación 3 modelos
comparison_bl_vs_markowitz_h7_f2	Black-Litterman	72	19	Delta BL vs Markowitz
bl_robust_validation_summary	Black-Litterman	36	10	Validación robusta BL
p4_montecarlo_summary	Simulación Monte Carlo	180	29	Resumen completo MC
p4_neutral_scenario_summary	Simulación Monte Carlo	60	29	Escenario neutro
p4_recommendation_ranking	Simulación Monte Carlo	60	30	Ranking recomendador
p4_model_inputs_kpis	Simulación Monte Carlo	60	13	Inputs desde modelos
p4_montecarlo_paths_quantiles	Simulación Monte Carlo	1 980	13	Bandas P5–P95

KPIs utilizados

Los KPIs de cliente son riqueza terminal media, percentiles 5/50/95, ganancia esperada, probabilidad de ganancia, probabilidad de pérdida mayor a la tolerancia, tasa de retiro

y semana promedio de retiro. Los KPIs de empresa son ingreso promedio, ingreso mediano, ingreso percentil 95, ingreso como porcentaje del capital inicial y tasa de aceptación de recomendaciones. El ranking final usa *p4_score*, que combina valor para el cliente y valor para la empresa.

En el informe integrado, estos KPIs se conectan con retorno total, retorno anual, volatilidad anual, *drawdown*, CVaR y Sharpe de los modelos de entrada. Por esta razón, una técnica con mayor retorno histórico puede perder en score si eleva demasiado retiros o dispersión de resultados.

Resultados del experimento pandemia

La Tabla 9.38 presenta la comparación final de modelos por escenario, extraída del informe de metodologías.

Tabla 9.38. Comparación final de modelos por escenario (mejor portafolio por modelo).

Escenario	Modelo	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	Sharpe
Sin pandemia	Markowitz	Ideal de mercado	76,5%	32,8%	12,3%	−12,6%	2,51
Sin pandemia	BL mom. top20 6m	Neutro	72,3%	31,2%	11,9%	−12,9%	2,46
Sin pandemia	Equiponderado	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,05
Con pandemia	BL mom. top20 6m	Neutro	69,5%	30,2%	11,9%	−11,7%	2,38
Con pandemia	BL desempleo	Arriesgado	71,9%	31,1%	12,4%	−13,3%	2,36
Con pandemia	Equiponderado	Benchmark	101,4%	41,9%	19,5%	−21,9%	2,05
Con pandemia	Markowitz	Muy conservador	54,5%	24,3%	11,0%	−10,2%	2,02

La Tabla 9.39 presenta el top 10 del ranking en escenario neutro.

Tabla 9.39. Top 10 ranking de Simulación Monte Carlo en escenario neutro.

Rank	Escenario	Técnica	Perfil	Riqueza	Retiro	Utilidad	Score
1	Con pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 8 974	3,1%	USD 474	9 417
2	Sin pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 7 753	2,0%	USD 419	8 151
3	Con pandemia	BL Momentum	Muy arriesgado	USD 6 436	14,6%	USD 335	6 625
4	Sin pandemia	BL Desempleo	Muy arriesgado	USD 5 434	0,5%	USD 221	5 650
5	Sin pandemia	Markowitz	Muy arriesgado	USD 5 349	2,1%	USD 215	5 543
6	Sin pandemia	BL Momentum	Arriesgado	USD 5 304	10,9%	USD 320	5 515
7	Con pandemia	Equiponderado	Muy arriesgado	USD 5 280	0,0%	USD 204	5 485
8	Con pandemia	BL Mom. Top20 6M	Arriesgado	USD 5 137	0,5%	USD 312	5 445
9	Sin pandemia	Equiponderado	Muy arriesgado	USD 5 222	0,0%	USD 203	5 425
10	Sin pandemia	Equiponderado	Arriesgado	USD 5 084	0,2%	USD 308	5 390

La mejor combinación es Black-Litterman Momentum Top20 6M con datos de pandemia y perfil Muy arriesgado. Su ventaja se explica por alta riqueza terminal, tasa de retiro baja para un perfil agresivo y mayor utilidad para la empresa.

Rebalanceo

La Simulación Monte Carlo no recalcula pesos de portafolio. Recibe KPIs que ya incorporan el rebalanceo semestral de Markowitz y Black-Litterman. Por eso, el rebalanceo entra de forma indirecta: afecta retornos, volatilidad, drawdown y CVaR base, que luego determinan riqueza simulada, retiro y utilidad. Esta estructura evita mezclar dos capas de decisión: la optimización de pesos queda en los modelos financieros y la simulación se concentra en la evaluación cliente-empresa.

Splits aleatorios

La Simulación Monte Carlo no ejecuta splits aleatorios propios. Su robustez temporal depende de los insumos previamente validados en Markowitz y Black-Litterman. Esta decisión evita duplicar experimentos y mantiene el foco en la pregunta de negocio: cuál combinación de técnica, escenario y perfil genera mejor equilibrio cliente-empresa. En consecuencia, la lectura de sus resultados debe considerar la evidencia de splits aleatorios y validación robusta reportada para los modelos de entrada.

Evaluación robusta

Tabla 9.40. Ganadores por escenario proyectado en Simulación Monte Carlo.

Escenario	Técnica	View	Perfil	Riqueza	Retiro	Utilidad
Desfavorable	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 5 009	8,8%	USD 327
Neutro	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 8 974	3,1%	USD 474
Favorable	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 15 451	1,6%	USD 690

La misma técnica domina en los tres escenarios proyectados, lo que refuerza su consistencia dentro del marco de supuestos del notebook. Esta conclusión debe leerse con cautela porque los retornos simulados son normales y pueden subestimar eventos extremos. Para implementación comercial, conviene mostrar al usuario tres escenarios y no solo el escenario neutro: el riesgo de retiro cambia fuertemente cuando el camino simulado atraviesa pérdidas tempranas.

Implicancias y conclusiones

El informe de metodologías concluye con las siguientes observaciones:

- El benchmark top-20 equiponderado es una referencia fuerte por retorno total, pero su volatilidad y drawdown son mayores que las carteras Black-Litterman ajustadas por riesgo.
- Markowitz aporta una base estable y trazable, especialmente para perfiles conservadores, aunque depende fuertemente de retornos históricos.
- Black-Litterman Desempleo ofrece un ajuste macro competitivo y en algunos escenarios lidera frente a Markowitz por delta Sharpe.
- Black-Litterman Momentum Top20 6M es la técnica más fuerte en la Simulación Monte Carlo y la mejor variante market-cap momentum por Sharpe en ambos escenarios de datos.
- La recomendación final depende del objetivo: si se prioriza riqueza esperada y score, gana Black-Litterman Momentum Top20 6M; si se prioriza mínimo retiro, se deben revisar perfiles menos agresivos o Black-Litterman Desempleo.

La Simulación Monte Carlo conecta desempeño financiero con variables de negocio. El resultado principal es que Black-Litterman Momentum Top20 6M domina el ranking al combinar alta riqueza esperada, baja tasa de retiro y mayor utilidad para la empresa. La principal limitación es el supuesto normal: para la siguiente etapa conviene probar t-Student, Johnson SU u otra distribución con colas pesadas, además de sensibilizar costos de transacción y reglas de retiro basadas en *drawdown*.

El informe final de metodologías de portafolios se encuentra disponible como archivo PDF en el repositorio del proyecto: <https://github.com/Psacevedo/Capstone.git>. El documento incluye 16 figuras, 18 tablas y el índice completo de 21 CSVs de auditoría.

Conclusión integrada

Los tres notebooks forman una cadena metodológica. Markowitz define la base y el benchmark; Black-Litterman reduce dependencia de medias históricas mediante prior y *views*; Simulación Monte Carlo traduce los KPIs en una decisión cliente-empresa. La recomendación actual es usar Black-Litterman Momentum Top20 6M como alternativa principal, mantener el benchmark como referencia exigente y usar Markowitz como base de comparación y diagnóstico de sensibilidad.

ANEXO N°5: DETALLE DE LA SIMULACIÓN DE SENSIBILIDAD DE $K\%$

9.3. Detalle de la simulación de sensibilidad de $K\%$

El notebook `simulacion_comisiones_k.ipynb` ejecuta la simulación Monte Carlo para 8 valores de comisión $K \in \{0.25\%, 0.5\%, 0.75\%, 1\%, 1.5\%, 2\%, 3\%, 5\%\}$. Para cada K , se simulan 5 000 trayectorias de 260 semanas para 5 perfiles de riesgo y 4 metodologías (Equiponderado, Markowitz, Mínima Varianza, BL Momentum General).

Los parámetros de retorno y volatilidad semanal se obtienen de los KPIs generados en la Entrega 2, almacenados en los archivos CSV de `01_markowitz_vs_benchmark/outputs/` y `02_black_litterman/outputs/`.

La comisión se aplica en dos momentos: una comisión inicial de $K\%$ sobre $C_0 = 1\,000$ USD y comisiones periódicas de $K\%$ sobre el 5% de la riqueza actual en cada recomendación aceptada.

Las métricas de salida para cada combinación (K , metodología, perfil) incluyen: riqueza terminal media, tasa de retiro media, utilidad empresa media, Score P4, y las métricas se exportan a `k_sensitivity_summary.csv`.

ANEXO N°6: DETALLE DE LA OPTIMIZACIÓN MULTIOBJETIVO DE λ

9.4. Detalle de la optimización multiobjetivo de λ

El notebook `simulacion_lambda_multiobjetivo.ipynb` evalúa 11 valores de $\lambda \in \{0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0\}$. Para cada λ , se utiliza el K óptimo determinado en el análisis de sensibilidad y la metodología de mejor Score P4.

Las funciones objetivo $f_1(w)$ (retorno esperado del cliente) y $f_2(w)$ (utilidad esperada de FinPUC) se normalizan mediante min-max scaling al rango $[0, 1]$ usando los valores mínimos y máximos observados en todas las simulaciones. El score compuesto es:

$$S_\lambda = \lambda \cdot \tilde{f}_1 + (1 - \lambda) \cdot \tilde{f}_2. \quad (9.25)$$

Para cada λ , se ejecutan 5 000 trayectorias Monte Carlo de 260 semanas y se registran riqueza terminal, utilidad empresa, tasa de retiro y Score P4. Los resultados se exportan a `lambda_optimal_summary.csv`.

La frontera de Pareto se construye graficando los pares $(\tilde{f}_1, \tilde{f}_2)$ para cada λ . Los puntos sobre la frontera representan soluciones no dominadas donde no es posible mejorar un objetivo sin empeorar el otro.

ANEXO N°7: DIAGNÓSTICOS DE LA CALIBRACIÓN SECUENCIAL DE BLACK-LITTERMAN

9.5. Diagnósticos de la calibración secuencial de Black-Litterman

La calibración secuencial se implementa en `calibracion_secuencial.bl.py` y se valida mediante `validacion_3h_rolling.bl.py`. A continuación se detallan los diagnósticos de cada etapa.

9.5.1. Stage 1: Selección de familia de *view*

Se evaluaron cuatro familias: desempleo macro, momentum general, momentum top/bottom 1Y y momentum top market-cap 6M. Para cada una se ejecutó Black-Litterman con configuración base y se midió el Sharpe medio y delta Sharpe en $\mathcal{H}_1$. La familia ganadora fue desempleo macro con Sharpe medio 0.854 y delta Sharpe 0.159.

9.5.2. Stage 2: Estructura de P

Se probaron 9 combinaciones de tasa de desempleo asumida $U \in \{3\%, 4\%, 5\%\}$ y sensibilidad sectorial $\beta \in \{1.0, 1.5, 2.0\}$. La combinación ganadora fue $U = 4\%$ con $\beta = 1.5$, reflejando un escenario de desempleo moderadamente bajo con respuesta sectorial intermedia.

9.5.3. Stage 3: Intensidad de Q

Se escaló el vector Q por factores $q_{\text{scale}} \in \{0.5, 1.0, 1.5, 2.0\}$. El factor 1.5 resultó óptimo, indicando que amplificar moderadamente la señal macroeconómica mejora el desempeño fuera de muestra sin introducir inestabilidad excesiva.

9.5.4. Stage 4: Confianza Ω

La confianza $c \in \{0.25, 0.35, 0.50, 0.75, 1.00\}$ controla la incertidumbre asignada a la *view*. Con $c = 0.50$, la matriz Ω refleja una incertidumbre intermedia: ni tan alta que diluya la *view*, ni tan baja que ignore el prior de equilibrio.

9.5.5. Stage 5: Parámetro τ

El parámetro $\tau \in \{0.05, 0.10, 0.20, 0.50, 1.00\}$ escala la incertidumbre del prior. El valor óptimo $\tau = 0.20$ es mayor que el valor teórico sugerido por la literatura ($\tau \approx 1/T \approx 0.0004$ para 2 500 observaciones), lo que es consistente con la práctica de usar τ como un hiperparámetro de calibración más que como una estimación puntual de la incertidumbre del prior.

9.5.6. Resultados de la validación rolling

La validación rolling utilizó 10 ventanas de calibración en el escenario con pandemia y 3 en el escenario sin pandemia. Los resultados completos por ventana y perfil se encuentran en `05_Validacion_modelo/outputs/resumen_ejecucion_3h.md`.