



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2122 - TALLER DE INVESTIGACIÓN OPERATIVA (CAPSTONE)

FINPUC ENTREGA 3 GRUPO 13

INTEGRANTES:

PATRICIO ANDRES ACEVEDO FLORES
BENJAMÍN ALONSO CANO ARAYA
MATÍAS BENJAMÍN CATALÁN CONTRERAS
GASPAR TEN BERG YUNUSIC
DIEGO BENJAMÍN VILLALOBOS MICHEA

Miembros del Comité:

PROFESOR GUÍA: AGUSTÍN MATÍAS ANTONIO CHIU LÓPEZ

AYUDANTE TUTOR: JUAN ENRIQUE HURTADO BROWNE

Santiago de Chile, Junio 2026

ÍNDICE DE CONTENIDOS

ÍNDICE DE FIGURAS	vii
ÍNDICE DE TABLAS	viii
ABSTRACT	xi
RESUMEN	xii
1. Introducción	1
2. Descripción del problema	2
2.1. Contexto y motivación	2
2.2. Ciclo operacional	2
2.3. Perfiles de riesgo	2
2.4. Formulación del problema	3
2.4.1. Decisión principal	3
2.4.2. Objetivos	3
2.4.3. Restricciones	3
2.5. Datos disponibles	3
2.5.1. Fuente y estructura	3
2.5.2. Proceso de filtrado	4
2.5.3. Justificación del filtrado	4
2.5.4. Diseño experimental: escenarios con y sin pandemia	5
2.5.5. Problema de negocio: retorno del cliente y sostenibilidad por saldo administrado	5
3. Metodología	6
3.1. Revisión bibliográfica	6
3.1.1. Modelos fundamentales de optimización de portafolios	6
3.1.2. El modelo Black-Litterman	6
3.1.3. Estimación de covarianzas y medidas de riesgo	7
3.1.4. Sistemas de asesoría financiera automatizada	7
3.1.5. Fortalezas y debilidades de la metodología seleccionada	7
3.2. Arquitectura general del sistema	8
3.3. Estimación de parámetros	9
3.3.1. Retornos esperados	9
3.3.2. Matriz de covarianzas con <i>shrinkage</i>	9

3.3.3.	Anualización	9
3.4.	Optimización media-varianza de Markowitz	9
3.4.1.	Formulación por perfil de riesgo	9
3.4.2.	Frontera eficiente y portafolio de tangencia	10
3.5.	Modelo Black-Litterman	11
3.5.1.	Prior de equilibrio de mercado	11
3.5.2.	Incorporación de <i>views</i>	11
3.5.3.	Construcción de <i>views</i>	11
3.6.	Simulación Monte Carlo (P4)	12
3.6.1.	Objetivo	12
3.6.2.	Función de abandono del cliente	13
3.6.3.	Estructura de la simulación	13
3.6.4.	Escenarios proyectados	14
3.6.5.	Reproducibilidad	15
3.7.	Análisis distribucional de retornos	15
3.8.	Validación robusta	15
3.9.	Calibración secuencial de Black-Litterman	16
3.9.1.	Diseño de tres horizontes	16
3.9.2.	Etapas de calibración	16
3.9.3.	Mecanismo de puntuación	17
3.10.	Validación rolling de tres horizontes	17
3.11.	Métricas de desempeño económico	18
3.12.	Comparación de <i>views</i> bajo un único modelo de abandono	18
3.12.1.	Modelo de probabilidad de abandono	18
3.12.2.	Comparación de <i>views</i>	18
4.	Supuestos	20
5.	KPIs	23
6.	Caso Base	25
6.1.	Markowitz como caso base	25
6.2.	Métricas del caso base	25
7.	Implementación y Herramientas	27
7.1.	Implementación y herramientas	27
7.2.	Pipeline de la Entrega 3	27
8.	Resultados y análisis	29

8.1.	Lectura general de los datos de retorno	29
8.2.	Comparación de metodologías calibradas	30
8.2.1.	Calibración independiente de <i>views</i>	30
8.2.2.	Desempeño agregado frente a Markowitz base	30
8.2.3.	Validación rolling y robustez	31
8.3.	Resultados por perfil de riesgo	31
8.4.	Abandono semanal y retención	32
8.5.	Utilidad de FinPUC por saldo administrado activo	34
8.6.	Sensibilidad post-optimal: panoramas de retorno	35
8.7.	Recomendación final	36
9.	Conclusiones	39
9.1.	Conclusiones principales	39
9.1.1.	Calibración independiente de <i>views</i>	39
9.1.2.	Comparación de <i>views</i>	39
9.1.3.	Abandono y utilidad por saldo	40
9.1.4.	Validación y robustez	40
9.1.5.	Limitaciones	40
9.1.6.	Trabajo futuro	40
9.2.	Carta Gantt: avance y fases restantes	41
	Referencias	42
	Anexo N°1: Declaración de uso de IA en este informe y presentación asociada	43
	Anexo N°2: Análisis de datos	45
	Descripción de la Fuente de Datos	45
	Estructura de archivos	45
	Formato de los CSV	45
	Cobertura temporal	46
	Tratamiento temporal de la pandemia	46
	Clasificación Sectorial	47
	Sistema de clasificación	47
	Distribución sectorial del universo completo	47
	Subsectores predominantes en Financial Services	49
	Tipos de instrumento	49
	Capitalización de Mercado	49
	Niveles de Filtrado	50
	Razones de exclusión	50

Definición formal de cada filtro	51
Universo Final Descriptivo: 636 Acciones	51
Distribución sectorial del universo final	52
Representantes por sector (top 5 por capitalización)	54
Universo Operacional con Inclusión de Pandemia: 601 Acciones	55
Escenarios de datos	55
Interpretación metodológica	56
Efecto observado en resultados	57
Implicaciones para el Modelo de Optimización	57
Conexión con parámetros del modelo	57
Sub-universos recomendados por perfil de riesgo	58
Consideraciones sobre la caja chica	59
Implicancia de la pandemia para los parámetros	59
Conclusión	59
 Anexo N°3: Análisis de ajuste de distribuciones	 61
Resumen	61
Metodología de cálculo	61
Pruebas de normalidad y distribuciones candidatas	62
Archivos generados	64
Resultados obtenidos	64
Discusión e implicancias para el modelo	66
Limitaciones	66
Conclusiones del anexo	67
 Anexo N°4: Análisis de metodologías y código relacionado	 68
Markowitz vs Benchmark	68
Resumen	68
Fundamentos metodológicos	69
Supuestos del experimento	70
Estructura del notebook	71
KPIs utilizados	72
Resultados del experimento pandemia	73
Rebalanceo	74
Splits aleatorios	74
Evaluación robusta	75
Implicancias y conclusiones	76
Black-Litterman	78

Resumen	78
Fundamentos metodológicos	78
Supuestos del experimento	80
Estructura del notebook	81
KPIs utilizados	83
Resultados del experimento pandemia	83
Rebalanceo	85
Splits aleatorios	85
Evaluación robusta	86
Implicancias y conclusiones	86
Simulación Monte Carlo	88
Resumen	88
Fundamentos metodológicos	88
Supuestos del experimento	88
Estructura del notebook	89
KPIs utilizados	90
Resultados del experimento pandemia	91
Rebalanceo	91
Splits aleatorios	92
Evaluación robusta	92
Implicancias y conclusiones	92
Conclusión integrada	93
Anexo N°5: Diagnósticos de la calibración independiente de Black-Litterman	94
9.3. Diagnósticos de la calibración independiente de Black-Litterman	94
9.3.1. Etapas de calibración	94
9.3.2. Configuraciones congeladas por <i>view</i>	94
9.3.3. Validación rolling	95

ÍNDICE DE FIGURAS

8.1	Probabilidad de abandono semanal, momentum general (BL calibrado), escenario con pandemia.	33
8.2	Clientes activos en el tiempo, momentum general (BL calibrado), escenario con pandemia.	33
8.3	Ganancia acumulada del cliente, momentum general (BL calibrado), escenario con pandemia.	34
8.4	Score P4 por panorama, Black-Litterman momentum general, escenario con pandemia.	36
8.5	Score P4 por panorama, Markowitz base, escenario con pandemia.	36
8.6	Riqueza terminal por panorama, Black-Litterman momentum general, escenario con pandemia.	37
8.7	Tasa de abandono por panorama, Black-Litterman momentum general, escenario con pandemia.	37
8.8	Riqueza semanal del perfil Muy arriesgado bajo panoramas de retorno, Black-Litterman momentum general, escenario con pandemia.	38

ÍNDICE DE TABLAS

2.1	Cascada de filtrado aplicada al universo sin pandemia.	4
3.1	Configuración de las cuatro variantes de <i>views</i> Black-Litterman.	11
4.1	Supuestos adicionales de la Entrega 3.	22
6.1	Desempeño de Markowitz base en test limpio P4 (agregado sobre perfiles, comisión 0,5% mensual sobre saldo).	25
8.1	Resumen transversal de estadísticos por ticker (universo F5 sin pandemia). . . .	29
8.2	Mejor familia distribucional según AIC y BIC.	29
8.3	Configuración Black-Litterman congelada por <i>view</i> (calibración independiente). .	30
8.4	Desempeño agregado de Black-Litterman calibrado por <i>view</i> frente a Markowitz base (test limpio, comisión 0,5% mensual sobre saldo).	30
8.5	Resultados P4 por perfil: momentum general (BL) vs Markowitz base (test limpio).	32
8.6	Utilidad de FinPUC por saldo administrado (test limpio, agregado).	34
8.7	Sensibilidad P4 por panorama de retorno: momentum general calibrado vs. Markowitz base.	35
9.1	Carta Gantt resumida: avance actual y fases restantes.	41
9.2	Distribución sectorial del universo completo con datos válidos	48
9.3	Razones de exclusión del universo final F5	50
9.4	Estadísticas por sector — universo F5 (636 tickers)	52
9.5	Top subsectores por sector en el universo F5	53
9.6	Top 5 Technology (por capitalización de mercado)	54
9.7	Top 5 Healthcare (por capitalización de mercado)	54
9.8	Top 5 Financial Services (por capitalización de mercado)	54
9.9	Top 5 Consumer Defensive + Utilities (perfiles conservadores)	55

9.10	Diagnóstico de escenarios para el universo operacional	56
9.11	Ventanas temporales en el experimento h7_f2	56
9.12	Efecto de incluir pandemia en el entrenamiento	57
9.13	Conexión entre parámetros del modelo y fuente de datos	58
9.14	Sub-universos recomendados por perfil de riesgo	58
9.15	Principales parámetros de configuración del análisis.	62
9.16	Distribuciones candidatas consideradas.	63
9.17	Archivos de salida generados por el script.	64
9.18	Resumen del tamaño muestral analizado.	65
9.19	Conteo de mejores distribuciones por criterio de información.	65
9.20	Resultados agregados de pruebas de normalidad.	66
9.21	Dimensión de resultados cacheados del experimento principal.	72
9.22	Comparación de portafolios con y sin pandemia en entrenamiento.	73
9.23	Mayores caídas de Sharpe al incluir pandemia en entrenamiento.	74
9.24	Resumen del experimento de splits aleatorios.	75
9.25	Promedio y variabilidad del Sharpe en splits aleatorios.	75
9.26	Sharpe futuro medio en validación robusta por ventanas móviles.	76
9.27	Escenarios evaluados en Black-Litterman.	78
9.28	Supuestos principales del experimento Black-Litterman.	81
9.29	Parámetros globales del experimento Black-Litterman.	82
9.30	Parámetros de las <i>views</i>	82
9.31	Dimensión de salidas del experimento Black-Litterman.	83
9.32	Mejores portafolios Black-Litterman del experimento central.	84
9.33	Comparación final entre Markowitz y Black-Litterman.	84
9.34	Mayor mejora de Black-Litterman frente a Markowitz.	84

9.35	Validación con 70 splits aleatorios para el portafolio Neutro.	85
9.36	Validación robusta con 18 ventanas para el portafolio Neutro.	86
9.37	Índice de CSVs generados por el proyecto.	90
9.38	Comparación final de modelos por escenario (mejor portafolio por modelo). . .	91
9.39	Top 10 ranking de Simulación Monte Carlo en escenario neutro.	91
9.40	Ganadores por escenario proyectado en Simulación Monte Carlo.	92
9.41	Configuración congelada por <i>view</i> (calibración independiente).	94

ABSTRACT

This report documents the development, calibration, and business evaluation of an investment recommendation system for FinPUC, a fictitious financial advisory platform that generates personalized portfolios for clients in the US stock market. The system serves five risk profiles and pursues a single objective: maximizing the client's expected return. The firm's revenue is measured afterwards, as a consequence of the active managed balance, through a fixed monthly fee of 0.5% on that balance, with no transaction or rebalancing fees.

The investment universe comprises 601 stocks filtered from 1,406 tickers. Three methodological layers were implemented: Markowitz mean-variance optimization as the base case, four Black-Litterman view families calibrated independently, and a Monte Carlo layer that simulates client behavior. Each view is tuned over a three-horizon sequential protocol (calibration, validation, and clean test) to avoid contaminating the evaluation period. Client behavior is modeled with a single weekly abandonment probability; recommendations are issued semiannually while abandonment is evaluated weekly.

Among the calibrated views, general momentum delivers the largest economic gain: it improves the P4 score by +12.4% under the robust median aggregation and by +85.7% under the average aggregation, while also improving Sharpe by +5.2% relative to the Markowitz base. This advantage comes with higher turnover (34.6%) and sector concentration (HHI 0.261), while the unemployment-macro view provides superior operational stability (7.3% turnover, HHI 0.157). The projected-return panorama analysis confirms that the recommendation does not depend on a single expected-return point. The recommended methodology is Black-Litterman with the general-momentum view for aggressive profiles, with the unemployment-macro view as a defensive alternative for conservative profiles.

Keywords: portfolio optimization, Markowitz, Black-Litterman calibration, Monte Carlo simulation, recommender system, weekly abandonment, managed-balance fee, rolling validation, CVXPY.

RESUMEN

El informe documenta el desarrollo, calibración y evaluación de negocio de un sistema recomendador de inversiones para FinPUC, una plataforma ficticia de asesoría financiera que genera portafolios personalizados para clientes del mercado accionario estadounidense. El sistema atiende cinco perfiles de riesgo, desde muy conservador hasta muy arriesgado, y persigue un único objetivo: maximizar el retorno esperado del cliente. La utilidad de la empresa se mide *a posteriori*, como consecuencia del saldo activo administrado, mediante una comisión mensual fija de 0,5% sobre dicho saldo, sin comisiones por transacción ni por rebalanceo.

El universo de trabajo comprende 601 acciones, obtenidas tras filtrar 1 406 tickers. Se implementaron tres capas metodológicas: optimización media-varianza de Markowitz como caso base, cuatro familias de *views* de Black-Litterman calibradas de forma independiente, y una simulación Monte Carlo que modela el comportamiento del cliente. Cada *view* se calibra bajo un protocolo secuencial de tres horizontes (calibración, validación y test limpio) para no contaminar el período de evaluación. El comportamiento del cliente se reduce a una única probabilidad de abandono semanal; las recomendaciones se emiten de forma semestral, mientras que el abandono se evalúa semanalmente.

Entre las *views* calibradas, momentum general entrega la mayor ganancia económica: mejora el Score P4 en +12.4% bajo agregación mediana robusta y en +85.7% bajo agregación promedio, además de mejorar el Sharpe en +5.2% frente a Markowitz base. Esta ventaja exige monitorear su mayor rotación (34.6%) y concentración sectorial (HHI 0.261), mientras que desempleo macro ofrece la mejor estabilidad operacional (7.3% de turnover, HHI 0.157). La sensibilidad con panoramas de retorno confirma que la recomendación no depende de un único retorno puntual. La metodología recomendada es Black-Litterman con la *view* de momentum general para perfiles agresivos, con desempleo macro como alternativa defensiva para perfiles conservadores.

Palabras clave: optimización de portafolios, Markowitz, Black-Litterman, calibración independiente, simulación Monte Carlo, sistema recomendador, abandono semanal, comisión sobre saldo administrado, validación rodante, CVXPY.

1. INTRODUCCIÓN

La gestión eficiente del capital constituye uno de los problemas fundamentales de las finanzas modernas. El problema de optimización de portafolios, formalizado por Markowitz (1952), establece los fundamentos matemáticos de la diversificación y define la frontera eficiente como el conjunto de portafolios óptimos en el espacio riesgo-retorno. En la práctica, el universo de activos puede comprender cientos de instrumentos, los clientes presentan perfiles de riesgo heterogéneos y las condiciones del mercado evolucionan continuamente. En este contexto, la consolidación de plataformas de asesoría financiera automatizada ha generado una demanda creciente de sistemas capaces de producir recomendaciones personalizadas, fundamentadas y actualizadas de forma periódica (D’Acunto, Prabhala, & Rossi, 2019).

El presente informe documenta la tercera fase del proyecto FinPUC, una plataforma ficticia de recomendación de inversiones desarrollada en el marco del curso Taller de Investigación Operativa (ICS2122) de la Pontificia Universidad Católica de Chile. La fase anterior estableció las tres capas metodológicas (Markowitz, Black-Litterman con cuatro variantes de *views* y simulación Monte Carlo), validó su desempeño fuera de muestra. La presente fase redefine el problema de negocio en torno a un objetivo único: maximizar el retorno esperado del cliente, midiendo la utilidad de FinPUC *a posteriori* como consecuencia del saldo activo administrado, sobre el que se cobra una comisión mensual fija de 0,5%. Para responder cuál metodología logra mejor este objetivo, esta fase calibra de forma independiente cada *view* del modelo Black-Litterman, las compara contra el caso base Markowitz bajo un único modelo de abandono semanal, y evalúa el resultado por perfil de riesgo mediante un protocolo de validación de tres horizontes.

El sistema opera en dos escalas temporales complementarias. A nivel de optimización, los pesos del portafolio se recalculan cada semestre (126 días hábiles bursatil) mediante rebalanceo con estimación actualizada de parámetros. A nivel de simulación del cliente, el modelo Monte Carlo evalúa semanalmente durante 260 semanas si el cliente acepta la recomendación vigente o retira sus fondos, generando métricas de riqueza terminal, probabilidad de ganancia y utilidad de la empresa. La decisión central consiste en determinar la fracción del capital a asignar a cada acción de un universo de 601 activos, maximizando simultáneamente el retorno esperado del inversionista y la utilidad de FinPUC.

2. DESCRIPCIÓN DEL PROBLEMA

2.1. Contexto y motivación

La gestión de inversiones requiere asignar capital entre múltiples activos considerando riesgo, horizonte y condiciones de mercado. FinPUC es una plataforma ficticia de recomendación de inversiones para clientes del mercado accionario estadounidense clasificados por perfil de riesgo. El sistema genera periódicamente portafolios optimizados buscando maximizar el retorno esperado y las utilidades por comisiones, sujeto a restricciones de riesgo y tiempo computacional.

2.2. Ciclo operacional

El sistema opera en dos escalas temporales. En primer lugar, las recomendaciones de inversión se actualizan de forma **semestral** (126 días hábiles bursátiles). En cada semestre se recalibran los parámetros μ y Σ con la información histórica disponible hasta ese punto y se obtiene una nueva recomendación de portafolio para cada perfil de riesgo.

En segundo lugar, el comportamiento del cliente se evalúa **semanalmente** durante el horizonte de simulación de 260 semanas (5 años). Esta separación es importante porque el cliente no necesariamente espera hasta el siguiente rebalanceo para abandonar la plataforma: si durante las semanas intermedias su experiencia acumulada empeora y supera los umbrales definidos por su perfil, puede activarse la probabilidad de abandono semanal.

La utilidad de FinPUC se calcula a partir del saldo administrado de los clientes que permanecen activos. La empresa no cobra una comisión por rebalanceo ni por cada transacción ejecutada; en cambio, cobra una comisión mensual equivalente al **0,5% del saldo activo administrado**. Por lo tanto, la sostenibilidad del negocio depende de dos elementos: que el cliente obtenga buenos retornos y que permanezca en la plataforma con saldo administrado.

2.3. Perfiles de riesgo

Se consideran cinco perfiles de riesgo definidos por una tolerancia máxima de pérdida de 0%, 5%, 15%, 30% y 40%, correspondientes a perfiles muy conservador, conservador, neutro, arriesgado y muy arriesgado, respectivamente.

2.4. Formulación del problema

2.4.1. Decisión principal

Para cada perfil de riesgo y cada punto de rebalanceo, el sistema debe determinar el vector de pesos $w \in \mathbb{R}^n$ que asigna una fracción del capital a cada una de las $n = 601$ acciones del universo.

2.4.2. Objetivos

El objetivo principal del recomendador es **maximizar el retorno esperado del cliente** ($\mu^\top w$). La utilidad de FinPUC no forma parte de la función objetivo: se mide *a posteriori* como consecuencia del saldo activo administrado de los clientes que permanecen en la plataforma. Esta separación evita que el sistema recomiende portafolios que sacrifiquen el retorno del cliente para inflar artificialmente la utilidad de la empresa.

2.4.3. Restricciones

- **No venta en corto:** $w_i \geq 0$ para todo i .
- **Presupuesto completo:** $\sum_{i=1}^n w_i = 1$.
- **Concentración máxima:** $w_i \leq w_{\max} = 0.20$ para todo i .
- **Riesgo por perfil:** $w^\top \Sigma w \leq \sigma_{\max}^2$, donde la cota depende del perfil de riesgo.
- **Tiempo de cómputo:** el sistema debe generar la recomendación en menos de 10 segundos.

2.5. Datos disponibles

2.5.1. Fuente y estructura

Los datos corresponden a registros históricos del mercado accionario estadounidense. El dataset original comprende 1 406 archivos CSV, uno por ticker, con precios diarios que cubren aproximadamente desde el año 2000 hasta marzo de 2026. Cada archivo incluye fecha, precio de apertura y cierre, máximo y mínimo del día, volumen de transacciones, dividendos y factores de *split*. Adicionalmente, se dispone de un archivo de metadatos con información fundamental de cada empresa: sector, industria, tipo de instrumento y capitalización de mercado.

El retorno diario total de cada acción se calcula incorporando dividendos:

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (2.1)$$

donde $P_{i,t}$ es el precio de cierre del activo i en el día t y $D_{i,t}$ el dividendo pagado en esa fecha.

2.5.2. Proceso de filtrado

A partir del universo crudo de 1 406 tickers se aplicó un proceso de filtrado secuencial. La Tabla 2.1 detalla la cascada del universo operacional comparable usado en los experimentos, que queda en 601 activos. En paralelo, el Anexo N°2 documenta el universo F5 descriptivo completo de 636 acciones. Esta diferencia no corresponde a dos universos finales distintos por escenario, sino a dos niveles de análisis: 636 acciones para caracterización descriptiva y 601 acciones para comparación experimental con y sin pandemia bajo el mismo periodo futuro.

Tabla 2.1. Cascada de filtrado aplicada al universo sin pandemia.

Filtro	Criterio operacional	Tickers	Retención F0
F0	Archivos CSV encontrados	1.406	100,0%
F1	Precio $\geq$ USD 5; historia $\geq$ 5 años; cap. $\geq$ USD 300M o sin dato	827	58,8%
F2	Excluye <i>Shell Companies</i> , sector desconocido y no EQUITY	824	58,6%
F3	Capitalización bursátil $\geq$ USD 2B	659	46,9%
F4	Historia fuera de pandemia $\geq$ 10 años, aproximada por 2.500 filas	606	43,1%
F5	Volatilidad anualizada fuera de pandemia entre 5% y 100%	601	42,7%

2.5.3. Justificación del filtrado

El proceso de filtrado busca construir un universo de activos estable e invertible para la optimización de portafolios. F1 elimina acciones con precios muy bajos, historia insuficiente o capitalización reducida, disminuyendo estimaciones poco robustas. F2 restringe el análisis a instrumentos EQUITY y excluye *Shell Companies* y sectores desconocidos para mantener comparabilidad entre activos.

Luego, F3 exige una capitalización mínima de USD 2B para reducir problemas de liquidez y volatilidad extrema. F4 requiere al menos diez años de historia fuera del periodo pandemia para estimar parámetros con mayor estabilidad. Finalmente, F5 elimina activos con volatilidad anualizada excesivamente alta o baja, asociados potencialmente a errores de datos o comportamientos incompatibles con un portafolio accionario tradicional.

2.5.4. Diseño experimental: escenarios con y sin pandemia

La evaluación del sistema se realiza bajo dos escenarios que comparten el mismo período futuro de evaluación (2 años fuera de muestra) pero difieren en la ventana de entrenamiento. El escenario “sin pandemia” excluye las observaciones de 2020 - 2022, estimando μ y Σ con un mercado relativamente normal. El escenario “con pandemia” las incluye, incorporando correlaciones de estrés y volatilidad extrema. Cualquier diferencia en resultados entre ambos escenarios se interpreta como efecto de la información usada para calibrar, no como diferencias de mercado futuro.

2.5.5. Problema de negocio: retorno del cliente y sostenibilidad por saldo administrado

La fase actual del proyecto busca determinar qué metodología de recomendación entrega el mejor desempeño para el cliente bajo distintos perfiles de riesgo. El objetivo principal es maximizar el retorno esperado del cliente, considerando que una mejor experiencia de inversión debería reducir la probabilidad de abandono y aumentar el saldo administrado activo en la plataforma.

A diferencia de versiones anteriores, la utilidad de FinPUC no se modela como una comisión por transacción ni como una comisión de rebalanceo. La empresa obtiene ingresos mediante una comisión mensual fija equivalente al 0,5% del saldo activo administrado. Por esta razón, la utilidad de FinPUC depende directamente de la capacidad del sistema para mantener clientes activos y con saldos mayores en el tiempo.

El problema central es entonces: ¿qué metodología de recomendación maximiza el retorno del cliente, mantiene controlada la probabilidad de abandono semanal y permite sostener una mayor base de saldo activo administrado?

Para responder esta pregunta se comparan el caso base **Markowitz** y las metodologías basadas en Black-Litterman con *views* calibradas de forma independiente. La comparación se realiza por perfil de riesgo, considerando retorno, riqueza terminal, abandono semanal y utilidad acumulada para FinPUC por saldo administrado activo.

3. METODOLOGÍA

3.1. Revisión bibliográfica

3.1.1. Modelos fundamentales de optimización de portafolios

La optimización de portafolios tiene su origen en el trabajo seminal de Markowitz (Markowitz, 1952), que formalizó el principio de diversificación mediante el modelo media-varianza. Su propuesta establece que un inversionista racional selecciona portafolios sobre la frontera eficiente, es decir, aquellos que maximizan el retorno esperado para un nivel de riesgo dado. La principal limitación del modelo es su sensibilidad a las estimaciones de μ y Σ : pequeños errores en los retornos esperados pueden generar portafolios concentrados o irrazonables (Michaud, 1989). En el presente proyecto, esta fragilidad se observa empíricamente: el portafolio Ideal de mercado de Markowitz exhibe un Sharpe teórico de 5,01 que colapsa a 1,80 fuera de muestra con datos de pandemia, confirmando el fenómeno de *overfitting* documentado por Michaud.

El modelo CAPM de Sharpe (Sharpe, 1964) extiende el trabajo de Markowitz introduciendo un modelo de equilibrio de mercado, donde el retorno esperado de un activo depende únicamente de su exposición al riesgo sistemático, medido por el coeficiente β . El modelo multifactorial de Fama y French (Fama & French, 1993) incorpora dos factores adicionales, tamaño (SMB) y valor (HML), para capturar anomalías empíricas. Aunque estos modelos no se implementan directamente en FinPUC, informan la construcción del prior de equilibrio en Black-Litterman: los retornos implícitos $\pi = \delta \Sigma w_{\text{market}}$ asumen que el mercado está en equilibrio, lo que es consistente con la lógica del CAPM.

3.1.2. El modelo Black-Litterman

Black y Litterman (Black & Litterman, 1992) propusieron un enfoque bayesiano que combina el equilibrio implícito del mercado con expectativas subjetivas del inversionista. El prior se obtiene invirtiendo el problema de Markowitz: dado que el mercado está en equilibrio, los retornos implícitos son $\pi = \delta \Sigma w_{\text{market}}$. Las *views* se incorporan mediante una actualización bayesiana que produce estimaciones más estables y portafolios menos extremos. He y Litterman (He & Litterman, 1999) documentaron la implementación práctica del modelo, destacando su capacidad para generar portafolios intuitivamente razonables sin restricciones artificiales de peso. Idzorek (Idzorek, 2005) extendió el marco proponiendo métodos para calibrar la confianza de cada *view*, problema que en FinPUC se aborda mediante calibración

secuencial independiente. La configuración final congela una confianza específica por familia de *view*: momentum general, momentum top/bottom 1Y y momentum top market-cap 6M quedan con $c = 0.80$, mientras que desempleo macro queda con $c = 0.50$.

3.1.3. Estimación de covarianzas y medidas de riesgo

Ledoit y Wolf (Ledoit & Wolf, 2004) propusieron el método de *shrinkage* para la estimación de matrices de covarianza de grandes dimensiones, demostrando que la combinación convexa entre la covarianza muestral y un estimador estructurado reduce el error de estimación fuera de muestra. En FinPUC se implementa con $\lambda = 0.20$, valor seleccionado para estabilizar una matriz de 601×601 sin perder demasiada estructura de correlación. La elección de λ no fue optimizada formalmente y constituye un supuesto del modelo.

Rockafellar y Uryasev (Rockafellar & Uryasev, 2000) introdujeron el Valor en Riesgo Condicional (CVaR) como medida coherente de riesgo, superando las limitaciones del VaR estándar al cuantificar la severidad promedio de las pérdidas en la cola. En el proyecto, el CVaR al 95% se utiliza como indicador de desempeño complementario al Sharpe, no como restricción del optimizador. Esta decisión responde a que la implementación con CVXPY utiliza cotas de volatilidad por perfil, que son computacionalmente más eficientes para la restricción de 10 segundos.

3.1.4. Sistemas de asesoría financiera automatizada

En el contexto de plataformas de *robo-advisory*, D'Acunto, Prabhala y Rossi (D'Acunto et al., 2019) documentaron cómo la automatización ha democratizado el acceso a estrategias de inversión, permitiendo recomendaciones personalizadas a bajo costo operacional. FinPUC se enmarca en esta línea, con la particularidad de que incorpora explícitamente el comportamiento del cliente (probabilidad de abandono semanal) y la utilidad de la empresa (comisión mensual sobre el saldo administrado) como variables del modelo, lo que va más allá de la optimización financiera pura.

3.1.5. Fortalezas y debilidades de la metodología seleccionada

La combinación de Black-Litterman con Monte Carlo resulta adecuada para el problema de FinPUC porque une dos necesidades del sistema recomendador: construir portafolios más estables que Markowitz puro y evaluar su impacto en variables de decisión para cliente y empresa. Black-Litterman reduce la dependencia de estimaciones históricas extremas al anclar

los retornos esperados al equilibrio de mercado. Esto se observa en los resultados: con datos de pandemia, la mejor variante BL alcanza Sharpe 2,38, mientras que Markowitz cae a 2,02.

Otra fortaleza es que el modelo permite incorporar *views* de forma controlada. En vez de reemplazar completamente el prior de mercado, las señales de momentum, desempleo o capitalización ajustan los retornos esperados según su nivel de confianza. Luego, Monte Carlo traduce esos portafolios a escenarios desfavorable, neutro y favorable, permitiendo medir riqueza terminal, retiro del cliente y utilidad para FinPUC sin depender solo de una métrica financiera.

La principal debilidad es que la calidad del resultado depende directamente de la calidad de las *views*. En particular, la view de desempleo se modela con un supuesto fijo y no con una serie macro observada, lo que limita su validez predictiva. Además, parámetros como τ , q_{scale} y la matriz $\Omega = P\tau\Sigma P^\top / c$ requieren calibración y sensibilidad, porque cambios en la confianza asignada a las *views* pueden modificar el ranking final.

Finalmente, la simulación Monte Carlo asume retornos normales, aunque el análisis distribucional rechaza normalidad en todos los activos. Esto puede subestimar eventos extremos y generar tasas de retiro demasiado optimistas. Además, los costos de transacción no se incorporan como penalización dentro de la optimización; por ahora se discuten a través de métricas operacionales como turnover. Sin esa penalización, algunas carteras podrían verse atractivas en el modelo pero ser menos eficientes en una implementación real con rotación alta.

3.2. Arquitectura general del sistema

El sistema se estructura en tres capas metodológicas de complejidad creciente, ejecutadas secuencialmente. La primera capa implementa la optimización media-varianza de Markowitz como línea base analítica. La segunda extiende Markowitz con el modelo Black-Litterman, que incorpora un prior de equilibrio de mercado y *views* cuantitativas. La tercera capa es una simulación Monte Carlo que traduce las métricas financieras de las capas anteriores en proyecciones de riqueza del cliente y utilidad de la empresa. En total, el sistema compara cinco metodologías: Markowitz como caso base, y cuatro variantes de Black-Litterman (momentum general, momentum por capitalización a 6 meses, momentum por capitalización a 1 año, y desempleo macro).

3.3. Estimación de parámetros

3.3.1. Retornos esperados

Los retornos esperados $\mu \in \mathbb{R}^n$ se estiman como promedios diarios históricos de los retornos totales de cada acción en la ventana de entrenamiento.

3.3.2. Matriz de covarianzas con *shrinkage*

La matriz de covarianzas muestral Σ_{muestral} se estabiliza mediante *shrinkage* lineal hacia su diagonal (Ledoit & Wolf, 2004):

$$\Sigma_{\text{shrink}} = (1 - \lambda) \Sigma_{\text{muestral}} + \lambda \cdot \text{diag}(\Sigma_{\text{muestral}}), \quad (3.1)$$

con $\lambda = 0.20$. Esto reduce el error de estimación fuera de muestra en matrices de alta dimensión ($n = 601$), donde la covarianza muestral tiende a sobreajustar correlaciones espurias. La matriz resultante se fuerza a ser semidefinida positiva mediante proyección espectral (`nearest_psd`), truncando valores propios negativos a cero. Este paso es requisito para que los problemas cuadráticos resueltos por CVXPY sean convexos.

3.3.3. Anualización

Los retornos se anualizan asumiendo 252 días hábiles bursátil por año: $R_{\text{anual}} = \bar{r}_{\text{diario}} \times 252$. La volatilidad se escala como $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \times \sqrt{252}$. La tasa libre de riesgo se fija en $R_f = 2\%$ anual.

3.4. Optimización media-varianza de Markowitz

3.4.1. Formulación por perfil de riesgo

Para cada perfil de riesgo con parámetro de aversión γ y cota de volatilidad σ_{max}^2 , se resuelve el problema cuadrático:

$$\max_w \quad \mu^\top w - \frac{1}{2} \gamma w^\top \Sigma w \quad (3.2)$$

sujeto a:

$$\sum_{i=1}^n w_i = 1 \quad (3.3)$$

$$0 \leq w_i \leq 0.20 \quad \forall i = 1, \dots, n \quad (3.4)$$

$$w^\top \Sigma w \leq \sigma_{\max}^2 \quad (\text{cuando el perfil lo requiere}) \quad (3.5)$$

La restricción $w_i \geq 0$ impide ventas cortas; la suma igual a 1 invierte todo el capital; y la cota superior $w_{\max} = 0.20$ evita concentración extrema en un solo activo. Cuando la cota de volatilidad hace infactible un perfil, se relaja esa cota manteniendo las demás restricciones.

3.4.2. Frontera eficiente y portafolio de tangencia

La frontera eficiente se construye resolviendo, para 30 retornos objetivo r_{obj} equiespaciados:

$$\min_w w^\top \Sigma w \quad \text{s.a.} \quad \mu^\top w \geq r_{\text{obj}}, \quad \sum_i w_i = 1, \quad 0 \leq w_i \leq 0.20 \quad (3.6)$$

El portafolio de tangencia (“Ideal de mercado”) se selecciona como el punto de la frontera que maximiza el ratio de Sharpe:

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p} \quad (3.7)$$

donde R_p es el retorno anualizado del portafolio y σ_p su volatilidad anualizada. Este portafolio es teórico: asume conocimiento perfecto de los parámetros, por lo que su desempeño fuera de muestra mide el grado de *overfitting* de la estimación histórica.

3.4.2.1. Rebalanceo semestral

El período futuro de evaluación, de 2 años o aproximadamente 504 días hábiles, se divide en segmentos de 126 días. Al inicio de cada segmento se actualiza la información disponible: se incorporan los retornos ya observados hasta ese punto, se reestiman μ y Σ , y se resuelven nuevamente los problemas de optimización para todos los perfiles. Los pesos resultantes se aplican al segmento siguiente y se mantienen constantes hasta el próximo rebalanceo.

Con este procedimiento, el modelo simula una implementación más realista que una cartera estática, pero sin usar información futura no observada. Las métricas finales se calculan concatenando los retornos diarios generados en todos los segmentos de rebalanceo.

3.5. Modelo Black-Litterman

3.5.1. Prior de equilibrio de mercado

El modelo parte de que, en equilibrio, los retornos implícitos del mercado son consistentes con los pesos observados por capitalización (Black & Litterman, 1992; He & Litterman, 1999):

$$\pi = \delta \cdot \Sigma \cdot w_{\text{market}} \quad (3.8)$$

donde w_{market} son los pesos normalizados por capitalización bursátil y δ es el coeficiente de aversión al riesgo implícito:

$$\delta = \frac{R_{\text{market}} - R_f}{\sigma_{\text{market}}^2} \quad (3.9)$$

3.5.2. Incorporación de *views*

Dadas las *views* representadas por la matriz de selección $P \in \mathbb{R}^{k \times n}$, el vector de expectativas $Q \in \mathbb{R}^k$ y la matriz de incertidumbre $\Omega \in \mathbb{R}^{k \times k}$, el retorno esperado posterior es:

$$\mu_{\text{BL}} = \pi + \tau \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} (Q - P \pi) \quad (3.10)$$

donde τ controla la incertidumbre del prior y se calibra de forma independiente por *view*. La covarianza posterior se calcula como:

$$\Sigma_{\text{BL}} = (1 + \tau) \Sigma - \tau^2 \Sigma P^\top \left(P \tau \Sigma P^\top + \Omega \right)^{-1} P \Sigma \quad (3.11)$$

y se fuerza a ser semidefinida positiva mediante `nearest_psd`. Con μ_{BL} y Σ_{BL} se resuelven los mismos problemas de optimización que en Markowitz.

3.5.3. Construcción de *views*

Se implementan cuatro *views* independientes, cada una generando su propia versión del modelo Black-Litterman. La Tabla 3.1 resume su configuración.

Tabla 3.1. Configuración de las cuatro variantes de *views* Black-Litterman.

View	Tipo	Lookback	Long	Short	Confianza	Universo
Momentum	Endógena	252 días	20	20	0.80	601 activos
Momentum Top20 6M	Market-cap	126 días	10	10	0.80	Top 20
Momentum Top20-Bottom20 1Y	Market-cap	252 días	20	20	0.80	Top 40
Desempleo	Macro asumida	1 764 días	466	135	0.50	601 activos

3.5.3.1. Views de momentum

Las *views* de momentum seleccionan activos por retorno acumulado durante el período de lookback. La matriz P tiene una fila que asigna $+1/n_{\text{long}}$ a los activos con mayor retorno y $-1/n_{\text{short}}$ a los de menor retorno. El valor Q corresponde a la diferencia promedio diaria entre los retornos de ambos grupos. La variante general opera sobre los 601 activos; las variantes por capitalización restringen el universo a los activos con mayor market cap (top 20 o top 40).

3.5.3.2. View de desempleo

Es un supuesto macroeconómico fijo, no un dato observado. Se asume una tasa de desempleo de 4% contra un nivel neutral de 5%. Con desempleo bajo, se favorecen sectores cíclicos (Technology, Consumer Cyclical, Industrials, Financial Services, Basic Materials, Real Estate, Energy) sobre defensivos (Healthcare, Consumer Defensive, Utilities, Communication Services). La señal es proporcional a la diferencia entre ambas tasas, escalada por $\beta_{\text{macro}} = 1.0$ y convertida a retorno diario dividiendo por 252. La confianza calibrada queda en $c = 0.50$, menor que la de momentum, reflejando que es un supuesto y no una observación.

3.5.3.3. Calibración de Ω

Para cada *view*, la incertidumbre se calibra como:

$$\Omega = \frac{P \cdot (\tau \Sigma) \cdot P^\top}{c} \quad (3.12)$$

donde c es la confianza de la *view*. Con una sola *view* ($k = 1$), Ω es escalar y la formulación se simplifica.

3.6. Simulación Monte Carlo (P4)

3.6.1. Objetivo

La tercera capa traduce los KPIs financieros de Markowitz y Black-Litterman en proyecciones de riqueza para el cliente y utilidad para la empresa. Simula el comportamiento completo del sistema recomendador durante 260 semanas (5 años), incorporando las decisiones del cliente mediante funciones logísticas.

3.6.2. Función de abandono del cliente

El comportamiento del cliente se modela únicamente mediante una probabilidad de **abandono semanal**, correspondiente al modelo implementado en `views_v1_plus`. Sea $x_t = \max(C_0 - W_t, 0)/C_0$ la pérdida acumulada respecto al capital inicial en la semana t y $\hat{x}$ la tolerancia de pérdida del perfil. La probabilidad conductual de abandono es:

$$p_{ab}(x_t) = \begin{cases} \frac{1}{1 + \exp(-(x_t - \hat{x}))}, & x_t > \hat{x}, \\ 0, & x_t \leq \hat{x}. \end{cases} \quad (3.13)$$

A esta regla se le superpone una restricción de ruina: si la riqueza llega a cero ($W_t \leq 0$), el abandono es forzoso. La probabilidad efectiva de abandono semanal es entonces:

$$p_{abandono}(x_t) = \begin{cases} 1, & W_t \leq 0, \\ p_{ab}(x_t), & W_t > 0. \end{cases} \quad (3.14)$$

La aceptación de recomendaciones sí se modela mediante una probabilidad logística que compara el retorno anual proyectado con la tolerancia de pérdida del perfil:

$$p_{act} = \frac{1}{1 + \exp[-(R_{proyectado} - \hat{x})]}. \quad (3.15)$$

Esta probabilidad determina si el cliente adopta la recomendación inicial y se mantiene como probabilidad de aceptación del rebalanceo cuando se evalúan los panoramas proyectados. Una vez activo, el cliente permanece en la plataforma mientras no se gatille el evento de abandono semanal. Los clientes que no se activan no aportan saldo administrado. La probabilidad de abandono debe interpretarse como una variable de retención: a menor abandono, mayor es el saldo activo administrado y, por lo tanto, mayor la utilidad esperada de FinPUC.

3.6.3. Estructura de la simulación

Para cada combinación de escenario de datos (con/sin pandemia), metodología (Markowitz base y las cuatro *views* de Black-Litterman calibradas) y perfil de riesgo (5 niveles), se ejecutan $N = 2000$ trayectorias independientes de 260 semanas. Cada metodología se simula con los KPIs provenientes de su propia configuración calibrada, dentro del protocolo de tres horizontes descrito más adelante.

Cada simulación opera semana a semana. El cliente inicia con $C_0 = 1\,000$ USD y se activa mediante p_{act} ; en cada semana se simula el retorno del portafolio como $r_{sem} \sim \mathcal{N}(\mu_{sem}, \sigma_{sem}^2)$,

calibrado a partir de los KPIs anualizados de la metodología. Sobre el saldo activo administrado, FinPUC percibe una comisión equivalente al 0,5% mensual; en la implementación semanal esto se acumula con una tasa semanal equivalente $k_{\text{sem}} = 0,005 \times 12/52$, de modo que la utilidad de la empresa proviene exclusivamente del saldo administrado y no de transacciones o rebalanceos. Finalmente, se evalúa el abandono semanal según $p_{\text{abandono}}(x_t)$. Cuando el cliente abandona, deja de aportar saldo administrado, su trayectoria se detiene y la riqueza terminal corresponde al valor disponible en ese momento.

3.6.4. Escenarios proyectados

Los tres panoramas proyectados de retorno se usan como análisis de sensibilidad de la simulación P4, no como una nueva calibración de Black-Litterman ni como un nuevo escenario histórico. Para cada técnica se parte del retorno anualizado base R_{base} y de la volatilidad anualizada σ_{base} ya observados en el test limpio:

$$R_{\text{favorable}} = R_{\text{base}} + 0.5 \sigma_{\text{base}} \quad (3.16)$$

$$R_{\text{neutro}} = R_{\text{base}} \quad (3.17)$$

$$R_{\text{desfavorable}} = R_{\text{base}} - 0.5 \sigma_{\text{base}} \quad (3.18)$$

Esto genera un abanico simétrico de $\pm 0.5\sigma$ alrededor del caso base. La volatilidad proyectada se mantiene fija:

$$\sigma_{\text{proyectada}} = \sigma_{\text{base}}. \quad (3.19)$$

En cada panorama, la simulación semanal utiliza el retorno proyectado para calibrar la media semanal:

$$\mu_{\text{sem}} = (1 + R_{\text{proyectado}})^{1/52} - 1, \quad \sigma_{\text{sem}} = \frac{\sigma_{\text{base}}}{\sqrt{52}}. \quad (3.20)$$

La activación inicial del cliente también usa el retorno proyectado, de modo que una mayor recompensa esperada aumenta la disposición a aceptar el riesgo del portafolio:

$$p_{\text{act}} = \frac{1}{1 + \exp[-(R_{\text{proyectado}} - \hat{x})]}. \quad (3.21)$$

La probabilidad de abandono semanal, la restricción de ruina y la comisión de FinPUC sobre saldo administrado permanecen sin cambios frente a la simulación base.

3.6.5. Reproducibilidad

La simulación utiliza semillas deterministas generadas mediante SHA-256 a partir de la combinación única de escenario, técnica, *view* y perfil. Esto garantiza que cada celda del experimento es reproducible individualmente sin afectar a las demás.

3.7. Análisis distribucional de retornos

Complementariamente a la optimización, se realizó un análisis distribucional sobre los retornos diarios del universo F5 sin pandemia, con el objetivo de caracterizar la forma estadística de los retornos y evaluar la validez del supuesto de normalidad.

Se ajustaron siete familias paramétricas candidatas: normal, t-Student, Laplace, logística, skew-normal, normal generalizada y Johnson SU. Los parámetros se estimaron por máxima verosimilitud. Para cada familia m se calcularon los criterios de información:

$$AIC_m = 2k_m - 2\ell_m, \quad BIC_m = k_m \log(n) - 2\ell_m, \quad (3.22)$$

donde k_m es el número de parámetros, n la cantidad de retornos y ℓ_m la log-verosimilitud. Se aplicaron adicionalmente pruebas de normalidad (Shapiro-Wilk, D'Agostino-Pearson, Jarque-Bera) y una prueba Kolmogorov-Smirnov aproximada.

3.8. Validación robusta

Para evitar que las conclusiones dependan de un único horizonte de entrenamiento, se aplicaron dos mecanismos de validación. Primero, se evaluaron 70 particiones aleatorias train/test, lo que permitió observar la distribución del Sharpe fuera de muestra para cada portafolio y técnica. Segundo, se probaron 18 ventanas móviles robustas, desde h2_f7 hasta h7_f2, variando la proporción entre datos de entrenamiento y evaluación para medir cómo cambia el desempeño futuro al usar más o menos historia.

El horizonte central seleccionado fue h7_f2, equivalente a 7 años de entrenamiento y 2 años de evaluación. Este horizonte entrega el mejor Sharpe futuro promedio: 2,32 en Markowitz y resultados comparables en Black-Litterman, con 2,32 para la *view* de desempeño y 2,22 para momentum. La validación muestra que ventanas históricas más largas producen estimaciones más estables, mientras que reducir el periodo de entrenamiento deteriora progresivamente el Sharpe fuera de muestra.

3.9. Calibración secuencial de Black-Litterman

3.9.1. Diseño de tres horizontes

La calibración de los hiperparámetros de Black-Litterman se realiza bajo un diseño experimental que separa estrictamente tres horizontes temporales no intercambiables. Sea $\mathcal{D}$ el conjunto completo de observaciones históricas, compuesto por retornos diarios de $N = 601$ activos. El experimento divide $\mathcal{D}$ en tres bloques funcionales:

$$\mathcal{D} = \mathcal{H}_1 \cup \mathcal{H}_2 \cup \mathcal{H}_3, \quad (3.23)$$

donde $\mathcal{H}_1$ corresponde al horizonte de calibración, $\mathcal{H}_2$ al horizonte de validación y $\mathcal{H}_3$ al horizonte de test limpio para la evaluación económica P4. La condición fundamental es que la selección de hiperparámetros no puede depender de $\mathcal{H}_3$:

$$\hat{\theta}_{BL} = \mathcal{A}(\mathcal{H}_1), \quad \hat{\theta}_{BL} \not\equiv \mathcal{A}(\mathcal{H}_3). \quad (3.24)$$

Esta separación evita el problema de *data snooping*: que los parámetros se ajusten al mismo período que después se usa para evaluar el desempeño económico.

3.9.2. Etapas de calibración

La calibración se organiza en cinco etapas secuenciales, cada una evaluada dentro de $\mathcal{H}_1$ y validada en $\mathcal{H}_2$ antes de congelar la decisión y avanzar. Las etapas son:

- (i) **Stage 1 — Calibración independiente de *views*:** En esta etapa no se selecciona una única familia de *view* ganadora. En cambio, se calibra cada *view* de forma independiente para que cada metodología sea evaluada bajo su mejor configuración posible. Las *views* consideradas son momentum general, desempleo macro y momentum por capitalización de mercado. Cada *view* conserva su mejor configuración propia y pasa así a la etapa de simulación, de modo que la comparación final no depende de una selección prematura, sino de un contraste directo entre metodologías calibradas bajo el mismo protocolo experimental.
- (ii) **Stage 2 — Estructura de P :** Para cada *view* se prueban combinaciones de los parámetros de la matriz de selección P propios de su familia (p. ej. tasa de desempleo asumida y sensibilidad sectorial β en la *view* macro; *lookback* y tamaño *long/short* en las de momentum).

- (iii) **Stage 3 — Intensidad de Q :** Se escala el vector de expectativas Q mediante un factor $q_{\text{scale}} \in \{0.5, 1.0, 1.5, 2.0\}$.
- (iv) **Stage 4 — Confianza Ω :** Se prueba la confianza $c \in \{0.25, 0.35, 0.50, 0.75, 1.00\}$ en la calibración de Ω . Con mayor c , menor es la incertidumbre asignada a la *view* y mayor su influencia en μ_{BL} .
- (v) **Stage 5 — Parámetro τ :** Se evalúa $\tau \in \{0.01, 0.05, 0.10, 0.20, 0.50, 1.00\}$.

Cada *view* se congela con su propia configuración calibrada de forma independiente; estas configuraciones se reportan por *view* en el capítulo de Resultados. Así, no existe una única configuración global, sino una por metodología, lo que evita imponer la estructura óptima de una *view* sobre las demás.

3.9.3. Mecanismo de puntuación

En cada etapa, cada configuración candidata se evalúa mediante un score compuesto que combina el Sharpe medio fuera de muestra en $\mathcal{H}_2$, el delta de Sharpe respecto a un baseline sin calibrar, y un término de penalización por inestabilidad. La configuración con mayor score acumulado avanza a la etapa siguiente, y las decisiones previas no se reabren.

3.10. Validación rolling de tres horizontes

La arquitectura de validación se implementa mediante ventanas móviles (*rolling windows*) que recorren el tiempo, generando múltiples particiones independientes de $\mathcal{H}_1$, $\mathcal{H}_2$ y $\mathcal{H}_3$. Para el escenario con pandemia se usaron 10 ventanas de calibración, 4 de test P4 y 3 de validación; para el escenario sin pandemia, 3, 1 y 1 respectivamente.

Cada ventana produce una evaluación completa del pipeline: calibración de BL sobre $\mathcal{H}_1$, generación de portafolios en $\mathcal{H}_2$, y simulación Monte Carlo P4 en $\mathcal{H}_3$. Las métricas agregadas (mejora de Sharpe, delta de drawdown, porcentaje de ventanas donde BL es recomendado sobre Markowitz base) se reportan por perfil de riesgo y escenario de datos.

El protocolo también registra métricas de dinámica del portafolio: turnover medio, número efectivo de activos (N_{eff}) y concentración sectorial (HHI) durante el horizonte de test limpio. Estas métricas permiten evaluar si la mejora financiera de BL es operacionalmente sostenible o viene acompañada de rotación y concentración excesivas.

3.11. Métricas de desempeño económico

En esta versión del modelo no se utiliza una optimización multiobjetivo ni una búsqueda de comisión óptima. La metodología recomendada se selecciona a partir del desempeño del cliente, medido principalmente por retorno esperado y riqueza terminal. La utilidad de FinPUC se calcula como una métrica económica posterior, asociada al saldo activo administrado de los clientes que no abandonan la plataforma, aplicando una comisión mensual de 0,5% sobre dicho saldo.

El análisis separa entonces dos dimensiones: (a) el objetivo de recomendación, que es maximizar el retorno del cliente, y (b) la métrica de negocio, que estima la utilidad de FinPUC a partir del saldo activo administrado. Esta separación evita que el modelo recomiende portafolios que sacrifiquen el retorno del cliente para aumentar artificialmente la utilidad de la empresa. La comisión se mantiene fija en 0,5% mensual sobre el saldo activo y está definida exógenamente para esta fase, por lo que no se evalúan escenarios alternativos de comisión.

3.12. Comparación de *views* bajo un único modelo de abandono

3.12.1. Modelo de probabilidad de abandono

El análisis utiliza un único modelo de probabilidad de abandono semanal, correspondiente a la implementación definida en `views_v1_plus` y detallada en la Sección 4.5. No se comparan modelos alternativos de abandono: se mantiene una única regla consistente para todas las metodologías evaluadas, de modo que las diferencias de resultado provengan de la *view* calibrada y no de reglas de comportamiento distintas. Este modelo se aplica semanalmente durante las 260 semanas; si el cliente abandona, deja de aportar saldo administrado y, desde ese momento, FinPUC deja de percibir la comisión mensual asociada a ese cliente.

3.12.2. Comparación de *views*

Las cuatro familias de *views* se comparan bajo el modelo único de abandono semanal y, cada una, con su propia configuración BL calibrada de forma independiente:

- **Desempleo macro:** tasa de desempleo asumida de 4% frente a 5% neutral, con $\beta = 1.5$. Favorece sectores cíclicos sobre defensivos.
- **Momentum general:** 20 activos long y 20 short sobre los 601 activos, con *lookback* de 252 días.

- **Momentum top/bottom 1Y:** 20 long y 20 short sobre el top 40 por capitalización, con *lookback* de 252 días.
- **Momentum top market-cap 6M:** 10 long y 10 short sobre el top 20 por capitalización, con *lookback* de 126 días.

La comparación se concentra en tres dimensiones: (a) mejora de Sharpe fuera de muestra, (b) mejora de Score P4 frente a Markowitz base, y (c) estabilidad operacional medida por turnover, concentración sectorial (HHI) y número efectivo de activos (N_{eff}).

4. SUPUESTOS

Datos y mercado. Se asume que los precios de cierre y dividendos de los CSV representan adecuadamente la información disponible para cada activo, por lo que el retorno total incorpora reinversión implícita de dividendos. La matriz de retornos se construye con `join="inner"`, suponiendo que eliminar fechas no comunes no introduce un sesgo relevante. La metadata de capitalización de mercado se considera suficiente para construir el benchmark y los pesos de equilibrio de Black-Litterman, aunque puede existir sesgo de supervivencia. Las carteras son *long-only*, cumplen $w_i \geq 0$ y $\sum w_i = 1$, no usan apalancamiento y permiten divisibilidad perfecta de acciones. La optimización omite costos de transacción, impuestos, *spreads* bid-ask, restricciones de liquidez, impacto de mercado y *slippage*. La utilidad de FinPUC se modela como una comisión mensual de 0,5% sobre el saldo activo administrado, sin comisiones por transacción ni por rebalanceo. La tasa libre de riesgo se mantiene constante en $R_f = 2\%$ anual.

Supuestos estadísticos. Los retornos históricos se usan como información para estimar retornos y riesgos futuros, bajo estabilidad temporal parcial de μ y Σ . Para estabilizar la covarianza muestral se aplica *shrinkage* de 20%: $\Sigma_{\text{shrink}} = (1 - \lambda)\Sigma + \lambda \cdot \text{diag}(\Sigma)$, con $\lambda = 0.20$. La anualización considera 252 días hábiles y escala la volatilidad por $\sqrt{252}$. En la simulación Monte Carlo, los retornos semanales se aproximan mediante $\mathcal{N}(\mu_{\text{sem}}, \sigma_{\text{sem}}^2)$, aun cuando el análisis distribucional muestra colas pesadas y curtosis elevada en los retornos diarios.

Optimización y rebalanceo. Los problemas formulados en CVXPY se tratan como convexos y adecuados para representar la decisión de inversión. Si una cota de volatilidad vuelve infactible un perfil, se relaja solo esa restricción. El portafolio de tangencia se aproxima eligiendo el mayor Sharpe dentro de la frontera eficiente discretizada, usando 30 puntos en Markowitz y 12 en Black-Litterman. En Black-Litterman, las *views* no requieren cubrir todos los activos: aquellos sin *view* explícita conservan el prior de equilibrio π y reciben ajustes indirectos por correlación a través de Σ . Las variantes por capitalización usan subconjuntos de 20 a 40 activos, mientras que momentum general y desempleo consideran los 601 activos. El rebalanceo se realiza cada 126 días hábiles; entre rebalanceos los pesos permanecen constantes y, en cada fecha, la ventana de entrenamiento incorpora solo retornos ya observados.

Experimento pandemia. La comparación entre escenarios “con pandemia” y “sin pandemia” mantiene fijo el período futuro fuera de muestra. Por ello, las diferencias se interpretan como efecto de la información utilizada para calibrar los modelos, no como cambios en

el mercado futuro. La base sin pandemia excluye las observaciones de 2020–2022, mientras que la base con pandemia las conserva.

Simulación Monte Carlo (P4). Cada cliente inicia con $C_0 = 1\,000$ USD. La utilidad de FinPUC proviene exclusivamente de una comisión mensual de 0,5% sobre el saldo activo administrado, acumulada en la implementación semanal con tasa equivalente $k_{\text{sem}} = 0,005 \times 12/52$; no hay comisiones por transacción ni por rebalanceo. El comportamiento del cliente combina una probabilidad de aceptación de la recomendación y una probabilidad de abandono semanal. La aceptación se modela como $p_{\text{act}} = 1/(1 + \exp[-(R_{\text{proyectado}} - \hat{x})])$, donde $R_{\text{proyectado}}$ es el retorno anual ofertado y $\hat{x}$ la tolerancia de pérdida del perfil. El abandono semanal usa el modelo `views_v1_plus`: la pérdida se mide respecto de C_0 y la probabilidad conductual sigue una logística sin reescalar, $1/(1 + \exp(-(x_t - \hat{x})))$, activa solo cuando la pérdida supera la tolerancia $\hat{x}$; además, si la riqueza llega a cero, el abandono es forzoso (restricción de ruina). Para el perfil muy conservador, con tolerancia 0%, cualquier pérdida genera probabilidad de abandono positiva. Se ejecutan 2 000 trayectorias por combinación, cantidad considerada adecuada para estabilizar riqueza terminal, tasa de abandono y utilidad de la empresa.

Sensibilidad. El impacto de los supuestos se evalúa mediante tres ejercicios: comparación del entrenamiento con y sin pandemia, midiendo el delta de Sharpe por portafolio y técnica; validación con 70 splits aleatorios y 18 ventanas móviles robustas, con horizontes desde `h2_f7` hasta `h7_f2`; y proyecciones Monte Carlo desfavorable, neutra y favorable, modificando el retorno esperado en $\pm 0.5\sigma$ para observar cambios en riqueza terminal, tasa de retiro y utilidad de la empresa.

Supuestos de la Entrega 3. La Tabla 4.1 resume los supuestos específicos de la tercera fase del proyecto, adicionales a los ya establecidos en la Entrega 2.

Tabla 4.1. Supuestos adicionales de la Entrega 3.

Supuesto	Valor
Caso base	Markowitz (no equiponderado)
Objetivo de recomendación	Maximizar el retorno esperado del cliente
Comisión de FinPUC	0,5% mensual sobre el saldo activo administrado
Tasa semanal equivalente	$k_{\text{sem}} = 0,005 \times 12/52$
Frecuencia de recomendación / abandono	Semestral / semanal
Modelo de abandono	Único, <code>views_v1_plus</code> (logística de umbral + ruina)
Probabilidad de abandono	$1/(1 + \exp(-(x_t - \hat{x})))$ si $x_t > \hat{x}$; 0 si no
Restricción de ruina	Abandono forzoso si riqueza ≤ 0
Aceptación de recomendación	$p_{\text{act}} = 1/(1 + \exp[-(R_{\text{proyectado}} - \hat{x})])$
Calibración BL	Independiente por <i>view</i> (config propia por metodología)
Retornos semanales en Monte Carlo	Normales i.i.d. con KPIs calibrados por metodología
Trayectorias por combinación	2 000
Horizontes de validación	$\mathcal{H}_1$ calibración, $\mathcal{H}_2$ validación, $\mathcal{H}_3$ test limpio P4

5. KPIS

Los KPIS se definieron para decidir qué combinación de técnica, *view* y perfil conviene recomendar.

- **Retorno total rebalanceado:** $R_{\text{total}} = \prod_t (1 + r_t) - 1$. Mide la ganancia acumulada fuera de muestra. Se usa para comparar el resultado final de cada cartera.
- **Retorno anualizado:** $R_{\text{anual}} = (1 + R_{\text{total}})^{1/T} - 1$. Normaliza el retorno por año y permite comparar horizontes de distinta duración.
- **Volatilidad anualizada:** $\sigma_{\text{anual}} = \sigma_{\text{diaria}} \sqrt{252}$. Mide la variabilidad del retorno. Sirve para descartar alternativas demasiado inestables para el perfil del cliente.
- **Ratio de Sharpe rebalanceado:** $\text{Sharpe} = (R_{\text{anual}} - R_f) / \sigma_{\text{anual}}$, con $R_f = 0.02$. Resume retorno ajustado por riesgo. Es el principal KPI para comparar eficiencia financiera entre técnicas.
- **Máximo drawdown:** mayor caída porcentual desde un máximo acumulado de riqueza. Evalúa la pérdida que el cliente habría tenido que tolerar, por lo que pesa especialmente en perfiles conservadores.
- **CVaR diario al 95%:** pérdida promedio en el 5% peor de días (Rockafellar & Uryasev, 2000). Se usa para medir riesgo de cola y evitar carteras con pérdidas extremas demasiado severas.
- **Riqueza terminal esperada:** valor final promedio desde $C_0 = 1000$ USD en las 2 000 simulaciones Monte Carlo por combinación. Traduce el desempeño financiero a una cifra monetaria para el cliente.
- **Probabilidad de ganancia:** proporción de simulaciones en que la riqueza terminal supera C_0 . Indica qué tan probable es que el cliente termine el horizonte con utilidad.
- **Tasa de retiro:** proporción de simulaciones en que el cliente abandona antes del final por superar su tolerancia de pérdida. Afecta la decisión porque reduce la continuidad del cliente y las comisiones futuras.
- **Utilidad de FinPUC por saldo administrado:** ingreso esperado de la empresa, calculado como una comisión mensual de 0,5% sobre el saldo activo administrado de los clientes que permanecen en la plataforma. No incluye comisiones por transacción ni por rebalanceo. Mide el atractivo de la alternativa para la empresa como consecuencia de la retención.
- **Clientes retenidos / saldo activo administrado:** número de clientes que permanecen activos al final del horizonte y saldo agregado bajo administración. Como

la comisión se cobra sobre el saldo activo, una mayor retención se traduce directamente en mayor utilidad para FinPUC.

- **Score P4:**

$$\text{ScoreP4}_{v,m,i} = \bar{W}_{v,m,i} + \bar{U}_{v,m,i} - C_0 r_{v,m,i}. \quad (5.1)$$

Para cada *view* v , modelo m y combinación $i = (s, p)$ de escenario histórico y perfil de riesgo, $\bar{W}_{v,m,i}$ corresponde a la riqueza terminal media del cliente, $\bar{U}_{v,m,i}$ a la utilidad media acumulada de FinPUC y $r_{v,m,i}$ a la tasa de abandono. Este índice resume riqueza del cliente, utilidad por saldo administrado y penalización por retiro (C_0 por cada cliente que abandona). La utilidad de FinPUC entra como resultado *ex post*; no forma parte del optimizador de portafolios.

Para comparar cada *view* Black-Litterman contra Markowitz base se calcula, en la misma combinación escenario–perfil, la mejora relativa:

$$\Delta_{v,i} = \frac{\text{ScoreP4}_{v,BL,i} - \text{ScoreP4}_{v,MK,i}}{|\text{ScoreP4}_{v,MK,i}|}. \quad (5.2)$$

La métrica final robusta de cada *view* se obtiene como la mediana de estas mejoras relativas:

$$\text{ScoreMediana}_v = \text{mediana}_{i \in S \times P}(\Delta_{v,i}). \quad (5.3)$$

La mediana mide el desempeño típico de la *view* frente a Markowitz y reduce el efecto de observaciones extremas, especialmente perfiles muy arriesgados en escenarios con pandemia. Por ello, el informe reporta el Score P4 promedio como medida de potencial económico y el Score P4 por mediana como criterio principal de robustez comparativa.

- **Mejora de Sharpe ΔSharpe :** diferencia entre el Sharpe de un portafolio Black-Litterman calibrado y el Sharpe del Markowitz base equivalente, evaluados en el mismo horizonte de test. Un valor positivo indica que la calibración agrega valor sobre la estimación histórica pura.
- **Turnover medio:** promedio de $\|w_t - w_{t-1}\|_1/2$ a lo largo del horizonte de evaluación. Mide la fracción del portafolio que se rota en cada rebalanceo; valores altos implican mayores costos operacionales implícitos.
- **Número efectivo de activos:** $N_{\text{eff}} = 1/\sum_i w_i^2$. Cuantifica la concentración del portafolio: $N_{\text{eff}} = N$ indica pesos uniformes, mientras que $N_{\text{eff}} \rightarrow 1$ indica concentración en pocos activos.
- **Concentración sectorial (HHI):** $\text{HHI} = \sum_s (\sum_{i \in s} w_i)^2$, donde s indexa los sectores económicos. Valores cercanos a 1 indican concentración en un solo sector; valores bajos indican diversificación.

6. CASO BASE

6.1. Markowitz como caso base

El caso base del proyecto es el portafolio **Markowitz** de optimización media-varianza. Todas las metodologías basadas en Black-Litterman se comparan contra esta referencia, de modo que una *view* solo se considera valiosa si mejora el desempeño del cliente respecto de Markowitz bajo el mismo protocolo de simulación.

La elección de Markowitz como caso base se justifica porque es la línea base analítica natural del problema: optimiza explícitamente la relación riesgo-retorno a partir de las estimaciones históricas de μ y Σ , sin incorporar *views* adicionales. Así, aislar la contribución de Black-Litterman equivale a medir cuánto aporta el prior de equilibrio y las *views* calibradas por sobre la estimación histórica pura. En versiones anteriores del proyecto se utilizó un benchmark equiponderado como caso base; este se descartó por ser una regla de asignación trivial que no representa una alternativa de inversión optimizada y comparable.

6.2. Métricas del caso base

La Tabla 6.1 resume el desempeño de Markowitz base en el horizonte de test limpio P4, agregado sobre perfiles, bajo el modelo de abandono semanal y la comisión de 0,5% mensual sobre el saldo activo. Al ser independiente de *views*, Markowitz base entrega las mismas métricas en todas las comparaciones por *view*.

Tabla 6.1. Desempeño de Markowitz base en test limpio P4 (agregado sobre perfiles, comisión 0,5% mensual sobre saldo).

Indicador	Sin pandemia	Con pandemia
Riqueza terminal media (USD)	2 342	2 140
Clientes retenidos (de 1 000)	865	850
Turnover medio	9,0%	9,4%
HHI sectorial	0,182	0,178
Utilidad FinPUC por saldo (USD)	258	243

Estos valores constituyen la referencia frente a la cual se mide la mejora de cada *view* de Black-Litterman. Una metodología agrega valor cuando incrementa la riqueza terminal del cliente y la retención sin elevar de forma excesiva el turnover ni la concentración sectorial; el

efecto neto sobre la utilidad de FinPUC se sigue, como consecuencia, del mayor saldo activo administrado que esa mejora sostiene.

7. IMPLEMENTACIÓN Y HERRAMIENTAS

7.1. Implementación y herramientas

La implementación se desarrolló en Python 3.11. Los notebooks de la Entrega 2 se mantuvieron como antecedente metodológico, pero la versión final de la Entrega 3 quedó organizada en scripts reproducibles por iteración. La arquitectura final se apoya en tres bloques:

- (i) `views_v1_plus/`: ejecuta la calibración independiente de cada *view*, la validación rolling de tres horizontes y la simulación P4 limpia con 2 000 trayectorias por combinación.
- (ii) `generar_informes_views_v1_plus.py`: consolida los resultados de las cuatro *views*, calcula la mejora de Score P4 promedio y por mediana frente a Markowitz base, y exporta tablas y figuras comparativas.
- (iii) `08_panoramas_retorno/`: toma la *view* ganadora momentum general ya calibrada y re-simula P4 bajo panoramas desfavorable, neutro y favorable, manteniendo fija la volatilidad base.

El código computacional se encuentra disponible en el repositorio GitHub del proyecto. El Anexo N°4 documenta la estructura de estos desarrollos computacionales, los archivos CSV generados y la relación entre código, supuestos, KPIs y resultados experimentales.

Las principales herramientas fueron **Pandas** para manejo de datos y exportación a CSV, **NumPy/SciPy** para cálculo numérico y simulación, **CVXPY** para resolver los problemas de optimización, **Matplotlib** para gráficos, y **Hashlib** para semillas deterministas en Monte Carlo.

La trazabilidad se asegura mediante carpetas `outputs/` por módulo. Cada etapa exporta CSV con pesos, KPIs, validaciones, rankings o simulaciones, y esos archivos son los que alimentan las tablas y figuras del informe. Además, los notebooks incluyen checklists finales que verifican archivos esperados, conteos por escenario/técnica/perfil y ausencia de NaN en columnas críticas.

7.2. Pipeline de la Entrega 3

La tercera fase organiza el pipeline en torno a la calibración independiente de cada *view* y a una única regla de abandono. Para cada una de las cuatro *views* se ejecuta el

script `validacion_<view>_v1_plus.py` (en la carpeta `views_v1_plus/`), que internamente:

- (i) **Calibra** la *view* de forma independiente en cinco etapas sobre $\mathcal{H}_1$, con validación en $\mathcal{H}_2$, congelando su propia configuración de hiperparámetros BL.
- (ii) **Valida** con ventanas rolling de tres horizontes, generando métricas de Sharpe, drawdown y dinámica de portafolio (turnover, N_{eff} , HHI) por ventana, perfil y escenario.
- (iii) **Simula** la evaluación económica P4 en el horizonte de test limpio $\mathcal{H}_3$, con 2 000 trayectorias por combinación, abandono semanal (`views_v1_plus`) y utilidad de FinPUC por comisión mensual de 0,5% sobre el saldo activo administrado.

Finalmente, `generar_informes_views_v1_plus.py` consolida los *outputs* de las cuatro *views*, comparando cada metodología Black-Litterman calibrada contra el caso base Markowitz y produciendo las tablas y figuras agregadas (mejora de Sharpe y de Score P4 —en promedio y mediana—, abandono, clientes retenidos y utilidad por saldo).

Todos los scripts utilizan las mismas librerías que la Entrega 2 (Pandas, NumPy/SciPy, CVXPY, Matplotlib, Hashlib), y los *outputs* se organizan en carpetas `outputs/` por módulo, manteniendo la trazabilidad del proyecto.

8. RESULTADOS Y ANÁLISIS

8.1. Lectura general de los datos de retorno

Antes de comparar metodologías conviene caracterizar el universo de activos. El análisis distribucional se aplicó a los 601 tickers del universo F5 sin pandemia, con 4 207 ajustes paramétricos. La Tabla 8.1 resume los estadísticos transversales y muestra dos rasgos centrales: la curtosis excedente es muy superior a la normalidad en casi todos los activos, con mediana 26,9 frente a 0 bajo normalidad, y la asimetría mediana es positiva (0,90), lo que sugiere colas derechas más pesadas. El detalle del ajuste por distribuciones se presenta en el Anexo N°3.

Tabla 8.1. Resumen transversal de estadísticos por ticker (universo F5 sin pandemia).

Variable	Mín.	Mediana	Media	Máx.
n retornos	2 518	7 949	8 263	15 400
Media diaria	0,011%	0,093%	0,102%	0,577%
Vol. anualizada	19,3%	36,5%	39,6%	214,9%
VaR 5%	-6,18%	-3,04%	-3,18%	-1,63%
CVaR 5%	-10,93%	-4,81%	-5,09%	-2,52%
Asimetría	-8,40	0,90	3,44	99,13
Curtosis exc.	3,42	26,90	179,07	10 151

La Tabla 8.2 confirma que la normal no es seleccionada como mejor distribución para ningún ticker, y las tres pruebas de normalidad rechazan la hipótesis nula al 5% en los 601 casos. AIC favorece Johnson SU por su flexibilidad para capturar asimetrías, mientras BIC prefiere t-Student por capturar colas pesadas con mayor parsimonia.

Tabla 8.2. Mejor familia distribucional según AIC y BIC.

Distribución	AIC	%	BIC	%
Johnson SU	247	41,1	180	30,0
t-Student	179	29,8	241	40,1
Normal generalizada	174	29,0	176	29,3
Laplace	1	0,2	4	0,7
Normal/log./skew-n.	0	0,0	0	0,0

Lectura. Estos resultados muestran que el universo de activos no se comporta como una distribución normal simple: presenta colas pesadas y asimetría. Por eso, la comparación

entre metodologías debe evaluarse no solo por retorno promedio, sino también por estabilidad, exposición a pérdidas y efecto sobre la permanencia del cliente. Además, dado que la riqueza terminal hereda una cola derecha pesada, el promedio puede sobreestimar el desempeño típico; por ello el Score P4 se reporta también en su versión mediana.

8.2. Comparación de metodologías calibradas

8.2.1. Calibración independiente de *views*

Cada *view* se calibró de forma independiente sobre el horizonte $\mathcal{H}_1$, congelando su propia configuración antes de la simulación económica. La Tabla 8.3 resume las configuraciones congeladas. La calibración no impone una estructura común: cada metodología llega a la simulación con sus mejores hiperparámetros propios.

Tabla 8.3. Configuración Black-Litterman congelada por *view* (calibración independiente).

<i>View</i>	Familia	q_{scale}	Confianza c	τ	Parám. extra
Momentum general	momentum	1.5	0.80	0.01	<i>lookback</i> 252, 20/20
Desempleo macro	unemployment	1.5	0.50	0.20	$U = 4\%$, $\beta = 1.5$
Mom. top/bottom 1Y	marketcap mom.	1.5	0.80	0.20	top 40, <i>lookback</i> 252
Mom. top market-cap 6M	marketcap mom.	1.5	0.80	0.20	top 20, <i>lookback</i> 126

8.2.2. Desempeño agregado frente a Markowitz base

La Tabla 8.4 compara cada *view* calibrada contra el caso base Markowitz, agregando sobre perfiles en el horizonte de test limpio.

Tabla 8.4. Desempeño agregado de Black-Litterman calibrado por *view* frente a Markowitz base (test limpio, comisión 0,5% mensual sobre saldo).

<i>View</i>	Mejora Sharpe	P4 mediana	P4 promedio	Turnover BL	HHI sector BL	Riqueza BL (USD)	Utilidad BL (USD)
Momentum general	+5.2%	+12.4%	+85.7%	34.6%	0.261	3 953	412
Desempleo macro	+2.0%	−10.5%	−10.4%	7.3%	0.157	1 735	222
Mom. top/bottom 1Y	−6.1%	−4.7%	−4.6%	30.7%	0.208	1 883	239
Mom. top market-cap 6M	−6.1%	−4.7%	−4.6%	30.7%	0.208	1 883	239

Momentum general domina económicamente: mejora el Score P4 promedio en 85.7% frente a Markowitz base y el Sharpe en 5.2%, con la mayor riqueza terminal (USD 3 953) y utilidad por saldo (USD 412). La lectura robusta por mediana reduce esa ventaja a 12.4%,

porque evita que combinaciones extremas, como el perfil Muy arriesgado con pandemia, determinen por sí solas el ranking. Aun con esta corrección, momentum general sigue siendo la mejor *view*. Esta ventaja viene acompañada de un costo operacional: turnover de 34.6% (frente a 7.3% de desempleo) y mayor concentración sectorial (HHI 0.261 vs. 0.157). Desempleo macro ofrece la mejor estabilidad operacional pero retrocede en Score P4 mediano (−10.5%). Las *views* por capitalización convergen a estructuras equivalentes y deterioran tanto el Sharpe (−6.1%) como el Score P4 mediano (−4.7%), por lo que no justifican su complejidad adicional.

Nota sobre el Score P4. El Score P4 promedio se mantiene como una medida de potencial económico, pero la recomendación final usa la versión por mediana como medida central de robustez. Esta elección es coherente con el análisis distribucional: la riqueza terminal presenta cola derecha, por lo que el promedio puede exagerar el desempeño típico de una *view*.

8.2.3. Validación rolling y robustez

La validación rolling de tres horizontes confirma que la ventaja de Black-Litterman calibrado se concentra en perfiles agresivos y escenarios con pandemia, donde la estimación histórica de Markowitz es menos confiable. Para momentum general con pandemia, la mejora de Sharpe en test limpio alcanza 75.6% en el perfil Muy arriesgado y 22.2% en Arriesgado, mientras que en perfiles conservadores y sin pandemia la mejora es marginal, lo que es consistente con que el prior de equilibrio ya está cerca de la solución óptima cuando los datos son estables. La separación estricta de los horizontes $\mathcal{H}_1 | \mathcal{H}_2 | \mathcal{H}_3$ evita el *data snooping* y es una fortaleza metodológica central del diseño.

Lectura. La comparación muestra que momentum general es la única metodología que mejora claramente el caso base Markowitz en términos económicos, y que esa mejora es más nítida en perfiles de mayor tolerancia al riesgo.

8.3. Resultados por perfil de riesgo

La metodología recomendada no es uniforme entre perfiles. La Tabla 8.5 contrasta momentum general (BL calibrado) con Markowitz base en el horizonte de test limpio, mostrando riqueza terminal, tasa de abandono y utilidad por saldo para las combinaciones dominantes.

Tabla 8.5. Resultados P4 por perfil: momentum general (BL) vs Markowitz base (test limpio).

Metodología	Escenario / Perfil	Riqueza (USD)	Abandono	Utilidad (USD)	Score P4
BL momentum	con pandemia / Muy arriesgado	15 983	5.7%	1 338	17 265
BL momentum	con pandemia / Arriesgado	6 847	2.9%	715	7 532
BL momentum	con pandemia / Neutro	3 311	2.1%	419	3 709
Markowitz	sin pandemia / Muy arriesgado	2 701	0.9%	344	3 036
Markowitz	con pandemia / Muy arriesgado	2 330	3.1%	297	2 596
BL momentum	sin pandemia / Neutro	2 274	1.6%	312	2 571
BL momentum	sin pandemia / Arriesgado	2 291	3.4%	305	2 562
Markowitz	sin pandemia / Arriesgado	2 255	0.1%	299	2 553

El beneficio de momentum general se concentra en los perfiles agresivos con pandemia: el perfil Muy arriesgado alcanza una riqueza terminal de USD 15 983, muy por encima de los USD 2 330 de Markowitz base en el mismo perfil, con una tasa de abandono moderada (5.7%). En perfiles neutros y conservadores, o en el escenario sin pandemia, las diferencias se comprimen y Markowitz base se mantiene competitivo. Esto se explica por la concentración de la señal de momentum en pocos activos (en Muy arriesgado, $N_{\text{eff}} = 6.4$ y HHI sectorial 0.545), que amplifica el resultado en condiciones favorables pero exige mayor tolerancia al riesgo.

Lectura. El resultado relevante no es solo qué metodología tiene mayor retorno promedio, sino cuál mantiene un mejor equilibrio entre retorno, permanencia del cliente y saldo administrado activo. Momentum general lo logra en perfiles agresivos; en perfiles conservadores la elección es menos concluyente.

8.4. Abandono semanal y retención

El comportamiento del cliente se reduce a la probabilidad de abandono semanal. La Figura 8.1 muestra la trayectoria de abandono semanal para momentum general (BL calibrado) con pandemia. En la mayoría de las configuraciones la probabilidad de abandono semanal es muy baja (cercana a 0% mensual a nivel agregado), porque los retornos esperados de los portafolios optimizados rara vez llevan la pérdida acumulada por encima de la tolerancia del perfil. La retención resultante es alta: del orden de 850 a 870 clientes activos de cada 1 000 al final del horizonte, según la metodología.

La Figura 8.2 muestra la evolución del número de clientes activos. La mayor parte de la pérdida de clientes proviene de la activación inicial (no todos los clientes adoptan la primera




Figura 8.1. Probabilidad de abandono semanal, momentum general (BL calibrado), escenario con pandemia.

recomendación), más que del abandono posterior, que es marginal una vez que el cliente está invertido.




Figura 8.2. Clientes activos en el tiempo, momentum general (BL calibrado), escenario con pandemia.

Lectura. Una metodología con mayor retorno promedio puede no ser la mejor si eleva demasiado el abandono. En este caso, momentum general mejora la experiencia del cliente sin

elevar de forma excesiva la salida de usuarios: su mayor turnover es un costo operacional, no un costo de retención.

8.5. Utilidad de FinPUC por saldo administrado activo

La utilidad de FinPUC se calcula *ex post*, aplicando una comisión mensual de 0,5% sobre el saldo activo administrado de los clientes que permanecen en la plataforma. La Tabla 8.6 compara la utilidad acumulada por metodología frente a Markowitz base.

Tabla 8.6. Utilidad de FinPUC por saldo administrado (test limpio, agregado).

Metodología	Utilidad (USD)	Δ vs Markowitz
Momentum general (BL)	412	+60% aprox.
Markowitz base	251	—
Mom. top/bottom 1Y (BL)	239	−5% aprox.
Desempleo macro (BL)	222	−12% aprox.

La utilidad de FinPUC sigue directamente al saldo administrado: como momentum general genera mayor riqueza terminal y mantiene una retención comparable, su saldo activo administrado es mayor y, con él, la utilidad por comisión mensual (USD 412 frente a USD 251 de Markowitz base). La Figura 8.3 ilustra la acumulación de ganancia del cliente bajo momentum general, que es la base sobre la cual se cobra la comisión.




Figura 8.3. Ganancia acumulada del cliente, momentum general (BL calibrado), escenario con pandemia.

Lectura. FinPUC no maximiza su utilidad cobrando por rebalanceos, sino manteniendo clientes activos con mayor saldo administrado. Por eso, la metodología recomendada debe mejorar el retorno del cliente y, al mismo tiempo, sostener la retención: ambas condiciones se cumplen en momentum general.

8.6. Sensibilidad post-optimal: panoramas de retorno

Como análisis posterior a la calibración, la *view* ganadora momentum general se evaluó bajo tres panoramas proyectados de retorno en la simulación Monte Carlo P4: desfavorable, neutro y favorable. Esta prueba no recalibra Black-Litterman ni cambia los escenarios históricos con/sin pandemia; solo desplaza el retorno esperado usado por P4 en $\pm 0.5\sigma$ manteniendo fija la volatilidad base. Por lo tanto, mide sensibilidad económica de la recomendación, no una nueva metodología.

Tabla 8.7. Sensibilidad P4 por panorama de retorno: momentum general calibrado vs. Markowitz base.

Modelo	Panorama	Riqueza (USD)	Utilidad (USD)	Abandono	Clientes finales	Score P4
BL calibrado	Desfavorable	2 448	269	15.6%	724	2 561
BL calibrado	Neutro	4 029	412	11.0%	870	4 331
BL calibrado	Favorable	6 521	611	8.2%	970	7 050
Markowitz base	Desfavorable	1 508	186	12.3%	757	1 571
Markowitz base	Neutro	1 977	249	9.0%	854	2 137
Markowitz base	Favorable	2 691	332	7.5%	930	2 948

El caso neutro replica conceptualmente la simulación base: mantiene $R_{\text{proyectado}} = R_{\text{base}}$. En ese punto, Black-Litterman con momentum general conserva una ventaja económica relevante sobre Markowitz (Score P4 promedio 4 331 vs. 2 137). Al tensionar el retorno hacia el panorama desfavorable, ambos modelos pierden riqueza y clientes, pero Black-Litterman mantiene un Score P4 superior. En el panorama favorable, la brecha se amplifica porque la mayor tasa esperada eleva la activación inicial, reduce el abandono y aumenta el saldo administrado.

Lectura. La sensibilidad confirma que la recomendación no depende de un único retorno puntual. Momentum general sigue siendo atractivo en el panorama neutro y conserva ventaja agregada incluso cuando el retorno esperado se desplaza en contra. La conclusión debe entenderse como resiliencia relativa: el modelo no busca ganar en cada celda, sino sostener mejor equilibrio entre riqueza, retención y utilidad ex post bajo perturbaciones razonables del retorno esperado.




Figura 8.4. Score P4 por panorama, Black-Litterman momentum general, escenario con pandemia.




Figura 8.5. Score P4 por panorama, Markowitz base, escenario con pandemia.

8.7. Recomendación final

Considerando conjuntamente el retorno del cliente, la retención y la utilidad por saldo administrado, la metodología recomendada es **Black-Litterman con *view* de momentum general calibrada**. Frente al caso base Markowitz, mejora el Score P4 en 12.4% bajo la agregación mediana y en 85.7% bajo la agregación promedio, además de mejorar el Sharpe en 5.2%. La mediana es la lectura principal porque representa el desempeño típico frente a




Figura 8.6. Riqueza terminal por panorama, Black-Litterman momentum general, escenario con pandemia.




Figura 8.7. Tasa de abandono por panorama, Black-Litterman momentum general, escenario con pandemia.

Markowitz; el promedio se reporta como evidencia complementaria del potencial económico cuando la señal de momentum captura escenarios favorables.

Esta metodología funciona mejor para los perfiles de mayor tolerancia al riesgo (**Arriesgado** y **Muy arriesgado**), especialmente en el escenario con pandemia, donde la señal de momentum agrega más valor. Su mayor turnover (34.6%) y concentración sectorial exigen monitoreo operacional, pero el beneficio económico neto es positivo. Para perfiles conservadores,




Figura 8.8. Riqueza semanal del perfil Muy arriesgado bajo panoramas de retorno, Black-Litterman momentum general, escenario con pandemia.

donde la mejora sobre Markowitz se comprime, se recomienda **desempleo macro** como alternativa defensiva por su baja rotación (7.3%) y mejor diversificación sectorial (HHI 0.157), aun cuando su Score P4 quede por debajo de Markowitz base.

9. CONCLUSIONES

9.1. Conclusiones principales

El proyecto implementó y calibró un sistema recomendador de inversiones para FinPUC en tres capas metodológicas (Markowitz, Black-Litterman, Monte Carlo P4). En esta fase, el objetivo se redefinió de forma clara: maximizar el retorno esperado del cliente, tratando la utilidad de FinPUC como una consecuencia *ex post* del saldo activo administrado, sujeto a una comisión mensual de 0,5% sobre dicho saldo.

El análisis permite concluir que la metodología **Black-Litterman con *view* de momentum general calibrada** es la alternativa más conveniente para los perfiles **Arriesgado** y **Muy arriesgado**, ya que mejora el retorno del cliente frente al caso base **Markowitz**: obtiene una mejora de Score P4 de 12.4% bajo la agregación mediana robusta, 85.7% bajo la agregación promedio y 5.2% en Sharpe. Desde la perspectiva del cliente, genera mayor riqueza terminal esperada; desde la de FinPUC, la mejora también es favorable porque un mayor saldo activo administrado se traduce en mayor utilidad por la comisión mensual, sin introducir comisiones por transacción ni por rebalanceo.

9.1.1. Calibración independiente de *views*

La calibración secuencial en cinco etapas se realizó de forma independiente para cada *view*, sobre tres horizontes estrictamente separados, evitando contaminar el período de evaluación. Cada metodología llega a la simulación con su propia configuración congelada (por ejemplo, momentum general con $c = 0.80$ y $\tau = 0.01$; desempleo macro con $c = 0.50$ y $\tau = 0.20$), de modo que la comparación final contrasta metodologías en su mejor versión y no depende de una selección prematura de *view*.

9.1.2. Comparación de *views*

Entre las cuatro familias evaluadas bajo el modelo único de abandono, momentum general domina en términos económicos con una mejora mediana de +12.4% en Score P4 frente a Markowitz base (+85.7% en promedio) y +5.2% en Sharpe. Esta ventaja conlleva mayor turnover (34.6%) y concentración sectorial (HHI 0.261). Desempleo macro ofrece la mejor estabilidad operacional (turnover 7.3%, HHI 0.157) pero retrocede en Score P4 mediano (−10.5%). Las *views* basadas en capitalización de mercado muestran deterioro tanto en Sharpe como en Score P4 mediano (−4.7%). La recomendación final prioriza momentum

general como *view* base, con desempleo macro como alternativa defensiva para perfiles conservadores.

9.1.3. Abandono y utilidad por saldo

El abandono semanal es marginal una vez que el cliente está invertido: la retención se ubica en torno a 850–870 clientes activos de cada 1 000 al final del horizonte. La utilidad de FinPUC sigue directamente al saldo administrado, de modo que las metodologías que generan mayor riqueza terminal y sostienen la retención producen también mayor utilidad (USD 412 para momentum general frente a USD 251 de Markowitz base).

9.1.4. Validación y robustez

La validación rolling de tres horizontes muestra que Black-Litterman calibrado agrega más valor en perfiles agresivos y escenarios con pandemia, donde la estimación histórica de Markowitz es menos confiable. En perfiles conservadores y sin pandemia, la mejora es marginal, lo que es consistente con que el prior de equilibrio ya está cerca de la solución óptima cuando los datos son estables. La separación estricta de horizontes $\mathcal{H}_1 | \mathcal{H}_2 | \mathcal{H}_3$ es una fortaleza metodológica central que debería mantenerse en cualquier iteración futura. Adicionalmente, los panoramas proyectados de retorno muestran que momentum general conserva ventaja agregada en el caso neutro y en el desfavorable, por lo que la recomendación no depende de un único retorno esperado puntual.

9.1.5. Limitaciones

Las principales limitaciones son: (a) los KPIs de retorno/volatilidad usados en Monte Carlo son fijos y no se re-optimizan dentro de la simulación; (b) la distribución normal de los retornos semanales subestima eventos extremos, lo que probablemente produce estimaciones optimistas de riqueza terminal; (c) el Score P4 por mediana reduce el efecto de outliers, pero no penaliza directamente turnover ni concentración sectorial; (d) la activación inicial del cliente y la comisión de 0,5% mensual son supuestos no calibrados con datos reales; y (e) la *view* de desempleo usa una tasa fija en lugar de series macroeconómicas observadas.

9.1.6. Trabajo futuro

Las extensiones prioritarias son: reemplazar la normalidad por t-Student o Johnson SU en Monte Carlo, incorporar *drawdown* respecto al máximo de riqueza como gatillo de abandono,

usar series macro observadas (BLS/FRED) para la *view* de desempleo, calibrar la activación y abandono con datos reales de clientes, y penalizar la rotación en la optimización para contener el turnover de momentum general.

9.2. Carta Gantt: avance y fases restantes

La Tabla 9.1 resume la Carta Gantt de trabajo posterior a esta entrega, diferenciando avance ya completado y tareas pendientes para la fase final del proyecto.

Tabla 9.1. Carta Gantt resumida: avance actual y fases restantes.

Fase	Periodo	Avance actual	Trabajo futuro
Calibración independiente y validación	12 mayo – 19 junio 2026	Calibración secuencial por <i>view</i> , validación rolling de tres horizontes y comparación de las cuatro <i>views</i> bajo un único modelo de abandono ya implementados.	Profundizar la comparación con nuevas distribuciones de retorno y validar la sensibilidad del ranking final.
Modelo de negocio por saldo administrado	12 mayo – 19 junio 2026	Comisión de 0,5% mensual sobre saldo activo y utilidad por retención implementadas y simuladas.	Re-ejecutar la evaluación económica con el dataset completo y validar la convergencia de Monte Carlo.
Mejoras del modelo	19 – 26 junio 2026	Se incorporó Score P4 mediana como métrica robusta y panoramas de retorno como sensibilidad post-optimal.	Incorporar distribuciones no normales, <i>drawdown</i> como gatillo de abandono y penalización de turnover.
Cierre del proyecto	13 – 26 junio 2026	Informe 3 en redacción y principales resultados ya consolidados.	Preparar la presentación final, documentar el modelo definitivo, ordenar el repositorio GitHub y realizar correcciones finales antes de la entrega.

REFERENCIAS

- Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. doi: 10.2469/faj.v48.n5.28
- D’Acunto, F., Prabhala, N., & Rossi, A. G. (2019). The promises and pitfalls of robo-advising. *Review of Financial Studies*, 32(5), 1983–2020. doi: 10.1093/rfs/hhz017
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. doi: 10.1016/0304-405X(93)90023-5
- He, G., & Litterman, R. (1999). *The intuition behind Black–Litterman model portfolios* (Tech. Rep.). Goldman Sachs Asset Management.
- Idzorek, T. M. (2005). A step-by-step guide to the Black-Litterman model. In *Forecasting expected returns in the financial markets* (pp. 17–38). Academic Press.
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. doi: 10.1016/S0047-259X(03)00096-4
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. doi: 10.1111/j.1540-6261.1952.tb01525.x
- Michaud, R. O. (1989). The Markowitz optimization enigma: Is ‘optimized’ optimal? *Financial Analysts Journal*, 45(1), 31–42. doi: 10.2469/faj.v45.n1.31
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41. doi: 10.21314/JOR.2000.038
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442. doi: 10.1111/j.1540-6261.1964.tb02865.x

ANEXO N°1: DECLARACIÓN DE USO DE IA EN ESTE INFORME Y PRESENTACIÓN ASOCIADA

Grupo:_____ 13 _____

¿Hicieron uso de herramientas de IA en su trabajo para este informe y/o presentación?

SI ☐ X ☒ NO ☐

¿Cuáles de las siguientes alternativas mejor describe el uso que hicieron de IA (puede ser más de una)

- X Apoyo a la redacción, ortografía, estructura gramatical, etc., de los documentos.
- X Apoyo al análisis de datos e información asociada al problema.
 - Búsqueda y/o filtro de referencias, contenidos web, literatura, etc., relevante al proyecto.
- X Apoyo para el desarrollo de modelos asociados al proyecto.
- X Apoyo en el desarrollo de código computacional necesario para el proyecto
- X Apoyo en el análisis de resultados (por ejemplo, de distintas corridas computacionales, tendencias de predicciones, etc.)
- x Apoyo para construir figuras, diagramas, etc.
 - Apoyo para obtener conclusiones a partir de los análisis de resultados.
- X Otro, especificar: Generación de un entorno Docker para visualización interactiva de datos financieros.

Herramientas utilizadas: Claude y Codex (principalmente para el desarrollo de código, apoyo en redacción, construcción de diagramas y análisis de resultados).

Reflexión sobre el uso de IA:

El uso de herramientas de inteligencia artificial durante el proyecto tuvo un carácter principalmente instrumental y de apoyo al aprendizaje. La IA se utilizó como una herramienta de consulta para comprender mejor distintas librerías de Python, revisar formas correctas de implementar procedimientos de optimización y simulación, y resolver dudas puntuales sobre

estructuras de código, manejo de datos y visualización de resultados. En este sentido, su aporte fue similar al de una fuente de asistencia técnica interactiva, que permitió acelerar la búsqueda de alternativas y contrastar posibles enfoques antes de incorporarlos al desarrollo del modelo.

En el desarrollo computacional, la IA fue útil para apoyar la implementación de los modelos de Markowitz, Black-Litterman y simulación Monte Carlo, especialmente en tareas relacionadas con el uso de librerías, organización del código y corrección de errores. También se empleó para revisar la consistencia de partes ya desarrolladas, detectar posibles problemas de implementación y proponer mejoras de eficiencia. Sin embargo, las decisiones metodológicas, la selección de supuestos, la interpretación de resultados y la evaluación final de las recomendaciones fueron realizadas por el grupo, verificando que las salidas fueran coherentes con los objetivos del proyecto y con la teoría financiera estudiada.

La experiencia mostró que la IA puede aumentar la productividad cuando se usa de manera crítica, pero también requiere validación constante. Sus respuestas no fueron tomadas como definitivas: cada sugerencia relevante fue revisada, adaptada y contrastada con el funcionamiento del código, los resultados obtenidos y los criterios del proyecto. Esto fue especialmente importante en un contexto financiero, donde errores de programación o interpretación pueden cambiar de forma significativa las conclusiones. Por ello, el uso responsable de IA no reemplazó el razonamiento del equipo, sino que ayudó a mejorar la calidad, eficiencia y claridad del trabajo desarrollado.

Patricio Andres Acevedo Flores	_____
Benjamín Alonso Cano Araya	_____
Matías Benjamín Catalán Contreras	_____
Gaspar Ten Berg Yunusic	_____
Diego Benjamín Villalobos Michea	_____

ANEXO N°2: ANÁLISIS DE DATOS

Este anexo presenta la fuente de datos, la estructura de los archivos, los criterios de clasificación sectorial, los niveles de filtrado aplicados y la caracterización del universo final de acciones utilizado en el modelo P4. Además, incorpora la metodología actual de análisis con pandemia, en la cual la pandemia no se elimina como única definición de base, sino que se compara explícitamente el desempeño de los modelos con y sin las observaciones de 2020–2022 dentro del entrenamiento. Ver documento completo

Descripción de la Fuente de Datos

Los datos históricos provienen del directorio `Data/Historical.Stocks/` del repositorio del proyecto. Fueron descargados con la librería `yfinance` de Yahoo Finance, incluyendo precios de cierre ajustados por splits, volumen, dividendos y metadatos fundamentales por ticker.

Estructura de archivos

El directorio contiene **1.407 archivos**:

- **1.406 archivos CSV** individuales con el formato `stock_return-<TICKER>.csv`
- **1 archivo de metadatos** `stocks_info.txt` con información fundamental de cada ticker (sector, industria, descripción, capitalización de mercado, empleados, etc.)

Formato de los CSV

Cada archivo contiene precios diarios con las siguientes columnas:

Columna	Tipo	Descripción
Date	datetime	Fecha de cierre (zona horaria US/Eastern)
Open	float	Precio de apertura ajustado
High	float	Precio máximo del día
Low	float	Precio mínimo del día
Close	float	Precio de cierre ajustado por splits
Volume	int	Volumen de transacciones
Dividends	float	Dividendo distribuido ese día (USD/acción)
Stock Splits	float	Factor de split (0 si no hubo split)

Nota: Los precios están ajustados hacia atrás (*backward-adjusted*) por splits de acciones, pero *no* por dividendos. Los dividendos se registran explícitamente en la columna `Dividends` y serán usados directamente para alimentar la **caja chica** del modelo de optimización.

Cobertura temporal

Indicador	Valor	Detalle
Total de tickers en archivos CSV	1.406	
Tickers con datos válidos	1.165	83% del total
Tickers con datos vacíos o errores	239	17% sin datos
Fecha de corte más frecuente	2026-03-13	1.158 tickers
Mediana de filas por archivo	6.532	$\approx$ 26 años
Tickers con ≥ 5 años (1.250 filas)	1.039	
Tickers con ≥ 10 años (2.500 filas)	912	

Los años de inicio más frecuentes son 1980 (100 tickers), 1999 (52), 2021 (49) y 1973 (41), lo que refleja una mezcla de empresas consolidadas y listados recientes, incluyendo SPACs post-2020.

Tratamiento temporal de la pandemia

La cobertura temporal incluye el periodo de crisis y recuperación asociado a COVID-19. En versiones preliminares del análisis, la pandemia se trataba principalmente como un periodo a excluir. En la versión actual, el criterio se modificó: se construyen dos escenarios comparables, uno que excluye 2020–2022 de la ventana de entrenamiento y otro que conserva ese periodo.

Esta decisión permite medir si los datos de estrés alteran las estimaciones de retorno, volatilidad y covarianza, sin confundir ese efecto con un cambio en el periodo futuro evaluado. Por lo tanto, la pandemia pasa de ser solo un filtro de limpieza a ser una variable metodológica explícita del diseño experimental.

Clasificación Sectorial

Sistema de clasificación

Los tickers se clasifican usando la taxonomía sectorial de **GICS**¹ a través de los metadatos de Yahoo Finance, que asigna a cada empresa un `sector` y una `industry` (subsector).

El archivo `stocks_info.txt` contiene 1.406 entradas en formato:

```
TICKER;{'sector': '...', 'industry': '...', 'marketCap':  
        ..., ...}
```

Distribución sectorial del universo completo

La Tabla 9.2 muestra la distribución de los tickers con datos válidos por sector.

¹Global Industry Classification Standard, desarrollado por MSCI y S&P Dow Jones Indices.

Tabla 9.2. Distribución sectorial del universo completo con datos válidos

Sector	Tickers	% del total
Financial Services	716	61.4%
Technology	81	6.9%
Industrials	74	6.4%
Healthcare	64	5.5%
Consumer Cyclical	59	5.1%
Consumer Defensive	38	3.3%
Real Estate	32	2.7%
Utilities	31	2.7%
Basic Materials	22	1.9%
Energy	21	1.8%
Communication Services	20	1.7%
Unknown	8	0.7%
Total	1.166	100%

Nota: Financial Services representa el 61% del universo crudo debido a la alta presencia de bancos regionales, gestores de activos y shell companies (SPACs). El filtrado posterior reducirá significativamente este sesgo sectorial.

Subsectores predominantes en Financial Services

Subsector (Industry)	Tickers	%
Banks – Regional	317	44.3%
Asset Management	101	14.1%
Capital Markets	56	7.8%
Credit Services	45	6.3%
Shell Companies	42	5.9%
Insurance – Property & Casualty	41	5.7%
Banks – Diversified	19	2.7%
Insurance – Life	17	2.4%
Insurance – Specialty	16	2.2%
Insurance Brokers	16	2.2%
Otros	46	6.4%
Total	716	100%

Tipos de instrumento

El campo `quoteType` de Yahoo Finance indica que 1.165 tickers corresponden a EQUITY (acciones individuales de empresas) y 1 ticker es MUTUALFUND (excluido del análisis). El universo es prácticamente homogéneo en acciones individuales.

Capitalización de Mercado

Se definen los siguientes rangos estándar de capitalización:

Categoría	Rango (USD)	Tickers	%
Mega cap	$\geq 200B$	50	4.3%
Large cap	10B – 200B	473	40.6%
Mid cap	2B – 10B	193	16.6%
Small cap	300M – 2B	234	20.1%
Micro cap	$< 300M$	210	18.0%
Sin dato	—	6	0.5%
Total con datos		1.160	

La capitalización de mercado se utiliza en dos niveles. Primero, permite filtrar empresas demasiado pequeñas o sin información suficiente, que podrían introducir problemas de liquidez o sesgos extremos en la estimación. Segundo, sirve como criterio para construir referencias de mercado, en particular el prior de equilibrio de Black-Litterman.

Niveles de Filtrado

Se definen cinco niveles de filtrado en cascada, cada uno más restrictivo que el anterior. El objetivo es obtener un universo operacional que sea **líquido, estable, representativo y estadísticamente válido** para el optimizador de Markowitz.

La secuencia de filtros es la siguiente:

- **F0 — Universo crudo:** 1.406 tickers
- **F1 — Liquidez básica:** 883 tickers (precio ≥ 5 USD, historia ≥ 5 años)
- **F2 — Sin shells ni desconocidos:** 881 tickers (excluye Shell Companies y sector Unknown)
- **F3 — Large/Mega cap:** 686 tickers (capitalización ≥ 2 B USD)
- **F4 — Historia suficiente:** 641 tickers (≥ 10 años de datos)
- **F5 — Volatilidad razonable (universo final descriptivo):** 636 tickers ($5\% \leq \sigma_{ann} \leq 100\%$)

Razones de exclusión

La Tabla 9.3 desglosa cuántos tickers fueron eliminados en cada filtro y por qué razón:

Tabla 9.3. Razones de exclusión del universo final F5

Razón de exclusión	Tickers	%
Historial < 10 años	254	47.9%
Cap. mkt < 2 B o sin dato	233	43.9%
Precio de cierre < 5 USD	37	7.0%
Volatilidad fuera de rango	5	0.9%
Datos vacíos o errores de lectura	239	—
Total excluidos (F0→F5)	529	

Definición formal de cada filtro

F1 — Liquidez básica. Un ticker i pertenece a $\mathcal{F}_1$ si y solo si cumple: número de filas con precios válidos $n_i \geq 1.250$ (≈ 5 años de historia), precio de cierre más reciente $P_i^{\text{last}} \geq 5$ USD, y capitalización de mercado $\text{Cap}_i \geq 300\text{M USD}$ (o sin dato). Esto excluye penny stocks y acciones ilíquidas sin historia suficiente para estimar parámetros estadísticos confiables.

F2 — Calidad de clasificación. $\mathcal{F}_2 \subset \mathcal{F}_1$: adicionalmente se excluye si `industry = "Shell Companies"` o `sector = "Unknown"`. Las shell companies, principalmente SPACs, no tienen operaciones reales ni retornos representativos, y los tickers sin sector asignado no pueden incluirse en análisis sectoriales.

F3 — Large/Mega cap. $\mathcal{F}_3 \subset \mathcal{F}_2$: adicionalmente se requiere $\text{Cap}_i \geq 2 \times 10^9$ USD. Las empresas de capitalización media-alta tienen mayor liquidez de mercado, menores spreads bid-ask, y sus precios reflejan mejor la información pública disponible, condición implícita del modelo de Markowitz.

F4 — Historia suficiente. $\mathcal{F}_4 \subset \mathcal{F}_3$: adicionalmente $n_i \geq 2.500$ (≈ 10 años de datos diarios). Con 10 años de historia se captura al menos un ciclo económico completo, incluyendo crisis (2008–09, 2020) y expansiones, lo que es necesario para la estimación robusta de matrices de covarianza.

F5 — Volatilidad razonable (universo final descriptivo). $\mathcal{F}_5 \subset \mathcal{F}_4$: adicionalmente se requiere:

$$5\% \leq \hat{\sigma}_i^{\text{ann}} \leq 100\% \quad \text{donde} \quad \hat{\sigma}_i^{\text{ann}} = \hat{\sigma}_i^{\text{diaria}} \times \sqrt{252}$$

$\sigma < 5\%$ indicaría datos incorrectos o instrumentos no bursátiles; $\sigma > 100\%$ corresponde a activos especulativos extremos incompatibles con el modelo de media-varianza.

Universo Final Descriptivo: 636 Acciones

El universo final descriptivo contiene **636 acciones** con historia ≥ 10 años, capitalización $\geq 2\text{B USD}$, precio ≥ 5 USD, y volatilidad anualizada entre 5% y 100%.

Se denomina “descriptivo” porque resume el resultado completo del proceso de depuración sobre los datos disponibles. Para los experimentos con y sin pandemia se aplica una restricción adicional de comparabilidad temporal, explicada más adelante, que reduce el universo operacional a 601 acciones.

Distribución sectorial del universo final

Tabla 9.4. Estadísticas por sector — universo F5 (636 tickers)

Sector	N	$\bar{\sigma}_{ann}$	$\overline{\text{CAGR}}$	% con dividendos
Financial Services	237	37.5%	10.6%	95%
Technology	73	44.6%	16.5%	70%
Industrials	64	34.6%	13.2%	95%
Healthcare	59	37.3%	13.4%	66%
Consumer Cyclical	55	41.2%	13.9%	78%
Consumer Defensive	33	29.3%	11.4%	97%
Utilities	29	24.7%	9.7%	100%
Real Estate	29	34.8%	11.3%	93%
Energy	20	37.5%	11.5%	100%
Basic Materials	19	35.1%	11.5%	100%
Communication Services	18	36.7%	14.6%	78%
Total	636	36.6%	11.9%	90%

Utilities es el sector de menor volatilidad promedio (24.7%), adecuado para perfiles conservadores con dividendos garantizados (100%). Technology lidera en CAGR (16.5%) pero con alta volatilidad (44.6%). Consumer Defensive combina volatilidad baja (29.3%) con dividendos casi universales (97%). Financial Services sigue siendo el sector más grande (37% del universo F5).

Tabla 9.5. Top subsectores por sector en el universo F5

Sector	Subsector (Industry)	N
Financial Services	Banks – Regional	93
	Asset Management	26
	Capital Markets	19
	Insurance – P&C	18
	Banks – Diversified	18
Technology	Semiconductors	14
	Software – Application	13
	Software – Infrastructure	12
	IT Services	10
	Computer Hardware	5
Industrials	Specialty Industrial Machinery	14
	Aerospace & Defense	11
	Integrated Freight & Logistics	5
	Airlines	4
Healthcare	Diagnostics & Research	11
	Medical Devices	10
	Drug Manufacturers – General	9
	Medical Instruments & Supplies	9
Consumer Cyclical	Packaging & Containers	6
	Auto Parts	6
	Restaurants	6
	Travel Services	5
Real Estate	REIT – Specialty	7
	REIT – Residential	6
	REIT – Retail	5
Energy	Oil & Gas E&P	8
	Oil & Gas Midstream	4
	Oil & Gas Refining	3
Basic Materials	Specialty Chemicals	10
	Agricultural Inputs	2
Utilities	Utilities – Regulated Electric	23
	Utilities – Diversified	2
	Utilities – Regulated Gas	2
Communication Services	Entertainment	6
	Telecom Services	5
	Internet Content & Information	4

Representantes por sector (top 5 por capitalización)

Tabla 9.6. Top 5 Technology (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
NVDA	NVIDIA Corp.	4.381	59.5%	36.7%	1999
AAPL	Apple Inc.	3.676	43.8%	18.9%	1980
MSFT	Microsoft Corp.	2.940	33.2%	24.6%	1986
AVGO	Broadcom Inc.	1.527	37.9%	40.6%	2009
MU	Micron Technology	480	60.3%	14.8%	1984

Tabla 9.7. Top 5 Healthcare (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
LLY	Eli Lilly & Co.	882	27.5%	13.9%	1972
JNJ	Johnson & Johnson	582	22.8%	13.8%	1962
ABBV	AbbVie Inc.	388	26.3%	19.6%	2013
MRK	Merck & Co.	286	24.9%	12.4%	1962
UNH	UnitedHealth Group	256	39.8%	20.9%	1984

Tabla 9.8. Top 5 Financial Services (por capitalización de mercado)

Ticker	Empresa	Cap (USD B)	σ_{ann}	CAGR	Inicio
JPM	JPMorgan Chase	764	35.0%	13.0%	1980
V	Visa Inc.	592	28.5%	19.5%	2008
MA	Mastercard Inc.	444	32.4%	27.4%	2006
BAC	Bank of America	341	37.5%	6.7%	1973
HSBC	HSBC Holdings	269	27.0%	5.9%	1999

Tabla 9.9. Top 5 Consumer Defensive + Utilities (perfiles conservadores)

Ticker	Sector	Empresa	Cap (B)	σ_{ann}	CAGR	Inicio
WMT	Cons. Def.	Walmart Inc.	1.009	29.1%	19.0%	1972
COST	Cons. Def.	Costco Wholesale	447	31.0%	13.2%	1986
PG	Cons. Def.	Procter & Gamble	353	21.3%	10.5%	1962
KO	Cons. Def.	Coca-Cola Co.	333	22.8%	12.3%	1962
NEE	Utilities	NextEra Energy	193	21.8%	11.1%	1973

Universo Operacional con Inclusión de Pandemia: 601 Acciones

Para los experimentos de portafolio no se usa directamente la totalidad del universo descriptivo de 636 acciones. Se requiere que los activos sean comparables entre los escenarios `sin_pandemia` y `con_pandemia` y que tengan datos suficientes en las ventanas de entrenamiento y evaluación. Al aplicar esta intersección temporal y operacional, el universo usado por los notebooks principales queda en **601 acciones**.

Esta diferencia no contradice el universo F5. El número 636 describe el resultado completo del proceso de filtrado de datos; el número 601 corresponde al subconjunto común y operacional usado para comparar metodologías bajo el horizonte `h7_f2`.

Escenarios de datos

La metodología actual define dos escenarios:

- **`sin_pandemia`**: excluye las observaciones de 2020–2022 de la base usada para calibrar los modelos.
- **`con_pandemia`**: conserva las observaciones de 2020–2022 dentro del historial de entrenamiento.

En ambos escenarios se mantiene fijo el periodo futuro fuera de muestra: 2024-01-29 a 2026-01-30. Por lo tanto, el experimento no compara dos futuros distintos. Compara dos formas de estimar los parámetros con distinta información histórica.

Tabla 9.10. Diagnóstico de escenarios para el universo operacional

Escenario	Activos	Retornos comunes	Días pandemia train	Días pandemia test
Sin pandemia	601	2.489	0	0
Con pandemia	601	3.245	756	0

Tabla 9.11. Ventanas temporales en el experimento h7_f2

Escenario	Retornos disponibles	Entrenamiento	Evaluación futura
Sin pandemia	2013-03-08 a 2026-01-30	2014-01-23 a 2024-01-26	2024-01-29 a 2026-01-30
Con pandemia	2013-03-08 a 2026-01-30	2017-01-24 a 2024-01-26	2024-01-29 a 2026-01-30

La ventana de entrenamiento del escenario sin pandemia comienza antes porque necesita recorrer más tiempo calendario para reunir una cantidad comparable de observaciones tras remover 2020–2022. En cambio, el escenario con pandemia conserva esos días y puede completar la muestra de entrenamiento con una ventana calendario más corta.

Interpretación metodológica

El tratamiento con/sin pandemia permite separar tres efectos:

- **Efecto de limpieza:** se mantiene un universo líquido, clasificado y con historia suficiente.
- **Efecto de calibración:** se observa cómo cambian μ , Σ , la frontera eficiente y los pesos cuando se incorpora un periodo de estrés.
- **Efecto de evaluación:** se mantiene fijo el futuro fuera de muestra, por lo que las diferencias no se atribuyen a distintos mercados futuros.

Así, la pandemia no se interpreta como ruido que deba eliminarse automáticamente. Se interpreta como información histórica extrema cuya inclusión puede mejorar o deteriorar la estimación, dependiendo del modelo.

Efecto observado en resultados

La inclusión de 2020–2022 afecta principalmente a los portafolios que dependen de retornos esperados históricos. La Tabla 9.12 resume el efecto en el experimento Markowitz vs Benchmark.

Tabla 9.12. Efecto de incluir pandemia en el entrenamiento

Portafolio	Ret. sin	Sharpe sin	Ret. con	Sharpe con	Δ Sharpe
Benchmark	101,4%	2,05	101,4%	2,05	0,00
Mínima varianza	56,6%	2,11	54,6%	2,02	−0,09
Muy conservador	58,0%	2,21	54,5%	2,02	−0,18
Conservador	67,8%	2,42	55,5%	1,97	−0,45
Neutro	82,9%	2,41	60,5%	1,76	−0,66
Ideal de mercado	76,5%	2,51	59,5%	1,40	−1,11
Arriesgado	91,6%	1,73	58,4%	1,17	−0,57
Muy arriesgado	102,7%	1,41	44,0%	0,55	−0,86

El benchmark permanece invariante porque su regla no depende de la estimación de μ ni de Σ . En cambio, las carteras optimizadas sí se modifican. El deterioro más fuerte ocurre en Ideal de mercado (−1,11 puntos de Sharpe) y Muy arriesgado (−0,86), lo que muestra que los perfiles más agresivos son los más sensibles a la inclusión de datos de crisis. Mínima varianza cae solo −0,09 puntos de Sharpe, porque depende más de covarianzas que de retornos esperados individuales.

Implicaciones para el Modelo de Optimización

Conexión con parámetros del modelo

El universo F5 alimenta directamente los parámetros del modelo MO-MS-SNLP descrito en la formulación matemática del P4:

Tabla 9.13. Conexión entre parámetros del modelo y fuente de datos

Parámetro	Fuente en los datos	Notas
$r_{i,t}^s$ (retorno escenario s)	Columna <code>Close</code> , retornos diarios	Agregado a retornos semanales
$d_{i,t}$ (dividendos)	Columna <code>Dividends</code>	Alimenta <code>CC_t</code> (caja chica)
μ_i (retorno esperado)	CAGR histórico o media móvil	Percentil 10/50/90 por escenario
Σ_{ij} (covarianza)	Retornos diarios, ventana de 2 años	Estimación rolling para rebalanceo
α_p (tolerancia de pérdida)	Perfil de riesgo del cliente	5 niveles: 0%, 5%, 15%, 30%, 40%

En la implementación actual, estos parámetros se calculan sobre dos bases comparables: una sin pandemia y otra con pandemia. Por lo tanto, el mismo pipeline de datos permite medir cómo la inclusión de 2020–2022 cambia los insumos de optimización.

Sub-universos recomendados por perfil de riesgo

Para mantener el problema computacionalmente tratable y respetar la restricción de respuesta < 10 segundos, se sugieren los siguientes sub-universos:

Tabla 9.14. Sub-universos recomendados por perfil de riesgo

Perfil	Tamaño sugerido	Criterio de selección
Muy conservador (0%)	30–50 acciones	$\sigma_{ann} < 30\%$, dividendos, sectores Utilities y Cons. Def.
Conservador (5%)	50–80 acciones	$\sigma_{ann} < 35\%$, dividendos $\geq 50\%$ del universo sectorial
Neutro (15%)	80–120 acciones	Todos los sectores, pesos del universo F5
Arriesgado (30%)	100–150 acciones	Incluye Tech y Consumer Cyclical de alta volatilidad
Muy arriesgado (40%)	Sin restricción	Universo F5 completo en descriptivo; universo operacional de 601 en experimentos con/sin pandemia

Para el prototipo inicial se recomienda trabajar con un universo de **50–100 acciones** seleccionadas por sector (representantes por capitalización), lo que garantiza la resolución en Gurobi en < 1 segundo para el LP de capas 0–2.

Consideraciones sobre la caja chica

Los dividendos en la columna `Dividends` representan el monto en USD por acción en la fecha de pago. Para el modelo:

$$d_{i,t} = \text{Dividends}_{i,t} \cdot \frac{w_{i,t} \cdot V_{t-1}}{P_{i,t}} \quad (9.1)$$

donde $P_{i,t}$ es el precio de cierre de la semana t y V_{t-1} el valor del portafolio en la semana anterior. El 90% del universo F5 distribuye dividendos, lo que implica que la caja chica será activa para la gran mayoría de portafolios.

Implicancia de la pandemia para los parámetros

La pandemia afecta principalmente la estimación de retornos esperados y covarianzas. En Markowitz, esto se traduce en cambios directos en la frontera eficiente y en la selección de portafolios por perfil. En Black-Litterman, el prior de equilibrio y las *views* amortiguan parcialmente la dependencia de la media histórica, pero la matriz de covarianzas y la volatilidad siguen capturando parte del shock. En Simulación Monte Carlo, los KPIs resultantes se usan como insumo para proyectar riqueza, retiro del cliente y utilidad de la empresa.

Por ello, mantener ambos escenarios es metodológicamente más informativo que reportar una sola base sin pandemia. Permite observar si una técnica es robusta cuando se entrena con datos de estrés y si el resultado depende de un supuesto de limpieza demasiado favorable.

Conclusión

En síntesis, a partir de un universo inicial de **1.406 tickers** se construyó un universo final descriptivo de **636 acciones** aptas para alimentar el modelo de optimización del proyecto. El proceso de depuración permitió eliminar instrumentos con información incompleta, baja liquidez, escasa historia o comportamiento incompatible con el enfoque de media-varianza.

El resultado es un universo más estable, representativo y utilizable computacionalmente, con presencia de 11 sectores económicos, una volatilidad promedio anualizada de 36.6%, y una alta proporción de acciones que pagan dividendos. Esto permite que el conjunto final no solo sea adecuado para la estimación de retornos y covarianzas, sino también consistente con la lógica financiera del modelo, incluyendo la incorporación de caja chica vía dividendos.

La metodología actual agrega una capa adicional: para los experimentos de Markowitz, Black-Litterman y Simulación Monte Carlo se trabaja con un universo operacional comparable de **601 acciones**, evaluado bajo escenarios `sin_pandemia` y `con_pandemia`. En ambos casos el periodo futuro se mantiene fijo, por lo que la comparación mide el efecto de incluir 2020–2022 en la calibración, no el efecto de cambiar el mercado evaluado.

Documento generado con datos al 13 de marzo de 2026.

Fuente: Yahoo Finance vía `yfinance`. Análisis: Python 3.11.

ANEXO N°3: ANÁLISIS DE AJUSTE DE DISTRIBUCIONES

Resumen

Este anexo resume la implementación y los resultados del análisis distribucional aplicado a los retornos diarios de los tickers filtrados del universo FinPUC. El objetivo fue evaluar si los retornos de cada activo se ajustan mejor a una distribución normal o a familias alternativas capaces de representar colas pesadas, asimetría y mayor concentración de observaciones alrededor de cero. El análisis se realizó sobre la base de datos sin pandemia, es decir, excluyendo las observaciones del periodo 2020–2022 y utilizando activos que ya habían superado los filtros de historia, capitalización, precio, clasificación y volatilidad.

El procedimiento fue implementado mediante el script `ajustar_distribuciones_retornos`, que automatiza la lectura de archivos CSV, el cálculo de retornos diarios totales, la aplicación de pruebas de normalidad, el ajuste de distribuciones candidatas por máxima verosimilitud y la exportación de resultados. La finalidad no fue imponer una distribución única para todo el universo de acciones, sino identificar, ticker por ticker, qué familia paramétrica describe mejor los retornos observados dentro del conjunto de distribuciones consideradas.

Metodología de cálculo

La primera etapa del script define las rutas de entrada y salida, las columnas requeridas y los parámetros generales del experimento. En particular, se exige un mínimo de 250 retornos válidos por ticker para evitar estimaciones con muestras demasiado pequeñas. Además, se eliminan retornos diarios menores a -95% o mayores a 300% , con el fin de controlar errores de datos, precios mal ajustados o registros extremos incompatibles con el análisis financiero estándar.

Para cada archivo, el script estandariza el nombre del ticker, valida que existan las columnas necesarias y, si no se encuentra la columna de dividendos, la crea con valor cero. Luego convierte las fechas a formato `datetime`, transforma precios y dividendos a valores numéricos, elimina fechas inválidas y precios nulos o no positivos, y ordena las observaciones cronológicamente. Con esta base limpia, el retorno simple total del ticker i en el día t se calcula como:

Tabla 9.15. Principales parámetros de configuración del análisis.

Parámetro	Descripción
RUTA_TICKERS_FILTRADOS	Carpeta con los CSV finales de acciones filtradas.
RUTA_SALIDA	Carpeta donde se guardan los resultados del ajuste.
Date, Close, Dividends	Columnas usadas para fecha, precio de cierre y dividendos.
TIPO_RETORNO	Tipo de retorno calculado; por defecto se usa <code>simple_total</code> .
MIN_RETORNOS_VALIDOS	Número mínimo de retornos requeridos para ajustar distribuciones.
RETORNO_MINIMO_PERMITIDO y RETORNO_MAXIMO_PERMITIDO	Umbral para remover retornos extremos asociados a errores de datos.
GENERAR_GRAFICOS_AJUSTE	Indica si se generan histogramas con densidades ajustadas por ticker.

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (9.2)$$

donde $P_{i,t}$ es el precio de cierre y $D_{i,t}$ corresponde al dividendo por acción pagado en ese día. Esta definición incorpora la rentabilidad por dividendos y, por tanto, representa mejor el retorno total del inversionista que una medida basada solo en precios. El script también permite calcular retornos logarítmicos totales,

$$r_{i,t}^{\log} = \log \left(\frac{P_{i,t} + D_{i,t}}{P_{i,t-1}} \right), \quad (9.3)$$

aunque el análisis final utiliza retornos simples totales para mantener consistencia con el resto del proyecto.

Pruebas de normalidad y distribuciones candidatas

Para evaluar normalidad se aplican tres pruebas formales: Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk. La hipótesis nula común es que los retornos del ticker provienen de una distribución normal,

$$H_0 : r_{i,t} \sim \mathcal{N}(\mu_i, \sigma_i^2). \quad (9.4)$$

Cuando el valor-p es menor a 0,05, se rechaza la normalidad al 5%. Jarque–Bera compara asimetría y curtosis respecto de los valores esperados bajo normalidad; D’Agostino–Pearson

combina transformaciones de ambos momentos de forma; y Shapiro–Wilk contrasta los cuantiles ordenados de la muestra con los cuantiles esperados bajo normalidad. En muestras muy grandes, esta última prueba se aplica sobre un máximo de 5 000 observaciones para evitar sensibilidad excesiva.

El ajuste paramétrico considera siete distribuciones candidatas, todas razonables para modelar retornos diarios porque admiten valores positivos y negativos o tienen flexibilidad suficiente para representar distintas formas empíricas.

Tabla 9.16. Distribuciones candidatas consideradas.

Distribución	Interpretación financiera
Normal	Modelo simétrico base, con colas delgadas y sin asimetría.
t-Student	Permite colas más pesadas, útil ante eventos extremos frecuentes.
Laplace	Presenta mayor concentración cerca de cero y colas más pesadas que la normal.
Logística	Distribución simétrica con colas algo más pesadas que la normal.
Skew-normal	Extiende la normal incorporando asimetría mediante un parámetro de forma.
Normal generalizada	Permite modificar concentración central y grosor de colas.
Johnson SU	Familia flexible para representar asimetría, colas pesadas y formas complejas.

Para cada ticker i y distribución candidata d , se estima un vector de parámetros $\theta_{i,d}$ por máxima verosimilitud:

$$\hat{\theta}_{i,d} = \arg \max_{\theta} \sum_{t=1}^{T_i} \log f_d(r_{i,t}; \theta), \quad (9.5)$$

donde $f_d(\cdot)$ es la densidad de la distribución candidata y T_i corresponde al número de retornos válidos del ticker. La log-verosimilitud maximizada se compara mediante AIC y BIC:

$$AIC = 2k - 2\ell, \quad (9.6)$$

$$BIC = k \ln(n) - 2\ell, \quad (9.7)$$

donde k es el número de parámetros, n el tamaño muestral y ℓ la log-verosimilitud maximizada. Ambos criterios equilibran ajuste y parsimonia: AIC tiende a favorecer modelos

más flexibles, mientras que BIC penaliza con mayor fuerza la complejidad cuando el tamaño muestral es grande.

Como medida adicional de bondad de ajuste se calcula el estadístico Kolmogorov–Smirnov aproximado:

$$D = \sup_x |F_n(x) - F_{\hat{\theta}}(x)|, \quad (9.8)$$

donde $F_n(x)$ es la distribución empírica y $F_{\hat{\theta}}(x)$ la distribución acumulada ajustada. Su valor-p se interpreta solo como referencia, ya que los parámetros se estiman con los mismos datos sobre los cuales se evalúa el ajuste.

Archivos generados

El proceso principal verifica la disponibilidad de las librerías necesarias, recorre todos los CSV disponibles, calcula retornos, descarta tickers con menos de 250 observaciones válidas, aplica pruebas de normalidad, ajusta las distribuciones candidatas y exporta resultados agregados y por ticker. Si una distribución no converge para un ticker específico, el script continúa con las restantes; si un ticker completo no puede analizarse, registra el motivo de exclusión.

Tabla 9.17. Archivos de salida generados por el script.

Archivo	Contenido
<code>ajuste_distribuciones_por_ticker.csv</code>	Resultados de todas las distribuciones ajustadas para cada ticker.
<code>mejor_distribucion_por_ticker.csv</code>	Mejor distribución por ticker según AIC y BIC.
<code>resumen_mejores_distribuciones.csv</code>	Conteo agregado de mejores distribuciones.
<code>pruebas_normalidad_por_ticker.csv</code>	Resultados de Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk.
<code>tickers_no_analizados.csv</code>	Tickers omitidos y motivo de exclusión.
<code>interpretacion_resultados.txt</code>	Guía breve para interpretar los resultados.
<code>graficos_ajuste/</code>	Histogramas con densidades paramétricas ajustadas.

Resultados obtenidos

El análisis final contiene 601 tickers y siete distribuciones candidatas por ticker, lo que produce 4 207 ajustes distribucionales. La cantidad de retornos disponibles es suficiente para realizar comparaciones estadísticas robustas: la mediana es 7 949 retornos por ticker y el promedio 8 262,83, incluso después de aplicar filtros de calidad y excluir el periodo pandémico.

Tabla 9.18. Resumen del tamaño muestral analizado.

Indicador	Valor
Tickers analizados	601
Distribuciones candidatas por ticker	7
Ajustes totales	4 207
Mínimo de retornos por ticker	2 518
Mediana de retornos por ticker	7 949
Promedio de retornos por ticker	8 262,83
Máximo de retornos por ticker	15 400

Los resultados muestran que la normal no fue seleccionada como mejor distribución para ningún ticker, ni por AIC ni por BIC. Según AIC, Johnson SU es la familia más frecuente, con 247 tickers, equivalente al 41,10% del total. Según BIC, t-Student pasa a ser la más frecuente, con 241 tickers y 40,10%. Esta diferencia es coherente con la mayor penalización de BIC sobre modelos con más parámetros: Johnson SU ofrece mayor flexibilidad para capturar asimetrías y formas complejas, mientras que t-Student representa colas pesadas con una estructura más parsimoniosa.

Tabla 9.19. Conteo de mejores distribuciones por criterio de información.

Distribución	Mejor AIC	% AIC	Mejor BIC	% BIC
Johnson SU	247	41,10%	180	29,95%
t-Student	179	29,78%	241	40,10%
Normal generalizada	174	28,95%	176	29,28%
Laplace	1	0,17%	4	0,67%
Normal	0	0,00%	0	0,00%
Logística	0	0,00%	0	0,00%
Skew-normal	0	0,00%	0	0,00%

AIC y BIC coinciden en la mejor distribución para 532 tickers, lo que representa el 88,52% del total. Las discrepancias se concentran principalmente en casos donde AIC selecciona Johnson SU y BIC selecciona t-Student. En términos prácticos, si se busca el mejor ajuste empírico por ticker, Johnson SU resulta atractiva; si se busca un modelo más simple y estable para simulación o escenarios, t-Student puede ser preferible.

Las tres pruebas rechazan normalidad en todos los tickers analizados, lo que constituye evidencia contundente contra el supuesto de retornos diarios normales. Desde el punto de vista financiero, este resultado es relevante porque la normalidad tiende a subestimar la probabilidad de pérdidas extremas cuando la distribución real presenta colas pesadas. Además,

Tabla 9.20. Resultados agregados de pruebas de normalidad.

Prueba	Rechazos al 5%	Porcentaje
Jarque–Bera	601	100,00%
D’ Agostino–Pearson	601	100,00%
Shapiro–Wilk	601	100,00%
Las tres pruebas simultáneamente	601	100,00%

usando la mejor distribución según AIC, solo 220 de 601 tickers tienen un valor-p aproximado de Kolmogorov–Smirnov mayor a 0,05, equivalente al 36,61%; según BIC, esto ocurre en 219 tickers, equivalente al 36,44%. Por tanto, aunque Johnson SU, t-Student y normal generalizada mejoran el ajuste relativo frente a la normal, una distribución paramétrica estática no captura completamente todos los rasgos empíricos de los retornos.

Discusión e implicancias para el modelo

Los resultados son consistentes con patrones frecuentes en series financieras: presencia de colas pesadas, asimetrías relevantes, baja validez empírica de la normalidad y tensión entre ajuste flexible y parsimonia. Para el sistema recomendador FinPUC, esto tiene implicancias directas. Si el modelo utiliza solo media y varianza, puede perder información importante sobre riesgo extremo; una cartera evaluada únicamente mediante volatilidad podría parecer aceptable aun cuando tenga exposición significativa a pérdidas de cola.

En modelos media-varianza, la normalidad facilita la interpretación del riesgo, pero no es estrictamente necesaria para calcular medias, varianzas y covarianzas. Sin embargo, cuando se desea proyectar escenarios desfavorables, calcular VaR o CVaR, o simular trayectorias futuras, la elección distribucional se vuelve más relevante. A partir de los resultados, t-Student aparece como una alternativa adecuada para simulaciones base por su parsimonia y capacidad de capturar colas pesadas; Johnson SU resulta útil para análisis por ticker cuando se requiere mayor flexibilidad; y los métodos empíricos, como *bootstrap* histórico, simulaciones por bloques o modelos de volatilidad condicional, pueden complementar el análisis al capturar dependencia temporal y cambios de régimen.

Limitaciones

El procedimiento presenta algunas limitaciones metodológicas. Los parámetros se estiman y evalúan sobre la misma muestra, por lo que ciertas pruebas de ajuste deben interpretarse como aproximadas. Además, el test Kolmogorov–Smirnov no corrige formalmente

por la estimación previa de parámetros. El análisis considera distribuciones incondicionales, aunque los retornos financieros suelen exhibir dependencia temporal y agrupamiento de volatilidad. La exclusión de 2020–2022 responde a una decisión metodológica del proyecto, pero también elimina un periodo con eventos extremos relevantes. Finalmente, la comparación se limita a siete familias candidatas, por lo que podrían existir otras distribuciones con mejor desempeño.

Conclusiones del anexo

El script implementa una metodología completa y replicable para evaluar distribuciones candidatas por ticker, desde la lectura de datos hasta la exportación e interpretación de resultados. La normalidad es rechazada de manera sistemática: Jarque–Bera, D’Agostino–Pearson y Shapiro–Wilk rechazan la hipótesis normal en el 100% de los 601 tickers. Además, la distribución normal no fue seleccionada como mejor ajuste para ningún activo, ni por AIC ni por BIC.

La evidencia indica que los retornos del universo filtrado presentan colas pesadas y desviaciones relevantes respecto de la normalidad. Johnson SU domina bajo AIC por su flexibilidad para capturar asimetría y formas complejas, mientras que t-Student domina bajo BIC por ofrecer un buen balance entre ajuste y parsimonia. Para FinPUC, el resultado más importante es que la estimación de riesgo no debería depender exclusivamente del supuesto normal. En escenarios desfavorables, estrés financiero o métricas como VaR y CVaR, distribuciones con colas pesadas o métodos empíricos ofrecen aproximaciones más realistas.

ANEXO N°4: ANÁLISIS DE METODOLOGÍAS Y CÓDIGO RELACIONADO

Este anexo consolida la documentación metodológica y de código de los tres notebooks principales de la primera iteración del proyecto: Markowitz vs Benchmark, Black-Litterman y Simulación Monte Carlo. La reorganización mantiene la información sustantiva de los anexos metodológicos originales, pero la presenta en un solo anexo y con la misma estructura para cada técnica: resumen, fundamentos metodológicos, supuestos del experimento, estructura del notebook, KPIs utilizados, resultados del experimento pandemia, rebalanceo, splits aleatorios, evaluación robusta e implicancias y conclusiones.

Nota de contexto. El benchmark equiponderado top-20 que aparece en este anexo corresponde a una referencia metodológica de la primera iteración y se conserva solo como documentación histórica del análisis realizado en su momento. En la versión actual del modelo, el caso base es **Markowitz** y el equiponderado ya no se considera una alternativa de recomendación ni una línea base oficial.

Markowitz vs Benchmark

Resumen

Este apartado resume el funcionamiento, los fundamentos y los principales resultados del notebook `markowitz_vs_benchmark_rebalanceo_pandemia.ipynb`. El objetivo del experimento fue comparar portafolios construidos mediante optimización media-varianza de Markowitz contra benchmarks simples y variantes teóricas, evaluando no solo el retorno obtenido, sino también la robustez del modelo ante cambios en tres decisiones metodológicas: horizonte de calibración y evaluación futura, inclusión o exclusión del periodo de pandemia 2020–2022 en los datos de entrenamiento, y uso de rebalanceo semestral. Además, se incorpora como referencia un benchmark top-20 equiponderado por capitalización bursátil.

El caso principal utiliza 601 activos, 7 años históricos de calibración, 2 años futuros fuera de muestra, tasa libre de riesgo anual de 2%, capital inicial de 1 000, cota máxima de peso de 20% para la frontera eficiente y rebalanceo cada 126 días hábiles, equivalente aproximadamente a medio año bursátil. La evaluación es fuera de muestra: los pesos se estiman con datos históricos y luego se aplican al periodo futuro. Esto permite distinguir

entre desempeño teórico dentro de la muestra y desempeño real en datos no usados para optimizar.

Fundamentos metodológicos

El modelo de Markowitz representa cada portafolio mediante un vector de pesos w , un vector de retornos esperados μ y una matriz de covarianzas Σ . En el notebook, μ se estima como promedio diario histórico y Σ como covarianza diaria de retornos. Para cada perfil de riesgo se resuelve el problema:

$$\max_w \mu^\top w - \frac{1}{2} \gamma w^\top \Sigma w, \quad (9.9)$$

sujeto a restricciones de presupuesto, no negatividad, peso máximo y, cuando corresponde, una cota de volatilidad:

$$\sum_i w_i = 1, \quad 0 \leq w_i \leq w_{\max}, \quad w^\top \Sigma w \leq \sigma_{\max}^2. \quad (9.10)$$

La restricción $w_i \geq 0$ impide ventas cortas, la suma igual a uno invierte todo el capital y el límite por activo evita concentración extrema. El parámetro γ controla la aversión al riesgo: valores altos penalizan más la varianza y producen carteras conservadoras, mientras que valores bajos permiten mayor exposición a retorno esperado.

La frontera eficiente se obtiene resolviendo, para distintos retornos objetivo, el portafolio de mínima varianza que alcanza al menos dicho retorno:

$$\min_w w^\top \Sigma w. \quad (9.11)$$

El portafolio denominado *Ideal de mercado* se selecciona como el punto de la frontera eficiente con mayor ratio de Sharpe,

$$Sharpe = \frac{R_p - R_f}{\sigma_p}. \quad (9.12)$$

Esta es una aproximación discreta al portafolio de tangencia, porque el código no maximiza directamente el cociente de Sharpe, sino que elige el mejor punto entre 30 puntos calculados sobre la frontera.

El benchmark base selecciona los 20 primeros activos del universo ordenado por `marketCap` y asigna pesos iguales. Esta regla no estima μ ni Σ , por lo que es menos sensible al error de parámetros. Además, se define `b_teorico`, que toma la volatilidad histórica del benchmark y construye un portafolio Markowitz que maximiza retorno esperado sujeto a esa misma volatilidad. Su objetivo es responder qué portafolio teórico podría obtenerse si se acepta el mismo nivel de riesgo que el benchmark.

Para estabilizar la matriz de covarianzas, el notebook aplica *shrinkage* de 20%, mezclando 80% de la covarianza completa con 20% de su diagonal:

$$\Sigma_{\text{shrink}} = (1 - \lambda)\Sigma + \lambda \text{diag}(\Sigma). \quad (9.13)$$

Luego se utiliza `nearest_psd` para forzar que la matriz sea semidefinida positiva, requisito técnico para resolver problemas cuadráticos convexos con CVXPY. El rebalanceo divide el periodo futuro en segmentos de 126 días hábiles; al inicio de cada segmento se reestima el portafolio usando la historia inicial y los retornos futuros ya observados hasta ese momento. Así, el modelo incorpora información nueva sin usar datos futuros no disponibles al momento de la decisión.

Supuestos del experimento

El experimento supone que los precios de cierre y dividendos de los CSV representan adecuadamente la información disponible para cada activo. Los retornos diarios se calculan como retornos totales, incorporando dividendos, por lo que se considera que estos forman parte del rendimiento económico del inversionista. Al construir la matriz de retornos se utiliza `join="inner"`, conservando solo fechas comunes a todos los activos seleccionados; esto facilita la estimación matricial, aunque asume que eliminar fechas no comunes no introduce sesgos relevantes.

Desde el punto de vista de mercado, las carteras son *long-only*, invierten el 100% del capital disponible, no usan apalancamiento y permiten divisibilidad perfecta de activos. El modelo omite costos de transacción, impuestos, *spreads* bid-ask, restricciones de liquidez, impacto de mercado y *slippage*. Por ello, los resultados deben interpretarse como una aproximación teórica del desempeño y no como una simulación completa de ejecución real. La tasa libre de riesgo se mantiene constante en 2% anual.

En términos estadísticos, se asume que los retornos históricos contienen información útil sobre retornos y riesgos futuros, aunque los propios resultados muestran que esta estabilidad

es imperfecta. La anualización usa 252 días hábiles; el retorno se anualiza por capitalización compuesta y la volatilidad mediante raíz del tiempo. Si una cota de volatilidad vuelve infactible un perfil, el código relaja esa cota manteniendo las restricciones restantes. Finalmente, en el experimento pandemia el periodo futuro fuera de muestra se mantiene fijo entre escenarios, por lo que las diferencias observadas se atribuyen a la información usada para calibrar y no a cambios en el mercado futuro evaluado.

Estructura del notebook

El notebook se organiza en bloques secuenciales. Primero define la documentación inicial, requisitos, estructura de carpetas y uso de archivos cacheados mediante `FORCE_RECOMPUTE`. Luego importa librerías, fija rutas, define `TRADING_DAYS_PER_YEAR = 252`, `REBALANCE_DAYS = 126`, delimita el periodo pandémico y crea los escenarios `sin_pandemia` y `con_pandemia`. Posteriormente carga el script base `markowitz_cvxpy_benchmark_teorico.py` como módulo local, reutilizando funciones de lectura, selección de universo, estimación de parámetros, optimización, frontera eficiente, benchmark y evaluación.

El experimento principal fija `DEFAULT_BENCHMARK_SIZE = 20`, `DEFAULT_MARKET_UNIVERSE_SIZE = 601`, `DEFAULT_FRONTIER_POINTS = 30`, `DEFAULT_FRONTIER_MAX_WEIGHT = 0.20`, `DEFAULT_RISK_FREE_RATE = 0.02`, `DEFAULT_INITIAL_CAPITAL = 1000.0`, `DEFAULT_SHRINKAGE = 0.20`, `HISTORICAL_YEARS = 7` y `FUTURE_YEARS = 2`. La configuración `h7_f2` se usa como caso central porque la validación robusta posterior la identifica como el horizonte con mejor desempeño agregado.

Las funciones auxiliares del notebook permiten cargar datasets por escenario, calcular retornos totales, generar ventanas de rebalanceo, definir la vista de entrenamiento disponible en cada segmento, resolver portafolios por instante y evaluar el periodo futuro completo. La clase `ScenarioDataset` agrupa la información de cada escenario, mientras que `evaluate_rebalanced` coordina el experimento: crea el split histórico/futuro, divide el futuro en segmentos, reestima pesos en cada rebalanceo, calcula retornos realizados y guarda métricas globales, por segmento y por punto de frontera.

La validación inicial verifica rutas, carga de datos y funcionamiento de ventanas. En una prueba reducida se obtienen 2 717 observaciones para el escenario sin pandemia y 3 473 para el escenario con pandemia, diferencia esperable porque la segunda base conserva 2020–2022. En el caso principal se cargan o generan cuatro CSV: `rebalance_summary_h7_f2_601activos.csv`,

rebalance_segments_h7_f2_601activos.csv,
segment_summary_h7_f2_601activos.csv y
frontier_segments_h7_f2_601activos.csv.

Tabla 9.21. Dimensión de resultados cacheados del experimento principal.

Escenario	Portafolios	Filas segmento	Puntos frontera
Sin pandemia	9	36	119
Con pandemia	9	36	119

Los 9 portafolios corresponden a cinco perfiles de riesgo, Benchmark, b_{teorico}, Mínima varianza e Ideal de mercado. Las 36 filas por escenario equivalen a 9 portafolios evaluados en 4 segmentos semestrales. Al exportar resultados, el notebook genera 18 filas de resumen global, 72 filas de segmentos rebalanceados, 72 filas de resumen por segmento y 238 puntos de frontera.

KPIs utilizados

El desempeño se evalúa mediante indicadores rebalanceados fuera de muestra. El retorno total rebalanceado mide la ganancia acumulada durante todo el periodo futuro:

$$R_{\text{total}} = \prod_t (1 + r_t) - 1. \quad (9.14)$$

El retorno anualizado para los dos años futuros se calcula como:

$$R_{\text{anual}} = (1 + R_{\text{total}})^{1/2} - 1. \quad (9.15)$$

La volatilidad diaria corresponde a la desviación estándar de los retornos concatenados de todos los segmentos y se anualiza mediante:

$$\sigma_{\text{anual}} = \sigma_{\text{diaria}} \sqrt{252}. \quad (9.16)$$

El Sharpe rebalanceado mide retorno excedente por unidad de riesgo:

$$Sharpe = \frac{R_{\text{anual}} - 0.02}{\sigma_{\text{anual}}}. \quad (9.17)$$

También se calculan máximo *drawdown*, CVaR diario al 95%, número de activos con peso positivo, mayor peso individual, cinco principales posiciones, riqueza final futura desde capital inicial 1 000, Sharpe teórico y Sharpe real futuro. Esta última comparación es central para diagnosticar *overfitting*, ya que contrasta la eficiencia esperada durante el entrenamiento con la eficiencia realizada fuera de muestra.

Resultados del experimento pandemia

La comparación entre escenarios calcula retorno total, retorno anual, volatilidad anual, Sharpe y diferencias `con_pandemia - sin_pandemia`. El resultado central se resume en la Tabla 9.22.

Tabla 9.22. Comparación de portafolios con y sin pandemia en entrenamiento.

Portafolio	Ret. sin pand.	Sharpe sin pand.	Ret. con pand.	Sharpe con pand.	Delta ret.	Delta Sharpe
Muy conservador	58,0%	2,208	54,5%	2,023	−3,4%	−0,184
Conservador	67,8%	2,425	55,5%	1,972	−12,3%	−0,453
Neutro	82,9%	2,413	60,5%	1,756	−22,5%	−0,657
Arriesgado	91,6%	1,733	58,4%	1,167	−33,2%	−0,566
Muy arriesgado	102,7%	1,412	44,0%	0,549	−58,7%	−0,863
b_teorico	104,5%	1,515	56,7%	0,966	−47,8%	−0,548
Mínima varianza	56,6%	2,110	54,6%	2,016	−2,0%	−0,094
Ideal de mercado	76,5%	2,507	59,5%	1,399	−16,9%	−1,108

Sin pandemia, el mejor portafolio es Ideal de mercado, con Sharpe 2,507 y retorno total de 76,5%. Con pandemia, el Sharpe de los portafolios optimizados se deteriora: incluir el periodo 2020–2022 afecta casi todos los portafolios, especialmente aquellos más agresivos o dependientes de estimaciones de retorno esperado. Los portafolios de menor varianza (Muy conservador, Mínima varianza) son los más robustos a la inclusión de la pandemia, al depender menos de la estimación de μ .

Tabla 9.23. Mayores caídas de Sharpe al incluir pandemia en entrenamiento.

Portafolio	Delta Sharpe
Ideal de mercado	−1,108
Muy arriesgado	−0,863
Neutro	−0,657
Arriesgado	−0,566
<code>b_teorico</code>	−0,548

La interpretación es que los datos de pandemia alteran las estimaciones de retornos y covarianzas. El efecto es más fuerte en carteras agresivas o de tangencia, que dependen de diferencias pequeñas en μ . En cambio, Mínima varianza es la cartera Markowitz más estable, con una caída de Sharpe de solo 2,110 a 2,016, porque depende principalmente de covarianzas y no de predicciones de retorno individual.

Rebalanceo

El rebalanceo semestral mejora el Sharpe en Conservador, Ideal de mercado, Mínima varianza y Neutro, pero deteriora Muy arriesgado, Arriesgado, `b_teorico` y Benchmark frente a una versión base sin rebalanceo. Por lo tanto, el rebalanceo funciona como un mecanismo de actualización y control, pero no garantiza mejor desempeño. Puede reducir deriva de pesos e incorporar información reciente, aunque también puede vender activos ganadores demasiado pronto o amplificar ruido en estimaciones nuevas.

Splits aleatorios

El experimento de splits aleatorios no recalcula Markowitz, sino que lee salidas preexistentes de `outputs.markowitz_cvxpy_splits_aleatorios`. El diseño considera una ventana base de 9 años, 28 combinaciones train/test con suma menor o igual a 9, 70 ventanas aleatorias con semilla 42, 560 evaluaciones de portafolio, 601 activos y 1 392 puntos de frontera.

Tabla 9.24. Resumen del experimento de splits aleatorios.

Indicador	Resultado
Combinaciones train/test	28
Ventanas aleatorias	70
Evaluaciones de portafolios	560
Activos	601
Puntos de frontera	1 392

El mejor split promedio global es $h5_f2$, con Sharpe futuro promedio de 2,34. Esta sensibilidad muestra que las conclusiones no deben depender de un único split.

Tabla 9.25. Promedio y variabilidad del Sharpe en splits aleatorios.

Portafolio	Sharpe medio	Desv. est. Sharpe
Mínima varianza	1,940	0,250
Muy conservador	1,885	0,288
Conservador	1,799	0,334
Ideal de mercado	1,799	0,421
Neutro	1,781	0,413
Arriesgado	1,644	0,449
Muy arriesgado	1,625	0,458

Entre los portafolios Markowitz, Mínima varianza aparece como la versión más robusta, ya que combina buen Sharpe con baja variabilidad.

Evaluación robusta

La validación robusta con ventanas móviles evalúa 6 horizontes y 18 ventanas fuera de muestra; sus resultados respaldan $h7_f2$ como caso principal.

Tabla 9.26. Sharpe futuro medio en validación robusta por ventanas móviles.

Horizonte	Sharpe futuro medio
h7_f2	2,32
h6_f3	2,07
h5_f4	1,88
h4_f5	1,66
h3_f6	1,60
h2_f7	1,35

El resultado indica que 7 años de historia y 2 años de futuro equilibran estabilidad de parámetros y relevancia temporal. Además, en los splits aleatorios el Ideal de mercado presenta Sharpe teórico medio de 5,01 y Sharpe real futuro de 1,80, una brecha que evidencia *overfitting* o error de estimación: la cartera parece excepcional en entrenamiento, pero no replica esa eficiencia fuera de muestra.

Implicancias y conclusiones

La primera implicancia es que Markowitz es altamente sensible a la estimación de retornos esperados. La matriz de covarianzas importa, pero μ suele ser más ruidoso; por eso los perfiles agresivos, que explotan diferencias pequeñas entre activos, son los que más se deterioran al incluir pandemia. En segundo lugar, cualquier superioridad de Markowitz debe justificarse con evidencia fuera de muestra y no solo en entrenamiento. En tercer lugar, Mínima varianza cumple un rol defensivo relevante, porque no maximiza retorno esperado y depende menos de predicciones individuales.

El rebalanceo semestral debe interpretarse como un *trade-off*. Actualizar pesos permite incorporar información reciente, pero puede amplificar ruido si las nuevas estimaciones son inestables. Asimismo, la inclusión de pandemia no significa que el mercado futuro evaluado sea peor, porque el periodo fuera de muestra se mantiene fijo en ambos escenarios. Lo que cambia es el conjunto de datos usado para entrenar, por lo que el resultado mide cómo los datos de estrés modifican la percepción estimada de riesgo-retorno.

En síntesis, el notebook implementa una comparación metodológicamente completa entre las variantes de Markowitz, incorporando escenarios de pandemia, rebalanceo y validación por múltiples splits. La principal conclusión es que no basta con reportar el portafolio de mayor Sharpe en un único periodo: se debe evaluar robustez temporal y separar desempeño

teórico de desempeño realizado. El caso $h7_f2$ queda justificado por la validación robusta, mientras que $h5_f2$ y $h6_f2$ deben reportarse como sensibilidad favorable. Para la entrega, conviene presentar Mínima varianza como línea base defensiva, usar $h7_f2$ como escenario principal y evitar afirmar superioridad de Markowitz sin evidencia fuera de muestra.

Black-Litterman

Resumen

Este apartado resume la implementación del notebook `black_litterman.ipynb`, que extiende el experimento de optimización de portafolios desarrollado previamente con Markowitz. Su objetivo no es reemplazar la lógica anterior, sino construir una versión Black-Litterman comparable, usando la misma base de datos, ventanas de entrenamiento y prueba, perfiles de riesgo e indicadores de evaluación. De esta forma, las diferencias observadas se atribuyen principalmente al cambio en la estimación de retornos esperados: desde promedios históricos puros hacia retornos posteriores que combinan equilibrio de mercado y *views* del inversionista.

El universo central corresponde a 601 activos del mercado F5, seleccionados desde meta-data y series históricas de retornos totales. Se comparan dos escenarios: una base sin el periodo pandémico y otra que incorpora las observaciones de 2020–2022. El experimento principal utiliza 7 años de calibración y 2 años de evaluación fuera de muestra, configuración denotada `h7_f2`. Durante el periodo futuro, el portafolio se recalibra semestralmente cada 126 días bursátiles; en cada rebalanceo se estima la matriz de covarianzas, se construye el prior Black-Litterman, se aplica una *view* y se optimizan portafolios con CVXPY.

Tabla 9.27. Escenarios evaluados en Black-Litterman.

Escenario	Descripción	Propósito
<code>sin_pandemia</code>	Base filtrada sin 2020–2022.	Evaluar desempeño en una muestra menos dominada por shocks extremos.
<code>con_pandemia</code>	Base que incorpora 2020–2022.	Medir sensibilidad ante un historial con estrés, recuperación y alta volatilidad.

Fundamentos metodológicos

El modelo Black-Litterman responde a una debilidad central de Markowitz: los retornos esperados son difíciles de estimar y pequeños cambios en ellos pueden generar variaciones importantes en los pesos óptimos. Para reducir esa sensibilidad, Black-Litterman combina dos fuentes de información: un prior de equilibrio de mercado, que representa retornos

implícitos en una cartera de mercado, y *views* del inversionista, que expresan opiniones absolutas o relativas sobre activos, grupos o factores.

La implementación calcula el prior como:

$$\pi = \delta \Sigma w_{\text{market}}, \quad (9.18)$$

donde Σ es la matriz de covarianzas diaria estimada, w_{market} son pesos por capitalización bursátil y δ es la aversión al riesgo implícita:

$$\delta = \frac{R_{\text{mercado}} - R_f}{\sigma_{\text{mercado}}^2}. \quad (9.19)$$

Las *views* se representan mediante:

$$P\mu = Q + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \Omega), \quad (9.20)$$

donde P define la combinación de activos observada, Q el retorno esperado de esa combinación y Ω la incertidumbre asociada. La actualización posterior utilizada es:

$$\mu_{\text{BL}} = \pi + \tau \Sigma P^\top (P \tau \Sigma P^\top + \Omega)^{-1} (Q - P\pi). \quad (9.21)$$

El término $Q - P\pi$ representa la sorpresa de la *view* respecto del prior. Si la opinión ya está incorporada en el equilibrio, el ajuste es pequeño; si contradice al prior y tiene baja incertidumbre, el posterior se desplaza con mayor fuerza hacia la *view*.

Construcción y peso de las *views*. La *view* de momentum se basa en persistencia de retornos. El código calcula el rendimiento acumulado de cada activo durante los últimos 252 días, selecciona los 20 con mayor momentum y los 20 con peor momentum, y construye una opinión relativa:

$$R(\text{top 20 momentum}) - R(\text{bottom 20 momentum}) = Q. \quad (9.22)$$

La matriz P asigna peso positivo igualitario a los ganadores y negativo igualitario a los rezagados. Esta formulación es adecuada para Black-Litterman porque no exige estimar el retorno absoluto de cada activo, sino solo expresar que un grupo debería superar a otro.

La *view* de desempleo se basa en sensibilidad cíclica sectorial. Si el desempleo asumido está por debajo de su nivel neutral, la economía se interpreta como más fuerte, por lo que sectores cíclicos deberían superar a sectores defensivos. Con los parámetros actuales:

$$\text{signal} = 0,05 - 0,04 = 0,01, \quad Q = \frac{0,01}{252} = 0,00003968. \quad (9.23)$$

En consecuencia, P queda long sectores cíclicos y short sectores defensivos. Esta *view* es conceptualmente razonable, pero debe leerse como un análisis de escenario, ya que el desempleo usado es fijo y no una observación actualizada en cada rebalanceo.

El peso de una *view* no se define como porcentaje de portafolio, sino mediante su precisión estadística relativa frente al prior. En el código:

$$\Omega = \frac{P\tau\Sigma P^\top}{\text{confidence}}. \quad (9.24)$$

Si la confianza aumenta, Ω disminuye y el posterior se mueve con mayor fuerza hacia Q . En esta implementación, momentum tiene confianza 0,50 y desempleo 0,35; por tanto, a igualdad de varianza de la *view*, momentum recibe mayor peso estadístico. Sin embargo, el impacto final también depende de Q , de P , de τ , de Σ y de la distancia entre Q y $P\pi$.

Supuestos del experimento

El experimento utiliza retornos totales diarios, 252 días bursátiles por año, covarianza con *shrinkage* de 20%, corrección `nearest_psd`, prior de equilibrio basado en capitalización, tasa libre de riesgo fija de 2% anual y $\tau = 0,05$. Las carteras finales son *long-only*, invierten todo el capital, aplican cotas de concentración y se rebalancean semestralmente. Las *views* pueden ser long-short, pero los portafolios finales no permiten ventas cortas. El benchmark top-20 equiponderado no depende de Black-Litterman ni de las *views*.

Tabla 9.28. Supuestos principales del experimento Black-Litterman.

Supuesto	Implementación	Implicancia
Retornos diarios	Series de retornos totales diarios	Se asume frecuencia diaria y 252 días bursátiles.
Covarianza estable	<code>estimate_parameters</code> con 20% <i>shrinkage</i>	Mejora estabilidad, pero no modela cambios de régimen.
Matriz PSD	<code>nearest_psd</code>	Evita problemas numéricos en optimización cuadrática.
Prior de equilibrio	$\pi = \delta \Sigma w_{\text{market}}$	Supone que capitalización contiene información agregada.
Tasa libre fija <code>tau</code>	2% anual 0,05	Simplifica Sharpe y prior. Incertidumbre del prior no calibrada empíricamente.
<i>Long-only</i>	$w \geq 0$	Las carteras finales no hacen ventas cortas.
Rebalanceo	126 días	Actualiza modelo, pero no incorpora costos de transacción.
Momentum persistente	Ganadores recientes superan perdedores	Puede ser sensible a reversals.
Desempleo fijo	4% vs 5% neutral	Escenario macro, no serie observada dinámica.

Estructura del notebook

El notebook importa funciones del módulo `markowitz_cvxpy_benchmark_teorico.py`, reutilizando la carga de datos, estimación de parámetros, perfiles de riesgo, restricciones, KPIs y optimizadores de Markowitz. Esta decisión permite que la comparación entre Markowitz y Black-Litterman sea metodológicamente consistente.

Tabla 9.29. Parámetros globales del experimento Black-Litterman.

Parámetro	Valor	Función
MARKET_SIZE	601	Número de activos del universo de mercado.
BENCHMARK_SIZE	20	Número de activos del benchmark equiponderado.
HISTORICAL_YEARS	7	Años de entrenamiento del experimento central.
FUTURE_YEARS	2	Años de evaluación fuera de muestra.
REBALANCE_DAYS	126	Frecuencia semestral de rebalanceo.
DEFAULT_MAX_WEIGHT	20%	Cota máxima general para portafolios especiales.
DEFAULT_RISK_FREE_RATE	2% anual	Tasa usada en Sharpe y prior.
DEFAULT_SHRINKAGE	20%	Regularización de la matriz de covarianzas.
DEFAULT_TAU	0,05	Incertidumbre del prior Black-Litterman.

Tabla 9.30. Parámetros de las *views*.

<i>View</i>	Parámetro	Valor	Interpretación
Momentum	MOMENTUM_LOOKBACK	252 días	Ventana reciente para medir momentum.
Momentum	MOMENTUM_TOP_BOTTOM	20	Activos long y short de la <i>view</i> relativa.
Momentum	MOMENTUM_CONFIDENCE	0,50	Confianza asignada a la <i>view</i> .
Desempleo	UNEMPLOYMENT_RATE_ASSUMED	4%	Desempleo asumido.
Desempleo	UNEMPLOYMENT_NEUTRAL	5%	Nivel neutral de desempleo.
Desempleo	MACRO_UNEMPLOYMENT_BETA	1,0	Sensibilidad del diferencial macro.
Desempleo	UNEMPLOYMENT_CONFIDENCE	0,35	Confianza asignada a la <i>view</i> macro.

La clase `ScenarioDataset` agrupa la llave del escenario, etiqueta legible, matriz de retornos, metadata y tickers cargados. La función `load_scenario_dataset` lee la metadata, selecciona activos de mercado y concatena retornos con intersección temporal mediante `join="inner"`, garantizando una matriz rectangular para optimización. La función `market_cap_weights` construye pesos de mercado con capitalización bursátil y cae a un portafolio equiponderado si las capitalizaciones son inválidas.

El pipeline central estima parámetros con *shrinkage*, calcula el prior de mercado, construye la *view*, aplica Black-Litterman y resuelve portafolios para cinco perfiles de riesgo, `b_teorico`, Mínima varianza, Benchmark e Ideal de mercado. Cuando se ejecutan validaciones más costosas, se usa una versión reducida que resuelve solo Neutro, Mínima varianza y Benchmark. El *smoke test* confirma que μ_{BL} y Σ_{BL} no contienen valores inválidos, que los pesos suman 1 y que no aparecen posiciones negativas relevantes.

Tabla 9.31. Dimensión de salidas del experimento Black-Litterman.

Objeto	Filas
Resultados centrales rebalanceados	36
Segmentos centrales	144
<i>Views</i> registradas	16
Ventanas aleatorias procesadas	70
Ventanas robustas procesadas	18
Filas de validación aleatoria	420
Filas de validación robusta	108

KPIs utilizados

Los KPIs utilizados son retorno total rebalanceado, retorno anual rebalanceado, volatilidad diaria y anual, Sharpe rebalanceado, máximo *drawdown*, CVaR diario al 95%, número de segmentos, activos con peso positivo y principales posiciones. El indicador principal para ordenar resultados es el Sharpe rebalanceado, porque resume retorno y riesgo fuera de muestra tras concatenar todos los rebalanceos.

Resultados del experimento pandemia

Los mejores portafolios Black-Litterman del experimento central se muestran en la Tabla 9.32. El mejor resultado global corresponde a la *view* de desempleo sin pandemia en el portafolio

Neutro, con Sharpe 2,44. Momentum también funciona bien sin pandemia, aunque pierde fuerza relativa cuando se incluye el periodo pandémico.

Tabla 9.32. Mejores portafolios Black-Litterman del experimento central.

Escenario	View	Portafolio líder	Ret. total	Vol. anual	Max drawdown	Sharpe
Sin pandemia	Desempleo	Neutro	63,1%	10,5%	−10,4%	2,44
Sin pandemia	Momentum	Muy conservador	64,0%	10,9%	−10,1%	2,38
Con pandemia	Desempleo	Arriesgado	71,9%	12,4%	−13,3%	2,36
Con pandemia	Momentum	Conservador	56,4%	11,2%	−10,3%	2,06

Tabla 9.33. Comparación final entre Markowitz y Black-Litterman.

Escenario	Modelo	View	Portafolio	Ret. total	Vol. anual	Drawdown	CVaR 95%	Sharpe
Con pandemia	Markowitz	Histórico	Muy conservador	54,5%	11,0%	−10,2%	1,50%	2,02
Con pandemia	Black-Litterman	Desempleo	Arriesgado	71,9%	12,4%	−13,3%	1,71%	2,36
Con pandemia	Black-Litterman	Momentum	Conservador	56,4%	11,2%	−10,3%	1,47%	2,06
Sin pandemia	Markowitz	Histórico	Ideal de mercado	76,5%	12,3%	−12,6%	1,67%	2,51
Sin pandemia	Black-Litterman	Desempleo	Neutro	63,1%	10,5%	−10,4%	1,41%	2,44
Sin pandemia	Black-Litterman	Momentum	Muy conservador	64,0%	10,9%	−10,1%	1,45%	2,38

La lectura principal es que Black-Litterman mejora claramente a Markowitz en el escenario con pandemia, especialmente con la *view* de desempleo. En el escenario sin pandemia, Markowitz alcanza el mayor Sharpe final con el portafolio Ideal de mercado, aunque Black-Litterman obtiene resultados cercanos con menor volatilidad y *drawdowns* controlados.

Tabla 9.34. Mayor mejora de Black-Litterman frente a Markowitz.

Escenario	View	Portafolio	Sharpe BL	Sharpe Markowitz	Delta Sharpe
Con pandemia	Desempleo	Arriesgado	2,36	1,17	+1,19

También destacan las mejoras de desempleo/Muy arriesgado con delta Sharpe +0,87, desempleo/b_teorico con +0,64 y momentum/Muy arriesgado con +0,59. Esto sugiere que Black-Litterman aporta mayor valor cuando el historial contiene episodios extremos, ya que el prior de equilibrio y las *views* reducen la dependencia de medias históricas inestables.

Al comparar el mismo portafolio y *view* entre bases con y sin pandemia, varios deltas de Sharpe son negativos. Momentum/Muy conservador cae $-0,37$, desempleo/Neutro cae $-0,31$, desempleo/Muy conservador cae $-0,30$ y desempleo/Conservador cae $-0,29$. Esto indica que incluir pandemia tiende a deteriorar la estabilidad relativa de varias configuraciones, pero también muestra que el escenario con pandemia es una prueba más exigente donde ciertas *views*, especialmente desempleo, siguen mejorando a Markowitz.

Rebalanceo

El rebalanceo Black-Litterman mantiene la frecuencia semestral de 126 días bursátiles. En cada fecha se reestiman covarianzas, prior de equilibrio, *views*, retornos posteriores y pesos finales. Esta decisión permite que la señal incorpore información disponible en cada segmento, pero mantiene la comparabilidad con Markowitz porque usa la misma ventana futura, las mismas restricciones y los mismos KPIs. Como en Markowitz, el rebalanceo no incorpora costos de transacción, por lo que sus resultados deben interpretarse como desempeño teórico fuera de muestra.

Splits aleatorios

En los 70 splits aleatorios, los mejores resultados para el portafolio Neutro favorecen horizontes con 6 años de entrenamiento y 2 de prueba. Esto es consistente con la necesidad de contar con suficiente historia para estabilizar covarianzas y prior, sin usar una ventana tan larga que diluya cambios estructurales.

Tabla 9.35. Validación con 70 splits aleatorios para el portafolio Neutro.

<i>View</i>	Horizonte	Sharpe prom.	Ret. total prom.	Vol. anual prom.	Ventanas
Desempleo	h6_f2	2,48	61,5%	10,4%	3
Momentum	h6_f2	2,31	68,6%	13,1%	3

Evaluación robusta

Tabla 9.36. Validación robusta con 18 ventanas para el portafolio Neutro.

<i>View</i>	Mejor horizonte	Sharpe prom.	Ret. total prom.	Vol. anual prom.	Drawdown prom.
Desempleo	h7_f2	2,35	59,2%	10,6%	−9,7%
Momentum	h7_f2	2,23	68,5%	13,6%	−12,8%

En validación robusta, desempleo domina en Sharpe para el portafolio Neutro porque logra menor volatilidad y menor *drawdown*. Momentum obtiene mayor retorno total promedio, pero a costa de mayor riesgo.

Implicancias y conclusiones

Los resultados muestran que Black-Litterman cumple su objetivo principal: suavizar la dependencia de medias históricas puras. Esto se observa con mayor claridad en el escenario con pandemia, donde Markowitz queda más castigado y Black-Litterman mejora el Sharpe en varios portafolios. El tipo de *view* es determinante. Desempleo genera portafolios más defensivos y mejor Sharpe en configuraciones centrales; aunque conceptualmente es una *view* cíclica, su menor Q y menor confianza producen ajustes más moderados. Momentum, en cambio, entrega una señal más intensa y puede capturar retornos altos, pero también expone a reversals y mayor volatilidad.

Los portafolios optimizados mejoran la relación retorno-riesgo respecto de las estimaciones históricas puras, aunque a costa de mayor dependencia de μ en los perfiles agresivos. Las diferencias entre *sin_pandemia* y *con_pandemia* deben entenderse como una prueba de robustez: incluir shocks históricos cambia la frontera eficiente y las estimaciones de riesgo, no necesariamente el mercado futuro evaluado.

Para mejorar la implementación, la *view* de desempleo debería pasar de supuesto fijo a señal observable o pronosticada, usando por ejemplo la tasa efectiva disponible al momento del rebalanceo, sorpresas respecto de expectativas o variaciones mensuales o trimestrales. La *view* de momentum podría refinarse con momentum ajustado por volatilidad, exclusión del mes más reciente para reducir reversals o combinación de ventanas de 6 y 12 meses. También sería valioso incorporar *views* de valor, calidad, tamaño, tasas de interés, inflación o revisiones de utilidades.

Otra mejora importante es calibrar Ω con evidencia empírica en lugar de fijar manualmente la confianza. Esta calibración podría usar error histórico de predicción, frecuencia de acierto del signo, correlación entre señal y retorno futuro, varianza residual de regresiones, metodología de desplazamiento deseado en pesos o validación cruzada temporal. Además, conviene analizar sensibilidad a τ , *shrinkage*, frecuencia de rebalanceo, `max_weight` y tasa libre de riesgo, e incorporar costos de transacción, restricciones sectoriales, cotas de liquidez, control de *tracking error*, penalización por rotación y estimadores robustos de covarianza.

En síntesis, la implementación construye un experimento Black-Litterman completo y comparable con el caso base Markowitz. Su principal aporte es reemplazar retornos esperados históricos por retornos posteriores que combinan equilibrio de mercado y *views*. Los resultados indican que Black-Litterman es especialmente valioso en escenarios exigentes, como el entrenamiento con pandemia, donde la *view* de desempleo mejora fuertemente el Sharpe frente a Markowitz. La conclusión central no es que una *view* sea universalmente superior, sino que la calidad, calibración y confianza de las *views* determinan el valor práctico del modelo.

Simulación Monte Carlo

Resumen

Como parte de la documentación técnica del proyecto FinPUC, se elaboró un informe consolidado que integra los resultados de los tres notebooks de implementación: Markowitz vs Benchmark, Black-Litterman y Simulación Monte Carlo. El propósito del documento es proveer trazabilidad completa entre los datos, cálculos, técnicas de optimización, comparaciones y conclusiones finales del proyecto.

El informe fue generado el 09 de mayo de 2026 y opera sobre el universo F5 de 601 activos, benchmark top-20, rebalanceo semestral de 126 días hábiles y simulación Monte Carlo a 260 semanas. En esta etapa, el notebook `p4_montecarlo_recomendador_portafolios.ipynb` transforma los KPIs de Markowitz y Black-Litterman en una evaluación de cliente y empresa. Para cada combinación de escenario, técnica, *view* y perfil simula trayectorias de riqueza, probabilidad de retiro, aceptación de recomendaciones, utilidad de la empresa y un score final de recomendación.

Fundamentos metodológicos

La Simulación Monte Carlo usa como insumos el retorno anual base y la volatilidad anual de cada estrategia. Estos parámetros provienen de los experimentos previos y se transforman a frecuencia semanal para simular trayectorias de riqueza de un cliente con capital inicial $C_0 = 1\,000$ USD. El retiro depende de la pérdida relativa frente a la tolerancia del perfil, mientras que la aceptación depende del atractivo riesgo-retorno de la recomendación.

El informe documenta una metodología de cálculo común para los modelos de entrada: estimación de parámetros (μ , Σ con *shrinkage* $\lambda = 0.20$, `nearest_psd`), anualización y frontera eficiente. La simulación no reoptimiza portafolios, sino que traduce esos KPIs financieros a variables de experiencia de cliente y de resultado para la empresa.

Supuestos del experimento

Se simulan 5 000 trayectorias por combinación durante 260 semanas, equivalentes a cinco años de evaluación semanal. Cada combinación se evalúa en tres escenarios proyectados: desfavorable, neutro y favorable. Los retornos semanales se aproximan con distribución normal, pese a que el análisis distribucional muestra colas pesadas. La comisión inicial es

$k = 1\%$ sobre el capital inicial y, en recomendaciones aceptadas, se cobra sobre una fracción de rotación de 5% de la riqueza vigente.

El diseño opera sobre el mismo universo F5 de 601 activos usado por los experimentos de optimización, benchmark top-20 y KPIs rebalanceados. Por lo tanto, la comparación final no cambia el universo de acciones, sino la manera en que se transforma el desempeño histórico de cada técnica en una distribución de resultados de negocio.

Estructura del notebook

El documento metodológico consolidado se organiza en ocho secciones:

- (i) **Resumen ejecutivo:** comparación final de los tres modelos por escenario, con tabla de KPIs y top 12 del ranking.
- (ii) **Datos, universo F5 y diseño experimental:** descripción del filtrado (1 406 a 601 tickers), split `h7_f2` y escenarios con/sin pandemia.
- (iii) **Metodología de cálculo común:** estimación de parámetros (μ , Σ con *shrinkage* $\lambda = 0.20$, `nearest_psd`), anualización y frontera eficiente.
- (iv) **Markowitz vs benchmark:** portafolios por perfil, impacto de la pandemia en Sharpe, validación robusta por horizonte.
- (v) **Black-Litterman y matriz de views:** configuración de las cuatro views (momentum, momentum top-20 6M, momentum top-20/bottom-20 1Y, desempleo), resultados por view y escenario.
- (vi) **Simulación Monte Carlo y recomendador:** supuestos operativos, promedios por técnica, ranking completo del recomendador.
- (vii) **Conclusión integrada:** hallazgos principales y recomendación final.
- (viii) **Índice de anexos y tablas de auditoría:** inventario completo de CSVs generados.

El notebook define funciones de retiro y aceptación, construye insumos por técnica y perfil desde los CSV de Markowitz y Black-Litterman, ejecuta la Simulación Monte Carlo, resume KPIs por escenario, genera gráficos, calcula el ranking recomendador cliente-empresa y exporta conclusiones.

Las salidas principales son:

```
p4_model_inputs_kpis.csv
p4_montecarlo_summary.csv
p4_neutral_scenario_summary.csv
p4_recommendation_ranking.csv
```

p4_montecarlo_paths_quantiles.csv

El informe documenta un total de 21 archivos CSV generados por los tres notebooks, organizados por metodología. La Tabla 9.37 presenta el inventario completo.

Tabla 9.37. Índice de CSVs generados por el proyecto.

Archivo	Metodología	Filas	Cols	Propósito
rebalance_summary_h7_f2_601activos	Markowitz	18	12	KPIs rebalanceados
comparison_sin_vs_con_pandemia_h7_f2	Markowitz	9	21	Comparación escenarios
validacion_robusta_ventanas_moviles	Markowitz	6	4	Sharpe por horizonte
frontier_segments_h7_f2_601activos	Markowitz	238	24	Frontera eficiente
heatmap_sharpe_train_test	Markowitz	7	8	Heatmap splits
bl_rebalance_summary_h7_f2_601activos	Black-Litterman	72	14	KPIs BL rebalanceados
bl_views_h7_f2_601activos	Black-Litterman	32	36	Configuración views
comparison_three_models_kpis_h7_f2	Black-Litterman	12	13	Comparación 3 modelos
comparison_bl_vs_markowitz_h7_f2	Black-Litterman	72	19	Delta BL vs Markowitz
bl_robust_validation_summary	Black-Litterman	36	10	Validación robusta BL
p4_montecarlo_summary	Simulación Monte Carlo	180	29	Resumen completo MC
p4_neutral_scenario_summary	Simulación Monte Carlo	60	29	Escenario neutro
p4_recommendation_ranking	Simulación Monte Carlo	60	30	Ranking recomendador
p4_model_inputs_kpis	Simulación Monte Carlo	60	13	Inputs desde modelos
p4_montecarlo_paths_quantiles	Simulación Monte Carlo	1 980	13	Bandas P5–P95

KPIs utilizados

Los KPIs de cliente son riqueza terminal media, percentiles 5/50/95, ganancia esperada, probabilidad de ganancia, probabilidad de pérdida mayor a la tolerancia, tasa de retiro y semana promedio de retiro. Los KPIs de empresa son ingreso promedio, ingreso mediano, ingreso percentil 95, ingreso como porcentaje del capital inicial y tasa de aceptación de recomendaciones. El ranking final usa `p4_score`, que combina valor para el cliente y valor para la empresa.

En el informe integrado, estos KPIs se conectan con retorno total, retorno anual, volatilidad anual, *drawdown*, CVaR y Sharpe de los modelos de entrada. Por esta razón, una técnica con mayor retorno histórico puede perder en score si eleva demasiado retiros o dispersión de resultados.

Resultados del experimento pandemia

La Tabla 9.38 presenta la comparación final de modelos por escenario, extraída del informe de metodologías.

Tabla 9.38. Comparación final de modelos por escenario (mejor portafolio por modelo).

Escenario	Modelo	Portafolio	Ret. total	Ret. anual	Vol. anual	Drawdown	Sharpe
Sin pandemia	Markowitz	Ideal de mercado	76,5%	32,8%	12,3%	−12,6%	2,51
Sin pandemia	BL mom. top20 6m	Neutro	72,3%	31,2%	11,9%	−12,9%	2,46
Con pandemia	BL mom. top20 6m	Neutro	69,5%	30,2%	11,9%	−11,7%	2,38
Con pandemia	BL desempleo	Arriesgado	71,9%	31,1%	12,4%	−13,3%	2,36
Con pandemia	Markowitz	Muy conservador	54,5%	24,3%	11,0%	−10,2%	2,02

La Tabla 9.39 presenta el top 10 del ranking en escenario neutro.

Tabla 9.39. Top 10 ranking de Simulación Monte Carlo en escenario neutro.

Rank	Escenario	Técnica	Perfil	Riqueza	Retiro	Utilidad	Score
1	Con pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 8 974	3,1%	USD 474	9 417
2	Sin pandemia	BL Mom. Top20 6M	Muy arriesgado	USD 7 753	2,0%	USD 419	8 151
3	Con pandemia	BL Momentum	Muy arriesgado	USD 6 436	14,6%	USD 335	6 625
4	Sin pandemia	BL Desempleo	Muy arriesgado	USD 5 434	0,5%	USD 221	5 650
5	Sin pandemia	Markowitz	Muy arriesgado	USD 5 349	2,1%	USD 215	5 543
6	Sin pandemia	BL Momentum	Arriesgado	USD 5 304	10,9%	USD 320	5 515
7	Con pandemia	BL Mom. Top20 6M	Arriesgado	USD 5 137	0,5%	USD 312	5 445

La mejor combinación es Black-Litterman Momentum Top20 6M con datos de pandemia y perfil Muy arriesgado. Su ventaja se explica por alta riqueza terminal, tasa de retiro baja para un perfil agresivo y mayor utilidad para la empresa.

Rebalanceo

La Simulación Monte Carlo no recalcula pesos de portafolio. Recibe KPIs que ya incorporan el rebalanceo semestral de Markowitz y Black-Litterman. Por eso, el rebalanceo entra de forma indirecta: afecta retornos, volatilidad, drawdown y CVaR base, que luego determinan riqueza simulada, retiro y utilidad. Esta estructura evita mezclar dos capas de decisión:

la optimización de pesos queda en los modelos financieros y la simulación se concentra en la evaluación cliente-empresa.

Splits aleatorios

La Simulación Monte Carlo no ejecuta splits aleatorios propios. Su robustez temporal depende de los insumos previamente validados en Markowitz y Black-Litterman. Esta decisión evita duplicar experimentos y mantiene el foco en la pregunta de negocio: cuál combinación de técnica, escenario y perfil genera mejor equilibrio cliente-empresa. En consecuencia, la lectura de sus resultados debe considerar la evidencia de splits aleatorios y validación robusta reportada para los modelos de entrada.

Evaluación robusta

Tabla 9.40. Ganadores por escenario proyectado en Simulación Monte Carlo.

Escenario	Técnica	View	Perfil	Riqueza	Retiro	Utilidad
Desfavorable	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 5 009	8,8%	USD 327
Neutro	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 8 974	3,1%	USD 474
Favorable	BL Momentum Top20 6M	momentum_top20_6m	Muy arriesgado	USD 15 451	1,6%	USD 690

La misma técnica domina en los tres escenarios proyectados, lo que refuerza su consistencia dentro del marco de supuestos del notebook. Esta conclusión debe leerse con cautela porque los retornos simulados son normales y pueden subestimar eventos extremos. Para implementación comercial, conviene mostrar al usuario tres escenarios y no solo el escenario neutro: el riesgo de retiro cambia fuertemente cuando el camino simulado atraviesa pérdidas tempranas.

Implicancias y conclusiones

El informe de metodologías concluye con las siguientes observaciones:

- Markowitz aporta una base estable y trazable, especialmente para perfiles conservadores, aunque depende fuertemente de retornos históricos.
- Black-Litterman Desempleo ofrece un ajuste macro competitivo y en algunos escenarios lidera frente a Markowitz por delta Sharpe.

- Black-Litterman Momentum Top20 6M es la técnica más fuerte en la Simulación Monte Carlo y la mejor variante market-cap momentum por Sharpe en ambos escenarios de datos.
- La recomendación final depende del objetivo: si se prioriza riqueza esperada y score, gana Black-Litterman Momentum Top20 6M; si se prioriza mínimo retiro, se deben revisar perfiles menos agresivos o Black-Litterman Desempleo.

La Simulación Monte Carlo conecta desempeño financiero con variables de negocio. El resultado principal es que Black-Litterman Momentum Top20 6M domina el ranking al combinar alta riqueza esperada, baja tasa de retiro y mayor utilidad para la empresa. La principal limitación es el supuesto normal: para la siguiente etapa conviene probar t-Student, Johnson SU u otra distribución con colas pesadas, además de sensibilizar costos de transacción y reglas de retiro basadas en *drawdown*.

El informe final de metodologías de portafolios se encuentra disponible como archivo PDF en el repositorio del proyecto: <https://github.com/Psacevedo/Capstone.git>. El documento incluye 16 figuras, 18 tablas y el índice completo de 21 CSVs de auditoría.

Conclusión integrada

Los tres notebooks forman una cadena metodológica. Markowitz define la base de comparación; Black-Litterman reduce dependencia de medias históricas mediante prior y *views*; Simulación Monte Carlo traduce los KPIs en una decisión cliente-empresa. La recomendación de esta primera iteración es usar Black-Litterman como alternativa principal y Markowitz como caso base de comparación y diagnóstico de sensibilidad.

ANEXO N°5: DIAGNÓSTICOS DE LA CALIBRACIÓN INDEPENDIENTE DE BLACK-LITTERMAN

9.3. Diagnósticos de la calibración independiente de Black-Litterman

La calibración se implementa dentro de cada script `validacion_<view>_v1_plus.py` y se consolida con `generar_informes_views_v1_plus.py`. A diferencia de versiones anteriores, no se selecciona una única familia de *view* ganadora: cada *view* se calibra de forma independiente y pasa a la etapa de simulación con su mejor configuración propia.

9.3.1. Etapas de calibración

Para cada *view* se recorren cinco etapas secuenciales sobre el horizonte $\mathcal{H}_1$, validadas en $\mathcal{H}_2$: (1) configuración base de la familia; (2) estructura de la matriz P propia de la familia; (3) intensidad del vector Q mediante $q_{\text{scale}} \in \{0.5, 1.0, 1.5, 2.0\}$; (4) confianza $c \in \{0.25, 0.35, 0.50, 0.75, 1.00\}$ en Ω ; y (5) parámetro $\tau \in \{0.05, 0.10, 0.20, 0.50, 1.00\}$. En cada etapa, la configuración con mayor score robusto fuera de muestra avanza y se congela.

9.3.2. Configuraciones congeladas por *view*

La Tabla 9.41 reporta la configuración congelada de cada *view*. El valor de $\tau = 0.20$ en la mayoría de las *views* es mayor que el teórico sugerido por la literatura ($\tau \approx 1/T$), lo que es consistente con el uso de τ como hiperparámetro de calibración más que como estimación puntual de la incertidumbre del prior.

Tabla 9.41. Configuración congelada por *view* (calibración independiente).

<i>View</i>	Familia	q_{scale}	c	τ
Momentum general	momentum	1.5	0.80	0.01
Desempleo macro	unemployment	1.5	0.50	0.20
Mom. top/bottom 1Y	marketcap mom.	1.5	0.80	0.20
Mom. top market-cap 6M	marketcap mom.	1.5	0.80	0.20

9.3.3. Validación rolling

La validación rolling utiliza, en el escenario con pandemia, 10 ventanas de calibración, 3 de validación y 4 de test limpio P4; en el escenario sin pandemia, 3, 1 y 1 respectivamente. Cada ventana ejecuta el pipeline completo (calibración en $\mathcal{H}_1$, validación en $\mathcal{H}_2$ y simulación P4 en $\mathcal{H}_3$). Los resultados completos por ventana y perfil se encuentran en los archivos `views_v1_plus/<view>_v1_plus/outputs/resumen_ejecucion_3h.md`.