

Informe académico: análisis de resultados de splits aleatorios en Markowitz

Sistema recomendador de portafolios FinPUC

Grupo 13

Mayo de 2026

Resumen

Este informe analiza los resultados generados por la variante `markowitz_cvxpy_splits_aleatorios.py`, cuyo objetivo es evaluar la sensibilidad del modelo de Markowitz frente a distintas razones de entrenamiento y prueba dentro de una ventana base de nueve años. La corrida disponible contiene 601 activos, 28 combinaciones de años históricos y años futuros, 70 ventanas aleatorias de validación, 560 evaluaciones de portafolios y 1392 puntos de frontera eficiente. El análisis muestra que el desempeño fuera de muestra es altamente dependiente del split, que los portafolios defensivos son más estables, que el benchmark top 20 fue muy competitivo en Sharpe futuro, y que la cartera de tangencia mantiene alto atractivo teórico pero no siempre traslada esa superioridad al periodo real futuro.

Índice

1. Contexto y objetivo del experimento	3
2. Diseño experimental	3
2.1. Combinaciones train/test evaluadas	3
2.2. Ventanas aleatorias y reproducibilidad	4
3. Implementación del modelo	4
4. Eficiencia computacional	5
5. Evaluación global por portafolio	5
6. Análisis por años futuros de test	7
7. Robustez por combinación train/test	8
8. Mejores splits por tipo de portafolio	9
9. Comparación esperado versus real	10

10.Evaluación de robustez	11
11.Limitaciones	11
12.Conclusiones	11
13.Archivos utilizados y generados	12

1. Contexto y objetivo del experimento

La variante implementada extiende la validación anterior del modelo de Markowitz. En lugar de evaluar solo horizontes agregados como 7:2, 6:3 o 5:4, el experimento prueba todas las combinaciones posibles de años históricos y años futuros que caben dentro de una ventana base de nueve años. El objetivo es responder una pregunta práctica: cuántos años de historia conviene usar para estimar retornos y covarianzas cuando el portafolio será evaluado durante distintos horizontes futuros.

Cada combinación se expresa como $(train, test)$. La parte *train* corresponde al periodo histórico usado para estimar el vector de retornos esperados y la matriz de covarianza. La parte *test* corresponde al periodo futuro, fuera de muestra, en el que se aplican los pesos calculados y se mide el desempeño real. El modelo no usa información del periodo de prueba para construir los portafolios.

La implementación mantiene la estructura financiera del modelo anterior: retornos diarios totales con dividendos, restricciones *long-only*, presupuesto completo, cotas de concentración por perfil, penalización cuadrática del riesgo y resolución convexa mediante CVXPY.

2. Diseño experimental

2.1. Combinaciones train/test evaluadas

La corrida considera 28 combinaciones. Para test de dos años se evalúan (7, 2), (6, 2), (5, 2), (4, 2), (3, 2), (2, 2) y (1, 2). Para test de tres años se evalúan (6, 3) hasta (1, 3). El patrón continúa hasta test de ocho años, donde solo cabe (1, 8). Todas las combinaciones cumplen:

$$\text{años train} + \text{años test} \leq 9. \quad (1)$$

Tabla 1: Estructura de combinaciones por cantidad de años futuros de test

Años test	N° splits	N° ventanas	Train mínimo	Train máximo
2	7	19	1	7
3	6	16	1	6
4	5	13	1	5
5	4	10	1	4
6	3	7	1	3
7	2	4	1	2
8	1	1	1	1

El número de ventanas no es idéntico para todas las combinaciones. Cuando $train + test = 9$, la subventana ocupa toda la ventana base de nueve años, por lo que solo existe una posición factible. Cuando $train + test < 9$, el script sortea hasta tres posiciones aleatorias reproducibles mediante semilla. Por esta razón se obtienen 70 ventanas totales y no 84.

2.2. Ventanas aleatorias y reproducibilidad

Las ventanas se generan dentro de los últimos nueve años de retornos comunes. La función `generate_random_validation_starts` selecciona inicios factibles para cada combinación, usando una semilla aleatoria. Esto permite repetir el experimento y obtener los mismos splits, lo que es fundamental para la trazabilidad académica.

En la corrida analizada se usaron 601 activos en todas las ventanas. La Tabla 2 muestra una muestra de las primeras ventanas generadas.

Tabla 2: Muestra de ventanas de validación aleatorias

Split	Train	Test	Ventana	Inicio hist.	Fin hist.	Inicio test	Fin test
h7_f2	7	2	1	2014-01-23	2024-01-26	2024-01-29	2026-01-30
h6_f2	6	2	1	2014-02-25	2023-02-27	2023-02-28	2025-03-03
h6_f2	6	2	2	2014-10-30	2023-11-02	2023-11-03	2025-11-06
h6_f2	6	2	3	2015-01-23	2024-01-26	2024-01-29	2026-01-30
h5_f2	5	2	1	2014-12-03	2019-12-04	2019-12-05	2024-12-06
h5_f2	5	2	2	2014-12-05	2019-12-06	2019-12-09	2024-12-10
h5_f2	5	2	3	2016-01-25	2024-01-26	2024-01-29	2026-01-30

3. Implementación del modelo

Para cada ventana, el script estima μ y Σ usando solamente el tramo histórico. La matriz de covarianza se regulariza mediante *shrinkage*, combinando la covarianza muestral con su diagonal:

$$\Sigma_\lambda = (1 - \lambda)\hat{\Sigma} + \lambda \text{diag}(\hat{\Sigma}), \quad (2)$$

donde $\lambda = 0,20$ por defecto. Esto reduce la dependencia de correlaciones ruidosas, una dificultad importante cuando se trabaja con 601 activos y ventanas históricas cortas.

Para cada perfil p , el problema resuelto es:

$$\max_w \quad \mu^\top w - \frac{\gamma_p}{2} w^\top \Sigma w, \quad (3)$$

sujeto a:

$$\sum_i w_i = 1, \quad (4)$$

$$0 \leq w_i \leq \bar{w}_p, \quad (5)$$

$$252 \cdot w^\top \Sigma w \leq \bar{\sigma}_p^2. \quad (6)$$

Además de los cinco perfiles de riesgo, se calcula un benchmark equiponderado top 20 por capitalización, el portafolio de mínima varianza y el portafolio ideal de mercado como máximo Sharpe sobre la frontera eficiente. Para cada combinación y ventana se exportan pesos, métricas de portafolio, puntos de frontera, información de ventanas y resúmenes agregados.

4. Eficiencia computacional

La corrida contiene 70 ventanas y 560 evaluaciones de portafolios. Para cada ventana se resuelven cinco problemas de perfil, un benchmark cerrado, mínima varianza, una cartera auxiliar de máximo retorno, múltiples puntos de frontera y el portafolio ideal de mercado. Los CSV registran 1392 puntos de frontera eficiente.

La suma de tiempos reportados para portafolios principales es aproximadamente 787.5 segundos, mientras que los puntos de frontera acumulan aproximadamente 218.3 segundos de resolución. Estas cifras no incluyen toda la sobrecarga de lectura, gráficos y escritura, pero permiten observar que la optimización convexa es factible para universos grandes.

Tabla 3: Tiempo medio de solver y diversificación media

Portafolio	Tiempo medio solver (s)	N° activos positivos medio
Muy conservador	1.91	51.83
Conservador	1.80	40.11
Neutro	1.65	26.16
Arriesgado	1.62	15.30
Muy arriesgado	1.81	9.03
Benchmark	0.00	20.00
Mínima varianza	0.42	112.37
Ideal de mercado	0.47	42.86

El benchmark no requiere solver. La mínima varianza y el ideal de mercado son computacionalmente livianos una vez construida la frontera, mientras que los perfiles requieren resolver problemas cuadráticos con restricciones adicionales de volatilidad y concentración. Los perfiles conservadores tienden a usar más activos positivos; los perfiles agresivos se concentran más, coherente con sus mayores límites de peso por activo.

5. Evaluación global por portafolio

Tabla 4: Desempeño futuro promedio por portafolio

Portafolio	N	Sharpe fut.	Desv.	Ret. fut.	Vol. fut.	Drawdown	CVaR 95 %	Sharpe teórico
Muy conservador	70	1.885	0.289	32.73 %	16.58 %	-12.16 %	1.56 %	4.177
Conservador	70	1.800	0.334	35.86 %	19.29 %	-13.28 %	1.71 %	4.805
Neutro	70	1.781	0.413	41.58 %	22.95 %	-16.50 %	2.09 %	4.867
Arriesgado	70	1.644	0.449	48.89 %	28.92 %	-22.42 %	2.78 %	4.518
Muy arriesgado	70	1.625	0.458	57.47 %	33.85 %	-27.99 %	3.47 %	4.024
Benchmark	70	2.057	0.381	64.15 %	30.50 %	-20.51 %	2.56 %	1.707
Mínima varianza	70	1.940	0.250	28.72 %	13.86 %	-11.06 %	1.47 %	2.491
Ideal de mercado	70	1.799	0.421	39.00 %	21.99 %	-12.99 %	1.71 %	5.014

El resultado más llamativo es que el benchmark top 20 obtiene el mayor Sharpe futuro promedio, 2.057. Esto indica que, durante los periodos de prueba sorteados, una cartera simple concentrada en grandes empresas fue extremadamente competitiva. Sin embargo, el benchmark también presenta drawdown medio de -20.51 %, superior al de portafolios defensivos y mínima varianza.

Los portafolios de perfil muestran una gradiente esperada: al pasar de muy conservador a muy arriesgado, el retorno futuro promedio sube de 32.73 % a 57.47 %, pero la volatilidad sube de 16.58 % a 33.85 %, el drawdown medio empeora de -12.16 % a -27.99 % y el CVaR diario 95 % aumenta de 1.56 % a 3.47 %. Esta coherencia es una señal positiva: aunque el ranking de Sharpe no favorece siempre a Markowitz, el modelo sí ordena la exposición al riesgo de manera consistente.

El portafolio de mínima varianza presenta uno de los mejores compromisos de estabilidad: Sharpe futuro promedio de 1.940, volatilidad de solo 13.86 % y drawdown medio de -11.06 %. Esta cartera sacrifica retorno esperado, pero confirma que la estimación de covarianzas captura información útil para construir portafolios defensivos.




Figura 1: Desempeño futuro promedio de los portafolios en el plano retorno-volatilidad.

6. Análisis por años futuros de test

Tabla 5: Top 3 portafolios por años futuros de test

Test	Portafolio	N exp.	Sharpe	Retorno	Volatilidad
2	Benchmark	19	2.319	70.70 %	29.49 %
2	Mínima varianza	19	2.194	31.38 %	13.48 %
2	Muy conservador	19	2.136	35.70 %	16.52 %
3	Benchmark	16	2.227	65.06 %	29.26 %
3	Mínima varianza	16	1.948	29.96 %	14.46 %
3	Muy conservador	16	1.761	31.19 %	16.31 %
4	Benchmark	13	1.943	68.25 %	34.10 %
4	Muy conservador	13	1.939	32.16 %	15.66 %
4	Neutro	13	1.938	40.81 %	20.56 %
5	Mínima varianza	10	1.748	26.13 %	13.95 %
5	Muy conservador	10	1.730	33.56 %	18.44 %
5	Benchmark	10	1.728	56.96 %	31.81 %
6	Benchmark	7	1.825	55.64 %	29.40 %
6	Mínima varianza	7	1.802	25.74 %	13.24 %
6	Muy conservador	7	1.787	32.20 %	17.28 %
7	Benchmark	4	1.818	52.94 %	28.02 %
7	Muy conservador	4	1.687	26.84 %	14.83 %
7	Mínima varianza	4	1.672	23.62 %	12.94 %
8	Benchmark	1	1.707	48.10 %	27.01 %
8	Mínima varianza	1	1.458	20.15 %	12.45 %
8	Muy conservador	1	1.408	26.98 %	17.74 %

El desempeño promedio cae a medida que se extiende el periodo futuro de test. Para test de dos años, el benchmark alcanza Sharpe promedio 2.319 y los portafolios defensivos también superan 2.1. En test de ocho años, el benchmark sigue liderando, pero con Sharpe 1.707, y el resto de las carteras cae bajo 1.46. Esto sugiere que la capacidad predictiva de una estimación histórica fija se deteriora cuando se exige que el portafolio permanezca válido por muchos años futuros.




Figura 2: Sharpe futuro promedio por años futuros de test.

7. Robustez por combinación train/test

Para evaluar robustez se agregan los resultados por combinación. La Tabla 6 muestra las combinaciones con mayor Sharpe promedio considerando todos los portafolios. Esta mirada no reemplaza el análisis por perfil, pero permite identificar regiones del espacio train/test que fueron favorables de forma transversal.

Tabla 6: Mejores combinaciones train/test por Sharpe promedio global

Test	Split	N eval.	Sharpe prom.	Retorno prom.	Vol. prom.	Drawdown prom.
2	h5_f2	24	2.339	55.13 %	22.37 %	-11.91 %
2	h6_f2	24	2.217	33.83 %	14.73 %	-13.29 %
2	h7_f2	8	2.168	34.96 %	15.62 %	-14.86 %
2	h4_f2	24	2.006	53.39 %	27.43 %	-14.93 %
2	h2_f2	24	1.956	51.73 %	25.77 %	-14.62 %
2	h3_f2	24	1.874	43.05 %	23.16 %	-14.03 %
2	h1_f2	24	1.853	50.45 %	26.87 %	-18.10 %
3	h4_f3	24	1.917	51.58 %	26.32 %	-18.53 %
3	h3_f3	24	1.911	39.35 %	19.42 %	-13.37 %
3	h5_f3	24	1.862	41.13 %	20.50 %	-14.93 %
3	h6_f3	8	1.848	29.61 %	14.67 %	-14.24 %
3	h2_f3	24	1.695	43.07 %	23.73 %	-18.13 %




Figura 3: Mapa de calor del Sharpe futuro promedio por combinación train/test.

El mapa de calor muestra que no existe una regla monotónica simple. En test de dos años, la combinación 5:2 logra el mejor promedio global, seguida por 6:2 y 7:2. Esto indica que, para horizontes de prueba cortos, una ventana histórica intermedia puede entregar suficiente información sin arrastrar excesivo ruido estructural antiguo. En cambio, para test más largos, la ventaja de una calibración corta o larga depende del régimen de mercado que queda incluido en el periodo futuro.

8. Mejores splits por tipo de portafolio

Tabla 7: Mejor split por portafolio según Sharpe futuro promedio

Portafolio	Mejor split	N ventanas	Sharpe	Desv.	Retorno	Volatilidad
Muy conservador	h5_f2	3	2.347	0.193	36.23 %	14.77 %
Conservador	h5_f2	3	2.310	0.127	38.17 %	15.79 %
Neutro	h7_f2	1	2.391	–	33.31 %	13.10 %
Arriesgado	h5_f4	1	2.345	–	56.28 %	23.15 %
Muy arriesgado	h5_f4	1	2.283	–	75.67 %	32.27 %
Benchmark	h6_f2	3	2.615	0.436	49.35 %	18.30 %
Mínima varianza	h5_f2	3	2.363	0.023	36.36 %	14.54 %
Ideal de mercado	h5_f2	3	2.458	0.175	39.34 %	15.10 %




Figura 4: Mejor split por portafolio según Sharpe futuro promedio.

Los perfiles conservadores encuentran su mejor desempeño en 5:2, al igual que la mínima varianza y el ideal de mercado. Los perfiles arriesgado y muy arriesgado encuentran su mejor Sharpe en 5:4, donde el periodo de test incluye más años favorables para activos de crecimiento. El benchmark alcanza su mejor resultado en 6:2. En conjunto, esto sugiere que la ventana de entrenamiento óptima depende del tipo de cartera: carteras defensivas se benefician de ventanas intermedias y tests cortos, mientras que carteras agresivas pueden lucir mejor cuando el periodo futuro captura tendencias alcistas prolongadas.

9. Comparación esperado versus real

Una observación crítica es la distancia entre Sharpe teórico y Sharpe futuro. Los perfiles optimizados presentan Sharpe teóricos muy altos: por ejemplo, el ideal de mercado tiene Sharpe teórico promedio 5.014, pero Sharpe futuro 1.799. El perfil neutro tiene Sharpe teórico 4.867 y Sharpe futuro 1.781. Esta brecha es un patrón clásico de Markowitz: la optimización explota diferencias pequeñas en retornos esperados muestrales, que no necesariamente persisten fuera de muestra.

El benchmark, por el contrario, tiene Sharpe teórico promedio bajo comparado con los portafolios optimizados, pero obtiene el mayor Sharpe futuro. Esto revela que el modelo de media-varianza no debe evaluarse solo por su frontera teórica. La validación fuera de muestra es indispensable porque mide si la estimación histórica realmente se traduce en decisiones superiores.

Aun así, la implementación sí logra separar perfiles por riesgo: las carteras agresivas obtienen mayores retornos y mayores pérdidas potenciales, mientras que mínima varianza y perfiles conservadores contienen drawdown y CVaR. Por tanto, el modelo funciona bien como

mecanismo de estructuración de riesgo, aunque no siempre domina al benchmark en retorno ajustado por riesgo.

10. Evaluación de robustez

La robustez se entiende como estabilidad de desempeño ante cambios en la ventana de entrenamiento y prueba. Los resultados muestran tres niveles de robustez. Primero, la mínima varianza es estable: tiene baja desviación de Sharpe, bajo drawdown y bajo CVaR. Segundo, los perfiles conservadores son razonablemente robustos, aunque con menor Sharpe que el benchmark. Tercero, los perfiles agresivos son sensibles al periodo elegido: obtienen altos retornos, pero su Sharpe y drawdown varían con fuerza.

La existencia de 70 ventanas permite detectar que varios resultados aparentemente buenos dependen del régimen de mercado. Por ejemplo, algunos splits cortos con test de dos años producen Sharpe muy alto cuando el periodo futuro incluye tramos favorables para acciones grandes o tecnológicas. Sin embargo, al extender el test a siete u ocho años, el Sharpe promedio cae y la incertidumbre aumenta. Esta evidencia favorece usar validación móvil antes de elegir un horizonte definitivo para producción.

11. Limitaciones

La principal limitación es que Markowitz depende fuertemente de la estimación de retornos esperados. Aunque el shrinkage estabiliza la covarianza, no resuelve completamente el error de estimación en μ . Además, el experimento mantiene pesos fijos durante el periodo test; en una implementación operacional semanal, los portafolios podrían rebalancearse y responder a nueva información. Finalmente, los resultados están influenciados por el periodo histórico disponible y por la exclusión de pandemia, lo cual mejora estabilidad pero también elimina un régimen de estrés importante.

12. Conclusiones

La variante de splits aleatorios entrega una validación mucho más exigente que un único train/test. Al evaluar 28 combinaciones y 70 ventanas sobre 601 activos, se obtiene una imagen más realista de la sensibilidad del modelo. La principal conclusión es que el horizonte de calibración importa: no existe una combinación universalmente superior, aunque 5:2, 6:2 y 7:2 aparecen como alternativas sólidas para tests cortos, y 5:4 favorece perfiles agresivos en la corrida analizada.

El benchmark top 20 domina en Sharpe futuro promedio, lo que sugiere que una regla simple de exposición a grandes empresas fue difícil de superar en estos periodos. No obstante, mínima varianza y los perfiles conservadores ofrecen mejor control de riesgo, con menores drawdowns y CVaR. El modelo de Markowitz, por tanto, es útil para construir carteras diferenciadas por tolerancia al riesgo, pero debe complementarse con estimadores más robustos de retorno, validación continua y eventualmente modelos como Black-Litterman para reducir sensibilidad a μ .

En términos académicos, el ejercicio confirma una enseñanza central de la teoría moderna de portafolios: la frontera eficiente es una herramienta poderosa para organizar el trade-off riesgo-retorno, pero su desempeño práctico depende de la calidad de los parámetros estimados y de la estabilidad temporal del mercado. Por eso, la validación con splits aleatorios es un componente esencial antes de convertir el modelo en un recomendador operativo.

13. Archivos utilizados y generados

Tabla 8: Archivos principales usados en el análisis

Archivo	Uso
<code>portfolios_summary_all_windows.csv</code>	Métricas por portafolio, split y ventana.
<code>validation_windows.csv</code>	Fechas, train/test y número de activos por experimento.
<code>validation_robustness_summary.csv</code>	Resumen por split y portafolio.
<code>validation_by_test_years_summary.csv</code>	Resumen por años futuros de test.
<code>frontier_points_all_windows.csv</code>	Puntos de frontera eficiente y validación futura.
<code>weights_all_windows.csv</code>	Pesos positivos de cada cartera.