

Informe académico sobre la implementación completa del modelo de Markowitz con validación robusta

Sistema recomendador de portafolios FinPUC

Grupo 13

Mayo de 2026

Resumen

Este informe documenta la implementación completa de una variante robusta del modelo de media-varianza de Markowitz para el sistema recomendador de portafolios FinPUC. El modelo fue desarrollado en Python y resuelto mediante CVXPY, utilizando la base `Historical_Stocks_filtrado_sin_pandemia`. La implementación calcula retornos diarios totales incorporando dividendos, estima retornos esperados y matrices de covarianza, resuelve portafolios óptimos para cinco perfiles de riesgo, construye un benchmark equiponderado de las veinte empresas de mayor capitalización, calcula el portafolio de mínima varianza y aproxima el portafolio ideal de mercado como el punto de máximo Sharpe sobre la frontera eficiente. Además, se implementa una validación robusta con múltiples horizontes de calibración y prueba, usando ventanas móviles para comparar desempeño esperado y desempeño futuro realizado. Los resultados muestran que el modelo es computacionalmente factible para un universo amplio de 601 activos, aunque también evidencian la sensibilidad del enfoque media-varianza a la ventana histórica utilizada y a la estabilidad de las estimaciones de retorno.

Índice

1. Introducción	3
2. Base de datos y preparación de retornos	3
2.1. Fuente de datos	3
2.2. Retornos diarios totales	4
3. Formulación matemática del modelo	4
3.1. Modelo media-varianza	4
3.2. Estimación de parámetros	5
3.3. Resolución con CVXPY	5

4. Portafolios implementados	5
4.1. Perfiles de riesgo	5
4.2. Benchmark equiponderado	6
4.3. Portafolio de mínima varianza	6
4.4. Portafolio ideal de mercado	6
5. Frontera eficiente y gráficos	7
6. Validación robusta	9
6.1. Horizontes de calibración y prueba	9
6.2. Ventanas móviles	9
7. Resultados y evaluación del modelo	10
7.1. Desempeño promedio por portafolio	10
7.2. Comparación por horizonte	11
7.3. Mejor horizonte por portafolio	12
8. Eficiencia computacional	12
9. Comparación esperado versus real	12
10. Archivos exportados	13
11. Conclusiones	13

1. Introducción

El problema de selección de portafolios consiste en determinar cómo distribuir el capital disponible entre un conjunto de activos financieros, considerando simultáneamente retorno esperado y riesgo. En el proyecto FinPUC, este problema aparece dentro de un sistema recomendador que debe entregar portafolios diferenciados según el perfil de riesgo del cliente. Para esta etapa del proyecto, el objetivo fue implementar de forma completa y reproducible el modelo clásico de Markowitz, usándolo como base metodológica y computacional antes de incorporar modelos más avanzados como Black-Litterman, CVaR operacional o dinámica de cliente.

El script desarrollado corresponde a:

```
markowitz_cvxpy_variante_validacion.py
```

El archivo implementa una variante robusta del modelo anterior, cuyo énfasis está en evitar exigir una historia común de 10 años exactos y en validar el modelo sobre múltiples ventanas temporales. Esta decisión es relevante porque, al trabajar con muchos activos, la intersección común de fechas puede reducirse. En la corrida analizada se utilizaron los 601 activos del universo final F5, con 2489 retornos diarios comunes, lo que permite evaluar horizontes máximos de 9 años sin caer en errores del tipo: “la matriz común tiene 2512 retornos diarios, pero el horizonte máximo requiere 2520”.

2. Base de datos y preparación de retornos

2.1. Fuente de datos

La implementación utiliza la carpeta:

```
Historical_Stocks_filtrado_sin_pandemia
```

Esta base contiene acciones filtradas previamente, excluyendo el periodo de pandemia, y considera criterios de liquidez, capitalización, historia mínima y volatilidad razonable. La metadata principal se lee desde:

```
tickers_filtrados_F5.csv
```

Este archivo contiene, entre otras variables, el ticker, nombre de la empresa, sector, industria y capitalización de mercado. La función `read_metadata` carga esta información, transforma `marketCap` a variable numérica, elimina tickers duplicados y ordena los activos de mayor a menor capitalización. Esta estructura permite seleccionar automáticamente el universo de inversión mediante el parámetro `-market-universe-size`. Si dicho parámetro toma valor cero, el modelo utiliza todos los activos F5 disponibles.

2.2. Retornos diarios totales

Para cada ticker se lee el archivo:

`stock_return_<TICKER>.csv`

La función `read_stock_total_return` usa las columnas `Date`, `Close` y `Dividends`. El retorno diario total se calcula como:

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1} + D_{i,t}}{P_{i,t-1}}, \quad (1)$$

donde $P_{i,t}$ corresponde al precio de cierre del activo i en el día t , y $D_{i,t}$ corresponde al dividendo pagado por acción en ese día. Esta definición es importante porque el retorno financiero de una acción no proviene únicamente de la apreciación de precio, sino también del flujo de dividendos.

Luego, la función `load_returns_matrix` concatena las series de retornos mediante una intersección de fechas. Esto genera una matriz:

$$R \in \mathbb{R}^{T \times n}, \quad (2)$$

donde T es el número de días comunes y n el número de activos utilizados. En los resultados analizados, al usar todos los activos F5 se obtiene $n = 601$.

3. Formulación matemática del modelo

3.1. Modelo media-varianza

Sea w_i la proporción del capital invertida en el activo i , y sea $w \in \mathbb{R}^n$ el vector de pesos del portafolio. El retorno esperado del portafolio se define como:

$$\mu_p = \mu^\top w, \quad (3)$$

donde μ es el vector de retornos diarios esperados estimados a partir de la ventana histórica. El riesgo se mide mediante la varianza del portafolio:

$$\sigma_p^2 = w^\top \Sigma w, \quad (4)$$

donde Σ es la matriz de varianzas y covarianzas de los retornos. El modelo de Markowitz implementado para cada perfil resuelve:

$$\max_w \quad \mu^\top w - \frac{\gamma_p}{2} w^\top \Sigma w, \quad (5)$$

sujeto a:

$$\sum_{i=1}^n w_i = 1, \quad (6)$$

$$0 \leq w_i \leq \bar{w}_p, \quad \forall i, \quad (7)$$

$$252 \cdot w^\top \Sigma w \leq \bar{\sigma}_p^2. \quad (8)$$

El parámetro γ_p representa la aversión al riesgo del perfil p , $\bar{w}_p$ limita la concentración máxima en una acción y $\bar{\sigma}_p$ actúa como cota de volatilidad anualizada. Si esta cota de volatilidad no es factible para un perfil, el script relaja únicamente dicha restricción, conservando las restricciones de presupuesto, no venta en corto y cota máxima por activo. Esto se registra en la columna `note` de los resultados.

3.2. Estimación de parámetros

La función `estimate_parameters` estima:

$$\hat{\mu} = \frac{1}{T_h} \sum_{t=1}^{T_h} R_t, \quad (9)$$

y:

$$\hat{\Sigma} = \text{Cov}(R_1, \dots, R_{T_h}). \quad (10)$$

Para reducir inestabilidad numérica se aplica regularización por *shrinkage*:

$$\Sigma_\lambda = (1 - \lambda)\hat{\Sigma} + \lambda \cdot \text{diag}(\hat{\Sigma}), \quad (11)$$

donde $\lambda = 0,20$ por defecto. Esta técnica disminuye el peso de covarianzas potencialmente ruidosas y mejora la estabilidad del problema cuadrático. Luego se proyecta la matriz a una forma semidefinida positiva mediante `nearest_psd`, lo que asegura compatibilidad con `CVXPY`.

3.3. Resolución con CVXPY

La función `solve_profile_portfolio` formula el problema de optimización usando variables de decisión `cp.Variable(n)` y la función cuadrática `cp.quad_form`. El script intenta resolver con los solvers instalados en el siguiente orden: `CLARABEL`, `OSQP`, `ECOS` y `SCS`. En la ejecución analizada, el solver principal fue `CLARABEL`. La formulación es convexa porque se maximiza una función cóncava: una parte lineal de retorno menos una penalización cuadrática positiva semidefinida.

4. Portafolios implementados

4.1. Perfiles de riesgo

El script resuelve Markowitz para cinco perfiles:

Tabla 1: Parámetros operacionales por perfil de riesgo

Perfil	γ_p	Peso máximo	Volatilidad anual máxima
Muy conservador	80	5 %	8 %
Conservador	45	7 %	12 %
Neutro	20	10 %	18 %
Arriesgado	8	15 %	28 %
Muy arriesgado	3	20 %	40 %

Estos parámetros traducen la tolerancia cualitativa al riesgo en reglas operativas. A mayor aversión al riesgo, mayor penalización de la varianza y menor concentración permitida.

4.2. Benchmark equiponderado

El benchmark se define como un portafolio equiponderado sobre las veinte empresas de mayor capitalización:

$$w_i^B = \begin{cases} \frac{1}{20}, & \text{si } i \text{ pertenece al top 20 por capitalización,} \\ 0, & \text{en otro caso.} \end{cases} \quad (12)$$

Este benchmark es simple, transparente y replicable. Su función no es maximizar matemáticamente una utilidad, sino entregar una referencia contra la cual comparar el valor agregado del optimizador.

4.3. Portafolio de mínima varianza

El portafolio de mínima varianza se calcula resolviendo:

$$\min_w w^\top \Sigma w, \quad (13)$$

sujeto a presupuesto completo, no venta en corto y peso máximo por activo. Este portafolio representa el extremo defensivo de la frontera eficiente y permite comparar si los perfiles conservadores se comportan de manera coherente.

4.4. Portafolio ideal de mercado

El portafolio ideal de mercado se aproxima como el punto de máximo Sharpe sobre la frontera eficiente calculada. Para cada punto de la frontera se evalúa:

$$S(w) = \frac{E[R_p] - R_f}{\sigma_p}, \quad (14)$$

donde R_f es la tasa libre de riesgo anual, fijada por defecto en 2 %. El punto con mayor razón de Sharpe se interpreta como el portafolio de tangencia entre la frontera eficiente y la línea de mercado de capitales.

5. Frontera eficiente y gráficos

La función `solve_efficient_frontier` construye la frontera eficiente resolviendo una secuencia de problemas de mínima varianza con retorno objetivo:

$$\min_w w^\top \Sigma w, \quad (15)$$

$$\text{s.a. } \mu^\top w \geq r_k, \quad (16)$$

$$\sum_i w_i = 1, \quad (17)$$

$$0 \leq w_i \leq \bar{w}. \quad (18)$$

Los retornos objetivo r_k se distribuyen entre el retorno del portafolio de mínima varianza y el retorno del portafolio de máximo retorno factible. Para cada ventana, el script genera tres gráficos:

- 1) frontera eficiente teórica sola;
- 2) frontera eficiente teórica con portafolios de perfiles, benchmark, mínima varianza e ideal de mercado;
- 3) frontera eficiente teórica versus resultados reales futuros, donde se evalúan los mismos pesos en la ventana futura.




Figura 1: Frontera eficiente teórica para la ventana h7_f2_w01.




Figura 2: Frontera eficiente teórica con portafolios relevantes para la ventana h7_f2_w01.




Figura 3: Comparación entre frontera teórica y desempeño futuro real para la ventana h7_f2_w01.

6. Validación robusta

6.1. Horizontes de calibración y prueba

La variante implementada reduce el horizonte máximo desde 10 a 9 años, permitiendo trabajar con todos los activos F5 aun cuando la matriz común no alcance 2520 retornos diarios. Los horizontes evaluados son:

Tabla 2: Horizontes de calibración histórica y prueba futura

Horizonte	Años históricos	Años futuros
h7_f2	7	2
h6_f3	6	3
h5_f4	5	4
h4_f5	4	5
h3_f6	3	6
h2_f7	2	7

La calibración corresponde al periodo histórico usado para estimar μ y Σ . La prueba corresponde al periodo futuro en que los pesos calculados se mantienen y se evalúan con retornos realizados. Por lo tanto, el modelo no usa información futura al momento de calcular los portafolios.

6.2. Ventanas móviles

No se utiliza un único split train/test. La función `generate_validation_starts` genera múltiples ventanas por horizonte. En la corrida analizada se usaron tres ventanas por horizonte, separadas a lo largo de la matriz común de retornos. Esto permite evaluar robustez temporal: un modelo es más confiable si mantiene un desempeño razonable en distintas fechas de calibración y prueba, no solo en la ventana más reciente.

Tabla 3: Ventanas de validación utilizadas

Horizonte	Ventana	Inicio hist.	Fin hist.	Inicio futuro	Fin futuro	Activos
h7_f2	1	2013-03-08	2023-03-10	2023-03-13	2025-03-14	601
h7_f2	2	2013-08-14	2023-08-17	2023-08-18	2025-08-21	601
h7_f2	3	2014-01-23	2024-01-26	2024-01-29	2026-01-30	601
h6_f3	1	2013-03-08	2019-03-11	2019-03-12	2025-03-14	601
h6_f3	2	2013-08-14	2019-08-15	2019-08-16	2025-08-21	601
h6_f3	3	2014-01-23	2023-01-25	2023-01-26	2026-01-30	601
h5_f4	1	2013-03-08	2018-03-08	2018-03-09	2025-03-14	601
h5_f4	2	2013-08-14	2018-08-14	2018-08-15	2025-08-21	601
h5_f4	3	2014-01-23	2019-01-24	2019-01-25	2026-01-30	601
h4_f5	1	2013-03-08	2017-03-08	2017-03-09	2025-03-14	601

Horizonte	Ventana	Inicio hist.	Fin hist.	Inicio futuro	Fin futuro	Activos
h4_f5	2	2013-08-14	2017-08-14	2017-08-15	2025-08-21	601
h4_f5	3	2014-01-23	2018-01-23	2018-01-24	2026-01-30	601
h3_f6	1	2013-03-08	2016-03-08	2016-03-09	2025-03-14	601
h3_f6	2	2013-08-14	2016-08-12	2016-08-15	2025-08-21	601
h3_f6	3	2014-01-23	2017-01-23	2017-01-24	2026-01-30	601
h2_f7	1	2013-03-08	2015-03-09	2015-03-10	2025-03-14	601
h2_f7	2	2013-08-14	2015-08-13	2015-08-14	2025-08-21	601
h2_f7	3	2014-01-23	2016-01-22	2016-01-25	2026-01-30	601

7. Resultados y evaluación del modelo

7.1. Desempeño promedio por portafolio

La Tabla 4 resume el desempeño futuro promedio considerando los 6 horizontes y 3 ventanas por horizonte. Cada portafolio tiene 18 evaluaciones fuera de muestra.

Tabla 4: Desempeño futuro promedio por portafolio

Portafolio	Sharpe futuro	Desv. Sharpe	Retorno futuro	Vol. futura	Drawdown	CVaR diario 95 %
Muy conservador	1.8305	0.2590	31.76 %	16.59 %	-11.81 %	1.46 %
Conservador	1.7835	0.3394	35.96 %	19.85 %	-13.45 %	1.58 %
Neutro	1.8455	0.4473	45.61 %	25.38 %	-15.39 %	1.89 %
Arriesgado	1.8334	0.4636	64.22 %	36.24 %	-19.41 %	2.65 %
Muy arriesgado	1.7793	0.4404	78.54 %	43.42 %	-25.92 %	3.52 %
Benchmark	1.9614	0.3452	57.34 %	28.86 %	-20.82 %	2.60 %
Mínima varianza	1.8069	0.2227	26.23 %	13.49 %	-10.36 %	1.43 %
Ideal de mercado	1.6550	0.5504	44.18 %	29.75 %	-13.04 %	1.61 %

Los resultados muestran una relación coherente entre perfil de riesgo y exposición: los perfiles más arriesgados presentan mayor retorno futuro promedio, pero también mayor volatilidad, mayor drawdown y mayor CVaR. El perfil muy arriesgado alcanza un retorno anual futuro promedio de 78.54 %, pero con una volatilidad futura promedio de 43.42 % y un drawdown promedio de -25.92 %. En contraste, el portafolio de mínima varianza obtiene menor retorno promedio, 26.23 %, pero también la menor volatilidad promedio, 13.49 %, y el menor drawdown promedio, -10.36 %.

Un resultado relevante es que el benchmark top 20 obtiene el mayor Sharpe futuro promedio, 1.9614. Esto no significa que el benchmark sea siempre superior, sino que durante las ventanas evaluadas las empresas de mayor capitalización tuvieron un desempeño futuro particularmente favorable. Este punto es importante para la interpretación del modelo: Markowitz optimiza en función de estimaciones históricas, mientras que el benchmark se beneficia de una regla simple expuesta a grandes empresas que tuvieron buenos resultados en el periodo posterior.

7.2. Comparación por horizonte

Tabla 5: Desempeño promedio por horizonte, considerando todos los portafolios

Horizonte	Sharpe futuro medio	Retorno futuro medio	Volatilidad futura media
h7_f2	2.3159	36.40 %	15.10 %
h6_f3	2.0673	46.94 %	20.94 %
h5_f4	1.8751	52.44 %	27.66 %
h4_f5	1.6585	57.06 %	33.22 %
h3_f6	1.6026	54.47 %	33.43 %
h2_f7	1.3522	40.57 %	29.84 %

El horizonte h7_f2 presenta el mayor Sharpe futuro promedio. Esto sugiere que usar siete años de datos históricos para estimar parámetros y evaluar dos años hacia adelante ofrece el mejor balance entre estabilidad estadística y vigencia de la información. A medida que la ventana histórica se reduce, como en h2_f7, las estimaciones de μ y Σ se vuelven menos estables, lo que deteriora el Sharpe futuro promedio. Por otro lado, horizontes futuros demasiado largos exponen al portafolio a cambios estructurales del mercado que no estaban presentes en la calibración.




Figura 4: Sharpe futuro medio por horizonte de calibración y prueba.

7.3. Mejor horizonte por portafolio

Tabla 6: Mejor horizonte por portafolio según Sharpe futuro promedio

Portafolio	Horizonte	Sharpe futuro	Desv. Sharpe	Retorno futuro	Vol. futura
Muy conservador	h7_f2	2.2635	0.0582	26.96 %	11.04 %
Conservador	h7_f2	2.3687	0.0829	28.54 %	11.21 %
Neutro	h7_f2	2.5467	0.1350	34.84 %	12.90 %
Arriesgado	h6_f3	2.3090	0.4134	57.47 %	23.35 %
Muy arriesgado	h6_f3	2.2207	0.4097	85.20 %	36.29 %
Benchmark	h7_f2	2.4125	0.4215	46.19 %	18.52 %
Mínima varianza	h7_f2	2.1872	0.1705	26.84 %	11.38 %
Ideal de mercado	h7_f2	2.5363	0.1458	32.07 %	11.87 %

La mayoría de los portafolios obtiene su mejor desempeño con **h7_f2**. Los perfiles arriesgado y muy arriesgado se benefician más del horizonte **h6_f3**, posiblemente porque una menor ventana histórica reacciona mejor a activos de alto crecimiento que aparecen con fuerza en años recientes, aunque con mayor variabilidad del Sharpe.

8. Eficiencia computacional

El modelo resuelve problemas convexos cuadráticos. Para cada ventana se calculan cinco portafolios por perfil, un benchmark cerrado, un portafolio de mínima varianza, un portafolio de máximo retorno auxiliar, múltiples puntos de frontera eficiente y el portafolio ideal de mercado. La complejidad depende principalmente del número de activos n y de la cantidad de puntos de la frontera.

En la corrida robusta se utilizaron 601 activos y tres ventanas por cada uno de los seis horizontes. El uso de CVXPY con CLARABEL permitió resolver problemas de alta dimensión de forma estable. La regularización de la matriz de covarianzas fue clave para evitar problemas numéricos, especialmente porque la matriz común contiene cientos de activos y las ventanas históricas más cortas tienen solo 504 observaciones.

La implementación también separa el costo computacional en etapas claras: carga de datos, estimación de parámetros, optimización de perfiles, construcción de frontera, evaluación futura y exportación. Esta modularidad permite reducir tiempos cuando sea necesario, por ejemplo disminuyendo `-frontier-points`, usando menos ventanas de validación o limitando el universo con `-market-universe-size`.

9. Comparación esperado versus real

La comparación esperado versus real es uno de los componentes centrales de la implementación. Para cada portafolio, el modelo calcula métricas teóricas usando la ventana histórica y luego evalúa los mismos pesos en la ventana futura. Esto permite observar si la frontera eficiente estimada conserva su capacidad explicativa fuera de muestra.

En términos generales, los resultados muestran que el orden de riesgo se mantiene: los portafolios arriesgados tienden a tener mayor volatilidad futura y mayores pérdidas máximas. Sin embargo, el desempeño real no coincide perfectamente con el desempeño esperado. El portafolio ideal de mercado, por ejemplo, tiene el mayor Sharpe teórico promedio entre los portafolios optimizados, 3.9765, pero su Sharpe futuro promedio cae a 1.6550. Esto evidencia una limitación clásica de Markowitz: el portafolio de tangencia es altamente sensible a errores en la estimación de retornos esperados.

Por el contrario, el benchmark obtiene un Sharpe teórico promedio menor, 1.7613, pero un Sharpe futuro promedio de 1.9614. Este resultado sugiere que, en el periodo evaluado, una regla simple de exposición a grandes empresas fue muy competitiva. La conclusión no es que Markowitz falle, sino que el modelo requiere validación fuera de muestra y posiblemente mejoras en la estimación de μ , como Black-Litterman o modelos factoriales.

10. Archivos exportados

El script exporta los siguientes archivos principales en:

`outputs_markowitz_cvxpy_variante_validacion`

- `portfolios_summary_all_windows.csv`: métricas teóricas y futuras por portafolio, horizonte y ventana.
- `weights_all_windows.csv`: pesos positivos de cada portafolio.
- `frontier_points_all_windows.csv`: puntos de frontera eficiente y desempeño futuro asociado.
- `validation_windows.csv`: fechas de calibración y prueba de cada ventana.
- `validation_robustness_summary.csv`: resumen agregado de robustez por horizonte y portafolio.

Además, para cada ventana se generan tres archivos gráficos: frontera teórica sola, frontera teórica con portafolios y frontera teórica versus desempeño real futuro.

11. Conclusiones

La implementación desarrollada entrega una versión completa, modular y validable del modelo de Markowitz para FinPUC. El modelo utiliza retornos diarios totales con dividendos, resuelve portafolios con CVXPY, incorpora perfiles de riesgo diferenciados, calcula benchmark, mínima varianza, portafolio ideal de mercado y frontera eficiente. La variante robusta mejora la versión anterior al reducir el horizonte máximo a 9 años y permitir el uso de todos los activos F5 sin exigir una matriz común de 2520 retornos diarios.

Desde el punto de vista metodológico, la principal contribución de esta variante es la validación móvil. Evaluar múltiples ventanas permite distinguir entre un resultado accidental

de un único split y un comportamiento más robusto del modelo. Los resultados indican que `h7_f2` es el horizonte más estable en términos de Sharpe futuro promedio, mientras que perfiles más arriesgados pueden beneficiarse de `h6_f3`. También se observa que los portafolios más riesgosos logran mayores retornos, pero con incrementos claros en volatilidad, drawdown y CVaR.

Finalmente, la comparación esperado versus real confirma tanto la utilidad como las limitaciones del modelo de Markowitz. La frontera eficiente es una herramienta potente para estructurar la decisión de inversión, pero depende fuertemente de la calidad de las estimaciones de retornos y covarianzas. Por ello, esta implementación constituye una base sólida para el sistema recomendador, pero debe complementarse en futuras etapas con métodos de estimación más robustos y métricas de riesgo adicionales.